

面试篇：270 题

AI Infra / 推理优化 / 分布式系统 · 校招与实习面试题库

源文件 interview.md · 3 张 mermaid 图已渲染为图片 · 导出工具 export_pdf.py

目录

\$2 计算机基础 (cache / OS / 并发 / C++) (Q1–Q55, 55 题)	2
\$3 CUDA 与算子优化 (Q56–Q91, 36 题)	13
\$4 推理框架层 (Q92–Q131, 40 题)	22
\$5 分布式与通信 (Q132–Q160, 29 题)	30
\$6 性能分析与排障 (Q161–Q175, 15 题)	36
\$7 CUDA 与算子手撕题 (Q176–Q190, 15 题)	38
\$8 系统设计 (Q191–Q200, 10 题)	140
\$9 补充：那些「会就是会、不会就是不会」的知识点 (Q201–Q225, 25 题)	141
\$10 SOTA 模型架构与推理 (DeepSeek / Qwen / Kimi 这一代) (Q226–Q255, 30 题)	145
\$11 并行策略深挖：TP / DP / PP / EP / CP (Q256–Q262, 7 题)	163
\$12 SOTA 算子全景：这一代开源模型到底用了哪些 kernel (Q263–Q270, 8 题)	167

图例

- 答· 必答要点 · 数字· 面试时要主动说出的数字 · 坑· 常见错答
- 标签 [基础] [进阶] [hard] [编程] [手撕] [开放] ; ★ = 最高频
- 口径: 内核层性能数字转录自一本 459 页 CUDA kernel 专著 (测试机 RTX PRO 5000 72GB / sm_120a / CUDA 13.2) , 绝对数字不可迁移到 A100/H100; 模型架构数字来自各家官方技术报告与 config.json ; JD 与面经来自公开渠道。数字都可能过期, 用前核对你手上的版本。

§2 计算机基础 (cache / OS / 并发 / C++) (Q1-Q55, 55 题)

2.1 Cache 与存储层次

Q1 [基础] ★ cache line 由哪三部分组成? 各自的作用?

答· tag、index (组号)、offset (块内偏移), 一个内存地址被切成这三段: offset 定位到 line 内部的哪个字节 (位数决定 line 大小, 占 6 位 → 64 字节); index 定位到哪个组 (set); tag 因为组里可能有多条 line (组相联), 要用它逐一比对确认是不是要找的那块内存。valid bit 和 dirty bit 也属于每条 line 的元数据: valid 表示数据是否有效, dirty 表示是否被写过 (决定驱逐时是否要写回)。数字· x86 常见 line = 64 字节。为什么这么设计: 用「地址分段」把「查哪个组」做成硬件并行比较, 所以组相联能一次比对多路 —— 这是 cache 能在一个周期内命中的关键。

Q2 [基础] 为什么需要多级缓存?

答· 因为存储器的速度、容量、成本三者不可兼得: 快的内存做不大, 大的内存做不快。多级缓存是用层次结构同时逼近「快」和「大」。成立的两个前提: ① 程序访问有局部性 (时间局部性 + 空间局部性), 没有局部性多级缓存就是浪费; ② 每级命中率要高 —— 整体平均访问时间 = 命中时间 + 缺失率 × 缺失代价, 缺失代价逐级放大, 所以 L1 的命中率尤其关键 (这也是它最小但最贵的原因)。数字· L1 ~1 ns (每核几十 KB)、L2 ~5-10 ns、L3 ~20-40 ns (几十 MB)。

Q3 [进阶] ★ 发生 cache miss 后硬件的处理流程?

答· 四步: ① 判断 miss (index 找组、tag 并行比对都没中, 或 valid=0); ② 选牺牲者 (victim) (LRU / 伪 LRU / 随机), 若它是 dirty 的必须先写回下一级 (write-back, 最贵的开销之一); ③ 发缺失请求向上游请求整条 line (现代 CPU 用非阻塞 MSHR 允许多个 miss 同时在飞, 并有预取); ④ 填回并唤醒停顿的指令重放。两个加分点: 乱序执行用窗口内其它不相关指令填补这几百周期, 所以「miss 很贵」≠「CPU 一定闲着」; miss 分三类 (3C): compulsory / capacity / conflict, 对应手段分别是预取 / 加容量 / 提高相联度或改数据布局。

Q4 [进阶] 页表引入了哪些性能开销? 怎么缓解?

答· 两个开销: ① 地址翻译要多次访存 (x86-64 四级页表, 理论上一次数据访问多 4 次内存访问); ② TLB miss 代价极高 (TLB 条目很少, 几十到几千条, miss 就要走完完整 page walk)。四个层次的缓解: TLB (命中时翻译零额外访存)、大页 (4 KB → 2 MB / 1 GB, 同样覆盖范围需要的 TLB 条目少 512 倍)、多级页表本身 (让未使用的地址空间不占页表内存, 是「空间换时间」的取舍)、page walk cache / 硬件预取页表项。数字· 大页是推理/数据库都爱用的原因; 碎片化会破坏大页可用性, 这是真实工程问题。

Q5 [基础] 页表机制带来了哪些好处?

答· 三个：① **进程隔离与内存保护**（每个进程独立页表，虚拟地址根本映射不到别人的物理页，**硬件层面挡住越界**）；② **支持虚拟内存 / 按需分页**（地址空间可大于物理内存，页可以不在内存里，访问时触发缺页异常再调入）；③ **简化内存管理 / 允许非连续物理内存**（分配只需管理固定大小的页，**从根本上消除外部碎片**）。加一个现代的用法：**共享内存**——两个进程把不同虚拟地址映射到**同一物理页**，就实现了零拷贝共享（写时复制 fork、共享库、GPU 的 IPC 都是这个原理）。数字· 这正是 PagedAttention 的思路来源：**块表 ≈ 页表，共享前缀 ≈ 共享物理页 + 写时复制**。

Q6 [进阶] float / int32 / fp16 的表示范围与精度各是多少？

答· fp32 = 1 符号 + 8 指数 + 23 尾数 (p=24, 约 7.2 位十进制有效数字)；fp16 = 1 + 5 + 10 (p=11, 约 3.3 位, 最大 65504)；bf16 = 1 + 8 + 7 (p=8, 约 2.4 位, **动态范围同 fp32**)；int32 是精确整数, 范围 $[-2^{31}, 2^{31}-1]$ 。数字· **fp32 最大正规数 $FLT_MAX \approx 3.4 \times 10^{38}$** , **$\ln(FLT_MAX) \approx 88.72$** ——所以 **fp32 下 e^t 不溢出的条件是 $t \leq 88.72$** , 而 **fp16 下只有 11**。坑· 把「动态范围大」当「精度高」：**bf16 的动态范围比 fp16 大得多, 但尾部精度更低**。

Q7 [进阶] FP32 / TF32 / FP16 / BF16 / FP8 的区别？各自用在哪？

答· 差别在**指数位（动态范围）与尾数位（精度）**怎么分：

格式	符号/指数/尾数	p	相对精度	用途
fp32	1/8/23	24	~7.2 位十进制	累加、master weight
TF32	1/8/10	11	$u = 2^{-11} \approx 4.88e-4$	Tensor Core 上的 fp32 替代
fp16	1/5/10	11	~3.3 位	主流推理/训练数据
bf16	1/8/7	8	~2.4 位	训练（要动态范围）
fp8 e4m3	1/4/3	4	相对步长 6.25%	量化 inference
fp8 e5m2	1/5/2	3	~12.5%	梯度（本材料未涉及）

数字· **TF32 与 fp16 的尾数完全相同（10 位），差别全在指数**——TF32 用 fp32 的 8 位指数，动态范围与 fp32 一致。坑· fp8 有两个变体，**e4m3 和 e5m2 的取舍不是「谁更好」而是「要精度还是要范围」**。

Q8 [基础] 浮点数为什么会有精度问题？ $0.1 + 0.2 \neq 0.3$ 怎么解释？

答· 因为二进制无法精确表示大多数十进制小数（0.1 在二进制里是无限循环小数），存储时就被舍入。加法再叠加一次舍入。数字· 更该讲的是**工程后果**：fp32 的 $u = 2^{-24} \approx 6e-8$ ；**浮点加法不满足结合律，所以大规模归约的结果依赖累加顺序，并行归约的结果 run-to-run 可能不一致——因此正确性判定必须用容差，不能逐位比较**。

Q9 [进阶] 什么是大端 / 小端？为什么网络序是大端？

答· 多字节数据的字节排列顺序。小端把低位字节放在低地址（x86、ARM 默认），大端相反（网络序、部分嵌入式）。数字· 工程上的坑是**类型双关（type punning）与序列化**：memcpy 出来的字节序依赖平台；跨机通信必须显式转换（htonl / ntohl）。坑· 在 GPU↔CPU 或跨节点传二进制结构体时忘了对齐和端序——这是真实 bug 来源。

Q10 [进阶] NUMA 是什么？对 AI 训练/推理有什么影响？

答· 多路 CPU 下，内存控制器分布在各 socket，**CPU 访问本地内存快、访问远端内存慢**（跨 socket 走 UPI/Infinity Fabric）。影响：线程绑核与内存亲和性没配好时，**带宽和延迟都会明显退化**；PCIe 拓扑上「哪张卡挂在哪个 socket 下」也影响 host↔device 拷贝。数字· 实践动作：`numactl --cpunodebind --membind、`

在 `nvidia-smi topo -m` 里看 `SYS` (跨 socket) 与 `PHB` / `NODE` 的区别。

Q11 [进阶] DMA 是什么？为什么需要它？

答· 让外设**不经过 CPU** 直接读写内存的机制。没有 DMA 的话每次拷贝都要 CPU 逐字节搬运 (PIO)，CPU 被占满且带宽很低。数字· 大模型里 DMA 无处不在：**GPU 内部的 TMA 就是硬件 DMA**（一条 `cp.async.bulk.tensor.2d` 由单线程提交，硬件搬整块 2D tile，**地址计算/OOB 填充/smem swizzle 全在 descriptor 里声明，搬运过程零寄存器开销**）；**RDMA 是跨机的 DMA**（网卡直接读写对端内存，绕过两端 CPU 与内核）。

Q12 [进阶] 存储金字塔每一层的容量与延迟量级？

答· 从快到慢：寄存器 → L1 → L2 → L3 → 内存 → SSD → HDD → 网络存储。**GPU 侧的对应**（原书 H100 参考口径）：

层级	带宽	容量	作用域	延迟
Register	~100+ TB/s	256 KB/SM	thread	~0
SMEM / L1	~19 TB/s	~228 KB/SM	block	L1 命中 ~30 cycle
L2	~12 TB/s	50 MB	device	~200 cycle
HBM3	~3.35 TB/s	80 GB	device	~500-800 cycle

数字· **相邻层级带宽差 1.5-5 倍，容量上寄存器与 smem 同量级，再往上每升一级差两个数量级以上。一次 float 读的完整旅程约 0.5 μs 量级。**

Q13 [进阶] CPU 和 GPU 的设计哲学差别是什么？

答· **CPU 用「大 cache + 乱序执行」少 stall，GPU 用「海量线程 + 零开销 warp 切换」盖 stall。** CPU 的核心少而强（深流水、分支预测、乱序窗口），适合串行/分支密集；GPU 的核心多而弱（每 SM 4 个 warp scheduler，每周期各发 1 条指令），**warp A 等 HBM 数据时 scheduler 立刻切到 warp B，切换不需要保存上下文。**数字· 每 SM 4 个 warp scheduler × 每周期 1 条 = **SM 每周期最多发 4 条指令 —— 「发射带宽」本身就是一种资源。**

2.2 操作系统

Q14 [基础] ★ 进程和线程的区别？

答· **进程是资源分配的单位，线程是调度的单位。** 同一进程的线程**共享地址空间**（代码段、数据段、堆、文件描述符），但各有独立的栈和寄存器上下文。**代价差异：**进程切换要换页表（TLB 失效），线程切换不用 —— 所以线程切换便宜得多。**通信方式也不同：**线程直接读写共享内存（要同步），进程要么走管道/socket/共享内存要么走 IPC。数字· 这正好对应到 GPU：**CUDA 的「进程」概念是 context，「线程」概念对应 CUDA thread —— 所以多进程共享 GPU 要走 CUDA IPC**（vLLM 的 custom all-reduce 就是这么做的）。

Q15 [进阶] 进程间通信有哪些方式？各自的代价？

答· 管道/FIFO、消息队列、信号量、共享内存、socket、信号。**最快的是共享内存**（零拷贝，但要自己做同步），**最慢的是 socket**（要经过内核协议栈多次拷贝）。数字· 在 GPU 场景里还有一个特殊通道：**CUDA IPC** —— 把一个进程的显存句柄（`cudaIpcMemHandle_t`）传给另一个进程，对方 `cudaIpcOpenMemHandle` 就能直接读写那块显存，**这是 vLLM CustomAllreduce 的基础。**

Q16 [进阶] 虚拟内存的作用是什么？

答· ① 让每个进程看到独立、连续的地址空间（隔离与保护）；② 允许地址空间大于物理内存（按需分页 + swap）；③ 让物理分配不必连续（消除外部碎片）；④ 支持 `mmap` 把文件映射进地址空间（零拷贝读、共享库）。
数字· **大模型加载权重时 `mmap` 是常见手段**：多个进程共享同一份只读权重页，**显存/内存占用立刻降下来**。

Q17 [进阶] 什么是零拷贝（zero-copy）？在 AI 里指什么？

答· 广义上指**减少数据在内存层级之间的拷贝次数**。在 AI 里至少有四个不同的含义，**面试时要先问清是哪个**：
① **CPU 侧**：`mmap` + `sendfile` 避免用户态↔内核态往返；② **Host↔Device**：pinned memory + `cudaMemcpyAsync` 让 DMA 直接搬（避免中间的 bounce buffer）；③ **Device↔Device**：GPUDirect P2P / **GPUDirect RDMA**（网卡直接读写显存，绕过 host 内存）；④ **框架层**：**NHD 布局的零拷贝**（diffusers 的 E2E 布局不用先 permute 成 BHND）。
数字· GPUDirect RDMA 是跨机 TP 能做到低延迟的前提之一。

Q18 [进阶] 死锁的四个必要条件？怎么排查？

答· 互斥、持有并等待、不可剥夺、循环等待。**破任何一个即可**：按全局顺序加锁（破循环等待）、一次性申请全部资源（破持有并等待）、设置超时与回滚（破不可剥夺）。
数字· **在 GPU 集群上「死锁」有更隐蔽的形态**：所有 rank 都在等对方先发（**集合通信顺序不一致**）；或者 barrier 的到达数算错，相位永不翻转。**排查第一步不是看堆栈，而是核对「三一致」**：所有 rank 的**通信顺序一致、dtype/形状一致、后端选择一致**（见 ch05）。

Q19 [进阶] 用户态和内核态的区别？为什么系统调用贵？

答· 内核态可以执行特权指令、访问全部硬件；用户态不行。切换要走中断/ `syscall` 指令，涉及**保存现场、切换栈、权限级切换**，还可能污染 cache/TLB。
数字· 一次系统调用量级 **几百 ns 到几 μs**；所以高性能 I/O 用 `io_uring` / **批量提交 / 用户态驱动**（RDMA 的 verbs 就是用户态驱动，**这正是不用 TCP 的原因之一**）。

2.3 并发与原子操作

Q20 [基础] ★ C++ 中原子操作是什么？为什么要引入？

答· **不会被其它线程观察到中间状态的操作**，要么完全完成、要么完全没发生。因为 `x++` 在机器层面是**三步**（读 → 加 → 写），两个线程同时做会丢失更新（各加 1000 次，结果小于 2000）。锁能解决，但锁有开销（系统调用、上下文切换、可能死锁），对「只是个计数器」这种场景，原子指令更快也更不容易出错。
数字· 底层是 CPU 的原子指令：x86 的 `LOCK` 前缀、`cmpxchg`（CAS）。**CAS 是无锁数据结构的基石**：「读旧值 → 算新值 → CAS 写回，失败重试」。

Q21 [进阶] ★ 原子性、可见性、顺序性有什么区别？

答· **三个独立的性质，这是最容易答混的一题**：**原子性** = 操作不可分割（不撕裂）；**可见性** = 一个线程的写何时对其它线程可见；**顺序性** = 指令能否被重排。原子操作**只保证原子性**，可见性与顺序性要靠**内存序**：
`relaxed` / `acquire` / `release` / `acq_rel` / `seq_cst`。默认的 `seq_cst` **最安全也最慢**，性能敏感时要显式放松。
数字· `relaxed` 只保证不撕裂，常用于计数器；`release-acquire` 配对是「发布-订阅」的标准写法。

Q22 [进阶] ABA 问题是什么？怎么解决？

答· CAS 只比较值。如果值从 A 变 B 又变回 A，CAS 会误判「没人改过」而成功，但中间状态可能已经不一致。**解法是加版本号**：`atomic<pair<T, uint64_t>>` 或 tagged pointer（把指针低位借出来存版本）。
数字· 在无锁队列/栈里这是真实 bug；**另一种规避是「不回收内存」**（hazard pointer / epoch-based reclamation）。

Q23 [进阶] 自旋锁和互斥锁怎么选？

答· **自旋锁忙等不睡眠**，适合**临界区极短且不会被抢占**的场景；**互斥锁会睡眠**，适合**临界区长或可能阻塞**的场景。自旋锁在单核上几乎一定是错的（占着 CPU 等自己）。**数字· GPU 上的情形反过来**：kernel 里没有「睡眠」，所以 `atomicCAS` 自旋是实现设备端锁的唯一办法，但**同一个 warp 内的 lane 互相自旋会死锁**（warp 是同步执行的）——这是 GPU 编程特有的坑。

Q24 [进阶] 内存屏障 / fence 是干什么的？

答· 限制编译器和硬件的重排，保证**跨线程/跨设备的可见顺序**。四个典型场景：① CPU 线程间（`std::atomic_thread_fence`）；② **CPU↔GPU**（`cudaDeviceSynchronize`、stream 语义）；③ **GPU 内部跨线程**（`__threadfence()`）；④ **异步代理之间**（TMA 的 `fence.proxy.async.shared::cta`）。**数字· 第④个是最容易被忽略的**：TMA 通过「异步代理」写 smem，普通 `ld.shared` 读之前必须 fence，否则可能读到旧数据。

2.4 C++ 语言特性

Q25 [基础] ★ 函数重载的机制？编译器怎么实现？

答· 编译期多态，靠 **name mangling（名字修饰）**：编译器把函数名和**参数类型信息**编码进符号名（`void f(int) → _Z1fi`，`f(double) → _Z1fd`），链接器看到两个不同符号所以能共存。**四条边界**：① **只有参数列表能用于重载，返回类型不能**（调用点不依赖返回类型）；② **const 成员函数的重载是特例**（`const` 修饰的是隐式的 `this` 参数，等价于参数类型不同）；③ **extern "C" 关掉 name mangling**，所以 C 没有重载，C++ 里被它修饰的函数也不能重载；④ **重载决议顺序**：精确匹配 → 提升转换 → 标准转换 → 用户定义转换，多个同样好的候选就是**二义性错误**。

Q26 [进阶] ★ 虚函数怎么实现的？虚函数表的开销是什么？

答· 每个含虚函数的类有一张**虚函数表（vtable）**，对象里存一个 **vptr** 指向它；调用时通过 vptr 查表间接跳转（**动态派发**）。**三笔开销**：① 每个对象多一个指针（**8 字节**，对小的 value type 很明显）；② 每次调用多一次**间接寻址**，且**难以内联**（内联是 C++ 性能的主要来源之一）；③ **vptr 破坏了 POD 语义**（不能 memcpy、不能直接序列化）。**数字· 工程上怎么规避**：模板/CRTP（编译期多态）、`std::variant` + `visit`、热路径上用 switch 而不是虚函数。**坑·** 在构造函数/析构函数里调虚函数**不会**派发到子类（此时 vptr 还指向基类）。

Q27 [进阶] vector 的扩容机制？reserve 为什么重要？

答· 容量不足时按**倍数**（libstdc++ 是 2×，MSVC 约 1.5×）申请新内存、**拷贝/移动**旧元素、释放旧内存。所以 `push_back` 的**均摊复杂度**是 $O(1)$ ，但**单次可能 $O(n)$** 。`reserve` 提前一次分配，**避免多次拷贝 + 避免迭代器/指针失效**。**数字·** 释放 vector 内存要用 `shrink_to_fit` 或 **swap 技巧**（`vector<T>().swap(v)`）——`clear()` **不释放容量**，这是真实内存问题的来源。**坑·** 扩容后**所有指向元素的指针与迭代器全部失效**，包括引用。

Q28 [进阶] 智能指针有哪些？shared_ptr 的代价是什么？

答· `unique_ptr`（独占、零开销、可 move）、`shared_ptr`（引用计数、线程安全的计数）、`weak_ptr`（不增加计数，用来打破循环引用）。**shared_ptr 三笔代价**：① 控制块是**额外的一次堆分配**（可用 `make_shared` 合并）；② 引用计数是**原子操作**（有 cache line 争用）；③ **循环引用会泄漏**（要用 `weak_ptr` 打破）。**数字·** `sizeof(shared_ptr) = 16 字节`（对象指针 + 控制块指针），`unique_ptr` 默认 = **8 字节**（无状态删除器时空优化）。

Q29 [进阶] 内存泄漏怎么排查？RAII 为什么重要？

答· RAII = 把资源的生命周期绑定到对象生命周期（构造获取、析构释放），**异常安全的前提**。排查工具：Linux 用 `valgrind / ASan ( -fsanitize=address ) / heaptrack`；Windows 用 CRT debug heap 或 Application Verifier。数字· **GPU 侧的对应物是显存泄漏**：`torch.cuda.memory_allocated()` 与 `memory_reserved()` 的差、`torch.cuda.memory_summary()`、以及「warmup 后快照再跑一遍看是否增长」的二分法。**vLLM 里 OOM 的一种常见形态就是 KV cache block 没被回收**（引用计数错）。

Q30 [进阶] 模板是什么？编译期计算的意义？

答· 模板是**编译期代码生成**，把「类型」当参数。价值在于**零开销抽象**：`std::sort` 的比较器被内联，和手写循环一样快。GPU 场景里模板用得极多——**tile 尺寸、stage 数、是否 f32 累加，全是模板参数**，因为这样才能让编译器把循环完全展开、把常量折叠进地址计算。数字· 原书的 HGEMM 有 **17 个模板参数**（`kHeadDim`, `kMmaAtomM/N/K`, `kMmaAccF32`, `kMmaTile*`, `kValTile*`, `kStagesK`, `kPadQ/K/V`），**改一个参数就能切换整套流水线结构**——这是模板在 kernel 工程里的真实用途。坑· 模板会让编译时间与二进制体积爆炸（每个实例化一份代码），所以生产代码常用**显式实例化 + `extern template`** 控制。

2.5 Cache 进阶（面试官用来区分「背过」和「真懂」）

Q31 [进阶] ★ 什么是伪共享（false sharing）？为什么它比想象中严重？

答· 两个线程访问**同一个 cache line 里的不同变量**时，硬件按 line 维护一致性（MESI），**一个线程写就让对方的副本失效** ⇒ 双方不停地把整条 line 在核间搬来搬去，**明明没有共享数据却表现出共享的代价**。解法：把热点变量按 **64 B 对齐并填充**（`alignas(64)` / padding / 每线程一个槽位）。数字· **这正是 `kNumBarrierSignalBytes = 128` 存在的原因**——MegaMoE 的 barrier 计数器（grid-sync / NVLink-barrier / schedule 计数器）要 **pad 到一个 L2 cache line (128 B)**，因为它们是热点原子，伪共享会让它们互相拖死。坑· 面试里常被追问「为什么是 128 而不是 64」：**不同硬件的 line 大小不同**（x86 常见 64 B，部分 ARM 128 B），**取大的那个最安全**；GPU 上 L2 line 是 128 B。

Q32 [进阶] ★ 分支预测失败有多贵？怎么写出对预测器友好的代码？

答· 现代 CPU 是**深流水 + 乱序**，预测失败要**冲刷流水线重新取指**。代价量级 **10–20 个周期**；对分支密集的代码，失败率从 1% 涨到 10% 就可能让吞吐减半。**友好写法**：① **让分支可预测或可消除**——排序后再处理（把随机分支变成「一段全 true、一段全 false」）、用算术代替分支（`cmov` / `select`）；② 热路径上避免数据依赖的分支；③ 用查表代替分支树。数字· 经典的「排序后快 6 倍」例子：先 `std::sort` 再分段处理，条件跳转从随机变为几乎全部命中/不命中。坑· **GPU 上答案相反**：warp 内分支发散是**两条路径都执行**（掩码屏蔽），没有「预测」这回事——**别把 CPU 的分支优化直觉搬到 kernel 上**。

Q33 [进阶] 缓存替换策略有哪些？LRU 在硬件里能实现吗？

答· 理论最优是 **Belady (OPT)**，但需要未来信息；实际用 **LRU**（最久未使用）、**伪 LRU / 树形 PLRU**（近似 LRU，硬件便宜）、**随机、FIFO、LFU**。**LRU 在硬件里成本高**（每次访问都要更新顺序，n 路就要 log n 位状态），所以真实 CPU 多用 **PLRU 或带保护的变体**。数字· 这直接影响「3C 模型」里的 **conflict miss**：同组挤掉 ⇒ **提高相联度或改数据布局**是最有效的缓解。坑· 面试官常接着问「为什么 LRU 对某些访问模式很糟」⇒ **循环扫描大于 cache 的工作集**（`for i in 0..N` 反复扫）会把 cache 全冲掉，这叫 **cache thrashing**，解法是**分块 (loop tiling)**。

Q34 [进阶] write-back 与 write-through 的区别？dirty bit 为什么重要？

答· **write-through**: 写命中也同步写下一级 (简单、一致性好、但写流量大); **write-back**: 只改本级的 line 并置 **dirty**, 驱逐时才写回 (省流量, 但有一致性风险)。配套还有 **write-allocate / no-write-allocate** (写缺失时要不要先取回整条 line)。数字· **dirty line 的驱逐是最贵的路径之一**: 要先把旧数据写回下一级, 再填入新 line —— 所以 miss 处理流程里专门有一句「若 victim 是 dirty 的必须先写回」。坑· GPU 上的对应物是 **cp.async.cg 不分配 L1、.ca 分配 L1 —— .cg (cache global, 只走 L2) 存在的意义就是避免污染 L1 并且不产生 dirty line**。

Q35 [进阶] MESI 协议是什么? 四个状态怎么转换?

答· 多核 cache 一致性协议, 四态: **M (Modified, 独占且脏)**、**E (Exclusive, 独占且干净)**、**S (Shared, 多核共享且干净)**、**I (Invalid, 无效)**。关键转换: 本地写命中 S 态 $\Rightarrow$ 要先让其它核的副本失效 (升级为 M), 这一步要走总线/互连的一致性消息, 是伪共享代价的来源; 本地读缺失而其它核是 M $\Rightarrow$ 必须先写回再共享。数字· 这就是为什么「只读共享」几乎免费 (都停在 S 态), 而「读写共享」很贵 (S $\leftrightarrow$ M 反复翻转)。坑· 面试里可以主动提到 **MOESI** (多了 O 态, 允许「拥有但共享脏数据」, 减少写回次数) —— 说明你知道协议有变体。

Q36 [进阶] ★ memory barrier / fence 在 CPU 和 GPU 上分别解决什么?

答· 都解决重排序导致的可见性顺序问题, 但层次不同:

层面	机制	典型场景
编译器重排	<code>std::atomic_signal_fence / asm volatile("" ::: "memory")</code>	编译器把写操作挪过标志位
CPU 访存重排	<code>std::atomic_thread_fence</code> 、 <code>mfence / sfence / lfence</code>	生产者-消费者发布数据
CPU $\leftrightarrow$ GPU	<code>cudaDeviceSynchronize</code> 、stream 语义、 <code>cudaMemcpyAsync</code> 的隐式同步	host 改完数据再 launch
GPU 内跨线程	<code>__threadfence()</code>	一个 block 写全局内存, 另一个 block 读
GPU 异步代理之间	<code>fence.proxy.async.shared::cta</code>	TMA 通过「异步代理」写 smem, 普通 <code>ld.shared</code> 读之前必须 fence

数字· 最容易被忽略的是最后一行: TMA 写 smem 与普通 load 属于两个不同的代理, 不加 fence 可能读到旧数据, 而且是偶发的、难复现。坑· x86 的 TSO 模型天然保证「读-读、读-写、写-写」不乱序, 只允许「写-读」乱序, 所以 `sfence / lfence` 在很多场景是多余的 —— 但别把这个当可移植结论。

Q37 [进阶] SIMD / AVX 是什么? 和 GPU 的 SIMT 有什么本质区别?

答· **SIMD 是指令级的并行**: 一条指令处理多个数据 (AVX-512 一次 16 个 fp32), 需要程序员显式使用向量类型 (或靠编译器自动向量化)。**SIMT 是线程级的并行**: 每个线程有自己的寄存器和 PC, 由硬件组织成 warp 一起执行。**本质区别**: SIMD 的向量宽度是指令的一部分 (写死在 ISA 里), SIMT 的「宽度」是硬件的调度选择 (warp = 32, 但线程可以独立分支)。数字· AVX-512 的 fp32 宽度是 16; warp 是 32; 两者都是「一条指令多个数据」, 但 SIMT 允许分支发散 (代价是串行化)。坑· 面试里可以提: **AVX-512 有 AVX-512 降频问题** (重向量指令导致频率下降), 这与 GPU 的「功耗墙导致降频」是同一类现象。

Q38 [进阶] 内存对齐为什么能提升性能? 未对齐会怎样?

答· 对齐让一次访问**不跨越 cache line / sector 边界** ⇒ 一次事务搞定。未对齐时：① 可能**跨两条 line**，要两次访问（甚至触发两次 miss）；② 某些指令**要求对齐**（float4 必须 16 B、AVX 对齐指令要求 32/64 B），**不对齐直接异常**（CUDA 里是 misaligned address 运行时错误）。数字· cudaMalloc 返回的基址满足 **256 B 对齐**，所以只要元素偏移是 4 的倍数（vec4 的 $\text{idx} = 4 \times \text{全局线程号}$ ）就天然满足 **16 B 对齐**。坑· 对子数组做 vec4 是最常见的踩坑方式（例如传 $a + 1$ ）—— 约定：vec4 主路径的指针必须来自整块分配的基址。

2.6 操作系统与内存（进阶）

Q39 [进阶] ★ 用户态、内核态、以及「零拷贝」到底省了什么？

答· 一次普通 `read()` + `write()` 要 **4 次拷贝 + 4 次上下文切换**（磁盘→内核缓冲→用户缓冲→内核 socket 缓冲→网卡）。零拷贝用 `sendfile` / `splice` / `mmap` 把中间的用户态往返砍掉，省的是「内核↔用户」的两次拷贝与两次切换，不是全部拷贝。数字· 在 AI 里「零拷贝」至少有四个不同含义，面试时要先问清：① CPU 侧（`mmap` / `sendfile`）；② Host↔Device（pinned memory + `cudaMemcpyAsync`，避免 bounce buffer）；③ Device↔Device（GPUDirect P2P / GPUDirect RDMA，网卡直接读写显存）；④ 框架层（NHD 布局零拷贝，diffusers 的 E2E 布局不用先 permute）。坑· 把「零拷贝」当万能词答会在追问下崩掉——主动分类反而加分。

Q40 [进阶] ★ 什么是 pinned memory（页锁定内存）？为什么它更快？

答· 普通 `malloc` 的内存**可能被换出**（pageable），所以驱动做 H2D 拷贝时**不能直接 DMA**，得先拷到一个临时的锁页缓冲（bounce buffer），再 DMA ⇒ 多一次拷贝。pinned memory 用 `cudaHostAlloc` 分配，**永不被换出，DMA 可以直达**。数字· 带宽差距可达 **2× 以上**；延迟差距更大（省掉一次拷贝与同步）。坑· 三个必须知道的代价：① **分配慢且有上限**（锁页是系统资源，分配过多会让系统内存吃紧）；② `cudaHostAlloc` 的默认 pinned 对多设备不友好，要 `cudaHostAllocPortable`；③ `cudaMemcpyAsync` 用 pageable 内存时会**退化成同步**（这是「为什么没重叠」的常见根因）。

Q41 [进阶] ★ cudaMemcpy 和 cudaMemcpyAsync 的区别？为什么会「没重叠」？

答· `cudaMemcpy` **同步**，且当源/目的是 pageable 内存时会**隐式同步整个流**（不是只同步这一个拷贝）⇒ 把本来可以并行的 kernel 也串行化了。`cudaMemcpyAsync` 只在 pinned memory + 指定非默认流时才真正异步。数字· 「很多『为什么没重叠』的根因就是同步版 `cudaMemcpy` 的隐式同步」—— 查法：nsys 时间线里看到 `Memcpy HtoD` 与 kernel **完全不重叠**。坑· 默认流（legacy default stream）有**隐式同步语义**，会与所有其它流同步 ⇒ 想真并行要用 `cudaStreamNonBlocking` 创建的流。

Q42 [进阶] 缺页异常（page fault）的处理流程？对它做优化意味着什么？

答· 访问的页不在物理内存（或被换出）⇒ MMU 触发缺页异常 ⇒ 内核陷入 ⇒ 找到/分配物理页 ⇒ 若需要就从磁盘换入（**major fault**）或只建立映射（**minor fault**）⇒ 更新页表 ⇒ 返回用户态重试该指令。数字· **major fault 是毫秒级**（要等磁盘），minor fault 是微秒级。坑· 在 AI 里最相关的是「懒加载/按需分页」：`mmap` 加载大权重时，**第一次访问每个页都会触发 minor fault** ⇒ 表现为「第一次推理特别慢」，之后正常。解法：预热（warmup）+ `MAP_POPULATE` / `madvise(MADV_WILLNEED)` 预取。GPU 侧对应物是 CUDA 的 **unified memory 缺页**（更贵，且会打断 kernel）。

Q43 [进阶] Huge Pages 怎么开？对 AI workload 的收益在哪？

答· Linux 上 `mmap(MAP_HUGETLB)` 或透明大页（THP，`/sys/kernel/mm/transparent_hugepage/enabled`）；GPU 侧有 CUDA VMM 的大页分配与驱动的 2 MB 页选项。收益：① **TLB 覆盖范围提升 512 倍**（4 KB → 2 MB）⇒ TLB miss 大减；② **页表遍历层次变浅** ⇒

地址翻译更快；③对**大块连续分配**（权重、KV cache）尤其有效。**数字·**大模型推理/数据库都爱用大页，原因就是第①条。**坑·****碎片化会破坏大页可用性** ⇒ 长期运行的进程可能申请不到 2 MB 页，表现为「刚启动很快、跑久了变慢」。这是真实的工程问题。

Q44 [hard] 为什么 `malloc / free` 会碎片化？内存分配器怎么解决？

答·不同大小的分配交错释放，空闲块被切成不连续的小块 ⇒ **总量够但装不下一个大的连续请求**。分配器策略：**size class**（尺寸分级，小对象用固定桶）、**segregated free list**、**合并相邻空闲块（coalescing）**、**arena / 线程本地缓存（tcmalloc/jemalloc 的 thread cache）**。**数字·****GPU 上完全对应：**`torch.cuda` 的 `caching allocator` 也做 size class + 缓存已申请的块 ⇒ 所以 `reserved > allocated`。**坑·****GPU 侧还需要 `cudaMallocAsync` / `expandable_segments` 这类手段**，因为显存不能 swap，碎片的后果比 host 更硬（直接 OOM）。

Q45 [hard] 一个进程的虚拟地址空间长什么样？为什么栈向下长、堆向上长？

答·典型布局（低地址→高地址）：**代码段（text）** → **只读数据（rodata）** → **已初始化数据（data）** → **BSS** → **堆（heap，向上增长）** → **空洞** → **共享库映射区（mmap）** → **栈（stack，向下增长）** → **内核空间**。栈向下、堆向上是**约定（不是硬件要求）**，好处是**两者之间留出最大的连续增长空间**，互不干扰。**数字·**`mmap`**区放在中间是关键设计：**它让共享库与大块映射（包括大模型的权重 `mmap`）有连续的地址空间可用。**坑·**这解释了为什么「`malloc` 一个巨大的块」和「`mmap` 一个文件」在地址空间里的行为不同（前者受堆连续性约束，后者走 `mmap` 区）。

Q46 [进阶] 线程池、协程、异步 I/O 各解决什么问题？

答·**线程池：**复用线程，省掉创建/销毁开销，控制并发度；**协程：**用户态调度，**切换不陷入内核**（比线程切换便宜 1-2 个数量级），适合大量「等待 I/O」的任务；**异步 I/O（io_uring / epoll）：****让内核通知你「好了」而不是你阻塞等着**。**数字·**三者的适用边界：CPU 密集 → 线程池（或进程池，绕开 GIL）；**I/O 密集且并发极高** → 协程 / 异步 I/O。**坑·****Python 的 GIL 让「CPU 密集用线程池」失效**——这时要么多进程，要么把热点丢给 C++/CUDA（这也是 AI 框架的常见分工）。


Q47 [进阶] 统计一下：一次 RPC/网络往返的下限是多少？为什么它决定了架构？

答·同机进程间 ~几十 μ s；同机房网络 ~0.1-0.5 ms；跨地域 ~几十 ms。**这些数字直接决定架构：**单次往返贵的操作要**批量/流水线化**，否则「每层通信一次」的设计在跨机时必然崩。**数字·****这正是 TP 不能跨机的定量理由：**TP 每层两次 all-reduce，几十层就是上百次同步，每次都要一次往返 ⇒ **延迟直接叠加**；而 EP 的 all-to-all 是**整块数据搬运**，带宽效率高得多。**坑·**面试里被问「为什么不让 TP 跨机」时，给出「**每层 2 次 × N 层 × 往返延迟**」这笔账比说「NVLink 更快」有说服力得多。


2.7 浮点与数值（★ 面量化/算力岗的高频区）

Q48 [进阶] ★ IEEE 754 的组成？为什么需要 subnormal（次正规数）？


答· $(-1)^s \times 1.m \times 2^{(e-bias)}$ （正规数），三类特殊值：**±0**（指数全 0、尾数全 0）、**subnormal**（指数全 0、尾数非 0，隐含位变成 0 ⇒ 表示比最小正规数更小的值）、**Inf / NaN**（指数全 1；尾数全 0 是 Inf，非 0 是 NaN）。**subnormal 的意义是「渐进下溢」：**如果没有它，最小正规数以下的差值会突然变成 0，导致 `a - b != 0` 却 `a == b` 的荒谬结果。



图源: IEEE 754 Single Floating Point Format, Wikimedia Commons, CC BY 3.0。



图源: IEEE 754r Half Floating Point Format, Wikimedia Commons, CC BY-SA 3.0。



图源: Bfloat16 format, Wikimedia Commons, CC BY-SA 4.0。三张图对照看 $s / e / m$ 的位数分配——这就是 Q7 那道「fp16 与 bf16 差在哪」的全部答案: bf16 用尾数换 range (8 位指数 = fp32), fp16 用 range 换精度 (10 位尾数)。

数字· fp32: 最小正规数 $\approx 1.18 \times 10^{-38}$, 最小 subnormal $\approx 1.4 \times 10^{-45}$ 。坑· 性能陷阱: 某些硬件处理 subnormal 会陷入微码 (慢几百倍), 所以很多 kernel 用 FTZ (flush-to-zero) 把它们当 0 —— 这会改变数值结果, 精度敏感的场景要注意 (`--use_fast_math` 会开 FTZ)。

Q49 [进阶] ★ 为什么浮点加法不满足结合律? 后果是什么?

答· 因为每次加法都要舍入到可表示精度, $(a+b)+c$ 与 $a+(b+c)$ 的中间舍入点不同 $\Rightarrow$ 结果可能不同。极端例子: $1e20 + 1 - 1e20$ vs $1e20 - 1e20 + 1$ (前者是 0, 后者是 1) —— 这叫「大数吃小数」(swamping)。数字· 后果有两个: ① 并行归约的结果依赖累加顺序 $\Rightarrow$ run-to-run 抖动 $\Rightarrow$ 正确性判定必须用容差; ② 集合通信的 all-reduce 换拓扑/换卡数会改变结果 $\Rightarrow$ 训练可复现性受损。坑· 面试官喜欢追问「那怎么办」: 用成对求和 / Kahan 求和 (补偿求和, 误差从 $O(n\epsilon)$ 降到 $O(\epsilon)$)、按绝对值排序后相加、或用 fp64 累加。

Q50 [进阶] 相对误差与绝对误差怎么选? 量化里为什么更关心相对误差?

答· 绝对误差: $|\hat{x} - x|$ (与量级无关); 相对误差: $|\hat{x} - x| / |x|$ 。量化的本质是相对误差: $\hat{x} = \text{round}(x/\delta) \cdot \delta \Rightarrow |\hat{x} - x| \leq \delta/2$, 而 $\delta = a_{\max}/2^m \Rightarrow$ 相对误差 $\approx \delta/a_{\max} = 2^{-m}$ 固定。所以 e4m3 的 $m=3 \Rightarrow$ 相对误差 $\leq 2^{-4} = 6.25\%$, e2m1 的 $m=1 \Rightarrow 25\%$ —— 这就是 fp8 和 fp4 精度差的全部来源。数字· 整数量化 (int8) 的误差是绝对的 (δ 固定), 所以动态范围小的张量适合 int8, 动态范围大的适合浮点格式。坑· 把「相对误差」当「精度」是一个常见混淆: 同一个 e4m3, 大值附近的绝对误差比小值附近大得多。

Q51 [进阶] ★ 混合精度训练里 fp16 / bf16 / fp32 各扮演什么角色？

答· 典型配置是 **bf16 或 fp16 前向 + fp32 主权重 (master weights) + fp32 累加**：- 前向/反向用低精度：省显存、吃 Tensor Core 吞吐；- 累加用 **fp32**：避免长 K 累加的误差累积 (f16 累加误差沿 $\sqrt{K}$ 增长)；- 主权重用 **fp32**：参数更新量 $lr \times grad$ 往往很小，在低精度下会被舍入吃掉——这是「必须留 fp32 副本」的根本原因。数字· **bf16 不需要 loss scaling, fp16 需要**：bf16 指数位与 fp32 相同 (动态范围 $\sim 10^{\pm 38}$)，fp16 只有 5 位指数 $\Rightarrow$ 梯度下溢成 0 $\Rightarrow$ 要用 loss scaling 把梯度整体放大。坑· 面试里可以主动区分「累加精度」与「存储精度」：`f32.f16.f16.f32` 这条 mma 变体就是「输入 f16、累加 f32」，它在 attention 里反而比 f16 累加更快 (省掉 half $\leftrightarrow$ float 转换)。

Q52 [hard] ★ 什么是 Kahan 求和 / 补偿求和？

答· 用一个补偿变量 `c` 记住每次加法被舍掉的低位：

```
y = x - c; t = sum + y; c = (t - sum) - y; sum = t;
```

数字· 误差从 $O(n\epsilon)$ 降到 $O(\epsilon)$ (与 n 基本无关)。代价是每次加法多 3 次浮点操作 (约 4 倍开销)，所以只在精度敏感、且 n 很大的归约里用。坑· GPU 上要小心：编译器在 `--use_fast_math` 下会把 `(t - sum) - y` 优化掉 (认为浮点运算满足结合律)，必须关掉这种优化或加 `volatile` / 内联汇编。这是一个真实的坑。

Q53 [hard] 量化里为什么会出现 outlier？它对量化意味着什么？

答· Transformer 的激活里存在系统性的**大值通道** (常见于 LayerNorm 后的少数维度、以及注意力 sink)，它们比典型值大一到两个数量级。而量化是按 **amax** 归一的 $\Rightarrow$ 一个 outlier 就毁掉整块的量化步长 (其余值全被压到很少的几个量化级上)。四种解法 (要能说出层次)：① **细粒度** (per-channel / per-token / per-128 块，让 outlier 只影响自己那一小块)；② **平滑** (smooth-K 减列均值、smooth-Quant 把激活的 outlier 迁移到权重上)；③ **旋转** (Hadamard, 把 outlier 能量摊平到所有维度)；④ **混合精度** (对敏感的层/行保持高精度，即 hybrid)。数字· smooth-K 的数学依据是 softmax 的平移不变性： $K' = K - \mathbf{1}\bar{k}^T \Rightarrow S' = S - \Delta$ (Δ 每行是常数) $\Rightarrow$ softmax 与 O 逐 bit 不变，只有 lse 要补一项——等价于免费收紧了量化步长。坑· Hadamard 的收益要用实测说话：FA-3 的实测是 与分块量化联合把 FP8 RMSE 降低 2.6 $\times$ 。

2.8 并发与性能 (进阶)

Q54 [进阶] ★ volatile 和 std::atomic 的区别？什么时候用哪个？

答· **volatile** 只管「别把这个访问优化掉」，它不提供原子性、不提供内存序、不做线程同步。`std::atomic` 提供原子性 + 可控的内存序 (`relaxed ... seq_cst`)。数字· 典型误用：用 `volatile bool` 当线程间标志位——在没有 fence 时另一个线程可能永远看不到 (编译器重排 + CPU 乱序 + cache 未回写)。正确写法是 `std::atomic<bool>` 配 `release / acquire`。坑· **volatile** 的合法用途其实只剩三类：**memory-mapped I/O**、信号处理里的 `sig_atomic_t`、以及阻止编译器优化掉某个变量的读写 (例如 Kahan 求和的补偿项)。

Q55 [hard] 无锁数据结构的三大难题是什么？

答· ① **ABA 问题**——CAS 只比值，`A $\rightarrow$ B $\rightarrow$ A` 会误判成功；解法是版本号 / tagged pointer (把指针低位借出来存版本)。② **内存回收 (safe memory reclamation)**——一个线程刚读到指针、另一个线程就把它 free 了，这就是 use-after-free；解法：**hazard pointer**、**epoch-based reclamation (EBR)**、**RCU**、引用计数。③ **内存序设计**——全用 `seq_cst` 能work 但慢；真正的无锁结构要靠 `acquire / release` 的配对把开销压下

来。数字· GPU 上的对应物：kernel 里没有「睡眠」，设备端锁只能用 `atomicCAS` 自旋实现，但同一 warp 内的 lane 互相自旋会死锁（warp 是同步执行的）——这是 GPU 特有的坑。坑· 面试时可以主动说「能用锁就别写无锁」：无锁的调试成本很高，除非临界区极短且竞争激烈，否则锁 + 分片往往更好。

§3 CUDA 与算子优化（Q56–Q91，36 题）

3.1 GPU 架构与执行模型

Q56 [基础] ★ SM 里有什么？warp 是什么？

答· 每 SM：4 个 warp scheduler（每个每周期发 1 条指令）、 $65536 \times 32\text{-bit}$ 寄存器文件（= 256 KB）、可配置划分的 shared memory / L1、Tensor Core。warp = 32 线程 = 最小调度与发射单元（SIMT 模型）。数字· SM 每周期最多发 4 条指令——「发射带宽」是一种资源；寄存器的分配粒度是 warp：每线程 64 个寄存器时，一个 256 线程 block 占 $256 \times 64 \times 4\text{B} = 64\text{ KB}$ ，SM 里最多驻留 4 个。

Q57 [进阶] ★ SIMT 与 SIMD 的区别？分支发散会怎样？

答· SIMD 要程序员显式写向量操作；SIMT 让每个线程有自己的寄存器和 PC，由硬件把它们组织成 warp 一起执行——所以线程可以独立分支。分支发散：同一 warp 内线程走不同分支时，硬件两条路径都执行，用执行掩码屏蔽不该执行的线程 $\Rightarrow$ 等价于串行化，最坏 32 路，掉到 1/32。缓解：让分支条件在 warp 内一致（按 warp 而不是按 thread 分配任务）；用算术代替分支（三元运算符编译成 `select`，无跳转）；重排数据把同分支的聚到一起。坑· 现代 GPU 的 divergence 代价没有教科书那么绝对——短分支很快汇合时影响有限，致命的是长分支（带循环）。所以先用 profiler 确认它是不是瓶颈，不要见到 `if` 就改。

Q58 [基础] `__syncthreads()` 的作用与限制？

答· block 内所有线程的栅栏 + 内存可见性保证。两条限制：① 只能同步 block 内（跨 block 要 kernel 边界或 cooperative groups）；② 必须放在所有线程都能到达的位置——放在发散分支里会死锁。数字· 在 GEMM 里有两道，各防一件事：第一道防「读到没写完的 smem」，第二道防「还没读完就被下一轮覆写」。省掉第二道是最常见的「优化」笔误——症状是偶发错数、难复现。双缓冲把第二道栅栏变成流水线节拍。

Q59 [进阶] occupancy 是什么？越高越好吗？受什么限制？

答· $\text{occupancy} = \text{active warps per SM} \div \text{max warps per SM}$ ，受三类资源钳制取最小值：每线程寄存器数、每 block 的 smem 用量、block 大小/数量。ncu 直接告诉你是哪一类（`launch__occupancy_limit_registers / _shared_mem / _blocks`）。不是越高越好：占用率想上 100% 就得少用寄存器、少用 smem，但 GEMM/attention 恰恰要用大 thread tile 与多级 smem 流水换性能。低 occupancy + 高 ILP 常优于高 occupancy + 低 ILP（用 ILP 换 TLP）。数字· 原书实例：REG:255 把 Block Limit Registers 压到 1 $\rightarrow$ 1 CTA/SM、12 warps、理论 occupancy 只有 25% (12/48)。

Q60 [进阶] ★ 寄存器 255 墙是什么？spill 的代价是什么？

答· 每线程寄存器硬上限 255；超出时编译器把变量溢出到 local memory，SASS 里表现为 `LDL / STL`。查法：编译期 `--ptxas-options=-v / cuobjdump --dump-resource-usage` 看 STACK；运行期 ncu 看 `lltex__t_bytes_pipe_lsu_mem_local_op__ld/st.sum` 是否非零。数字· spill 的代价主要不是流量，而是延迟暴露：原书 fp4 attention 在 D=512 时 spill 总量 234 MB，但 local 流量只有 12.8 GB/s；真正的代价是 8 warps/SM 意味着每 scheduler 只有 2 个 warp 可切换，LDL 的几百 cycle 藏不住，而且指令数变多了。一个

可背的寄存器预算公式 (attention 的 O 累加器, M8N1) : $\text{每线程 O 寄存器数} = \text{kBr} \cdot \text{D} / 256$ (256 = 32 lanes × 8 warps) —— $\text{kBr}=128$ 时 = $\text{D}/2$, **D=512 就要 256 个 → 撞穿 255 墙。这个大 head_dim 必须换 M4N2 atom (每线程降到 D/4) 的数学来源。**

Q61 [进阶] 如何隐藏访存延迟?

答· 三条路: ① **增加并行 warp (TLP)** ; ② **增加每线程的独立操作 (ILP, 如 thread tile)** ; ③ **异步搬运** (cp.async / TMA —— 把「搬」和「算」解耦, 不再靠线程等)。数字· 本质上 GPU 靠**堆并发**掩盖延迟, 而**warp 切换是零开销的** (不保存上下文)。**第三条路是 Hopper/Blackwell 的分水岭**: TMA 让搬运完全脱离线程, **实测相对 cp.async 版稳定 +20%**。

3.2 访存优化

Q62 [基础] ★ 什么是 coalescing? 怎么算有效率?

答· 把 warp 内 32 个线程的地址**按 sector 归类合并成尽量少的访存请求。从 Volta 起访存以 32 字节 sector 为最小搬运粒度。** 数字· $\eta = 32b / (S \times 32)$ (b = 每线程字节数, S = 32 个地址触及的 sector 数): **连续访问 S = 4, $\eta = 100\%$; stride=2 时 S = 8, $\eta = 50\%$; 大 stride (每线程落在不同 sector) S = 32, $\eta = 12.5\%$ (按 L1↔L2 的 128 B line 口径约 3%)。矩阵转置的朴素版本就是第三种形态。**

Q63 [进阶] float4 向量化的收益来源与前提?

答· **减少 load/store 指令数 (降为 1/4) 与提升 ILP (翻两番), 不是减少字节数。** 前提是 **16 B 对齐** (cudaMalloc 基址 256 B 对齐, 只要元素偏移是 4 的倍数就对齐)。坑· **口径勘误**: 很多资料 (包括不少代码注释) 说「向量化把内存事务数减为 1/4」—— **这在 Volta 之后过时了**: coalesced 场景下搬运的 **sector 数由总数据量决定, 向量化只减指令数。** 数字· 原书在 L2 口径下测出 **relu 1862 GB/s vs relu_vec4 1866 GB/s** (±2% 噪声内), **因为瓶颈在 L2/互联的搬运能力而非指令发射。**

Q64 [进阶] ★ 什么时候 vec4 的收益才显性化?

答· **当瓶颈是指令发射或 HBM 直读时。** 原书有一组极好的对照实验: 同一批 kernel 在两个口径下测 ——

口径	vec4 的收益
L2 口径 (16 MB 数据落在 96 MB L2 内)	rms_norm + 16% 、layer_norm + 24%
HBM 口径 (数据放大到超出 L2)	四个 kernel 全部收敛到 1000–1070 GB/s, 收益消失

数字· **但同一批实验里有一个「两个口径都成立」的优化: 单 pass RMSNorm 在两种口径下都快约 7% (–6.9% / –6.5%)** —— 因为它减少的是**数据往返次数** (真正的流量), 而不是指令数。**这个对比值得背下来: 「减少指令数」只在指令受限时有效; 「减少数据流量」在任何口径下都有效。**

Q65 [进阶] ★ bank conflict 怎么产生? 怎么数?

答· smem 由 **32 个 bank、每 bank 宽 4 B** 组成, $\text{bank}(a) = \lfloor a/4 \rfloor \bmod 32$; 128-bit 访问**按 8 lane 一组分 phase 服务** (一组 8 lane × 16 B = 128 B 恰好用满全部 bank), **同 phase 内两 lane 落同一 bank 的不同 word 即冲突, n 路冲突拆成 n 个 bank 周期。** 数字· 三档实测 (M=N=K=512, 指标 `lltex__data_bank_conflicts_pipe_lsu_mem__shared_op_ld.sum`) :

配置	冲突计数	耗时	冲突度
BK=16 (32 B 行宽)	98,304	17.6 μ s	2-way
BK=64 (128 B 行宽) 无 swizzle	691,067	30.2 μ s	8-way

配置	冲突计数	耗时	冲突度
BK=64 + <code>swizzle<16></code>	297,628	20.7 μ s	4-way

为什么 BK=64 是 8-way: $a = 128i + 32s + 16c \rightarrow \text{bank} = (8s + 4c) \bmod 32$ ，行号 i 的贡献消失（行 stride 128 B 恰为 bank 计数环的整数倍）。

Q66 [进阶] ★ XOR swizzle 的原理？为什么可逆？

答· 把 **chunk 号位与行号低位异或**：`Swizzle<B,M,S>: apply(a) = a  $\oplus$  ((a & yyy) >> S)`，`yyy = (2^B - 1) << (M+S)`。**可逆性来自「对合」**：设 $\sigma(a) = a \oplus m(a)$ ， $m(a) = ((a \& M_hi) \gg S)$ ，只要 XOR 的**源位域与目标位域不相交**（ $S \geq B$ ），就有 $\sigma(\sigma(a)) = a$ 。**工程推论：编码与解码用同一个函数**——
cp.async 写入与 ldmatrix 读出各调一次即互逆，**不需要维护任何逆置换表**。**数字·** 三档标准档位与周期：
`(1,4,3) = SWIZZLE_32B / 256 B`；`(2,4,3) = 64B / 512 B`；`(3,4,3) = 128B / 1024 B`。（**M = 基本元素宽度位**：fp16 的 16 B chunk $\Rightarrow M=4$ ；**S = 每行 chunk 数位**：8 chunk $\Rightarrow S=3$ 。）

Q67 [hard] ★ 为什么 `swizzle<16>` 在 128 B 行宽下只能到 4-way？

答· 因为行号更高的 bit 乘上 128 B 行 stride 后落在 bit7 以上，无法进入 bank 位，单个 XOR bit 最多把 phase 内 8 lane 分到 2 个四联组。要真正 1-way 需要 `swizzle<64>`（`SWIZZLE_128B, B=3`）：`c' = c  $\oplus$  (i & 7)`，行 0-7 的 8 个 chunk 恰好铺满 `q = 0,4,...,28`。**坑·** 原书源码注释在这里写错了（声称「降到 1-way fully conflict-free」），而它自己的 NCU 实测是 297,628 次冲突（4-way）。别把「swizzle 后零冲突」当结论背——**冲突度由行宽决定**。

Q68 [进阶] swizzle 比 padding 好在哪？

答· 三个理由：① **零 smem 浪费**（不花一个字节 padding）；② **保持 16 B 对齐粒度**（padding 改变行 stride，破坏对齐假设）；③ 地址计算只是**几条位运算**（padding 方案不同访问方向要不同 pad 量）。**坑·** 但「**swizzle 一定优于 padding**」不是定律。原书的消融实验：`kPad=0`（compact XOR swizzle，省 ~5 KiB smem、消除 ldmatrix 冲突）让 cp.async 的 LDGSTS wavefronts 从 30.15 M 涨到 68.16 M (2.26 $\times$)，long-scoreboard / LG-throttle / MIO-throttle 分别放大 3.25 $\times$ / 2.74 $\times$ / 1.60 $\times$ ，最终 120.0 TFLOPS vs `kPad=8` 的 166.6 TFLOPS (差 28%)，且未提高 occupancy。**结论：默认 Q/K/V 全用 `kPad=8`**。


Q69 [进阶] 转置的 bank conflict 怎么算？

答· 用行/列 stride 推起始 bank：原始 `64tx + 16j + ty` $\rightarrow$ **16-way**；`PAD=1` 后 `68tx + 17j + ty` $\rightarrow$ **2-way**（`68  $\equiv$  4 (mod 32)`），行 stride 不再是 bank 环长的整数倍）。**数字·** 代价只有 64 行 $\times$ 4 B = 256 B（约 6% 的额外 smem），但**加速比在两个口径下差很多**：L2 口径 2.40 $\times$ vs HBM 口径 1.11 $\times$ 。又一次印证 Q39 的结论：**优化的收益必须标注测试口径**。

3.3 Roofline 与 bound 判断

Q70 [基础] ★ 写出 Roofline 模型与判据。

答· $P = \min(P_peak, AI \times BW)$ ， $AI = \text{FLOPs} / \text{Bytes}$ ， $AI^* = P_peak / BW$ （**ridge point**）。 $AI < AI^* \rightarrow$ **memory-bound**； $AI > AI^* \rightarrow$ **compute-bound**。**数字·** H100: FP16 TC `989/3.35  $\approx$  295`，FP32 `67/3.35  $\approx$  20`。原书测试机（PRO 5000）：**1344 GB/s / 66.9 TFLOPS / ridge $\approx$ 49.8 FLOP/Byte**。



图源: [Roofline model](#), Wikimedia Commons, CC0 (公有领域奉献)。看图的一句话: 拐点 AI^* 左右两侧是两种完全不同的优化问题——左边优化访存 (提高 AI 或换更宽的带宽), 右边优化计算 (用 Tensor Core、降精度)。

Q71 [进阶] ★ 写出 GEMM / GEMV / softmax 的算术强度。

GEMM : $FLOPs = 2MNK$, Bytes = $4(MK+KN+MN)$ → $M=N=K$ 时 $AI = K/6$
 $K=4096 \rightarrow 682.7 \text{ FLOP/Byte}$
 GEMV : $FLOPs = 2MK$, Bytes $\approx 4MK$ → $AI \approx 0.5 \text{ FLOP/Byte}$ (与 M 、 K 无关)
 softmax: $5N \text{ FLOPs} / 8N \text{ Bytes}$ → $AI = 0.625 \text{ FLOP/Byte}$

数字· 原书 `ch01_roofline.cu` 的实测输出可直接当自测: $AI(\text{GEMM})=682.6667$ 、 $\text{GEMV}=0.4998$ 、 $\text{softmax}=0.6250$ 、 $\text{eadd}=0.0833$ 、 $\text{relu}=0.1250$ 、 $\text{dot}=0.2500$ 。坑· Bytes 必须包含输出写回 (读 a 、读 b 、写 $y = 3 \times 4N$ 字节, 不是 $2 \times 4N$) , 漏算会把 memory-bound 算成 compute-bound。

Q72 [进阶] ★ 为什么同一个 AI , bound 类别可以相反?

答· 因为同一块 GPU 有多条屋顶线: FP16 TC 与 FP32 CUDA core 的 P_{peak} 相差约 15 倍, ridge point 也差 15 倍。数字· $AI = 100$ 的算子: FP32 上 $100 > 20 \rightarrow \text{compute-bound}$; FP16 TC 上 $100 < 295 \rightarrow \text{memory-bound}$ (H100 FP16 TC dense 989 TFLOPS $\div$ 3.35 TB/s)。推论: 把 kernel 迁到 Tensor Core 上未必变快——本来 memory-bound 的算子换通路只是把拐点推远, 天花板仍是带宽。坑· 不要把稀疏峰值当 dense 用: H100 FP16 TC 的 1979 TFLOPS 是 sparse 口径 (对应 $AI^* \approx 590$) , 用错会让 bound 类别判反。(另有取整口径差异: $1000 \div 3.35 \approx 300$ 是常见近似, $989 \div 3.35 \approx 295$ 是 dense 精确值。)

Q73 [进阶] 为什么 decode 是 memory-bound 而 prefill 是 compute-bound?

答· decode 每步只生成 1 个 token, 形态接近 GEMV/小 GEMM, AI 是常数级别 (0.5–1), 比拐点低两个数量级; prefill 序列长 (4096) 时每个权重被复用 4096 次, AI 可达 4096, 远超拐点。数字· 这直接解释了「batching 对 decode 几乎免费」(权重搬运已被摊掉), 也解释了附录 E 里「推理优化本质是 memory-bound 优化」。

Q74 [hard] 为什么小数据集的带宽实测会超过 HBM 理论值？

答· 因为数据装进了 L2。原书实测：16 MB 数据落在 96 MB L2 内，测出 1862 GB/s > GDDR7 理论 1344 GB/s。roofline 里的 BW 要用「你的 kernel 实际受限于哪一层」的那个带宽；标定 HBM 带宽时数据集至少要数倍于 L2 容量。

3.4 GEMM 阶梯

Q75 [进阶] ★ 为什么 tiling 能提升 GEMM 性能？AI 公式？

```
AI_naive = 2K / 8K = 0.25 FLOP/B          ← 与 K 无关的常数！
AI_tile  = 2·BM·BN·BK / (4·BK·(BM+BN)) = BM·BN / (2(BM+BN))
AI_smem  = 2·TM·TN / (4(TM+TN)) = TM·TN/(2(TM+TN))
```


数字· BK 在分子分母间相消 —— AI 由 BM×BN 唯一决定：32² tile → AI = 8；128² tile → AI = 32（方型简化为 B/4）。thread tile 优化的是另一层（smem→寄存器）：1×1 → 0.25，4×4 → 1.0，即每 FMA 的 smem 读从 2 次降到 0.5 次。二者正交、可叠加。坑· 既然 AI 与 BK 无关，为什么不把 BK 拉满？因为只增加 smem 驻留、降占用率，并放大单次同步覆盖的计算量；32/64 是常见值。

Q76 [进阶] ★ 讲一遍 GEMM 从 naive 到 TMA 的阶梯，每步解决什么？

阶梯	解决上一步的什么问题	关键机制	实测 (PRO 5000)
L0 naive	——	直译	2048³: 3.144 ms / 5.46 T
L1 tiling + vec4	数据被反复从 HBM 搬 (AI 只有 0.25)	Block Tile 把复用搬进 smem；vec4 把搬运指令砍到 1/4	2048³: 0.661 ms / 25.97 T (4.76×)
L2 TF32 WMMA + cp.async 双缓冲	每 FMA 要 2 次 smem 读；加载时 Tensor Core 闲着	一条 m16n8k8 = 1024 MAC (FFMA 的 32 倍密度)；cp.async 让搬运绕过寄存器	1024³: 28.19 T
L3 mma.sync + Idmatrix + 3 级流水	WMMA 四宗罪 (布局黑盒/寄存器失控/无寄存器双缓冲/流水只有 2 级)	TN 布局 + BK=16 + wait_group(1)	1024³: 76.55 T (2.71×)
L4 swizzle + 寄存器双缓冲 + Block Swizzle	BK 加深后 Idmatrix 撞 bank；slice 间串行；L2 里 block 呈宽条带	XOR swizzle (8-way→4-way)；RA/RB 乒乓；3D grid 重排	4096³: 124.7 T；L2 命中 64.45% → 96.15%，宽 N +4.2%
L5 TMA + mbarrier + WGMMMA + WS	搬运仍占线程；__syncthreads 只能表达「全部到齐」；mma.sync 是同步指令	TMA 零寄存器开销搬运；mbarrier 双计数器；warp specialization	2048³: 164.64 T (1.57×)

数字· L5 那 1.57× 是在「计算指令一条没改」的前提下拿到的 —— 纯靠把搬运移出关键路径 + 让 producer/consumer 重叠。这是最能说明「编排比数学更重要」的一个数字。

★ 先看这条加速曲线 —— 它比任何文字都更能说明「优化是分台阶的」：



每一级在解决什么、又留下什么（这笔账才是面试要讲的；数字口径：RTX PRO 5000 72GB，sm_120a）：

级	解决了什么	遗留问题（下一级的动机）	实测
L0 naive	——	数据被反复从 HBM 搬，A/B 的每个元素只被用一次 ⇒ AI 只有 0.25 且与 K 无关	2048 ³ : 3.144 ms / 5.46 T
L1 block tile + vec4	把 A 行块 / B 列块的复用搬进 smem，vec4 把搬运指令砍到 1/4	每 FMA 要 2 次 smem 读；加载时 Tensor Core 闲着	2048 ³ : 0.661 ms / 25.97 T (4.76×)
L2 TF32 WMMA + cp.async 双缓冲	一条 m16n8k8 = 1024 MAC（FFMA 的 32 倍密度）；cp.async 让搬运绕过寄存器	WMMA 四宗罪：布局黑盒 / 寄存器失控 / 无寄存器双缓冲 / 流水只有 2 级	1024 ³ : 28.19 T
L3 mma.sync + ldmatrix + 3 级流水	掀掉厚抽象：布局白盒、寄存器显式声明、BK 8→16、wait_group(1)	BK 加深后 ldmatrix 撞 bank；slice 间 ldmatrix 与 MMA 串行；L2 里同时在飞的 block 呈宽条带	1024 ³ : 76.55 T (2.71×)
L4 swizzle + 寄存器双缓冲 + Block Swizzle	冲突 8-way→4-way；RA/RB 乒乓盖住 k_step 级延迟；3D grid 重排把 L2 footprint 缩小 4.8 倍	搬运仍占线程（地址计算挤占发射槽）；__syncthreads 只能表达「全部到齐」；mma.sync 是同步指令	4096 ³ : 124.7 T ；L2 命中 64.45%→96.15% ，宽 N +4.2%
L5 TMA + mbarrier + WGMMA + WS	搬运零寄存器开销；双计数器精确同步；释放 127 个线程的寄存器给 consumer	装载已不在关键路径（Sk 2→3 收益 < 0.5%）⇒ 瓶颈回到消费侧的 mma 与 softmax 串行	2048 ³ : 164.64 T (1.57×)
L6 FA3 双 consumer warpgroup	两个独立流在硬件调度器上统计性交错，把 softmax 藏进 GEMM 的影子	——	190–195 T

数字· L5 那 1.57× 是在「计算指令一条没改」的前提下拿到的 —— 纯靠把搬运移出关键路径 + 让 producer/consumer 重叠。这是最能说明「编排比数学更重要」的一个数字。

Q77 [进阶] ★ mma.sync.aligned.m16n8k16.row.col.f16.f16.f16.f16 每段什么意思？

答· .sync 全 warp 到齐；.aligned 要求全 warp 执行同一条指令（条件分歧下使用属未定义行为）；m16n8k16 = A 16×16、B 16×8、C/D 16×8 → 一条 2×16×8×16 = 4096 FLOP；.row / .col 是 A/B 的 fragment 主序；四个类型依次 D / A / B / C；变体 f32.f16.f16.f32 用 4 个 f32 寄存器做累加。

Q78 [进阶] ★ f16 累加的误差为什么是 √K 而不是 K？

答· 因为 f16.f16.f16.f16 变体在每条 mma 指令边界处都舍回 fp16，每步舍入误差近似独立同分布（随机游走）⇒ 累加后是 √K 量级。PTX 还明确声明累加顺序、舍入与次正规处理均未指定 ⇒ 不同架构/驱动逐位结果可不同，正确性判定必须用容差。数字· 原书实测 K=128 时 f16 累加误差约 1.5×10⁻²，同形状 TF32 版是 10⁻⁵ 量级。什么时候必须换 fp32 累加：K 到千级，或输入幅值大于 1 —— 误差进入 10⁻¹ 量级，并在个别元素上溢出 f16 范围（65504）。

Q79 [进阶] fragment 每个 lane 持哪些元素？

答· 口诀：g = lane>>2 管行/列块，tig = lane mod 4 管 2 元素对。

```
A: row = g 或 g+8; col = 2·tig + (i mod 2) + 8·[i≥4]
B: row = 2·tig + (i mod 2) + 8·[i≥2]; col = g
C: row = g + 8·[i≥2]; col = 2·tig + (i mod 2)
```

数字· 寄存器带宽（每 warp 每条指令）：A 输入 4 个 .b32、B 输入 2 个、C/D 各 2 个。

Q80 [进阶] ldmatrix 的寻址协议？为什么和 mma「天作之合」？

答· 每矩阵 8 行 → 8 个 lane 各供一行 16 B 首地址；x4 用全 32 lane 的地址，x2 只用 lane 0-15；要求 16 B 自然对齐。三个理由：① 结果直接落在 mma fragment 期望的分布上；② 一条指令替代 32 lane 各自的 ld.shared 寻址；③ 天然规避多数 bank conflict。坑· .trans 的方向：PTX 原文是「.trans indicates that the matrix is loaded in column-major format」——不加 .trans 才是行装载。（原书源码注释写反了，按它推理会在 NN 布局下选错。）

Q81 [进阶] TN 布局为什么是 Tensor Core GEMM 的默认姿势？

答· A 行主序 + B^T 行主序 ⇒ 搬运两侧对称、内维都是 K；且 mma 要求的 .row.col 恰好被「逐行装载 B^T = 逐列装载 B」天然满足 ⇒ ldmatrix 一个 .trans 都不用加。数字· 代码里的全部体现是索引差别：A 用 m*K + k、B 用 n*K + k。

Q82 [进阶] ★ cp.async 三件套的语义？wait_group(0) vs (1)？

答· cp.async.cg.shared.global（绕过寄存器；.cg 只走 L2 不分配 L1，16 B 是 .cg 唯一合法宽度，.ca 支持 4/8/16 B）→ commit_group（把本线程未提交的拷贝打包成组）→ wait_group N（N 是「允许保留的未完成组数」，不是「第 N 组完成」）。建立期/排空期用 0，稳态满载用 kStages - 2。数字· ★ 为什么 wait 之后必须再跟一次 __syncthreads()？因为 cp.async 的组是 per-thread 的，wait 只保证「本线程发出的搬运」完成，而计算要读的 smem 可能由别的线程搬入——漏掉是 warp 间数据竞争，症状是偶发错数。

Q83 [进阶] kStages 越大越好吗？

答· 不是。深流水容忍更长搬运延迟（稳态 wait_group(kStages-2)），但 smem 随 S 线性增长、挤压占用率与后续 swizzle/padding 预算；S 超过「搬运延迟 / 迭代时间」后收益归零，S ∈ {2,3,4} 常见。数字· FA2 TMA+WS 版 Sk=2 即饱和（Sk 2→3 收益 < 0.5%），而 Sk=3 的 96 KB smem 反而挤掉 2 blocks/SM 的驻留可能。

Q84 [hard] 两级双缓冲各盖什么延迟？

答· 分工明确，不能互相替代：

双缓冲	盖的是什么延迟	机制
smem 多级流水	gmem → smem 的跨 k 迭代延迟	kStages + cp.async + wait_group
寄存器双缓冲	smem → 寄存器的 k_step 级 ldmatrix 延迟	RA[2] / RB[2] 乒乓

3.5 TMA 与 Warp Specialization

Q85 [进阶] ★ TMA 相比 cp.async 解决了什么？

答· 三个：① 搬运不占线程——一条 cp.async.bulk.tensor.2d 由单线程提交，硬件 DMA 搬整块 2D tile，地址计算 / OOB 填充 / smem swizzle 全在 descriptor 里声明，搬运过程零寄存器开销；② 同步语义精确（mbarrier 的 tx count 让「数据到齐」可表达，__syncthreads 只能表达「全部到齐」）；③ 释放出 127

个线程的执行资源与寄存器（经 `setmaxnreg` 让渡给 consumer）。数字· 实测 TMA+WS 相对 cp.async 版稳定 +20%。

Q86 [hard] TMA box 几何的关键约定？

答· 最容易背反的一条：descriptor 的 `globalDim` 写作 (K, M) —— minor 在前。以 $A \in \mathbb{R}^{M \times K}$ 行主序、 $\text{off}(m, k) = m \cdot K + k$ 为例：k 是连续维 (minor)、m 是跨步维 (major)，`boxDim = (BK, BM)`，`tensorCoords = (k0, m0)` 给出 box 左上角。PTX 硬约束：box 总字节数是 16 B 的倍数、地址 16 B 对齐；OOB 行为由 fill mode 决定 (zero fill 或 OOB-NaN fill)。数字· box 内维 $BK = 64 \text{ half} = 128 \text{ B}$ ，恰好等于 SWIZZLE_128B 的宽度 —— 内维字节不能超过 swizzle 档位宽度。D=128 的行有 256 B 塞不进单个 box $\Rightarrow$ box 固定 (64, B)、沿 head_dim 发 2 次 TMA，写 chunk-major 布局；多次 TMA 共享同一个 mbarrier，`expect_tx` 一次声明总字节。

Q87 [hard] ★ mbarrier 的四个量？相位翻转条件？

答· 8 字节对齐、驻留 smem 的 `.b64` 对象，维护：相位 π 、本相位待到达数 P、期望到达数 E、本相位待完成事务量 T；`init` 置 $(0, N, N, 0)$ 。`arrive-on` 做 $P \leftarrow P - \text{count}$ ；`expect-tx` 做 $T \leftarrow T + \Delta T$ ；`complete-tx` 不由软件调用 —— TMA 带 `.mbarrier::complete_tx::bytes`，由 DMA 引擎自动记账。翻转条件： $P = 0 \wedge T = 0 \Rightarrow \pi \leftarrow \pi + 1, P \leftarrow E$ 。核心洞察：「多少个信号」与「多少字节数据」是两把独立的锁 —— 只有全部信号到齐且全部字节落盘数据才算就绪，producer / consumer 之间因此不需要任何 `__syncthreads`。

Q88 [hard] ★ arrive count 为什么是 129 / 257 / 129？

场景	count	为什么
HGEMM WGMMA 版	129 = 128 + 1	consumer 最小单位是整个 128 线程 warpgroup (warpgroup 对齐指令)
FA2 TMA+WS (consumer 用 warp 级 <code>mma.sync</code>)	257 = 256 + 1	8 个 warp 独立推进，每个线程都必须 arrive 一次
FA3 双 consumer、per-WG stage	129 = 128 + 1	屏障按 <code>[cid][stage]</code> 切开，每张只放行一个 WG

答· 「协议只认线程数，不认角色」 —— 把 ws 协议从 Hopper 搬到 SM120 时，这是最容易算错的数字。账本不闭合的两种后果：少算 $\rightarrow$ 永不翻转 $\rightarrow$ 挂死；多算 $\rightarrow$ 提前翻转 $\rightarrow$ 读到半新半旧数据 $\rightarrow$ 静默错误（更危险，因为没有报错）。


Q89 [hard] 什么是 early release？为什么能这么早？

答· consumer 在「数据已进寄存器」时就立刻 `arrive(empty)`：

信号	释放时机	为什么
<code>empty_K[stage]</code>	QKT 一算完	softmax 只碰寄存器、PV 只读 V，K 的 smem 再无人读
<code>empty_V</code>	PV 的最后一组 <code>LDMATRIX_X2_T</code> 之后	V 数据已全在寄存器

共同点：smem 一进寄存器就放行。producer 因此能在 consumer 的 softmax 阶段 就开始覆盖该 stage，把 K 的 stage 周期压缩了 softmax + PV 两段。

★ 这张时序图把「C0 点火」与「两处 early release」都画出来了：



Q90 [hard] 「挂死但没有任何报错」的经典事故是什么？

答· **setmaxnreg** 池数学算到恰好等于上界。每 SM 寄存器文件 65536 个 32-bit 寄存器，triple-WG 配置提出公因子 128： $r_p + 2 \cdot r_c \leq 65536/128 = 512$ 。正常 $40 + 2 \times 168 = 376$ ；事故 $64 + 2 \times 224 = 512$ （恰好等于上界）。为什么恰好等于上界反而挂死：驱动对寄存器文件另有保留份额，有效池小于 65536，**alloc** 永远凑不齐 → **consumer** 卡在 **setmaxnreg**、**producer** 卡在等 **consumer** 的 **barrier arrive**，双向互等纯挂死（无 illegal instruction、无 error code、无超时）。**数字·修复**：留 ≥ 2048 slack → $64/208/208 = 480$ 或 $32/232/232 = 496$ 。

Q91 [hard] 两个 ptxas 静默降级陷阱？

陷阱	症状
setmaxnreg 的 TMA dst 写成 shared::cluster	ptxas 以 C7506 静默丢弃该指令（必须写 shared::cta ）
__launch_bounds__(N) 缺第二个参数	触发 C7508

数字· 相关的硬门槛：**sm_90a 必须用** `-gencode arch=compute_90a,code=sm_90a` (`-arch sm_90a` 会降级为 `compute_90`)；**smem 上限 sm_90a 227 KB vs sm_120a 99 KB**；**TMA 章硬要求 CUDA ≥ 13.0**；**动态 smem > 48 KB 必须** `cudaFuncSetAttribute` `opt-in`，否则 `launch` 报 `invalid argument`。

§4 推理框架层 (Q92–Q131, 40 题)

4.1 PagedAttention 与 KV cache

Q92 [基础] ★ PagedAttention 解决了什么问题？

答· 传统做法按**最大序列长度预分配连续显存**，三种浪费：**内部碎片**（用不满）、**外部碎片**（空洞装不下新请求）、**无法共享**。PagedAttention 把 KV cache 切成**固定大小的 block**（默认 16 个 token），每个请求维护一张 **block table**（逻辑块 → 物理块），**按需分配**——**逻辑连续、物理可以不连续**。数字· 显存利用率从三四成提到 90%+，**同样显存能并发更多请求**，而并发数直接决定吞吐（decode 是 memory-bound，多一个请求几乎不增加时间）。**类比**：完全对应操作系统的**分段 vs 分页**。

Q93 [进阶] ★ PagedAttention 的实现代价是什么？

答· 三个（主动说代价是加分点）：① **attention kernel 要改写**——不能再假设 KV 连续，必须按 **block table gather K 和 V**，这是它最主要的代价；② **block 管理器的 CPU 开销**——分配/回收/引用计数/淘汰都在 CPU 侧做，高 QPS 下会成为瓶颈；③ **前缀共享靠引用计数**——多个请求指向同一物理块，要改时才复制（写时复制），引用计数保证「还在用的块不被回收」。数字· block size 是权衡：**小则 block table 大、kernel 效率低；大则内部碎片回升**。

Q94 [进阶] ★ KV cache 显存怎么估算？batch 1→32 怎么变？

```
KV cache = 2 × num_layers × num_kv_heads_per_rank
            × head_dim × seq_len × batch × dtype_bytes
```

答· 开头的「2」是 K 和 V 两份；注意是 **num_kv_heads** 而不是 **num_heads**——GQA/MQA 下 KV head 远少于 Q head，**这正是 GQA 省显存的原理**；而且 TP 会切 KV head，所以要算「每 rank」的值。数字· LLaMA-70B 风格（80 层、8 个 KV head、head_dim 128、fp16、序列 4096、batch 1）： $2 \times 80 \times 8 \times 128 \times 4096 \times 1 \times 2 \approx 1.34 \text{ GB}$ （每 rank，未做 TP）。**batch 1 → 32 是线性增长约 32 倍 (1.34 → 43 GB)**。

Q95 [进阶] ★ 为什么「显存不够就降 max_model_len」有效？

答· 因为 KV cache 随 batch 与序列长度线性涨，而权重是固定的——长上下文/大 batch 时 KV cache 会超过权重的显存占用。数字· vLLM 启动日志那两行就是算好的结果：`GPU KV cache size: N tokens` 与 `Maximum concurrency`（= 容量 ÷ 单请求最大长度，直接给出并发上限）。坑· PagedAttention 提高的是「利用率」（消碎片），不减少这个公式的值；真要减少用量得靠 KV 量化或 GQA/MLA 这类结构改动。

Q96 [进阶] gpu_memory_utilization 是怎么用的？

答· vLLM 启动时用**总显存 × 该比例**作为可用预算，先装权重 + 激活峰值，剩下的全部切成 KV cache block。数字· 默认值是 0.92（不是 0.9）。坑· 调太高会被别的进程/驱动占用挤爆（OOM 或莫名其妙的失败）；调太低则并发上不去。多实例共享一张卡时必须下调。

Q97 [进阶] Prefix caching 和 PagedAttention 是什么关系？

答· **同一套机制**。前缀共享就是「多个请求的 block table 指向同一物理块」，配合**引用计数 + 写时复制**。数字· 收益取决于**前缀重合度**：多轮对话（system prompt + 历史）、few-shot 模板、RAG 的固定文档场景收益最大。坑· **不是所有场景都开**：前缀不重合时它只增加哈希与查找开销。

4.2 调度与 batching

Q98 [基础] ★ Continuous batching 和 static batching 的区别？

答· **static**：攒一批请求 → 一起跑到全部结束 → 再收下一批。问题是**同批里最长的那条决定整批时间**（短请求被迫等待），而且新请求必须等到批次结束。**continuous**（又称 **iteration-level batching**）：**每个 iteration 结束就重排批次**——完成的请求立刻退出、等待的请求立刻补位。数字· 效果是**吞吐大幅提升且尾延迟下降**；它成立的前提是 **decode 阶段 batch 内的请求彼此独立**（各自有 block table）。

Q99 [进阶] Chunked prefill 是什么？为什么需要它？

答· 把一条长 prompt 的 prefill **切成若干 chunk**，与 decode 请求**混在同一个 batch** 里跑。解决的是 **prefill 与 decode 争抢**：一个长 prefill 会占满算力，让所有 decode 请求的 **ITL 尖刺**。数字· 它与 **PD 分离** 解决的是**同一个问题的两种方案**（时间上切 vs 空间上切）。坑· 它会**增加 TTFT**（单条请求的 prefill 被拉长），所以是用 **TTFT 换 ITL 稳定性**的取舍——这句话是这一题的得分点。

Q100 [进阶] Prefill 和 decode 为什么要分开考虑？

答· 因为它们的**算术强度差两个数量级**（见 Q73）：prefill 是大 GEMM（compute-bound）→ 优化方向是**提高算力利用率**（Tensor Core、量化）；decode 是 GEMV/小 GEMM（memory-bound）→ 优化方向是**减少字节**（量化权重、GQA）和**提高并发**（batching）。数字· 这解释了为什么 **PD 分离** 能各自用最合适的并行策略与硬件配比，也解释了为什么 **decode 上加量化收益最大**。

Q101 [进阶] 投机解码为什么能加速？什么时候会变慢？

答· decode 是 memory-bound —— **每生成一个 token 都要把全部权重读一遍**。投机解码用一个小 draft 模型一次猜 k 个 token，再让大模型**一次 forward 验证这 k 个**：验证的算力成本远低于 k 次串行 decode，因为**权重只读了一遍**。**变慢的场景**：① **acceptance rate 低**（draft 猜不准 → 白算）；② **draft 模型本身太慢**；③ **batch 很大时**——decode 已经从 memory-bound 偏向 compute-bound，“**省权重读取**”的收益被摊薄甚至消失。数字· 典型加速 1.5–2.5×，取决于任务（〔推断〕）。

Q102 [进阶] PD 分离（prefill-decode disaggregation）的收益与代价？

答· 收益：prefill 与 decode 各自用最合适的并行策略与硬件配比、避免互相干扰（ITL 尖刺消失）、可以独立扩缩容。代价：**KV cache 要在 prefill 节点与 decode 节点之间传输**（RDMA / NVLink），而且**多了一跳延迟与一套连接器实现**。数字· 它不提升单卡吞吐，提升的是 SLO 下的有效吞吐与资源利用率——这个「不提升吞吐」的诚实说法是这一题的得分点。

4.3 量化

Q103 [基础] ★ 量化为什么要分 W8A8 / W4A16？各省的是什么？

答· **W 是权重 (Weight)**，**A 是激活 (Activation)**。**W4A16**：权重 4 bit、激活 fp16 —— 省的是**权重显存与权重读取带宽**，主要用于 memory-bound 的 decode。**W8A8**：权重和激活都 8 bit —— 除了省带宽，还能把 GEMM 换成 INT8/FP8 的整数/低精度 Tensor Core，于是 **compute-bound 的 prefill 也受益**。数字· **W4A16 的收益在 decode（省字节）；W8A8 的收益在 prefill（省算力）**——这句话是这道题的核心。坑· 只做权重量化（W4A16）时，**激活仍是 fp16** ⇒ **kernel 里要做反量化**，所以提速上限受限于「带宽减少的比例」，不会因为算力变多而更快。

Q104 [进阶] ★量化的粒度有哪些？各自的精度/成本？

粒度	覆盖	用在哪
per-tensor	整个张量一个 scale	最简单，精度最差（激活 outlier 会毁掉整层）
per-block	128 行 tile	fp8 Q/K/V 默认；量化 kernel 的向量化红利，实测最快档
per-thread	MMA fragment 对齐（64 scale / 128 行）	fp8 Q/K（零 shuffle 反量化）
per-channel	沿 D 每通道、跨 N 取 amax	fp8 V（ $\delta V = \text{colmax}/448$ ）
per-row	softmax 行	fp8 P
per-16 组	1×16 microscaling block	NVFP4 的 Q/K/V/P 的 SF

数字· 两端各自的失败模式：per-block 对 outlier 最脆弱（一个 outlier 毁一整块）；per-row / per-16 的 scale 数量与数据同阶 $\Rightarrow$ SF 本身成为新的访存项。速度差其实很小（ $\pm 2.7\%$ 以内），精度差才是主要动机。

Q105 [hard] 为什么 per-thread 恰好是 64 scale / 128 行？

答· 由 m16n8k16 的 fp32 C-fragment 布局决定：每线程持 2 行 $\times$ 1 个列对，quad 内 4 个 lane 分摊 $n=8$ 列且持有相同 2 行。若 scale 按「C-fragment 行对」组织——每 scale 覆盖 {r, r+8} 两行（quad 共享）——则每线程的全部累加值共享一个 scale，反量化变成「fragment 提升时顺手乘一个寄存器标量」，零 shuffle。

数字· 每 128 行量化块铺 $8 \times 8 = 64$ 个 scale（行维按 16 行一组分 8 组，组内按 {r, r+8} 行对分 8 档）。精度贴近 per-token，消费成本贴近 per-block。

Q106 [进阶] ★fp8 的格式与相对误差？


答· e4m3: ± 448 ，尾数 3 位，相对步长 $\approx 2^{-4} = 6.25\%$ （fp8 路径的 Q/K/V/P）；另有对称 int8（ ± 127 ，均匀， $\text{scale} = \text{amax}/127$ ）作为 QK 的变体（走 $s8 \times s8 \rightarrow s32$ MMA）。scale 专用格式：ue4m3（ $2^{-6} \sim 448$ ）用于 NVFP4 的 per-16 SF；ue8m0（ $2^{\pm 127}$ ，纯指数、整数 SF 步长 100%）用于 MXFP8 的 per-32 SF。坑· e5m2 与 e4m3 的取舍不是「谁更好」而是「要精度还是要范围」。

Q107 [hard] ★fp8 attention 的所有 scale 是怎么消去的？

答· 三条折叠代数，目标是「除 round() 外无额外数学误差源」：① QK: $\exp(\text{scale} \cdot \delta Q \delta K \cdot \hat{S}) = \exp2(\text{scale} \cdot \delta Q \delta K \cdot \log2 e \cdot \hat{S})$ ——一个 fp32 系数折进 exp2，在 tile max 归约之后一次乘入（每元素省一次 FMUL）；② PV: $(P \cdot \text{vs}/\text{pscale})(V/\text{vs}) = PV/\text{pscale}$ ——vs 精确消去（不是近似），好处是 gmem 里预量化的 V8 原样复用、无需重写；③ epilogue: $0 = o_acc \cdot (1/448)/q$ ——一步同时完成反量化与 softmax 归一化。数字· fp4 再加两条：两级 P 的 $1/2688$ 与 $\log2 6$ 全折进 exp2；smooth-V 的 vm 在 finalize 处加回（softmax 权重和为 1 $\Rightarrow$ 提出列和后与归一化相消）。

Q108 [hard] NVFP4 与 MXFP4 的区别？fp4 的收益来自哪里？

答· 数据都是 e2m1（ ± 6 ，可表示值只有 {0, ± 0.5 , ± 1 , ± 1.5 , ± 2 , ± 3 , ± 4 , ± 6 }，相对步长约 25%）；差别在 SF：NVFP4 用 ue4m3 / 16 元素块，MXFP4 用 ue8m0 / 32 元素块——



图源：NVFP4 相关论文，[arXiv:2509.25149](https://arxiv.org/abs/2509.25149)，CC BY 4.0。这是 NVFP4 那一半；MXFP4 的差别只有两个数字：块从 16 变 32、scale 从 E4M3 变 E8M0 —— E8M0 是纯指数，步长恒为 100%，这就是 MXFP4 精度更低的全部原因。

SF 的尾数位决定尺度精度，MXFP4 的整数 SF 步长 100%，所以精度更低。**fp4 的收益「不是」MMA 吞吐** —— blockscale `mx4nvf4` 的吞吐只与 **fp8 dense** 相当；收益全在带宽：K/V/SF 的字节数减半以上。数字· attn kernel 本身 fp4 比 fp8 快 $\approx 23\%$ ，e2e 1.2–2.1 $\times$ ；代价是 ~ 1 ms 量级的前处理链固定成本 $\Rightarrow$ 只与 prefill 绑定，小 Nq (cross / decode) 结构性不划算。

Q109 [hard] smooth-K / Hadamard / delta_s 三个量化技巧各是什么？

答· 都是在量化之前把数据变得更“好量化”：① **smooth-K**： $K' = K - 1\bar{k}^T$ （减列均值）， $S' = QK'^T = S - \Delta$ （ Δ 每行是常数） $\Rightarrow$ softmax 不变 $\Rightarrow$ P 与 O 逐 bit 不变，只有 lse 需要把 `scale·qs,m` 加回。收益来源：LLM 的 K 矩阵常有系统性非零列均值（位置编码残余、layer norm 偏置），减去后 amax 显著下降 $\Rightarrow$ 等价于免费收紧了量化步长。② **Hadamard 旋转**： $(Q\hat{H})(K\hat{H})^T = Q\hat{H}\hat{H}^TK^T = QK^T$ （逐元素精确、零修正项），靠 whitening/Jackson 性质把 outlier 能量摊平 $\Rightarrow$ 块 scale 收敛。数字· **FA-3 实测：与分块量化联合可将 FP8 RMSE 降低 2.6 $\times$** 。③ **delta_s rank-1 修正**（fp4 版 smooth-K）： $S = \hat{Q}\hat{K}^T + \Delta S$ ， $\Delta S = q_m \cdot K^T - q_m \cdot \bar{k}$ 。坑· 右边的 $K - \bar{k}$ 千万不要物化 —— 前半是低秩 GEMM、后半是每行常数；任何多余的行常数会平移 lse 但不改变 O。

Q110 [进阶] ★ 量化的调参杠杆在哪？（一个很有说服力的实测）

答· 实测的 knob 矩阵 (fp8 D=128 self-attn, 基线 = QK fp8 / PV f32 / Q/K/V 全 per-block) :

配置	时间	性能	相对
基线	3.01 ms	365 T	—
qk=int8	3.06	359 T	-1.7%
pv-acc=f16	3.01	365 T	±0%
q/k per-thread	3.10	355 T	-2.7%
v per-channel	3.07	359 T	-1.7%
smooth-v	2.98	369 T	+1.0%

数字· 主权区里 kernel 主体是 QK+PV tensor pipe (占 77%) , 数值通路 knob 全部落在 ±2.3% 内 ⇒ 精度选择可以按需开、速度代价可忽略; 而默认的 per-block 恰是最快档 (量化 kernel 的向量化红利) 。真正的杠杆在两端: causal 精度 (hybrid, 前缀行 fp16) 与大 D dispatch, 不在主权区的数值通路。

4.4 显存与 OOM

Q111 [进阶] 显存都花在哪了?

答· 五块: 权重、KV cache、激活/临时 buffer、CUDA context + 框架预留、显存碎片。 数字·

gpu_memory_utilization 默认 0.92; 推理时权重固定、KV cache 随 batch×seq 线性涨; CUDA context 本身就要几百 MB (多进程共享一张卡时这项会翻倍) 。

Q112 [进阶] OOM 怎么排查?

答· 按顺序: ① 看是启动时 OOM 还是运行中 OOM (前者是权重/配置问题, 后者是 KV cache 涨爆); ② 降 max_model_len / max_num_seqs (直接压 KV cache 上界); ③ 看 maximum concurrency (启动日志给的上限, 对不上就是估算错了); ④ 查碎片 (torch.cuda.memory_summary() 的 reserved vs allocated 差); ⑤ 查泄漏 (warmup 后快照、跑一轮再快照, 看是否持续增长) 。 数字· KV cache block 没被回收 (引用计数错) 是一种典型泄漏形态。 坑· 一上来就 PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True 是碰运气; 先分清是“真的不够”还是“分配器碎片”。

Q113 [进阶] 显存碎片怎么产生? 怎么缓解?

答· 不同大小的分配交错释放后, 空闲块被切成不连续的小块, 够用的总量却装不下一个大的连续请求。缓解: PagedAttention 本身就是最大的缓解手段 (KV cache 变成固定大小的块); expandable_segments、预分配大块池、统一 batch 形状。 数字· GPU 的分配器 (caching allocator) 只缓存自己申请过的块, 所以 reserved 通常大于 allocated —— 这两个数的差就是碎片+缓存的量级。

4.5 指标体系与性能

Q114 [基础] ★ TTFT / TPOT / ITL / goodput 的定义?

指标	定义
TTFT	Time To First Token: 请求发出到第一个 token 返回
TPOT	Time Per Output Token: (总时延 - TTFT) / (输出 token 数 - 1)
ITL	Inter-Token Latency: 相邻两个 token 之间的间隔 (逐次测量, 不是一个平均值)

指标	定义
goodput	满足 SLO 的有效吞吐（每秒多少条“达标”的请求），不是裸吞吐

坑· 用平均延迟当 SLO 载体是错的——流式服务的 SLA 约束的是 ITL 的 p99（用户感受到的是“卡顿”）。吞吐与延迟是 tradeoff：batch 越大吞吐越高，但每个请求的 ITL 越差——goodput 就是把这两者放在同一个数里的办法。

Q115 [进阶] 一个 decode 请求变慢了，怎么定位？

答· 按范围从大到小：① **先排除客户端/网络**（用服务端指标对比 TTFT 与 ITL，看是哪一段变差）；② **看是不是 batch 变大**（并发上去后单请求变慢是正常的，看 goodput 有没有涨）；③ **看 GPU 利用率与显存**（`nvidia-smi dmon`、`torch.cuda` 指标）；④ **区分通信 vs kernel**（`--enforce-eager` 或关掉重叠，看差异）；⑤ **上 profiler**（`nsys` 拿占比 → `ncu` 定性）。**数字·** 如果 ITL 出现周期性尖刺而平均正常 ⇒ 大概率是 prefill 插进来了（chunked prefill 没开，或 chunk 太大）。

Q116 [进阶] 怎么压 ITL 的尾延迟？

答· ① **开 chunked prefill**（把长 prefill 切小，避免它独占算力）；② **限制 `max_num_batched_tokens`**（每步计算量有上界）；③ **PD 分离**（物理上隔离）；④ **调度上优先照顾长尾**（不能只按 FCFS）。**数字·** 权衡要点：这些手段都会牺牲 TTFT 或吞吐——面试时要主动说出你牺牲了什么。

4.6 CUDA Graph 与编译

Q117 [进阶] ★ CUDA Graph 省的是什么？适合什么场景？

答· 省的是**每个 kernel 的 launch 开销**（几微秒 × 几百个）以及 CPU 侧提交开销。**适合：kernel 多、每个 kernel 小、执行序列固定的负载**——典型就是 **decode**（每步几百个小 kernel，launch 开销占比高）。反之计算量大、kernel 少的 prefill 收益就小。

Q118 [进阶] ★ 动态输入下怎么用 CUDA Graph？

答· 三种做法：① **按形状分桶 (bucketing)**——为常见 batch size 各 capture 一张图，落到哪档用哪张，**vLLM 就是这么做的**，最主流，代价是显存随图的个数增长；② **Padding 到固定形状**——简单，但 padding 部分白算；③ **只把固定部分放进图**——变化输入通过**拷贝进预注册 buffer** 喂进去，**这正是 vLLM custom all-reduce 的做法**。**数字·** 硬约束：**kernel 参数必须固定**（所以 buffer 要预注册）、**capture 期间不能建连和同步**（所以 NCCL 的懒初始化会炸，vLLM 因此自己写了 `pyncccl`）。

Q119 [进阶] `--enforce-eager` 什么时候用？有副作用吗？

答· 它是**排障时区分「graph 问题」和「计算/通信问题」的第一步**：开了之后行为退化到 eager，如果问题消失就说明是 capture 相关的。**坑·** 它有副作用：会连带废掉依赖 **FULL graph 的优化**（例如 DBO 通算重叠）。所以它只能当**诊断手段**，不能当长期配置。

4.7 MoE 与并行（框架侧）

Q120 [进阶] ★ MoE 为什么用 all-to-all 而不是 all-reduce？

答· 因为 MoE 的专家是按 **token 路由** 的：每个 token 要去不同的专家。**all-to-all 交换的是「数据」**（token 到专家的分派），**all-reduce 归约的是「结果」**（同一份数据在所有 rank 上的和）。语义完全不同。**数字·** 代价是 **all-to-all 的通信量随「token 数 × top-k × hidden」增长**，而且是**数据依赖的**（路由结果决定发送量）⇒ **负载不均衡 + 需要 permute/unpermute 两个额外 kernel**。

Q121 [进阶] ★ MoE 的 all-to-all 有哪些实现？wire format 有什么区别？

答· vLLM 里有多个 **all-to-all backend** (`FusedMoEPrepareAndFinalize` 的各个实现) , 差别在 **wire format**: 有的传量化后的 **token** (fp8/nvfp4 + scale) , 有的传**原始 dtype**; 因此对**尺寸与对齐**的要求不同。

数字· 三条通用约束 (详见 ch08 §8.1) : ① **尺寸往往是 2 的幂取整** (避免 cicc 编译风暴); ② **量化后需要额外的 scale 布局**; ③ **专家坐标系有三套** (全局专家 id / 本地 id / 路由表里的 id) , **混淆它们是经典 bug**。

Q122 [进阶] EPLB 是什么? 为什么需要它?

答· Expert Parallel Load Balancer: **在线统计每个专家的负载, 然后把热点专家复制/迁移到别的 rank**。需要它是因为 **MoE 的路由是数据依赖的** $\Rightarrow$ **专家负载天然不均衡**, 个别 rank 成为瓶颈, 整个 all-to-all 就被最慢的 rank 拖住。数字· vLLM 里 EPLB 有**独立通信组**、按 **window (如 1000) + step (如 3000)** 周期重排 (详见 ch04 与 `appendix-code-tour.md`) 。

Q123 [hard] MegaMoE 是什么? 它解决了什么?

答· 把**整个 MoE 层** (dispatch all-to-all + 专家 GEMM + combine all-to-all) **压成一个 cooperative kernel**, 用**对称内存 (symmetric memory)** 做跨卡通信、在 kernel 内直接读写对端显存, 从而**消除 kernel 边界、消除 permute/unpermute 的中间张量**。数字· 关键设计: `kNumBarrierSignalBytes = 128` (一个 L2 line, 用于热点原子)、**7 个候选 BLOCK_M** ({8,16,32,64,96,128,192} , LCM = 384) 、 `TokenSrcMetadata` 12 字节; `NCCL_MAX_CTAS=8` **是为了避免死锁** (通信 kernel 与计算 kernel 抢 SM) 。详细拆解见附录 F。

Q124 [hard] 为什么 MegaMoE 要动态选 BLOCK_M ?

答· 因为**每个专家的 token 数极不均衡** (热门专家几千个 token、冷门专家几个) 。固定 `BLOCK_M` 会导致: 太大 $\Rightarrow$ 冷门专家浪费大量 padding 计算; 太小 $\Rightarrow$ 热门专家启动太多 block、调度开销大。所以**按实际 token 数从 7 个候选里选一个**, 并用 **LCM = 384** 保证不同 `BLOCK_M` 的 block 之间**不重复也不遗漏地覆盖 token**。

4.8 服务化与容错

Q125 [进阶] 你会用哪些指标描述推理服务性能?

答· 四组: ① **延迟**: TTFT、TPOT、ITL (**p50/p90/p99, 不只看平均**) ; ② **吞吐**: tokens/s、requests/s、**goodput (满足 SLO 的)** ; ③ **资源**: GPU 利用率、显存占用、**KV cache 使用率/命中率**; ④ **质量**: acceptance rate (投机)、量化后的精度回归结果。数字· **一定要说「p99 而不是平均」** —— 这是判断你有没有做过线上的分水岭。

Q126 [进阶] 服务的容错与弹性怎么做?

答· ① **请求级重试与超时**; ② **实例健康检查 + 摘除**; ③ **PD 分离时 KV 传输失败的降级** (重算 prefill) ; ④ **权重加载失败的回滚**; ⑤ **弹性扩缩容时 KV cache 的迁移或放弃**。数字· **推理比训练好做容错** (无状态请求、可以重试) , 但 **PD 分离引入了跨节点的中间状态**, 这一块是新难点 (见附录 E §E.10) 。

4.9 Attention 后端

Q127 [进阶] vLLM 里有哪些 attention 后端? 怎么选?

答· FlashAttention、FlashInfer、Triton 自研、xFormers、以及各种量化/稀疏变体。选择依据: **GPU 架构 (是否支持 FA3/FP8)** 、**dtype**、是否要 **sliding window / chunked prefill / prefix caching**、**head_dim 与 GQA 配置**。数字· 详见附录 E §E.2.2 (vLLM 的 attention 后端表) 。

Q128 [hard] ★ FlashAttention 为什么不减少 FLOPs 却更快?

答· 因为它把 attention 从 **memory-bound 变成 compute-bound**：朴素实现要物化 $N \times N$ 的 S 和 P 矩阵并来回搬 HBM，IO 是 $O(N^2)$ 量级；FA 用 **tiling + online softmax** 把 S/P 留在片上，IO 降到 $O(Nd + N^2 d^2 / M)$ 。

数字· $AI_naive \approx d/2 = 32$ ($d=64, fp16$)， $AI_FA \approx Br = 64-128$ ； $B=1, H=32, N=4096, D=64$ 时朴素实现的中间矩阵 HBM 往返 ≈ 4.3 GB，而有效数据只有 67 MB (1/64)。而且 $O(N^2)$ 的显存账在长序列下先于时间把方案毙掉。

Q129 [hard] ★ 写出 online softmax 的五步更新。

```
1. m_new = max(m_old, rowmax(S))
2. P      = exp(S - m_new)                ← 减【新】max
3. q_new = exp(m_old - m_new) ⊙ q_old + rowsum(P)
4. O      ← O · diag(exp(m_old - m_new)) + P · V   ← q 与 O 用同一个 rescale 因子
5. (全部块扫完后只做一次) O ← diag(1/q) O
```

答· 数学基础是**平移不变性** $\text{softmax}(x - c \cdot 1) = \text{softmax}(x)$ (分子分母同乘 $e^{\{-c\}}$ 严格约掉) —— **减 max 不改变结果，只改变中间量的量级**。减 max 后的界： $x(i) - m \leq 0 \Rightarrow e^{\{x(i)-m\}} \leq 1$ ，分子绝不溢出。

数字· $1/q$ 只在循环外做一次 是 FA2 相对 FA1 的关键简化；副产品是退化情形天然安全 ($m=-\infty, q=0, 0=0$ 时 $e^{\{-\infty\}} = 0$ 精确给出，不产生 NaN)。

Q130 [hard] ★ FA1 / FA2 / FA3 各改了什么？

代	改动	数字
FA1	tiling + online softmax + 反向 recomputation ("三板斧"是 FA1 的贡献)	以约 30% 量级重算换 $O(N^2)$ 激活显存；GPT-2 ($N=1K$) 端到端 3× 加速，激活显存省 10–20×
FA2	削非 matmul FLOPs + seqlen(Q) 维并行 + warp 级 split-Q	比 FA1 快约 2×；A100 前向最高 230 TFLOPS (峰值 73%)
FA3	warp specialization + pingpong + FP8	比 FA2 快 1.5–2×；H100 fp16 前向最高 740 TFLOPS (75%)，FP8 接近 1.2 PFLOPS

坑· 不少资料把“三板斧”算在 FA2 名下，这是常见的归属错误。

Q131 [hard] merge_attn_states 的 LSE 合并与 FA 主循环的 rescale 是什么关系？

答· 两套口径，不可混搭： $LSE = m + \log q$ (把 (m, q) 无损打包成一个标量)； $L = \max(LSE_A, LSE_B)$ 、 $w = e^{\{LSE-L\}}$ 、 $\alpha = w_A / (w_A + w_B)$ 、 $O = \alpha O_A + \beta O_B$ ($\alpha + \beta = 1$ 的凸组合)。主循环里的 $e^{\{m_old-m_new\}}$ 是「在线合并」(寄存器里一份 O 滚动)；LSE 式是「事后合并」(两块各落盘 O 与 LSE 后用 elementwise kernel 拼回)。

数字· LSE 式作用在【已归一化】的 O 上，而 FA 主循环的 O 是【未归一化】的 —— 混搭是最常见的隐蔽错误。merge kernel 实测 0.7849 ms / 1031.4 GB/s ($\approx$ 峰值 77%，搬 809.5 MB)。

§5 分布式与通信 (Q132–Q160, 29 题)

5.1 并行策略

这里是「一句话版」；通信量公式、流水气泡、ZeRO、EP vs TP、CP 的 ring attention、以及五者的组合决策树都在 §11 (Q256–Q262) —— 面分布式/训练/集群岗请直接跳那里。


Q132 [基础] ★ TP、PP、DP、EP 分别解决什么问题？

策略	切什么	解决什么	代价
TP (张量并行)	层内的权重矩阵 (按列/行切)	单层放不下一张卡	每层两次 all-reduce, 通信最频繁
PP (流水并行)	按层切	跨机扩展	流水气泡; 需要 micro-batch 调度
DP (数据并行)	数据 (每卡一份完整模型)	吞吐	训练要 all-reduce 梯度; 推理时各副本独立
EP (专家并行)	MoE 的专家	MoE 参数量	all-to-all (数据依赖、负载不均)

坑· 推理的 DP 不 broadcast 梯度 —— 这是常见的口误 (推理没有反向)。推理 DP 的每个副本各自独立处理请求，只在负载均衡层面协作。

Q133 [进阶] ★ 为什么 TP 不能跨机？

答· 因为 TP 每层要做两次 all-reduce，通信延迟敏感且频繁。跨机走 IB 的延迟 (几 μ s) 与带宽都远不如 NVLink，通信时间会超过计算时间，扩展效率崩塌。数字· 所以实践是 $TP \leq 8$ (一个 NVLink 域内)，跨机靠 PP / DP / EP；EP 的 all-to-all 虽然也跨机，但它是“整块数据搬运”而不是每层两次的细粒度同步，带宽效率高得多。



图源: [Amdahl's law](#), Wikimedia Commons, CC BY-SA 3.0。读法: 横轴并行度、纵轴加速比; 串行占比 $1-p$ 决定渐近上限。TP 跨机时 $1-p$ 被 all-reduce 的同步开销抬高, 曲线会提前压平——这就是「扩展效率崩塌」的定量含义。

Q134 [进阶] Sequence Parallel 提性能吗?

答· ★ SP 本身不提升性能——它把 `all_reduce` 换成 `reduce_scatter + 本地 norm + all_gather`, 通信量完全不变, 只是创造了一个可以融合的接缝。真正的收益来自 AsyncTP 的 GEMM+RS / AG+GEMM 融合 (让通信与相邻 GEMM 重叠)。数字· 详见 ch08 §8.2 与 `sequence_parallelism.py` (源码里明确写了这一点)。坑· 把 SP 当成“减少通信”来答会立刻暴露没读过代码。

Q135 [hard] DCP 和 PCP 的区别?

答· 两个不同的东西: PCP (prefill context parallel) 会扩大 world size, 把 prefill 的序列切开算; DCP (decode context parallel) 不扩大 world size, 只是把 decode 阶段的 KV cache 按序列维切到已有的 TP rank 上 (“用通信换显存”)。数字· DCP 的 `ag_rs` → `a2a` 后端把每层 NCCL 调用从 3 次降到 2 次 (`parallel.py:126-128`、`:351-354`)。

5.2 集合通信与 NCCL

Q136 [基础] ★ 集合通信有哪些操作?

答· 八个: `broadcast`、`reduce`、`all-reduce`、`scatter`、`gather`、`all-gather`、`reduce-scatter`、`all-to-all` (另有 `scan` 等)。数字· 关键恒等式: `all-reduce = reduce-scatter + all-gather`, `reduce = all-reduce` 到单 rank。ring all-reduce 的通信量是 $2(N-1)/N \cdot S \approx 2S$ ——与 rank 数无关, 这是它最重要的性质。

Q137 [进阶] ★ ring all-reduce 怎么算？为什么是 2S？

答· 分两阶段：**reduce-scatter**（每 rank 负责 S/N 的一段，在环上转 $N-1$ 步把各段归约）+ **all-gather**（再转 $N-1$ 步把结果广播）。每阶段每 rank 收发 $(N-1)/N \cdot S$ 字节 $\Rightarrow$ 总通信量 $2(N-1)/N \cdot S \approx 2S$ 。数字· 与 N 无关，但延迟随 N 线性增长（ $N-1$ 步），所以小消息时 ring 不是最优 $\Rightarrow$ NCCL 对大消息用 ring、小消息用 tree。

Q138 [进阶] tree all-reduce 什么时候比 ring 好？

答· 小消息 / 延迟主导时。ring 要 $2(N-1)$ 步，tree 只要 $2 \cdot \log_2 N$ 步（reduce 阶段 $\log$ 步 + broadcast 阶段 $\log$ 步），步数从 $O(N)$ 降到 $O(\log N)$ 。代价是带宽利用率低（树的上层链路成为瓶颈）。数字· 所以判断是「延迟敏感还是带宽敏感」：decode 里的 all-reduce 消息很小（hidden $\times 2$ bytes），延迟主导 $\Rightarrow$ tree 可能更优；prefill 的大 all-reduce 是带宽主导 $\Rightarrow$ ring。

Q139 [进阶] all-to-all 的通信量与 ring all-reduce 有什么本质不同？

答· all-reduce 的通信量是 $2S$ （与 N 无关）；all-to-all 是每个 rank 向每个其它 rank 发一份 $\Rightarrow$ 通信量 $S \cdot (N-1)/N \approx S$ 但每个 rank 的收发对端是 $N-1$ 个，且必须等到所有对端都交换完。数字· 更关键的区别是「数据依赖」：all-to-all 的发送量由运行时数据决定（MoE 路由结果），而 all-reduce 的通信量在编译期就已知——这导致 all-to-all 需要 permute/unpermute、负载均衡（EPLB）、以及必须处理“某个 rank 没有数据要发”的情形。

Q140 [进阶] α - β 模型是什么？怎么用它判断优化方向？

答· $T = \alpha + S/\beta$ （ α = 固定延迟， β = 带宽， S = 消息大小）。小消息时 α 主导（优化目标是减少通信次数、降低延迟）；大消息时 S/β 主导（优化目标是提高有效带宽：多网卡、NVLink、减少协议开销）。数字· 详见 ch01 与 [figures/alpha-beta-bandwidth.svg](#)（量化曲线）。

Q141 [进阶] InfiniBand 和 RoCE 的区别？为什么 RDMA 重要？

答· IB 是专用网络（自己的 HCA、交换机、链路层协议），原生无损、延迟最低；RoCE 是「以太网 + RDMA」，成本低但要靠 PFC/ECN 做无损，调参复杂。RDMA 的价值是「绕过 CPU 与内核」：网卡直接读写对端内存，零拷贝、单边操作（RDMA READ/WRITE）、延迟从几十 μs 降到几 μs 。数字· GPUDirect RDMA 再进一步：网卡直接读写显存，绕过 host 内存 $\Rightarrow$ 跨机 TP 与 PD 分离的 KV 传输都依赖它。

Q142 [进阶] NVLink / NVSwitch 和 PCIe 的差距有多大？

答· PCIe Gen5 $\times 16 \approx 64$ GB/s（单向），NVLink 4 (H100) ≈ 450 GB/s 单向 / 900 GB/s 双向，差距接近一个数量级；而且 PCIe 的 P2P 在部分平台上受限（需要 ACS 关闭等）。数字· `nvidia-smi topo -m` 看拓扑：NV# = 经过 # 个 NVSwitch；PIX/PXB/PHB = PCIe 层级；SYS = 跨 NUMA socket（最差）。一条经验规则：TP 域要全在 NV# 内。

Q143 [进阶] NCCL 怎么选算法和协议？

答· 算法（Ring / Tree / CollNet / NVLS / PAT）：按消息大小、拓扑、rank 数选，小消息偏 tree、大消息偏 ring、单机内可用 NVLS（NVSwitch 内建归约）。协议三档：LL（低延迟，小消息）、LL128（折中）、Simple（高带宽，大消息）。坑· NCCL 的具体启发式规则没有公开且逐版本变化——不要把「小消息必用 tree」当定理背。该说的是行为层面的准确描述 + 用 `NCCL_DEBUG=INFO` 实测试证。

Q144 [进阶] NCCL 卡住了怎么排查？

答· 第一步不是看堆栈，而是核对「三一一致」：① 通信顺序一致（所有 rank 的集合操作序列必须严格相同）；② dtype / 形状 / 设备一致；③ 后端选择一致（别出现部分 rank 走 custom、部分走 NCCL）。然后：`NCCL_DEBUG=INFO` 看卡在哪个 op；`NCCL_DEBUG_SUBSYS=INIT,NET` 看建链；`NCCL_IB_DISABLE=1` 排除 IB 问

题； `NCCL_P2P_DISABLE=1` 排除 P2P 问题。 `数字·` 详见 ch05 的排障手册（含决策流程图与「三一致」原则）。

Q145 `[进阶]` **symmetric memory 是什么？NCCL 什么时候支持？**

`答·` 让**所有 rank 的同一块 buffer 在彼此的地址空间里可寻址**的机制（类似分布式共享内存）。它让「单边通信」（一个 rank 直接读写另一个 rank 的 buffer）成为可能，是**通算融合与 MoE megakernel 的基础**。 `数字·`
五个里程碑要分清（这是最容易被讲糊的一题）：

NCCL 版本	引入的能力
2.27.3	对称内存 window API (<code>ncclCommWindowRegister</code>) , vLLM 硬断言 <code>>= 22703</code>
2.28.3	Device API (<code>ncclGetLsaPointer</code> 等, LSA + Multimem)
2.28.7	GIN (GPU-Initiated Networking)
2.29.2	host 侧单边 RMA (<code>ncclPutSignal</code> / <code>ncclSignal</code> / <code>ncclWaitSignal</code>)
2.31	CFT

⚠ 两个常见错误：① 说「GIN 是 2.30.4 引入的」—— **2.30.4 是 DeepEP v2 的要求**，GIN 特性本身在 **2.28.7**；② 说「vLLM 用 GIN」—— **vLLM 自己只做 host 侧对称内存**（ `win_flags` 硬编码、整个 checkout 里没有 device 侧 NCCL 调用）；**GIN 进入 vLLM 的唯一入口是 `deepep_v2` 后端**（要求 `DeepEP ≥ 2.0 + NCCL ≥ 2.30.4 + IBGDA` 网卡）。③ 还有一条**官方文档 → 源码的交叉验证**很值得说：NCCL 2.27.3 release notes 原文写 *“Initial support includes P2P and NVLS connectivity, floating point types up to 32 bits, sum as the reduction operator, and one collective operation per group.”*——这正好解释了为什么 vLLM 的 `SymmMemCommunicator` **把 dtype 写死成 `bfloat16`、op 写死成 `sum`**。

5.3 通算融合与重叠

Q146 `[进阶]` **★ 通信和计算怎么重叠？难点在哪？**

`答·` 常见手段：① **多 stream**（通信流与计算流分开发，用 event 建立依赖）；② **DBO (Dual Batch Overlap)** —— 把两个 micro-batch 的计算与通信乒乓起来；③ **kernel 级融合**（把通信 kernel 和计算 kernel 合成一个）；④ **异步 TP**（AsyncTP，GEMM 与 RS/AG 融合）。**三个根本障碍：**① **依赖链**（通信的输入依赖计算的输出）；② **SM 争用**（通信 kernel 也要占 SM，和计算抢资源）；③ **同步点**（ `__syncthreads` 级别的 barrier 无法重叠）。

Q147 `[hard]` **DBO 的双线程 ping-pong 是什么？**

`答·` 用**两个 CPU 线程**分别驱动两个 micro-batch 的执行流：线程 A 提交 batch 0 的计算 → 通信；线程 B 提交 batch 1 的通信 → 计算。关键在于**用一个 yield 点把 CPU 的执行权交出去**，让另一个线程的 GPU 工作能排进 stream 而不被阻塞。 `数字·` `--enforce-eager` 会废掉 DBO（它依赖 FULL CUDA Graph）；**DBO 的 `previous_event` 必须在 yield 之前 capture**——计算 stream 是两个 ubatch 共享的，**在 yield 之后记录会让 event 覆盖另一个 ubatch 的工作，重叠静默失效**（ `deepep_ht.py:119-123` ）。

Q148 `[hard]` **DBO 的准入条件有哪些？**

`答·` 有**一整套条件**（ch07 列了 14 条），典型几条：后端必须是支持 DBO 的（DeepEP 的 HT/LL 等）、**不能用 `--enforce-eager`**（要 FULL CUDA Graph）、**不支持与投机解码组合**、batch 要能切成两个 ubatch（有最小尺寸要求）等。 `坑·` **不满足条件时 DBO 会静默不生效**（而不是报错）——所以要用 **profiler 验证它真的重叠了**，不能只看日志说“enabled”。

Q149 [hard] SM 仲裁 (`max_sms_used`) 是什么? 为什么重要?

答· NCCL 的通信 kernel 也要占 SM。如果不限制, 通信 kernel 可能占满 SM, 把计算 kernel 挤出去 $\Rightarrow$ 不但不重叠, 反而串行化甚至死锁。所以要把通信能用的 SM 数限制住 (vLLM 里是 `max_sms_used` / `VLLM_DBO_COMM_SMS`)。数字· `VLLM_DBO_COMM_SMS` 默认 20 (`envs.py:287`)。一个很容易踩的坑: 不同 backend 的 `max_sms_used()` 返回值语义不一致——HT 返回 `None` (`min(20, None) = 20`, 即用默认值), 而 LL/NIXL 返回 0 $\Rightarrow$ `comm_sms = 0` $\Rightarrow$ SM 控制被静默跳过 (`all2all.py:346/559/1085`)。一个返回值同时承载了「我用 0 个 SM」和「别限制我」两种含义。

Q150 [hard] `NCCL_MAX_CTAS=8` 是干什么的?

答· 它不是一个调优旋钮, 而是一个正确性开关。DeepGEMM 的 Mega MoE 用 cooperative launch, 要求所有 CTA 同时常驻; 如果 NCCL 占了 SM, cooperative launch 就凑不齐 CTA $\Rightarrow$ 永远挂住 $\Rightarrow$ 互等死锁。所以必须限制 NCCL 的 CTA 数。数字· `eplb_utils.py:83-107`; 这是“MegaMoE 与 NCCL 抢 SM”这个根本矛盾的具体表现。

5.4 MoE 通信细节

Q151 [进阶] ★ MoE all-to-all 的完整数据流是什么?

答· 六个阶段: ① routing (算 router logits $\rightarrow$ top-k 专家 id 与权重); ② permute (按目标专家把 token 重排, 生成发送缓冲与 routing table); ③ dispatch all-to-all (token 发到专家所在的 rank); ④ 专家 GEMM (本地专家算); ⑤ combine all-to-all (结果发回原 rank); ⑥ unpermute + 加权求和。数字· ② 和 ⑥ 是两个额外的 kernel (纯数据搬运, 没有计算)——MegaMoE 的存在意义之一就是把它俩消掉。

Q152 [hard] ★ MoE 的「三套专家坐标系」是什么? 为什么容易出 bug?

答· ① 全局专家 id (模型层面的 $0..E-1$); ② 本地专家 id (本 rank 上的第几个); ③ routing table 里的 id (发送缓冲里的排布顺序)。三者之间要做映射, 一旦混淆就会出现“token 被送给错误的专家”——而且形状完全合法、不报错, 只是结果错。数字· 详见 ch08 §8.1 的坐标系对照表。

Q153 [hard] MoE 的 wire format 有哪些? 约束是什么?

答· 各 backend 传的东西不同: 量化后的 token + scale (fp8 / nvfp4) 或原始 dtype; 因此对尺寸与对齐的要求不同。三条通用约束: ① 尺寸往往取整到 2 的幂 (避免编译器/cicc 的编译风暴); ② 量化后需要额外的 scale 布局; ③ 接收侧必须能处理“某 rank 没有数据”的情形。

5.5 KV 传输与权重

Q154 [进阶] KV 传输做什么用?

答· 把 prefill 阶段算出来的 KV cache 传给 decode 实例 (PD 分离), 或者在实例之间迁移请求 (弹性/负载均衡)。坑· 教程里有一处口径冲突需要按代码统一: ch06 的速查表写「KV 传输三层抽象», 而 ch08 §8.3.2 的结论是「文档写三层、代码只剩一层」——以代码为准。

Q155 [进阶] PD 分离的 KV 传输有几种实现?

答· vLLM 里是一组 KV connector (`KVConnectorBase_V1` 的各个实现), 差别在传输介质 (RDMA / NVLink / 共享存储) 与同步粒度 (per-layer 还是整块; layer 粒度需要更细的握手, 见 `kv_transfer/kv_connector/v1/base.py:307` 的 layer-granular KV load sync)。数字· HF3FS 这类“共享存储”方案的取舍: 不占网络带宽、但要过一遍存储; 本材料在写作时的 checkout 上发现两个真实缺陷 (`hf3fs_connector.py:499` 的 metadata URL 读了但从不使用; `:433` 的 `_fail_task` 用 `False` 兑现 future, 让“失败”和“完成”无法区分)——这类“代码缺陷”是很好的项目深挖素材。

Q156 [进阶] 权重怎么在多实例间同步？

答· 三种：① **各实例独立加载**（简单，但慢且占带宽）；② **广播**（一个加载完再分发）；③ **共享存储 + mmap**（多进程共享同一份只读权重页，内存占用立刻降下来）。数字· 弹性扩容时权重同步是冷启动延迟的主要来源之一（几十 GB 要过网络/存储）。

5.6 训练 vs 推理

Q157 [进阶] ★ 训练和推理的通信模式有什么本质差异？

维度	训练	推理
主要通信	梯度 all-reduce（每一层反向都有）+ 优化器状态	激活 all-reduce（TP）+ KV 传输（PD 分离）+ all-to-all（EP）
通信量	与参数量成正比、每步都有	与 token 数成正比、与 batch/序列强相关
重叠机会	反向计算与 all-reduce 天然可重叠（bucket + 梯度就绪即发）	decode 的通信很小、延迟主导；prefill 通信大但计算也大
精度	梯度需要高精度（bf16 + fp32 master）	可以激进量化（fp8/fp4）
容错	需要 checkpoint、断点续训	请求级重试即可

数字· 最重要的一条差异：推理的 DP 不做梯度同步（没有反向），所以「推理 DP = 训练 DP」是错的。

Q158 [进阶] 为什么推理的 batch 能开得比训练大？

答· 因为推理不用存激活与优化器状态（训练每层的激活都要留到反向），显存几乎全部给权重 + KV cache。数字· 训练激活占用与 batch × seq × hidden × layers 成正比，是训练显存的主要部分（gradient checkpointing 就是用时间换这块）。

Q159 [hard] 跨机通信怎么排查「带宽只有一半」？

答· 按这五步（从物理层往上）：① **确认实际链路**：nvidia-smi topo -m 看是不是走了 sys（跨 NUMA socket），IB 用 ibstat / ibv_devinfo 确认链路速率（HDR 200 Gb/s vs EDR 100 Gb/s）；② **确认没用错网卡**：多网卡机器上 NCCL 可能挑了慢的那张（NCCL_SOCKET_IFNAME / NCCL_IB_HCA 显式指定）；③ **确认算法/协议**：NCCL_DEBUG=INFO 看实际选的 algo/proto（大消息应该走 ring + Simple，走了 tree + LL 就说明判定错了）；④ **确认拓扑**：跨机是否经过 PCIe switch、NVLink 是否被切断（MIG 会切断 P2P）；⑤ **做微基准**：用 allreduce_bench.py 扫大小-带宽曲线，和理论值（α-β 模型）对比，看是延迟项还是带宽项异常。数字· 一个常见答案：带宽只有一半往往是因为单向 vs 双向口径混淆（NVLink 4 的 900 GB/s 是双向，单向 450 GB/s），或者 NCCL 用了 2 个 channel 而链路能开 8 个（NCCL_MIN_NCHANNELS）。

Q160 [进阶] 为什么「通信量大」不等于「通信慢」？


答· 因为通信是否在关键路径上才是决定性的：如果通信能完全与计算重叠，通信量大也不会拖慢 e2e；反之通信量很小但每步都要同步等待（比如 decode 里每层两次 all-reduce），延迟会成为瓶颈。数字· 判据：通信时间 / 计算时间 的比值——比值 < 1 时理论上可以完全隐藏（前提是有足够 SM 和 stream 可以并行）；比值 > 1 时必须减少通信量本身。这就是 DBO / AsyncTP / kernel 融合这些“重叠类”优化与 量化 / 压缩这些“减量类”优化的分界线。

§6 性能分析与排障 (Q161-Q175, 15 题)

Q161 [基础] ★ nsys 和 ncu 各自回答什么问题？为什么顺序不能反？

答· nsys 是 trace 型（记录 API/kernel/拷贝的时间戳，回答「时间花在哪」）； ncu 是 counter replay 型（把 kernel 回放多遍采硬件计数器，回答「这个 kernel 内部慢在哪」）。顺序不能反不是习惯问题而是成本问题：nsys 先给出优化预算的上限——主 kernel 占 86% 时，其他所有地方加起来最多只有 14% 的空间。数字· 原书有个例子：一次 nsys 时间线三分钟就否定了整个「优化前处理链」的方向。

★ 这张图是「你怎么优化一个 kernel」的完整答题骨架（下面 Q137-Q142 都是它的展开）：



Q162 [基础] ★ ncu 报告第一屏看哪两个指标？四象限怎么判？

答· sm__throughput (SM%) 与 gpu__compute_memory_throughput (MEM%)：MEM% >> SM% → memory-bound；SM% >> MEM% → compute-bound；双低（都 < 40）→ latency-bound；双高（都 > 60）→ 接近平衡上限，停止优化。坑· 「双低」这一态是 roofline 图上看不出来的第三种瓶颈——管线都没喂满说明问题既不在带宽也不在算力，而在并行度或依赖链。能主动说出这一点是加分项。坑· ⚠ 别把两个指标混起来：gpu__compute_memory_throughput (MEM%，SOL 口径) 用来做四象限；而 dram__throughput 是下一题分层归因里判「带宽墙已到 (> 70%)」的那个 DRAM 吞吐。它们不是同一个指标，混用会答错。

Q163 [进阶] ★ 哪些 stall 是「好 stall」，哪些是「坏 stall」？

stall	含义	对策	好/坏
wait	等固定延迟依赖 (FMA 链)	拆链、增并行 warp、重排指令	坏 (可拆)
long_scoreboard	等 gmem / TMA	cp.async / TMA + 加深 stage	坏 (可藏)
short_scoreboard	等 smem / MIO 队列	swizzle 布局、减少 smem 往返	坏
math_pipe_throttle	数学管线排队满	——	要看 pipe_tensor 配合读
sleeping	warp 休眠 / mbarrier 退避	重排 producer/consumer 与栅栏	高几乎总是结构问题
not_selected	就绪但调度器选了别人	——	好 (机器在干活)
selected	正在发射	——	基线

坑· math_pipe_throttle 高不一定是好事：原书案例里 mpt 1.32 主导而 pipe_tensor 只有 49%，结论是「管线在排队却没排满 Tensor Core——依赖链/发射受限」。这个指标必须与 pipe_tensor 合读。

Q164 [进阶] memory-bound 时怎么分层归因？

答· 按三层往下问（三个正交维度）：① 吞吐（哪层饱和）：`dram__throughput` > 70% ⇒ 带宽墙已到，只能减流量；② 命中率（数据该由哪层负责）：`L1` < 20% 且本该复用 ⇒ tiling 进 smem；`L2` < 50% 且 `DRAM` > 40% ⇒ 工作集/`L2` 局部性问题；③ 合并度（流量有没有被放大）：每请求扇区数，32-bit 连续访问的理想值是 4（一个 warp 的 128 B 恰好 4 个 32 B sector）。

Q165 [进阶] compute-bound 时第一问是什么？

答· 看指令 mix：`pipe_tensor` 高 ⇒ 真的在用 Tensor Core；`pipe_fma` 高而 `pipe_tensor` 低 ⇒ 还在用 CUDA Core 算乘加，该换 `mma / wmma` 了。数字· 这也是「我的 kernel 和 cuBLAS 差 3 倍」的第一排查项——宏门控把 Tensor Core 路径剪掉、走了 CUDA Core fallback 是最常见的原因。

Q166 [进阶] 为什么 ncu 的耗时不等于真实耗时？

答· 因为 ncu 回放多遍（一遍采不完成百上千个计数器）、锁定时钟保证数据可比、并把 kernel 串行化。所以报告内的时间只能做相对比较。数字· 做 A/B 时还要先核对公共参照（±1%）——被 GPU 级干扰污染的一轮，被测实现与参照会同比例膨胀（原书实测约 2×），直接对比会得出「-50% 全面加速」这种物理上不可能的假结论。

Q167 [进阶] 你会怎么做一次完整的性能分析？

答· 六步：① 先看占比（nsys），算优化预算上限，决定优化哪个 kernel；② 算 bound 与上界（roofline：`min(P_peak, AI×BW)`）；③ SOL 两个百分比 → 分四象限；④ 按象限分流（memory-bound 查三层；latency-bound 看 stall 前两名）；⑤ 查 occupancy 限制源，并核对寄存器是否撞 255；⑥ 单变量改动 → 复测 → 用指标确认瓶颈确实迁移了（不能只看总时间变快）。数字· 第⑥步是最容易漏的，也是最能体现工程素养的。

Q168 [进阶] 一个 kernel 在小 shape 上正确、大 shape 上偶发 NaN，怎么排查？

答· 按可能性排序：① f16 累加溢出（65504）——长 K / 大动态范围；② 除零（`0 = 0` 的全 mask 行；`amax = 0` 的全零块）；③ `-∞` 参与的 `inf - inf`（首块全 mask 时 `exp(-∞ - (-∞)) = NaN`，需要把 mask 位置洗成极小有限值）；④ 量化的 `vscale_max` 忘压缩（f16 PV 累加路径要把 448 压到 2.25，忘了就是「短序列正确、长序列偶发 inf」）；⑤ `cp.async` 的 wait 后漏 `__syncthreads`（warp 间竞争，偶发）；⑥ 尾 tile 越界（`N % Bc ≠ 0` 而加载路径没有边界处理，把垃圾算进 softmax）。

Q169 [进阶] 带宽测试为什么经常测不准？

答· 三个坑：① 数据集小于 L2 —— 测出来的是 L2 带宽（原书实测 16 MB 数据测出 1862 GB/s，超过 HBM 理论 1344 GB/s）；② 没有 warmup / 时钟未稳定（GPU 有 boost 与降频）；③ 把理论峰值当可达峰值（HBM3 理论 3.35 TB/s，实际 2.5–3.0 TB/s）。数字· 正确做法：数据集数倍于 L2、warmup 若干轮、取多次的最小值（不是平均）。

Q170 [进阶] 怎么判断瓶颈在通信而不是计算？

答· ① 看时间线（nsys：通信 kernel 与计算 kernel 是串行还是重叠）；② 做对照实验：把通信换成 no-op 或缩小 world size 看时间变化；③ 看 SM 占用（通信 kernel 占了几个 SM）；④ 算理论值：按 α - β 模型算通信应该花多久，和实测比。数字· 最快的诊断手段是 `--enforce-eager` + 关掉重叠，看时间差多少——差得多说明重叠原本是有效的。

Q171 [hard] Blackwell 上 `setmaxnreg` 被静默丢弃会怎样？

答· 寄存器重分配静默失效 ⇒ consumer 拿不到足够的寄存器 ⇒ 溢出到 local memory ⇒ 性能暴跌（原书记录：静态 170 上限会 spill 约 60 个寄存器）。数字· 触发条件：TMA dst 写成 `shared::cluster` 时 ptxas 以 C7506 丢弃；`__launch_bounds__(N)` 缺第二参数触发 C7508。排查方法：`cuobjdump -sass` 检索

USEMAXREG (注意 SASS 助记符没有 “n”)。

Q172 [hard] 怎么确认 kernel 真的跑在 Tensor Core 上?

答· 两级证据：① **SASS 级**：cuobjdump -sass 检索 HMMA.16816 (应出现成串 HMMA.16816.F16) 与 LDSM (ldmatrix 的 SASS 形态, x4 对应 LDSM.128)；② **profile 级**：ncu 的 sm__inst_executed_pipe_tensor_op 应占主导；若 HMMA 计数为零而 FFMA/HFMA2 居高，说明源码被宏门控剪掉、走了 CUDA Core fallback。

Q173 [进阶] 显存泄漏怎么查?

答· ① torch.cuda.memory_summary() 看 reserved vs allocated 的差 (碎片+缓存)；② **warmup 后打快照，跑一轮负载再打快照，看是否持续增长**；③ torch.cuda.memory._record_memory_history() 拿分配栈；④ 查引用计数错 (PagedAttention 的 block 没被回收是一种典型形态)。数字·
PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True 是缓解碎片的手段，不是泄漏的解法——别用它掩盖问题。

Q174 [进阶] 线上报「推理变慢」，你的排查顺序?

答· ① **先分清是哪一段慢** (TTFT vs ITL；服务端 vs 客户端)；② **看是不是负载变了** (并发/batch 变大 → 单请求变慢是正常的，看 goodput)；③ **看周期性尖刺** → 大概率 prefill 插进来了；④ **看显存/KV cache 使用率** (是否开始频繁 preempt/换出)；⑤ **看通信** (--enforce-eager 对照)；⑥ **最后才 profile**。数字· 先看指标再上 profiler —— 因为 profiler 有开销、且会改变时序。

Q175 [hard] 你怎么证明一次优化真的有效?

答· 四条纪律：① **单变量** (一次只改一个东西)；② **同一口径** (同一张卡、同一份数据、同样的 warmup；数据集要大于 L2)；③ **校验公共参照** (A/B 两轮的参照实现时间要吻合到 $\pm 1\%$ ，否则这一轮作废)；④ **用指标确认瓶颈迁移了** (不只看总时间)。数字· 原书的完整范例：909.4 μ s → 864 μ s (−5%)，同时 mpt 1.32 → 0.72、tensor pipe 49% → 59.5%、每线程寄存器 255 → 250、2 blocks/SM —— 指标和时间一致，这才叫结论。

§7 CUDA 与算子手撕题 (Q176–Q190, 15 题)

§7.0 LeetCUDA 溯源 (每题对应参考仓库的哪份实现)

题	本节的实现	LeetCUDA 参考实现 (文件·符号)
Q176	q176_vec add.cu	kernels/relu/relu.cu · relu / relu_vec4 — 向量化的边界守卫 kernels/elementwise/elementwise.cu · elementwise_add / elementwise_add_vec4 — 二段式守卫 + 尾部标量处理的标准写法
Q177	q177_reduce.cu	kernels/interview/base.cuh · warp_reduce_sum / warp_reduce_max / block_reduce_sum / block_reduce_all — Phase 1a/1b: 本节的归约结构与之一致 kernels/reduce/block_all_reduce.cu · block_all_reduce 各版本 — 独立文件版，含更多归约变体

题	本节的实现	LeetCUDA 参考实现 (文件·符号)
Q178	q178_dot.cu	<code>kernels/interview/base.cuh</code> · <code>dot / dot_vec4</code> — Phase 2: 同址 <code>atomicAdd</code> 的写法与「 <code>vec4</code> 不提速」的结论 <code>kernels/dot-product/dot_product.cu</code> · <code>dot_product</code> 各版本 — 独立文件版
Q179	q179_elementwise.cu	<code>kernels/gelu/gelu.cu</code> · <code>gelu</code> 变体 — 激活函数的多种近似 <code>kernels/interview/base.cuh</code> · <code>relu / elementwise_add</code> — Phase 2 的融合写法
Q180	q180_histogram.cu	<code>kernels/histogram/histogram.cu</code> · <code>histogram</code> — 全局原子版 (对照 <code>smem</code> 私有化) <code>kernels/interview/base.cuh</code> · <code>histogram</code> — Phase 2 里的同名 kernel
Q181	q181_transpose.cu	<code>kernels/mat-transpose/mat_transpose.cu</code> · <code>mat_transpose / mat_transpose_padded</code> — <code>padding</code> 打散 <code>bank conflict</code> 的原始实现 <code>kernels/interview/base.cuh</code> · <code>mat_transpose / mat_transpose_padded</code> — Phase 5: <code>Bank Conflict</code> 专题 <code>kernels/swizzle/mat_trans_swizzle.cu</code> · <code>swizzle</code> 版转置 — 用 XOR <code>swizzle</code> 替代 <code>padding</code>
Q182	q182_norm.cu	<code>kernels/rms-norm/rms_norm.cu</code> · <code>rms_norm / rms_norm_vec4</code> — 独立文件版 <code>kernels/layer-norm/layer_norm.cu</code> · <code>layer_norm / layer_norm_vec4</code> — 独立文件版 <code>kernels/interview/base.cuh</code> · <code>rms_norm / rms_norm_vec4 / layer_norm / layer_norm_vec4</code> — Phase 3b/3c: 1-pass RMSNorm vs 2-pass LayerNorm
Q183	q183_sgemmm.cu	<code>kernels/sgemm/sgemm.cu</code> · <code>sgemm</code> 阶梯 (<code>naive</code> -> <code>tile</code> -> <code>vec4</code>) — 本节三级阶梯的参考实现 <code>kernels/interview/sgemm.cuh</code> · Phase 7a 的 SGEMM — 面试精简版
Q184	q184_sgemm_dbuf.cu	<code>kernels/interview/common.cuh</code> · <code>permuted<kColStride,kStep> / SwizzleBMS<B,M,S></code> — ★ 本节的 <code>swizzle</code> 就取自这里 (三种档位的位运算公式逐字对齐) <code>kernels/swizzle/hgemm_mma_swizzle.cu</code> · <code>swizzle</code> 版 HGEMM — <code>swizzle</code> 在真实 GEMM 里的用法 (含 <code>register</code> 双缓冲) <code>kernels/swizzle/mma_simple_swizzle.cu</code> · 最小 <code>swizzle</code> 示例 — 先看这个再看 GEMM <code>kernels/swizzle/print_swizzle_layout.py</code> · <code>swizzle</code> 布局打印 — 把 <code>swizzle</code> 后的 <code>bank</code> 分布打出来, 验证「到底降了几路」
Q185	q185_sgemm_async.cu	<code>kernels/sgemm/sgemm_async.cu</code> · <code>cp.async</code> 多 stage 版 SGEMM — ★ 本节流水的参考实现 <code>kernels/sgemm/sgemm_wmma_tf32_stage.cu</code> · TF32 WMMA + stage — 同一套流水的 Tensor Core 版 <code>kernels/interview/common.cuh</code> · <code>CP_ASYNC_CG / CP_ASYNC_COMMIT_GROUP / CP_ASYNC_WAIT_GROUP</code> — 语义注释 (<code>wait_group N</code> = 允许保留 <code>N</code> 组未完成) 取自这里
Q186	q186_hgemm_mma.cu	<code>kernels/interview/hgemm.cuh</code> · Phase 7b-d 的 HGEMM 全部阶梯 — ★ 本节的手写 <code>mma</code> 版与之一致 (TN 布局 + <code>ldmatrix</code> + <code>multistage</code>) <code>kernels/interview/common.cuh</code> · <code>HMA16816 / HMA16816F32 / LDMATRIX_X4 / LDMATRIX_X2 / LDMATRIX_X2_T</code> — ★ 本节的 PTX 宏与这里的定义逐字一致

题	本节的实现	LeetCUDA 参考实现 (文件·符号)
Q187	q187_hgemm_ws_tma.cu	kernels/interview/common.cuh · <code>make_smem_desc</code> / <code>tma_load_2d</code> / <code>tma_arrive_expect_tx</code> / <code>warpgroup_reg_*</code> — ★ <code>descriptor</code> 位域布局与 TMA/mbarrier helper 取自这里 kernels/interview/hgemm.cuh · WGMMMA m64n128k16 + TMA MMA WS — 本骨架对应的完整实现 kernels/ws-hgemm/naive_ws_hgemm_sm8x.cu · <code>warp specialization</code> 的教学版 — 在 sm_80 上就能理解的 WS 结构 (不含 TMA)
Q188	q188_softmax_tmax.cu	kernels/interview/base.cuh · <code>softmax_per_token</code> / <code>safe_softmax_per_token</code> / <code>online_safe_softmax_per_token</code> / <code>warp_reduce_md</code> / MD — ★ 三级递进的原始实现与 MD 结构体 (本节的 <code>md_merge</code> 与之同构) kernels/softmax/softmax.cu · <code>softmax</code> 各版本 — 独立文件版
Q189	q189_flash_attn_u.cu	kernels/interview/flash_attn.cuh · FA2 MMA cp.async split-Q / FA2 TMA MMA WS / FA3 dual-consumer / FA Split-D — ★ 本节内层循环对应的完整实现 (含 split-Q 与 WS 版本) kernels/interview/ffpa_attn.cuh · FFPA: fp8/fp4 量化注意力 — 再往前一步: scale 折叠与 split-D 的工程实现
Q190	q190_merge_attn_u.cu	kernels/interview/base.cuh · <code>merge_attn_states</code> (kernel) — ★ LSE 合并的原始实现 (本节的公式与之一致) kernels/interview/notes-v2.cu · <code>merge_attn_states</code> 的 test/bench — 完整测试: 跑 <code>-help</code> 可以看到 CLI 入口

Q176 [手撕] ★ 向量加法 $c = a + b$

考点: 一线程一元素 / float4 二段式守卫 / grid-stride —— 三个版本对照 源

码: [../code/interview/kernels/q176_vecadd.cu](#) (153 行, sha256 063af85592e7)

```

// q176_vecadd.cu - Q176: 向量加法 c = a + b
//
// 三个版本，对应面试时的三步递进：
// 1) vecadd_naive      -- 一线程一元素 + 边界守卫（先写对的）
// 2) vecadd_vec4       -- float4 主路径 + 标量尾巴（二段式守卫）
// 3) vecadd_gridstride -- grid-stride loop（尾块不再需要单独处理，且 grid 可调）
//
// 编译：./build.sh q176
//
// -----
// 解析要点（面试官真正在看的东西）
// -----
// ① 为什么 vecadd_naive 的守卫写成 `if (idx < n)`，而 vec4 版要写成两段？
//   vec4 版一次读 4 个 float。如果只写 `if (idx < n)`，当 n 不是 4 的倍数时
//   最后一个线程会读到数组外 -- **越界读不报错**，只是结果里混进垃圾。
//   二段式守卫 `if (idx + 3 < n) {...} else if (idx < n) {...}` 才是安全的。
//   （这是本书第 4/9 章反复强调的坑：k32/k128 的 GEMV 就因为没有守卫而静默越界。）
//
// ② 为什么 4 个 float 一定对齐？（float4 要求 16 B 对齐）
//   cudaMalloc 返回的基址满足 256 B 对齐；只要元素偏移是 4 的倍数就天然满足。
//   本文件里 idx = 4 * 全局线程号，所以成立。**传子数组（如 a+1）就会炸**。
```

```

//
// ③ vec4 到底省了什么？
//   省的是【load/store 指令数】（4 条 32-bit -> 1 条 128-bit），不是字节数。
//   Volta 起访存以 32 B sector 为粒度，coalescing 场景下 sector 数由总数据量决定
//   -- 所以"向量化把事务数减为 1/4"这个老说法已经过时（口径要纠正）。
//   什么时候真的快？当瓶颈在指令发射（小 shape、grid 受限）或 HBM 直读时。
//
// ④ grid-stride 的价值：固定 grid 大小（比如 = SM 数 × 每 SM 的 block 数），
//   每个线程处理多个元素。好处是 grid 与 n 解耦、尾块不需特判、且能控制占用率。
// -----

#include "lc_common.cuh"

// -----
// 版本 1: 一线程一元素
// -----

__global__ void vecadd_naive(const float* __restrict__ a,
                             const float* __restrict__ b,
                             float* __restrict__ c, int n) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) c[idx] = a[idx] + b[idx];
}

```



```

// -----
// 版本 2: float4, 主路径 + 标量尾巴
// -----
__global__ void vecadd_vec4(const float* __restrict__ a,
                           const float* __restrict__ b,
                           float* __restrict__ c, int n) {
    int idx = 4 * (blockIdx.x * blockDim.x + threadIdx.x);
    if (idx + 3 < n) { // 主路径: 一次 16 B (= 4 个 sector 中的 4 个 float)
        float4 x = FLOAT4(a + idx);
        float4 y = FLOAT4(b + idx);
        float4 z = make_float4(x.x + y.x, x.y + y.y, x.z + y.z, x.w + y.w);
        FLOAT4(c + idx) = z;
    } else if (idx < n) { // 尾巴: 最多 3 个元素, 标量收
        for (int i = 0; idx + i < n; ++i) c[idx + i] = a[idx + i] + b[idx + i];
    }
}

// -----
// 版本 3: grid-stride loop
// -----
__global__ void vecadd_gridstride(const float* __restrict__ a,
                                  const float* __restrict__ b,
                                  float* __restrict__ c, int n) {
    int stride = gridDim.x * blockDim.x;
    for (int idx = blockIdx.x * blockDim.x + threadIdx.x; idx < n; idx += stride) {
        c[idx] = a[idx] + b[idx];
    }
}

// -----
// host 侧参考实现
// -----
static void ref_vecadd(const std::vector<float>& a, const std::vector<float>& b,
                      std::vector<float>& c) {
    for (size_t i = 0; i < a.size(); ++i) c[i] = a[i] + b[i];
}

int main() {
    TEST_BEGIN("Q176 vector add (naive / vec4 / grid-stride)");

    // 关键: 既要测 4 的倍数, 也要测非 4 的倍数 — 后者才是二段式守卫的考点
    const std::vector<int> sizes = {1, 3, 4, 5, 1021, 1024, 1 << 20, (1 << 20) + 3};

```

```

for (int n : sizes) {
    std::vector<float> ha(n), hb(n), href(n), hgot(n);
    fill_random(ha, 1u, -1.f, 1.f);
    fill_random(hb, 2u, -1.f, 1.f);
    ref_vecadd(ha, hb, href);

    float *da, *db, *dc;
    CUDA_CHECK(cudaMalloc(&da, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&db, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dc, n * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(da, ha.data(), n * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(db, hb.data(), n * sizeof(float), cudaMemcpyHostToDevice));

    const int T = 256;
    GpuTimer timer;

    // --- naive ---
    CUDA_CHECK(cudaMemset(dc, 0, n * sizeof(float)));
    double ms_naive = timer.bench([&] {
        vecadd_naive<<<(n + T - 1) / T, T>>>(da, db, dc, n);
    });
    CUDA_CHECK_KERNEL();
    hgot = to_host(dc, n);
    report(("naive          n=" + std::to_string(n)).c_str(),
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_naive);

    // --- vec4 (block 用 64: 4*64 = 256 元素/block, 与 naive 的 256 元素/block 对齐) ---
    CUDA_CHECK(cudaMemset(dc, 0, n * sizeof(float)));
    const int T4 = 64;
    double ms_vec4 = timer.bench([&] {
        vecadd_vec4<<<(n + 4 * T4 - 1) / (4 * T4), T4>>>(da, db, dc, n);
    });
    CUDA_CHECK_KERNEL();
    hgot = to_host(dc, n);
    report(("vec4          n=" + std::to_string(n)).c_str(),
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_vec4);

    // --- grid-stride (grid 固定成 4 倍 SM 数) ---
    CUDA_CHECK(cudaMemset(dc, 0, n * sizeof(float)));
    int gs_blocks = dev.sm_count * 4;
    double ms_gs = timer.bench([&] {
        vecadd_gridstride<<<gs_blocks, T>>>(da, db, dc, n);
    });
}

```

```

});
CUDA_CHECK_KERNEL();
hgot = to_host(dc, n);
report(("grid-stride n=" + std::to_string(n)).c_str(),
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_gs);

// 大 shape 才报带宽（小 shape 的耗时被 launch 开销主导，带宽没有意义）
if (n >= (1 <= 20)) {
    // 元素级加法：读 a + 读 b + 写 c = 12 B/元素
    size_t bytes = static_cast<size_t>(n) * 3 * sizeof(float);
    printf("        带宽口径 12 B/元素: naive %.0f GB/s | vec4 %.0f GB/s | "
           "grid-stride %.0f GB/s (理论峰值 %.0f)\n",
           to_gbps(bytes, ms_naive), to_gbps(bytes, ms_vec4),
           to_gbps(bytes, ms_gs), dev.theoretical_gbps);
}

CUDA_CHECK(cudaFree(da));
CUDA_CHECK(cudaFree(db));
CUDA_CHECK(cudaFree(dc));
}

printf("\nQ176 done.\n");
return 0;
}

```

Q177 【手撕】 ★ warp 内蝶形归约 + block 两级归约

考点：XOR 蝶形归约 + block 两级归约：步数账、单位元、广播那一步为什么不能省 **源**

码： [../code/interview/kernels/q177_reduce.cu](https://code.interview.kernels/q177_reduce.cu) (276 行, sha256 `dc31d36dfce4`)

```

// q177_reduce.cu - Q177: warp 内蝶形归约 + block 两级归约
//
// 这是 §7 里**最常被要求白板写出来**的一题，因为它是 softmax / norm / dot 的公共底座。
//
// 1) warp_reduce_sum<W>    -- XOR 蝶形，R 轮后【每个 lane 都持有全和】
// 2) warp_reduce_max<W>    -- 同构，哨兵换成 -FLT_MAX
// 3) block_reduce_sum<T>    -- warp 内蝶形 -> smem -> 各 warp 冗余二次归约 -> 广播
// 4) block_reduce_sum_v2    -- 对照实现：只让 warp 0 做二次归约（少算但也少广播）
//
// 编译：./build.sh q177
//
// -----
// 解析要点
// -----
// ① ★ 为什么用 __shfl_xor_sync 而不是 __shfl_down_sync?
//   down 模式 lane i 每轮读 lane i+m, **越界 lane 读自己（复制）**；
//   R 轮后只有 lane 0 凑齐全和，其余 lane 拿着被污染的部分和；
//   而且每轮真正有效的 lane 数逐轮减半，**硬件却在为全 warp 买单**。
//   xor 模式三个性质：配对对称  $(i^m)^m = i$ ；每轮一对一（ $m \neq 0$  时  $i^m \neq i$ ）；
//   距离逐轮减半（ $16 \rightarrow 8 \rightarrow 4 \rightarrow 2 \rightarrow 1$ ）而信息量翻倍。
//    $\Rightarrow$  R 轮后每个 lane 都拿到完整结果（all-reduce 语义，不是 reduce 到 lane 0）。
//
// ② ★ 步数账（T=256, W=8 个 warp）
//   log2(32)（warp 内 5 轮 shuffle）
//   + 1（smem 写 + 一次 __syncthreads）
//   + log2(W)=3（二次归约）
//   = 8 轮 + 1 次同步
//   smem 流量只有 W 次写 + W 次读（各 4 B），相比"所有中间量走 smem"的朴素树形
//   归约（log2(T)=8 轮 smem 往返）**降了一个量级** — 这是"能在寄存器层完成的
//   绝不下放到 smem 层"的直接应用。
//
// ③ ★ 本实现的精髓：二次归约不做在 warp 0，而是【每个 warp 的前 W 个 lane 都
//   读入全部 W 个部分和、各自再归约一遍】。多余的 W-1 份计算白扔（反正是寄存器
//   加法），换来**不需要第二次 smem 往返与第二次同步**。
```

```

//
// ④ ★ 广播那一步不能省：归约函数的契约是"block 内全员可见"。
//   后续 softmax 除以  $q$ 、norm 除以  $\sigma$  都依赖它。省掉的话只有每个 warp 的前 W 个
//   lane 持有正确结果 — 而且在小例子里可能"碰巧"是对的（warp 0 的 lane 恰好对）。
//
// ⑤ 网格形状的坑：`__shfl_xor_sync(0xffffffff, ...)` 要求**参与线程都在**。
```

```

//   如果 kernel 里有 `if (idx < n) return;` 这种提前退出，mask 就得跟着改，
//   否则是未定义行为。本文件的 kernel 里**没有提前 return**，边界线程携带单位元
//   参与归约，所以 mask 用 0xffffffff 是安全的。

```

```
//
// ⑥ 但要注意: **一个 block 内的线程数必须是 32 的倍数** (否则最后一个不满的 warp
//    要单独处理)。本文件用 T=256 固定, 规避了这个问题; 生产代码要么保证整除,
//    要么让部分 warp 携带单位元。
```

```
#include "lc_common.cuh"
```

```
// ① warp 内蝶形归约
```

```
template <int kWarpWidth = 32>
```

```
__device__ __forceinline__ float warp_reduce_sum(float v) {
```

```
#pragma unroll
```

```
    for (int mask = kWarpWidth >> 1; mask >= 1; mask >>= 1) {
```

```
        v += __shfl_xor_sync(0xffffffffu, v, mask, kWarpWidth);
```

```
    }
```

```
    return v;
```

```
}
```

```
template <int kWarpWidth = 32>
```

```
__device__ __forceinline__ float warp_reduce_max(float v) {
```

```
#pragma unroll
```

```
    for (int mask = kWarpWidth >> 1; mask >= 1; mask >>= 1) {
```

```
        v = fmaxf(v, __shfl_xor_sync(0xffffffffu, v, mask, kWarpWidth));
```

```
    }
```

```
    return v;
```

```
}
```

```
// ② block 两级归约 (推荐写法: 各 warp 冗余二次归约 + 广播)
```

```
template <int kNumThreads = 256>
```

```
__device__ __forceinline__ float block_reduce_sum(float v) {
```

```
    constexpr int kNumWarps = kNumThreads / 32;
```

```
    __shared__ float shared[kNumWarps];
```

```
    const int tid = threadIdx.x;
```

```
    const int lane = tid & 31;
```

```
    const int warp = tid >> 5;
```

```
    v = warp_reduce_sum(v);
```

```
    if (lane == 0) shared[warp] = v;    // 每个 warp 只需 lane 0 写
```

```
    __syncthreads();                    // ★ 不能省: smem 写与读之间
```



```

// 每个 warp 的前 kNumWarps 个 lane 读全部分和，各自再归约一遍
v = (lane < kNumWarps) ? shared[lane] : 0.0f;    // 越界 lane 给【加法单位元】
v = warp_reduce_sum<kNumWarps>(v);
return __shfl_sync(0xffffffffu, v, 0, 32);      // ★ 广播给全员
}

```

```

template <int kNumThreads = 256>
__device__ __forceinline__ float block_reduce_max(float v) {
    constexpr int kNumWarps = kNumThreads / 32;
    __shared__ float shared[kNumWarps];
    const int tid = threadIdx.x;
    const int lane = tid & 31;
    const int warp = tid >> 5;

    v = warp_reduce_max(v);
    if (lane == 0) shared[warp] = v;
    __syncthreads();

    v = (lane < kNumWarps) ? shared[lane] : -FLT_MAX; // ★ max 的单位元
    v = warp_reduce_max<kNumWarps>(v);
    return __shfl_sync(0xffffffffu, v, 0, 32);
}

```

```

// -----
// ③ 对照组：二次归约只留给 warp 0（结果只用于写出，不广播）
// 与推荐版的差别：少算了 w-1 份，但需要第二次 __syncthreads 才能让
// lane 0 拿到结果并写出 —— 这就是"用计算换同步"的取舍。
// -----

```

```

template <int kNumThreads = 256>
__device__ __forceinline__ float block_reduce_sum_warp0(float v, float* out_smem) {
    constexpr int kNumWarps = kNumThreads / 32;
    __shared__ float shared[kNumWarps];
    const int tid = threadIdx.x;
    const int lane = tid & 31;
    const int warp = tid >> 5;

    v = warp_reduce_sum(v);
    if (lane == 0) shared[warp] = v;
    __syncthreads();

    if (warp == 0) {
        v = (lane < kNumWarps) ? shared[lane] : 0.0f;
    }
}

```

```

    v = warp_reduce_sum<kNumWarps>(v);
    if (lane == 0) *out_smem = v;    // 只写给 tid==0
}

__syncthreads();                    // ★ 第二次同步：让写出可见
return *out_smem;
}

// -----
// 用 reduce 实现两个真实算子：block 求和、block 求 max
// -----
template <int kNumThreads = 256>
__global__ void kernel_block_sum(const float* __restrict__ x,
                                float* __restrict__ y, int n) {

    float v = 0.0f;
    for (int i = blockIdx.x * kNumThreads + threadIdx.x; i < n;
         i += gridDim.x * kNumThreads) {
        v += x[i];
    }
    float s = block_reduce_sum<kNumThreads>(v);
    if (threadIdx.x == 0) y[blockIdx.x] = s;
}

// ★ 这个 kernel 演示一个经典错误：用 warp0 版做"全员可见"的归约
//  — 它只保证 tid==0 拿到结果，其它线程拿到的是 smem 里的旧值。
//  为了对比，我们仍然把它写完整，但只让 tid==0 使用结果。
template <int kNumThreads = 256>
__global__ void kernel_block_sum_warp0(const float* __restrict__ x,
                                       float* __restrict__ y, int n) {

    __shared__ float s_out;
    float v = 0.0f;
    for (int i = blockIdx.x * kNumThreads + threadIdx.x; i < n;
         i += gridDim.x * kNumThreads) {
        v += x[i];
    }
    float s = block_reduce_sum_warp0<kNumThreads>(v, &s_out);
    if (threadIdx.x == 0) y[blockIdx.x] = s;
}

// 演示 max 归约的用法：求一行的最大值（softmax 的第一步）
template <int kNumThreads = 256>
__global__ void kernel_block_max(const float* __restrict__ x,
                                float* __restrict__ y, int n) {

    // 边界线程必须携带 -FLT_MAX，否则会把"没参与"当成 0 混进 max

```

```

float v = (threadIdx.x < n) ? x[threadIdx.x] : -FLT_MAX;
float m = block_reduce_max<kNumThreads>(v);
if (threadIdx.x == 0) y[blockIdx.x] = m;    // ★ tid==0, 不是 lane==0
}

// -----
// host 侧
// -----
int main() {
    TEST_BEGIN("Q177 warp/block reduction");

    // ---- 测试 1: 一个 warp 的蝶形 (32 个数) ----
    {
        const int n = 32;
        std::vector<float> h(n);
        fill_random(h, 7u, -1.f, 1.f);
        float ref = std::accumulate(h.begin(), h.end(), 0.0f);

        float* d = nullptr;
        CUDA_CHECK(cudaMalloc(&d, n * sizeof(float)));
        CUDA_CHECK(cudaMemcpy(d, h.data(), n * sizeof(float), cudaMemcpyHostToDevice));
        // 复用 kernel_block_sum: grid=1 时它正好做一次 warp 内归约
        CUDA_CHECK(cudaMemset(d, 0, 0));
        float* out = nullptr;
        CUDA_CHECK(cudaMalloc(&out, sizeof(float)));
        kernel_block_sum<32><<<1, 32>>>(d, out, n);
        CUDA_CHECK_KERNEL();
        std::vector<float> got = to_host(out, 1);

        // 32 项求和的 fp32 舍入误差在 1e-6 量级; 用相对容差 1e-5
        CompareResult r = compare(got, std::vector<float>{ref}, 1e-5, 1e-6);
        report("warp butterfly (n=32)", r, 1e-5, 1e-6);
        CUDA_CHECK(cudaFree(d));
        CUDA_CHECK(cudaFree(out));
    }

    // ---- 测试 2: block 归约 vs CPU (多个 block、非整除的 n) ----
    for (int n : {256, 1000, 4096, 100000, 1000003}) {
        const int T = 256;
        const int blocks = 64;
        std::vector<float> h(n);
        fill_random(h, 11u, -1.f, 1.f);
    }
}

```

```

float *dx, *dy, *dy2;
CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy, blocks * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy2, blocks * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dx, h.data(), n * sizeof(float), cudaMemcpyHostToDevice));

kernel_block_sum<T><<<blocks, T>>>(dx, dy, n);
CUDA_CHECK_KERNEL();
kernel_block_sum_warp0<T><<<blocks, T>>>(dx, dy2, n);
CUDA_CHECK_KERNEL();

std::vector<float> got = to_host(dy, blocks);
std::vector<float> got2 = to_host(dy2, blocks);
double sum = 0;
for (float v : got) sum += v;
double sum2 = 0;
for (float v : got2) sum2 += v;
double ref = std::accumulate(h.begin(), h.end(), 0.0);

// 归约是并行的 ⇒ 累加顺序与 CPU 不同 ⇒ 只能用容差, 不能逐位比
double rel = std::fabs(sum - ref) / (std::fabs(ref) + 1e-12);
printf("  %-34s %s  gpu=%.6f cpu=%.6f rel=%.2e\n",
       ("block sum  n=" + std::to_string(n)).c_str(),
       rel < 1e-4 ? "PASS" : "FAIL", sum, ref, rel);
printf("  %-34s %s  gpu=%.6f cpu=%.6f rel=%.2e  (warp0 变体, 数值应当一致)\n",
       "    L warp0 variant", std::fabs(sum2 - ref) / (std::fabs(ref) + 1e-12) < 1e-4
       ? "PASS" : "FAIL",
       sum2, ref, std::fabs(sum2 - ref) / (std::fabs(ref) + 1e-12));

CUDA_CHECK(cudaFree(dx));
CUDA_CHECK(cudaFree(dy));
CUDA_CHECK(cudaFree(dy2));
}

// ---- 测试 3: max 归约 (含单位元正确性) ----
for (int n : {1, 100, 256, 1000}) {
    std::vector<float> h(256, 0.0f);           // 先全 0; 只有前 n 个填负值
    std::mt19937 gen(n);
    std::uniform_real_distribution<float> d(-100.f, -1.f); // ★ 全负, 专门验哨兵
    for (int i = 0; i < n; ++i) h[i] = d(gen);
    float ref = -FLT_MAX;
    for (int i = 0; i < n; ++i) ref = std::max(ref, h[i]);
}

```

```

float *dx, *dy;
CUDA_CHECK(cudaMalloc(&dx, 256 * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy, sizeof(float)));
CUDA_CHECK(cudaMemcpy(dx, h.data(), 256 * sizeof(float), cudaMemcpyHostToDevice));
kernel_block_max<256><<<1, 256>>>(dx, dy, n);
CUDA_CHECK_KERNEL();
std::vector<float> got = to_host(dy, 1);
// 全负的输入是"哨兵写错就立刻暴露"的用例：如果哨兵用 0，结果会变成 0
CompareResult r = compare(got, std::vector<float>{ref}, 0.0, 0.0);
report(("block max  n=" + std::to_string(n) + " (all negative)").c_str(),
      r, 0.0, 0.0);
CUDA_CHECK(cudaFree(dx));
CUDA_CHECK(cudaFree(dy));
}

printf("\nQ177 done.\n");
return 0;
}

```

Q178 【手撕】 ★ dot product, 以及“为什么 vec4 可能一点也不快”

考点：原子版 vs 两级归约 vs vec4 —— 用数字证明「瓶颈不是访存指令数」 **源**

码： [../code/interview/kernels/q178_dot.cu](https://code.interview.kernels/q178_dot.cu) (200 行, sha256 `4ed76ceb28ff`)


```

// q178_dot.cu - Q178: dot product, 以及"为什么 vec4 可能一点也不快"
//
// 1) dot_atomic    -- 每 block 一次全局 atomicAdd (最直观, 但会被原子串行化钉死)
// 2) dot_two_stage -- 两级归约: block 部分和落到 G 个【互不冲突】的地址,
//                      再起一个小 kernel 归约 G 个数 (★ 改进方向)
// 3) dot_vec4       -- 访存指令数降到 1/4, 用来验证"瓶颈不在访存"
//
// 编译: ./build.sh q178
//
// -----
// 解析要点
// -----
// ① 通用范式: **算子 = 元素级预变换 + 归约 + 后处理**
// dot 的预变换是逐元素乘, 归约是求和, 后处理(本例)没有。
// softmax 的预变换是 exp, 后处理是除法; norm 的预变换是平方、后处理是 rsqrt。
// 面试时先把这个范式说出来, 再写代码, 结构立刻就清楚了。
//
// ② ★ 这道题最有价值的结论(可以直接背下来当谈资):
// 在 N=4,194,304 这个规模上, dot 与 dot_vec4 的耗时【几乎完全相同】,
// 因为**真正的瓶颈既不是带宽也不是访存指令数, 而是全局原子的串行化**：
// G = N/256 = 16384 个 block 各做一次 atomicAdd(y)
// 同址全局原子在 L2 原子单元上串行 ⇒ 每次约 2.6 ns
// 16384 x 2.6 ns ≈ 42 μs ← 恰好是实测总时长
// 而 32 MB 数据按 HBM 口径只要 ~24 μs。
// ⇒ 结论: **这个实现的上限不是带宽, 是全局原子的串行吞吐**；
// 改进方向是把 atomic 次数从 G 降到 [G/K] (两级归约 / block 内先累积)。
//
// ③ 为什么两级归约会更快?
// 第一级每个 block 写【自己的】地址 (G 个地址, 无冲突);
// 第二级用 1 个 block 归约 G 个数。atomic 从 G 次降到 0 次(或几次)。
// 代价是多一次 kernel launch 与 G 个 float 的中间缓冲。
//
// ④ float 的 atomicAdd 还会破坏确定性: 加法不满足结合律 + block 完成顺序不定
// ⇒ 同一份输入两次运行结果可能不同 (run-to-run 抖动)。
// 正确性判定必须用容差; 要可复现就得用两级归约这种【固定顺序】的方案。
// -----

#include "lc_common.cuh"

// -----
// 版本 1: 每 block 一次全局原子
// -----

template <int kNumThreads = 256>

```

```

__global__ void dot_atomic(const float* __restrict__ a,
                           const float* __restrict__ b,
                           float* __restrict__ y, int n) {

    float prod = 0.0f;
    for (int i = blockIdx.x * blockDim.x + threadIdx.x; i < n;
         i += blockDim.x * blockDim.x) {
        prod += a[i] * b[i];
    }

    float s = block_reduce_sum<blockDim.x>(prod);
    if (threadIdx.x == 0) atomicAdd(y, s);    // ★ tid==0, 不是 lane==0
}

// -----
// 版本 2: 两级归约（第一级：每 block 写自己的地址）
// -----

template <int blockDim = 256>
__global__ void dot_partial(const float* __restrict__ a,
                            const float* __restrict__ b,
                            float* __restrict__ partial, int n) {

    float prod = 0.0f;
    for (int i = blockIdx.x * blockDim + threadIdx.x; i < n;
         i += blockDim) {
        prod += a[i] * b[i];
    }

    float s = block_reduce_sum<blockDim>(prod);
    if (threadIdx.x == 0) partial[blockIdx.x] = s;    // 无冲突写
}

// 第二级：1 个 block 归约 G 个部分和（这里 G <= blockDim 就够；否则要递归）
template <int blockDim = 256>
__global__ void dot_finalize(const float* __restrict__ partial, int g,
                             float* __restrict__ y) {

    float v = (threadIdx.x < g) ? partial[threadIdx.x] : 0.0f;
    float s = block_reduce_sum<blockDim>(v);
    if (threadIdx.x == 0) *y = s;
}

// -----
// 版本 3: float4 版（访存指令数降到 1/4，用来验证瓶颈位置）
// -----

template <int blockDim = 64>
__global__ void dot_vec4(const float4* __restrict__ a,
                        const float4* __restrict__ b,

```

```

        float* __restrict__ partial, int n4) {
    float prod = 0.0f;
    for (int i = blockIdx.x * blockDim.x + threadIdx.x; i < n4;
        i += blockDim.x * blockDim.x) {
        float4 x = a[i];
        float4 y = b[i];
        prod += x.x * y.x + x.y * y.y + x.z * y.z + x.w * y.w;
    }
    float s = block_reduce_sum<kNumThreads>(prod);
    if (threadIdx.x == 0) partial[blockIdx.x] = s;
}

// -----
// host 侧: CPU 参考 (用 double 累加, 作为"真值")
// -----
static double ref_dot(const std::vector<float>& a, const std::vector<float>& b) {
    double s = 0.0;
    for (size_t i = 0; i < a.size(); ++i) s += static_cast<double>(a[i]) * b[i];
    return s;
}

int main() {
    TEST_BEGIN("Q178 dot product (atomic / two-stage / vec4)");

    const int n = 1 << 22;    // 4,194,304 — 与书里那个"原子瓶颈"用例同量级
    const int G = 512;        // grid 大小 (两级归约的中间缓冲长度)
    const int T = 256;

    std::vector<float> ha(n), hb(n);
    fill_random(ha, 3u, -1.f, 1.f);
    fill_random(hb, 4u, -1.f, 1.f);
    const double ref = ref_dot(ha, hb);

    float *da, *db, *dy, *dpartial;
    CUDA_CHECK(cudaMalloc(&da, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&db, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dy, sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dpartial, G * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(da, ha.data(), n * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(db, hb.data(), n * sizeof(float), cudaMemcpyHostToDevice));

    const size_t bytes = static_cast<size_t>(n) * 2 * sizeof(float); // 只读, 不写
    GpuTimer timer;

```

```

// ---- 版本 1: 原子 ----
CUDA_CHECK(cudaMemset(dy, 0, sizeof(float)));
double ms1 = timer.bench([&] { dot_atomic<T><<<G, T>>>(da, db, dy, n); });
CUDA_CHECK_KERNEL();
double got1 = to_host(dy, 1)[0];
printf(" %-30s %s got=%.6f ref=%.6f rel=%.2e %.4f ms %.0f GB/s\n",
        "dot_atomic", close_enough(got1, ref, 1e-4, 1e-3) ? "PASS" : "FAIL",
        got1, ref, std::fabs(got1 - ref) / std::fabs(ref), ms1,
        to_gbps(bytes, ms1));

// ---- 版本 2: 两级 ----
double ms2 = timer.bench([&] {
    dot_partial<T><<<G, T>>>(da, db, dpartial, n);
    dot_finalize<T><<<1, T>>>(dpartial, G, dy);
});
CUDA_CHECK_KERNEL();
double got2 = to_host(dy, 1)[0];
printf(" %-30s %s got=%.6f ref=%.6f rel=%.2e %.4f ms %.0f GB/s\n",
        "dot_two_stage", close_enough(got2, ref, 1e-4, 1e-3) ? "PASS" : "FAIL",
        got2, ref, std::fabs(got2 - ref) / std::fabs(ref), ms2,
        to_gbps(bytes, ms2));

// ---- 版本 3: vec4 (n 必须是 4 的倍数) ----
const int n4 = n / 4;
double ms3 = 0.0, got3 = 0.0;
if (n % 4 == 0) {
    double ms_launch = timer.bench([&] {
        dot_vec4<64><<<G, 64>>>(reinterpret_cast<const float4*>(da),
                                reinterpret_cast<const float4*>(db), dpartial, n4);
        dot_finalize<T><<<1, T>>>(dpartial, G, dy);
    });
    ms3 = ms_launch;
    CUDA_CHECK_KERNEL();
    got3 = to_host(dy, 1)[0];
    printf(" %-30s %s got=%.6f ref=%.6f rel=%.2e %.4f ms %.0f GB/s\n",
            "dot_vec4 (instr/4)", close_enough(got3, ref, 1e-4, 1e-3) ? "PASS" : "FAIL",
            got3, ref, std::fabs(got3 - ref) / std::fabs(ref), ms3,
            to_gbps(bytes, ms3));
}

// ---- 结论区: 把"到底瓶颈在哪"用数字摆出来 ----
printf("\n ---- 瓶颈判读 ----\n");

```

```

printf(" G=%d 个 block, atomic 版本每 block 一次同址 atomicAdd\n", G);
printf(" 理论下界 (HBM 口径): %.1f us (%.0f GB/s 峰值)\n",
      bytes / dev.theoretical_gbps / 1e3, dev.theoretical_gbps);
printf(" 实测: atomic %.1f us | two-stage %.1f us | vec4 %.1f us\n", ms1 * 1e3,
      ms2 * 1e3, ms3 * 1e3);
printf(" ⇒ atomic 与 vec4 接近 ⇒ **瓶颈不是访存指令数**:\n");
printf(" 把 G 调大 (下面用 --grid 试) 会看到 atomic 版本恶化更快 -- 那就是原子串行化.\n");

// ---- 稳定性: 浮点原子 ⇒ 结果有 run-to-run 抖动 ----
double r1 = 0.0, r2 = 0.0;
CUDA_CHECK(cudaMemset(dy, 0, sizeof(float)));
dot_atomic<T><<<G, T>>>(da, db, dy, n);
CUDA_CHECK_SYNC();
r1 = to_host(dy, 1)[0];
CUDA_CHECK(cudaMemset(dy, 0, sizeof(float)));
dot_atomic<T><<<G, T>>>(da, db, dy, n);
CUDA_CHECK_SYNC();
r2 = to_host(dy, 1)[0];
printf(" 确定性: atomic 两次运行差 = %.3e (%.1e 量级属正常抖动, 因为加法不满足结合律)\n",
      std::fabs(r1 - r2), std::fabs(r1) * 1e-6);

CUDA_CHECK(cudaFree(da));
CUDA_CHECK(cudaFree(db));
CUDA_CHECK(cudaFree(dy));
CUDA_CHECK(cudaFree(dpartial));
printf("\nQ178 done.\n");
return 0;
}

```

Q179 [手撕] ★ ReLU / elementwise 融合, 以及“为什么用 fmaxf 不用 if”

考点: fmaxf 而不是 if/else; 融合省的是流量, 不是 launch 源

码: [../code/interview/kernels/q179_elementwise.cu](https://code.interview/kernels/q179_elementwise.cu) (226 行, sha256 653db7d8b51d)


```

// q179_elementwise.cu - Q179: ReLU / elementwise 融合, 以及"为什么用 fmaxf 不用 if"
//
// 1) relu_branchy  -- 写成 if/else (错误示范: warp 内会发散)
// 2) relu          -- fmaxf(0, x) (编译成单条 max.f32, 无分支)
// 3) relu_vec4     -- float4 版
// 4) fused_bias_gelu -- 广播 bias + GELU 融合 (演示"融合省的是流量")
// 5) unfused       -- 分成两步做 (bias 一个 kernel、gelu 一个 kernel), 做对照
//
// 编译: ./build.sh q179
//
// -----
// 解析要点
// -----
// ① ★ 分支要写进【指令选择】而不是【控制流】:
//   `if (x > 0) y = x; else y = 0;` 会让 warp 因 lane 间条件不同而发散 --
//   硬件两条路径都执行、用掩码屏蔽, 等价于串行化 (最坏 32 路)。
//   `fmaxf(0.0f, x)` 编译成一条 `max.f32`, 没有跳转、没有掩码、没有分支预测。
//   ★ 同一个道理在 tanh/gelu 上就是: 用精确的数学函数或多项式近似, 而不是分段 if。
//
// ② ★ 融合的收益来自【少一次全局往返】, 不是"少一次 launch":
//   unfused: 读 x、写 t; 读 t、读 bias、写 y  ⇒ 4 读 + 2 写
//   fused   : 读 x、读 bias、写 y              ⇒ 2 读 + 1 写
//   在 memory-bound 的逐元素算子上, **流量减半 ⇒ 时间减半**。
//   但注意★: 如果 kernel 已经贴满带宽, 融合"省 launch"是没有杠杆的
//   (书的原话: 此时只有减流量才有用)。
//
// ③ 广播下标 `idx % hidden` 是最廉价的写法 (bias 会被 L1/L2 命中)。
//   如果 hidden 是编译期常量, 做成模板参数能让编译器把它变成位运算/常量折叠。
//
// ④ 测试要点:
//   - ReLU 是精确运算 (没有舍入), 可以用 err == 0 的严格断言;
//   - bias 广播下标写错是**静默 bug** (形状合法、结果错), 所以要专门用
//     hidden 不整除 n 的用例来测;
//   - GELU 用 erff 精确版本, 容差取 1e-6 (fp32 单精度)。
// -----

#include "lc_common.cuh"

// -----
// ① 错误示范: 分支版 ReLU
// -----
__global__ void relu_branchy(const float* __restrict__ x, float* __restrict__ y,
                             int n) {

```

```

int idx = blockIdx.x * blockDim.x + threadIdx.x;
if (idx < n) {
    // ★ 同一 warp 内 idx 相邻, x[idx] 的符号随机 ⇒ 50% 概率发散
    if (x[idx] > 0.0f)
        y[idx] = x[idx];
    else
        y[idx] = 0.0f;
}
}

// -----
// ② 正确写法: fmaxf
// -----
__global__ void relu(const float* __restrict__ x, float* __restrict__ y, int n) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) y[idx] = fmaxf(0.0f, x[idx]);    // 一条 max.f32, 零分支
}

// -----
// ③ vec4 版 (二段式守卫)
// -----
__global__ void relu_vec4(const float* __restrict__ x, float* __restrict__ y,
                          int n) {
    int idx = 4 * (blockIdx.x * blockDim.x + threadIdx.x);
    if (idx + 3 < n) {
        float4 v = FLOAT4(x + idx);
        v.x = fmaxf(0.0f, v.x);
        v.y = fmaxf(0.0f, v.y);
        v.z = fmaxf(0.0f, v.z);
        v.w = fmaxf(0.0f, v.w);
        FLOAT4(y + idx) = v;
    } else if (idx < n) {
        for (int i = 0; idx + i < n; ++i) y[idx + i] = fmaxf(0.0f, x[idx + i]);
    }
}

// -----
// ④ 融合: y = gelu(x + bias[col]), 一个 kernel 走完
// -----
__device__ __forceinline__ float gelu_exact(float t) {
    // 精确版 (erf), 与 PyTorch 的 gelu(approximate='none') 对齐
    return 0.5f * t * (1.0f + erff(t * 0.70710678118654752440f));
}

```

```

__global__ void fused_bias_gelu(const float* __restrict__ x,
                               const float* __restrict__ bias,
                               float* __restrict__ y, int n, int hidden) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) {
        float t = x[idx] + __ldg(bias + (idx % hidden));    // 广播 + 融合
        y[idx] = gelu_exact(t);
    }
}

// -----
// ⑤ 对照：分成两步（两个 kernel）—— 观察流量翻倍带来的差异
// -----
__global__ void add_bias(const float* __restrict__ x,
                        const float* __restrict__ bias,
                        float* __restrict__ t, int n, int hidden) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) t[idx] = x[idx] + __ldg(bias + (idx % hidden));
}

__global__ void gelu_only(const float* __restrict__ t, float* __restrict__ y,
                          int n) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) y[idx] = gelu_exact(t[idx]);
}

// -----
// host 侧参考
// -----
int main() {
    TEST_BEGIN("Q179 ReLU / elementwise fusion");

    const int T = 256;

    // ---- ReLU: 三个版本 + 严格断言（ReLU 无舍入） ----
    {
        const int n = 1 << 20;
        std::vector<float> hx(n), href(n), hgot(n);
        fill_random(hx, 5u, -2.f, 2.f);
        for (int i = 0; i < n; ++i) href[i] = std::max(0.0f, hx[i]);

        float *dx, *dy;

```

```

CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));

GpuTimer timer;
const size_t bytes = static_cast<size_t>(n) * 2 * sizeof(float); // 读 + 写

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_b = timer.bench([&] { relu_branchy<<<(n + T - 1) / T, T>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report("relu_branchy (if/else)", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_b);

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_f = timer.bench([&] { relu<<<(n + T - 1) / T, T>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report("relu (fmaxf)", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_f);

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_v = timer.bench([&] { relu_vec4<<<(n + 4 * 64 - 1) / (4 * 64), 64>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report("relu_vec4", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_v);

printf("          带宽口径 8 B/元素: branchy %.0f | fmaxf %.0f | vec4 %.0f GB/s "
       "(峰值 %.0f)\n",
       to_gbps(bytes, ms_b), to_gbps(bytes, ms_f), to_gbps(bytes, ms_v),
       dev.theoretical_gbps);
printf("          ★ 注意: 在本机 (L2 口径、数据 4MB 落在 L2 内) 三者可能都在噪声内 --\n");
printf("          这正说明【瓶颈不在指令而是带宽】; 把 n 放大到远超 L2 再看会有区别.\n");

CUDA_CHECK(cudaFree(dx));
CUDA_CHECK(cudaFree(dy));
}

// ---- 融合 vs 不融合 ----
{
    const int seq = 4096, hidden = 1024; // ★ hidden 不整除 seq, 专门测广播下标
    const int n = seq * hidden;
    std::vector<float> hx(n), hb(hidden), href(n), hgot(n);
    fill_random(hx, 6u, -3.f, 3.f);
    fill_random(hb, 7u, -0.5f, 0.5f);

```

```

for (int i = 0; i < n; ++i) {
    float t = hx[i] + hb[i % hidden];
    href[i] = 0.5f * t * (1.0f + std::erf(t * 0.70710678118654752440));
}

float *dx, *db, *dy, *dt;
CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&db, hidden * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dt, n * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(db, hb.data(), hidden * sizeof(float), cudaMemcpyHostToDevice));

GpuTimer timer;
const int blocks = (n + T - 1) / T;

// fused: 读 x + 读 bias + 写 y
CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_fused = timer.bench([&] { fused_bias_gelu<<<blocks, T>>>(dx, db, dy, n, hidden); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
CompareResult rf = compare(hgot, href, 1e-6, 1e-6);
report("fused bias+gelu", rf, 1e-6, 1e-6, ms_fused);

// unfused: 读 x/bias、写 t; 读 t、写 y
CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_unfused = timer.bench([&] {
    add_bias<<<blocks, T>>>(dx, db, dt, n, hidden);
    gelu_only<<<blocks, T>>>(dt, dy, n);
});
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
CompareResult ru = compare(hgot, href, 1e-6, 1e-6);
report("unfused (2 kernels)", ru, 1e-6, 1e-6, ms_unfused);

size_t b_fused = static_cast<size_t>(n) * 2 * sizeof(float) + hidden * sizeof(float);
size_t b_unfused = static_cast<size_t>(n) * 4 * sizeof(float) + hidden * sizeof(float);
printf("        流量口径: fused %.1f MB / unfused %.1f MB (差 %.2fx) \n",
        b_fused / 1e6, b_unfused / 1e6, double(b_unfused) / b_fused);
printf("        带宽: fused %.0f GB/s | unfused %.0f GB/s (按各自流量算) \n",
        to_gbps(b_fused, ms_fused), to_gbps(b_unfused, ms_unfused));
printf("        ⇒ 融合的收益来自【少一次全局往返】，这里流量比 %.2fx, "
        "实测时间比 %.2fx\n",

```

```

        double(b_unfused) / b_fused, ms_unfused / (ms_fused > 0 ? ms_fused : 1));

    CUDA_CHECK(cudaFree(dx));
    CUDA_CHECK(cudaFree(db));
    CUDA_CHECK(cudaFree(dy));
    CUDA_CHECK(cudaFree(dt));
}

printf("\nQ179 done.\n");
return 0;
}

```

Q180 [手撕] ★ histogram (朴素全局原子 vs smem 私有化)

考点：原子代价模型与 smem 私有化的「次数账」（ $T > B$ 才有收益） **源**

码： [../code/interview/kernels/q180_histogram.cu](https://code.interview.kernels/q180_histogram.cu) (188 行, sha256 484377d78031)


```

// q180_histogram.cu - Q180: histogram (朴素全局原子 vs smem 私有化)
//
// 1) hist_global -- 每次命中直接 atomicAdd 到全局 (最朴素)
// 2) hist_smem -- block 内先在 smem 上计数, 最后每 block 对全局做 B 次合并写
//
// 编译: ./build.sh q180
//
// -----
// 解析要点
// -----
// ① 原子操作的代价模型:
//     atomicAdd 是 RMW (读-改-写), 在 **L2 的原子处理单元**上排队执行,
//     **同地址串行、不同地址并行**。
//     设一次全局原子延迟约  $\tau$  (书里实测约 2.6 ns):
//     - 全部 N 次砸向同一个 bin  $\rightarrow$  吞吐被钉死在  $1/\tau$ 
//     - B 个 bin 均匀承压  $\rightarrow$  理论上限约  $B/\tau$  op/s
//
// ② ★ smem 私有化的"次数账" (最容易答漏的一点):
//     全局原子总次数 =  $G \times B$  ( $G$  = block 数,  $B$  = bin 数)
//     **仅当  $T > B$  时才低于 N** ( $T$  = 每 block 线程数)。
//      $T \leq B$  时次数不变! 收益来自:
//     (a) **smem 原子远快于全局原子** (smem 在片上, 且冲突域只在 block 内)
//     (b) 写模式去热点 (B 个 bin 分散到 B 个地址)
//     所以正确说法不是"原子次数变少了", 而是"原子变便宜了 + 冲突域缩小了"。
//
// ③ 书里的实测 (RTX PRO 5000,  $N=4,194,304$ , 256 bins):
//     elementwise_add 0.01897 ms / 2653.73 GB/s
//     histogram      0.62860 ms / 26.69 GB/s  ← 慢两个数量级
//     按"256 bin 理想并行 + 同址 2.6 ns"模型, 理想耗时  $\approx 4.2M/256 \times 2.6ns \approx 42 \mu s$ ,
//     **实测 0.63 ms 慢了约 15 倍** — 缺口来自 4M 个原子请求在 **L1 侧 atomic
//     路径**的排队与串行化。这正是"模型能算出的下界"与"实际硬件路径"的差距。
//
// ④ 两个必须注意的正确性问题:
//     (a) **复用缓冲区必须每轮清零** (atomicAdd 是加在旧值上) — 用 cudaMemset;
//     (b) 输入值的范围必须严格  $< B$ , 否则 atomicAdd 写到数组外 (越界写, 比越界读更危险)。
//
// ⑤ 为什么不用寄存器/局部数组先数再合并?
//     每个线程先数自己那段、再用 __syncthreads 合并, 本质是 smem 私有化的一种变体;
//     直接对 smem 做原子在 GPU 上已经足够快 (smem 原子由硬件在片上完成)。
//
// -----
#include "lc_common.cuh"

```

```

// -----
// ① 朴素: 全局原子
// -----
__global__ void hist_global(const unsigned char* __restrict__ a,
                           int* __restrict__ y, int n) {
    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) atomicAdd(&y[a[idx]], 1);
}

// -----
// ② smem 私有化
// -----
template <int kBins = 256, int kThreads = 256>
__global__ void hist_smem(const unsigned char* __restrict__ a,
                        int* __restrict__ y, int n) {
    __shared__ int cnt[kBins];

    // 初始化 (避免用 memset 之外的隐式假设)
    for (int b = threadIdx.x; b < kBins; b += kThreads) cnt[b] = 0;
    __syncthreads(); // ★ 必须在任何原子之前

    int idx = blockIdx.x * blockDim.x + threadIdx.x;
    if (idx < n) atomicAdd(&cnt[a[idx]], 1); // smem 原子: 冲突域只在 block 内

    __syncthreads(); // ★ 必须在合并写之前
    for (int b = threadIdx.x; b < kBins; b += kThreads) {
        if (cnt[b]) atomicAdd(&y[b], cnt[b]); // 全局原子次数 = G x B (G 为 block 数)
    }
}

// -----
// ③ 变体: 每个线程先在自己的一段里数 (寄存器累加), 再合并到 smem
// 适合"每线程处理的元素很多"的场景, 能进一步减少 smem 原子次数
// -----
template <int kBins = 256, int kThreads = 256, int kItemsPerThread = 16>
__global__ void hist_smem_batched(const unsigned char* __restrict__ a,
                                int* __restrict__ y, int n) {
    __shared__ int cnt[kBins];
    for (int b = threadIdx.x; b < kBins; b += kThreads) cnt[b] = 0;
    __syncthreads();

    // 每个线程负责连续的 kItemsPerThread 个元素 (用 smem 暂存而不是寄存器数组,
    // 因为 B 可能很大; 这里为了讲清结构, 仍然是逐个原子提交)

```

```

    int base = (blockIdx.x * kThreads + threadIdx.x) * kItemsPerThread;
#pragma unroll
    for (int i = 0; i < kItemsPerThread; ++i) {
        int idx = base + i;
        if (idx < n) atomicAdd(&cnt[a[idx]], 1);
    }
    __syncthreads();
    for (int b = threadIdx.x; b < kBins; b += kThreads) {
        if (cnt[b]) atomicAdd(&y[b], cnt[b]);
    }
}

// -----
// host 侧参考
// -----
static void ref_hist(const std::vector<unsigned char>& a, std::vector<int>& y,
                    int bins) {
    std::fill(y.begin(), y.end(), 0);
    for (unsigned char v : a) y[v]++;    // 前提: v < bins
}

int main() {
    TEST_BEGIN("Q180 histogram");

    const int kBins = 256;
    const int n = 1 << 22;           // 4,194,304 (与书里同量级)
    const int T = 256;
    const int G = 512;               // 与 dot 的 grid 对齐, 便于比较

    // 均匀分布 + 倾斜分布: 后者更接近真实场景 (少数 bin 扛大部分流量)
    for (int mode = 0; mode < 2; ++mode) {
        std::vector<unsigned char> ha(n);
        if (mode == 0) {
            std::mt19937 gen(21u);
            std::uniform_int_distribution<int> d(0, kBins - 1);
            for (auto& v : ha) v = static_cast<unsigned char>(d(gen));
        } else {
            // 倾斜: 80% 的元素落在前 8 个 bin — 冲突热点更明显
            std::mt19937 gen(22u);
            std::uniform_int_distribution<int> hot(0, 7), cold(8, kBins - 1);
            std::uniform_int_distribution<int> pick(0, 99);
            for (auto& v : ha)
                v = static_cast<unsigned char>(pick(gen) < 80 ? hot(gen) : cold(gen));
        }
    }
}

```

```

}

std::vector<int> href(kBins), hgot(kBins);
ref_hist(ha, href, kBins);

unsigned char* da = nullptr;
int* dy = nullptr;
CUDA_CHECK(cudaMalloc(&da, n));
CUDA_CHECK(cudaMalloc(&dy, kBins * sizeof(int)));
CUDA_CHECK(cudaMemcpy(da, ha.data(), n, cudaMemcpyHostToDevice));

GpuTimer timer;
const int blocks = (n + T - 1) / T;

// --- 朴素: 每轮必须清零 ---
CUDA_CHECK(cudaMemset(dy, 0, kBins * sizeof(int)));
double ms_g = timer.bench([&] { hist_global<<<blocks, T>>>(da, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, kBins);
report(mode == 0 ? "hist_global (uniform)" : "hist_global (skewed)",
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_g);

// --- smem 私有化 ---
CUDA_CHECK(cudaMemset(dy, 0, kBins * sizeof(int)));
double ms_s = timer.bench([&] { hist_smem<kBins, T><<<G, T>>>(da, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, kBins);
report(mode == 0 ? "hist_smem (uniform)" : "hist_smem (skewed)",
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_s);

// --- 多线程多元素 ---
CUDA_CHECK(cudaMemset(dy, 0, kBins * sizeof(int)));
const int items = 16;
const int blocks_b = (n + T * items - 1) / (T * items);
double ms_b = timer.bench([&] { hist_smem_batched<kBins, T, items><<<blocks_b, T>>>(da, dy, n)
CUDA_CHECK_KERNEL();
hgot = to_host(dy, kBins);
report(mode == 0 ? "hist_batched(uniform)" : "hist_batched(skewed)",
        compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_b);

// 带宽口径: 只读 1 B/元素 (原子不计入流量)
size_t bytes = n;
printf("          %.0f MB 输入, 带宽口径 1 B/元素: global %.1f GB/s | smem %.1f | "

```

```

        "batched %.1f\n",
        n / 1e6, to_gbps(bytes, ms_g), to_gbps(bytes, ms_s), to_gbps(bytes, ms_b));
printf("        耗时比 smem/global = %.2fx, batched/global = %.2fx\n",
        ms_s / ms_g, ms_b / ms_g);
if (mode == 0) {
    printf("        ★ 对照：教科书说 smem 私有化能快一个数量级，但**倾斜分布下"
        "收益会缩小**\n        （热点 bin 的 smem 原子同样会串行化）。\n");
}

    CUDA_CHECK(cudaFree(da));
    CUDA_CHECK(cudaFree(dy));
}

printf("\nQ180 done.\n");
return 0;
}

```

Q181 [手撕] ★ 矩阵转置 (smem + padding 打散 bank conflict)

考点：transpose + padding：bank conflict 的算术与「口径决定加速比」 **源**

码： [../code/interview/kernels/q181-transpose.cu](https://code.interview.kernels/q181-transpose.cu) (240 行, sha256 `f8c416b417e8`)

```

// q181_transpose.cu - Q181: 矩阵转置 (smem + padding 打散 bank conflict)
//
// 1) transpose_naive  -- 直接读写全局内存 (写侧跨步, coalescing 崩掉)
// 2) transpose_tiled  -- 经 smem 中转 +1 padding, 读写两侧都合并
// 3) transpose_tiled32 -- 32x32 tile 版本 (教学常考的形状)
//
// 编译: ./build.sh q181
//
// -----
// 解析要点
// -----
// ① 为什么朴素版慢: 写 `out[x * rows + y]` 时, warp 内 x 连续  $\Rightarrow$  **写地址跨步 rows**
//  $\Rightarrow$  每个线程落在不同的 32 B sector  $\Rightarrow$  **有效率掉到 12.5% (按 32 B sector 口径)
// 甚至约 3% (按 128 B line 口径)**。读是合并的, 写不是。
// 经 smem 中转后, **读和写各自都是合并访问**, 中间的转置在片上完成。
//
// ② ★ bank conflict 的算术 (面试会让你现场推):
// smem 32 个 bank x 4 B,  $\text{bank}(a) = (a/4) \bmod 32$ 。
// 写  $\text{tile}[ty][tx]$  (tx 连续)  $\Rightarrow$  地址连续  $\Rightarrow$  无冲突。
// 读  $\text{tile}[tx][ty]$  (tx 连续、ty 固定)  $\Rightarrow$  地址  $= (tx * \text{TILE} + ty) * 4$ 
//  $\Rightarrow \text{bank} = (tx * \text{TILE} + ty) \bmod 32$ 
// TILE = 32 时  $\text{bank} = ty \bmod 32 \Rightarrow$  **与 tx 无关  $\Rightarrow$  32 路撞同一个 bank**。
// 加 1 列 padding: 地址  $= (tx * 33 + ty) * 4$ 
//  $\Rightarrow \text{bank} = (tx * 33 + ty) \bmod 32 = (tx + ty) \bmod 32 \Rightarrow$  **tx 连续  $\Rightarrow$  bank 连续  $\Rightarrow$  无冲突**。
// ★ 代价只是 TILE x 4 B (32x32 时 128 B, 占用率损失可忽略)。
//
// ③ ★ 一个必须说清的口径问题 (书里专门强调):
// 同一个 padding 优化, **L2 口径下加速比 2.40x, HBM 口径下只有 1.11x**。
// 因为 L2 口径下瓶颈是访存模式 (sector 利用率), HBM 口径下瓶颈是带宽本身。
//  $\Rightarrow$  报告加速比必须带口径, 否则数字没有意义。
// 本文件里 ` -DHBM_SCALE=1 ` 可把矩阵放大到远超 L2 来复现这个差异。
//
// ④ 泛化到 fp16 时要注意: 一个 16 B chunk = 8 个 half, 所以 bank 的"字"单位变了:
// 书里用 `Swizzle<3,3,3>` (元素口径) 而不是 `Swizzle<3,4,3>` (字节口径),
// 差一个 M 就完全错位 -- 这是 CuTe/TMA 路径上的常见坑。
// -----

#include "lc_common.cuh"

// -----
// ① 朴素版: 读合并、写跨步
// -----

__global__ void transpose_naive(const float* __restrict__ in,

```



```

        float* __restrict__ out, int rows, int cols) {
    int x = blockIdx.x * blockDim.x + threadIdx.x;    // 列
    int y = blockIdx.y * blockDim.y + threadIdx.y;    // 行
    if (x < cols && y < rows) {
        // 读 in[y][x]: warp 内 x 连续 ⇒ 合并
        // 写 out[x][y]: warp 内 x 连续 ⇒ 地址跨步 rows ⇒ 不合并
        out[x * rows + y] = in[y * cols + x];
    }
}

// -----
// ② tiled + padding
// -----
template <int TILE = 32>
__global__ void transpose_tiled(const float* __restrict__ in,
                                float* __restrict__ out, int rows, int cols) {
    __shared__ float tile[TILE][TILE + 1];    // ★ +1: 把行 stride 从 32 变成 33

    int x = blockIdx.x * TILE + threadIdx.x;
    int y = blockIdx.y * TILE + threadIdx.y;

    if (x < cols && y < rows) tile[threadIdx.y][threadIdx.x] = in[y * cols + x];
    __syncthreads();                          // ★ 中转必须在读完之前不可覆写

    // 交换 block 坐标: 写出的 tile 是转置后的
    int xo = blockIdx.y * TILE + threadIdx.x;
    int yo = blockIdx.x * TILE + threadIdx.y;
    if (xo < rows && yo < cols) out[yo * rows + xo] = tile[threadIdx.x][threadIdx.y];
}

// -----
// ③ 无 padding 的对照版 (用来实测 bank conflict 的代价)
// -----
template <int TILE = 32>
__global__ void transpose_tiled_nopad(const float* __restrict__ in,
                                       float* __restrict__ out, int rows, int cols) {
    __shared__ float tile[TILE][TILE];        // ★ 没有 +1

    int x = blockIdx.x * TILE + threadIdx.x;
    int y = blockIdx.y * TILE + threadIdx.y;
    if (x < cols && y < rows) tile[threadIdx.y][threadIdx.x] = in[y * cols + x];
    __syncthreads();

    int xo = blockIdx.y * TILE + threadIdx.x;
    int yo = blockIdx.x * TILE + threadIdx.y;

```

```

    if (xo < rows && yo < cols) out[yo * rows + xo] = tile[threadIdx.x][threadIdx.y];
}

// -----
// ④ XOR swizzle 版: 不 padding, 靠 `x ^ y` 打散 bank
// ★ 与 LeetCUDA `kernels/swizzle/mat_trans_swizzle.cu` 的
// `mat_trans_smem_swizzle_kernel` 逐字同构 (同样是 32x32 tile、
// 同样 `block(32,32)` + `grid(N/32, M/32)`):
// 写: s_data[x][x ^ y] = A[...]
// 读: B[...] = s_data[y][x ^ y]
// 直观理解: 逻辑坐标 (row=x, col=y) 存到物理位置 (row=x, col=x^y);
// 读的时候按逻辑 (row=y, col=x) 取, 物理位置同样是 (row=y, col=x^y)。
// ★ 与 padding 的取舍: swizzle 不浪费 smem、也不破坏 16 B 对齐,
// 但它是「按访问模式定制的置换」—— 换一个访问方向就得换一个公式。
// -----
template <int TILE = 32>
__global__ void transpose_swizzle(const float* __restrict__ in,
                                   float* __restrict__ out, int rows, int cols) {
    __shared__ float tile[TILE][TILE];          // ★ 没有 +1
    int x = blockIdx.x * TILE + threadIdx.x;    // 列
    int y = blockIdx.y * TILE + threadIdx.y;    // 行
    if (x < cols && y < rows) {
        tile[threadIdx.x][threadIdx.x ^ threadIdx.y] = in[y * cols + x];
        __syncthreads();
        int xo = blockIdx.y * TILE + threadIdx.x;
        int yo = blockIdx.x * TILE + threadIdx.y;
        if (xo < rows && yo < cols) {
            out[yo * rows + xo] = tile[threadIdx.y][threadIdx.x ^ threadIdx.y];
        }
    }
}

// -----
// ⑤ 只读 smem 的 bank conflict 探针 (把冲突程度变成一个可报告的数字)
// 这个 kernel 不产出数据, 只用来让 ncu 观察 shared_op_ld 的冲突计数。
// -----
template <int TILE = 32, int kPad = 1>
__global__ void bank_probe(float* __restrict__ sink) {
    __shared__ float tile[TILE][TILE + kPad];
    // 先用合并访问填满
    for (int i = threadIdx.y; i < TILE; i += blockDim.y)
        for (int j = threadIdx.x; j < TILE + kPad; j += blockDim.x)
            tile[i][j] = static_cast<float>(i * 100 + j);
}

```

```

__syncthreads();
// 再列方向读（这是冲突发生的地方；kPad=1 时无冲突，kPad=0 时 32 路）
float acc = 0.0f;
for (int i = threadIdx.y; i < TILE; i += blockDim.y) acc += tile[threadIdx.x][i];
if (acc == -1.0f) *sink = acc;    // 防止被优化掉
}

// -----
// host 侧参考
// -----
static void ref_transpose(const std::vector<float>& in, std::vector<float>& out,
                        int rows, int cols) {
    for (int y = 0; y < rows; ++y)
        for (int x = 0; x < cols; ++x) out[x * rows + y] = in[y * cols + x];
}

int main() {
    TEST_BEGIN("Q181 matrix transpose");

    // 关键：既要方阵（bank conflict 最明显），也要非方阵与非 tile 倍数
    struct Case { int rows, cols; };
    const std::vector<Case> cases = {{32, 32}, {1024, 1024}, {1000, 17},
                                      {33, 65}, {1, 4096}, {4096, 1}};

    for (const auto& c : cases) {
        const int rows = c.rows, cols = c.cols;
        const size_t n = static_cast<size_t>(rows) * cols;
        std::vector<float> hin(n), href(n), hgot(n);
        fill_random(hin, 31u, -1.f, 1.f);
        ref_transpose(hin, href, rows, cols);

        float *din, *dout;
        CUDA_CHECK(cudaMalloc(&din, n * sizeof(float)));
        CUDA_CHECK(cudaMalloc(&dout, n * sizeof(float)));
        CUDA_CHECK(cudaMemcpy(din, hin.data(), n * sizeof(float), cudaMemcpyHostToDevice));

        dim3 block(32, 8);
        dim3 grid((cols + 31) / 32, (rows + 31) / 32);
        GpuTimer timer;
        const size_t bytes = n * 2 * sizeof(float);    // 读 + 写

        CUDA_CHECK(cudaMemset(dout, 0, n * sizeof(float)));
        double ms_naive = timer.bench([&] { transpose_naive<<<grid, block>>>(din, dout, rows, cols); }

```

```

CUDA_CHECK_KERNEL();
hgot = to_host(dout, n);
report(("naive      " + std::to_string(rows) + "x" + std::to_string(cols)).c_str(),
      compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_naive);

dim3 grid32((cols + 31) / 32, (rows + 31) / 32);
dim3 block32(32, 32);
CUDA_CHECK(cudaMemset(dout, 0, n * sizeof(float)));
double ms_nopad = timer.bench([&] {
    transpose_tiled_nopad<32><<<grid32, block32>>>(din, dout, rows, cols);
});
CUDA_CHECK_KERNEL();
hgot = to_host(dout, n);
report("tiled32  (no pad)", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_nopad);

CUDA_CHECK(cudaMemset(dout, 0, n * sizeof(float)));
double ms_pad = timer.bench([&] {
    transpose_tiled<32><<<grid32, block32>>>(din, dout, rows, cols);
});
CUDA_CHECK_KERNEL();
hgot = to_host(dout, n);
report("tiled32  (pad +1)", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_pad);

// ★ swizzle 版: 与 LeetCode kernels/swizzle/mat_trans_swizzle.cu 同构
CUDA_CHECK(cudaMemset(dout, 0, n * sizeof(float)));
double ms_sw = timer.bench([&] {
    transpose_swizzle<32><<<grid32, block32>>>(din, dout, rows, cols);
});
CUDA_CHECK_KERNEL();
hgot = to_host(dout, n);
report("tiled32  (xor swizzle)", compare(hgot, href, 0.0, 0.0), 0.0, 0.0, ms_sw);

printf("      带宽口径 8 B/元素: naive %.0f | nopad %.0f | pad+1 %.0f | swizzle %.0f GB/s\n",
      to_gbps(bytes, ms_naive), to_gbps(bytes, ms_nopad), to_gbps(bytes, ms_pad),
      to_gbps(bytes, ms_sw));
printf("      加速比: pad+1/naive = %.2fx | pad+1/nopad = %.2fx | swizzle/nopad = %.2fx\n",
      ms_naive / ms_pad, ms_nopad / ms_pad, ms_nopad / ms_sw);
if (rows == 1024 && cols == 1024) {
    printf("      ★ 这里数据 4 MB, 落在 L2 内 ⇒ 是 **L2 口径**.\n");
    printf("      同一个 padding 优化在 HBM 口径下加速比会小得多 (书里 2.40x -> 1.11x), \n");
    printf("      因为瓶颈从「访存模式」变成了「带宽本身」.\n");
}

```

```

    CUDA_CHECK(cudaFree(din));
    CUDA_CHECK(cudaFree(dout));
}

// ---- bank conflict 探针: 跑一次, 让 ncu 能抓到 shared_op_ld 的冲突计数 ----
{
    float* d_sink = nullptr;
    CUDA_CHECK(cudaMalloc(&d_sink, sizeof(float)));
    // kPad=0 与 kPad=1 各跑一次; 用 ncu 对比两者的 bank_conflicts 计数
    bank_probe<32, 0><<<1, dim3(32, 8)>>>(d_sink); // unchecked: 探针 kernel, 无输出
    bank_probe<32, 1><<<1, dim3(32, 8)>>>(d_sink); // unchecked: 探针 kernel, 无输出
    CUDA_CHECK_KERNEL();
    printf("\n bank 探针已跑两次 (kPad=0 与 kPad=1)。用 ncu 看差别: \n");
    printf("      ncu --metrics lltex__data_bank_conflicts_pipe_lsu_mem_shared_op_ld.sum \\n");
    printf("      --kernel-name regex:bank_probe --launch-count 2 ./q181\n");
    printf("      书里的参考量级 (M=N=K=512, per-launch 冲突计数): \n");
    printf("      BK=16 无 swizzle 98,304 次 (2-way) \n");
    printf("      BK=64 无 swizzle 691,067 次 (8-way) \n");
    printf("      BK=64 + swizzle<16> 297,628 次 (4-way, 耗时 30.2 -> 20.7 μs) \n");
    CUDA_CHECK(cudaFree(d_sink));
}

printf("\nQ181 done.\n");
return 0;
}

```

Q182 [手撕] ★ RMSNorm / LayerNorm (归一化算子的两种实现与一趟方案)

考点: 两趟 vs 一趟 (单 pass) 与 Welford; 减少流量 vs 减少指令的区别 **源**

码: [../code/interview/kernels/q182_norm.cu](https://code.interview.kernels/q182_norm.cu) (317 行, sha256 `fa10ee9af2b9`)

```
// q182_norm.cu - Q182: RMSNorm / LayerNorm (归一化算子的两种实现与一趟方案)
//
// 1) rms_norm_twopass  -- 第一趟求平方和，第二趟归一化（两趟读 x）
// 2) rms_norm_onepass  -- 一趟：把 x 留在寄存器/smem 里，只做一次全局读
// 3) layer_norm        -- 需要 mean 与 var（本文件用两趟，便于对照）
// 4) layer_norm_welford -- 一趟 Welford：合并 (mean, M2) 状态，与 online softmax 同构
//
// 编译：./build.sh q182
//
// -----
// 解析要点
// -----
// ① RMSNorm 与 LayerNorm 的差别（写代码前先说清）：
//      RMSNorm:  $y = x / \sqrt{\text{mean}(x^2) + \text{eps}} * w$           -- 不减均值，只除 RMS
//      LayerNorm:  $y = (x - \text{mean}) / \sqrt{\text{var} + \text{eps}} * w + b$  -- 减均值再除标准差
//      ⇒ RMSNorm **少一次归约**（不需要 mean），少一次全局同步，且不需要 bias。
//
// ② ★ 两趟 vs 一趟的取舍（这道题的核心）：
//      两趟：读 x 两遍（第二遍通常 L1 命中，但**不是零成本**）+ 2 次 block 归约 + 2 次同步
//      一趟：把 x 留在寄存器或 smem ⇒ 只读全局一次，但**占用寄存器/smem**，
//            且 Welford 的归约算子更重（每次合并 2 个状态）
//      ★ 书里有一个非常值得背的实测结论：
//      vec4 对 rms_norm/layer_norm 的收益在 **L2 口径下是 +16%/+24%**，
//      但在 **HBM 口径下四个 kernel 全部收敛到 1000-1070 GB/s、收益消失**；
//      而**「单 pass」在两种口径下都快约 7%（-6.9% / -6.5%）**。
//      ⇒ **减少指令数的优化只在指令受限时有效；减少数据流量的优化在任何口径下都有效。**
//
// ③ Welford 的合并公式（要能默写）：
//      给定两段各自的 (n1, mean1, M2_1) 与 (n2, mean2, M2_2)：
//      n  = n1 + n2
//      d  = mean2 - mean1
//      mean = mean1 + d * n2 / n
//      M2 = M2_1 + M2_2 + d * d * n1 * n2 / n
//      var = M2 / n。 **只做一次全局读**，且数值上比"先求和再求平方和"稳定
//      （后者在 mean 很大、方差不大的时候会发生灾难性抵消）。
//
// ④ 一个每帧都会踩的细节：eps 的位置。
//      PyTorch 的 LayerNorm 是  $(x - \text{mean}) / \sqrt{\text{var} + \text{eps}}$ ，而 RMSNorm 常见两种写法：
//      rsqrt(mean(x^2) + eps)      ← Llama 系
//      rsqrt(mean(x^2)) + eps      ← 少数实现
//      写 kernel 前必须和参考实现对齐，否则数值对不上（而且形状完全合法）。
// -----
```



```

#include "lc_common.cuh"

// -----
// ① RMSNorm 两趟
// -----
template <int kThreads = 256>
__global__ void rms_norm_twopass(const float* __restrict__ x,
                                const float* __restrict__ w,
                                float* __restrict__ y, int n, float eps) {
    __shared__ float s_scale;
    float ss = 0.0f;
    for (int i = threadIdx.x; i < n; i += kThreads) ss += x[i] * x[i];
    float total = block_reduce_sum<kThreads>(ss);
    if (threadIdx.x == 0) s_scale = rsqrtf(total / n + eps);
    __syncthreads();           // ★ 广播需要同步
    const float scale = s_scale;
    for (int i = threadIdx.x; i < n; i += kThreads) y[i] = x[i] * scale * w[i];
}

// -----
// ② RMSNorm 一趟: 把 x 缓存在 smem (前提: n <= smem 容量 / 4)
// 注意: 这只对"一行能放进 smem"的情况成立 (hidden <= ~8K 时可行)
// -----
template <int kThreads = 256, int kMaxN = 4096>
__global__ void rms_norm_onepass(const float* __restrict__ x,
                                const float* __restrict__ w,
                                float* __restrict__ y, int n, float eps) {
    __shared__ float s_x[kMaxN];
    __shared__ float s_scale;
    float ss = 0.0f;
    for (int i = threadIdx.x; i < n; i += kThreads) {
        float v = x[i];
        s_x[i] = v;           // 缓存, 第二趟不再读全局
        ss += v * v;
    }
    float total = block_reduce_sum<kThreads>(ss);
    if (threadIdx.x == 0) s_scale = rsqrtf(total / n + eps);
    __syncthreads();
    const float scale = s_scale;
    for (int i = threadIdx.x; i < n; i += kThreads) y[i] = s_x[i] * scale * w[i];
}

// -----

```

```

// ③ LayerNorm (两趟 + 广播)
// -----
template <int kThreads = 256>
__global__ void layer_norm(const float* __restrict__ x,
                           const float* __restrict__ w,
                           const float* __restrict__ b,
                           float* __restrict__ y, int n, float eps) {
    __shared__ float s_mean, s_rstd;
    float sum = 0.0f;
    for (int i = threadIdx.x; i < n; i += kThreads) sum += x[i];
    const float mean = block_reduce_sum<kThreads>(sum) / n;

    float sq = 0.0f;
    for (int i = threadIdx.x; i < n; i += kThreads) {
        const float d = x[i] - mean;
        sq += d * d;
    }
    const float var = block_reduce_sum<kThreads>(sq) / n;
    if (threadIdx.x == 0) {
        s_mean = mean;
        s_rstd = rsqrtf(var + eps);
    }
    __syncthreads();
    for (int i = threadIdx.x; i < n; i += kThreads)
        y[i] = (x[i] - s_mean) * s_rstd * w[i] + b[i];
}

// -----
// ④ LayerNorm 一趟 (Welford: 状态 (count, mean, M2) 的归约)
// -----
struct Welford {
    float n, mean, m2;
};

__device__ __forceinline__ Welford welford_merge(Welford a, Welford b) {
    if (a.n == 0.0f) return b;
    if (b.n == 0.0f) return a;
    Welford r;
    r.n = a.n + b.n;
    const float d = b.mean - a.mean;
    r.mean = a.mean + d * (b.n / r.n);
    r.m2 = a.m2 + b.m2 + d * d * (a.n * b.n / r.n);
    return r;
}

```

```

}

template <int kThreads = 256>
__global__ void layer_norm_welford(const float* __restrict__ x,
                                   const float* __restrict__ w,
                                   const float* __restrict__ b,
                                   float* __restrict__ y, int n, float eps) {
    // 每个线程先算自己那段的局部 Welford 状态, 再做 warp/block 归约
    Welford local{0.0f, 0.0f, 0.0f};
    for (int i = threadIdx.x; i < n; i += kThreads) {
        local.n += 1.0f;
        const float d = x[i] - local.mean;
        local.mean += d / local.n;
        local.m2 += d * (x[i] - local.mean);
    }
    // warp 内合并
#pragma unroll
    for (int mask = 16; mask >= 1; mask >= 1) {
        Welford o{__shfl_xor_sync(0xfffffffffu, local.n, mask),
                  __shfl_xor_sync(0xfffffffffu, local.mean, mask),
                  __shfl_xor_sync(0xfffffffffu, local.m2, mask)};
        local = welford_merge(local, o);
    }
    // 跨 warp: 写 smem 再合并 (与 block_reduce 同构)
    __shared__ Welford welf[kThreads / 32];
    __shared__ float s_mean, s_rstd;
    const int lane = threadIdx.x & 31, warp = threadIdx.x >> 5;
    if (lane == 0) welf[warp] = local;
    __syncthreads();
    if (warp == 0) {
        Welford o = (lane < kThreads / 32) ? welf[lane] : Welford{0.0f, 0.0f, 0.0f};
#pragma unroll
        for (int mask = 16; mask >= 1; mask >= 1) {
            Welford p{__shfl_xor_sync(0xfffffffffu, o.n, mask),
                      __shfl_xor_sync(0xfffffffffu, o.mean, mask),
                      __shfl_xor_sync(0xfffffffffu, o.m2, mask)};
            o = welford_merge(o, p);
        }
        if (lane == 0) {
            s_mean = o.mean;
            s_rstd = rsqrtf(o.m2 / o.n + eps);
        }
    }
}

```

```

__syncthreads();
const float mean = s_mean, rstd = s_rstd;
// ★ 第二趟仍然要读 x — 真正的"一趟"需要把 x 留在 smem/寄存器里;
// 这里演示的是"只做一次归约" (Welford), 全局读仍然是两趟。
for (int i = threadIdx.x; i < n; i += kThreads)
    y[i] = (x[i] - mean) * rstd * w[i] + b[i];
}

// -----
// host 侧参考 (用 double 提高精度, 作为"真值")
// -----
static void ref_rms(const std::vector<float>& x, const std::vector<float>& w,
                  std::vector<float>& y, int n, float eps) {
    double ss = 0.0;
    for (int i = 0; i < n; ++i) ss += double(x[i]) * x[i];
    double scale = 1.0 / std::sqrt(ss / n + eps);
    for (int i = 0; i < n; ++i) y[i] = float(double(x[i]) * scale * w[i]);
}

static void ref_ln(const std::vector<float>& x, const std::vector<float>& w,
                  const std::vector<float>& b, std::vector<float>& y, int n,
                  float eps) {
    double mean = 0.0;
    for (int i = 0; i < n; ++i) mean += x[i];
    mean /= n;
    double var = 0.0;
    for (int i = 0; i < n; ++i) {
        double d = x[i] - mean;
        var += d * d;
    }
    var /= n;
    double rstd = 1.0 / std::sqrt(var + eps);
    for (int i = 0; i < n; ++i)
        y[i] = float((double(x[i]) - mean) * rstd * w[i] + b[i]);
}

int main() {
    TEST_BEGIN("Q182 RMSNorm / LayerNorm");

    const int T = 256;
    const float eps = 1e-5f;

    for (int n : {128, 1024, 4096}) {

```

```

std::vector<float> hx(n), hw(n), hb(n), href(n), hgot(n);
fill_random(hx, 41u, -2.f, 2.f);
fill_random(hw, 42u, 0.5f, 1.5f);
fill_random(hb, 43u, -0.1f, 0.1f);

float *dx, *dw, *db, *dy;
CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dw, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&db, n * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(dw, hw.data(), n * sizeof(float), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(db, hb.data(), n * sizeof(float), cudaMemcpyHostToDevice));

GpuTimer timer;
const size_t bytes = n * 2 * sizeof(float); // 读 x + 写 y

// ---- RMSNorm 两趟 vs 一趟 ----
ref_rms(hx, hw, href, n, eps);
CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_2 = timer.bench([&] { rms_norm_twopass<T><<<1, T>>>(dx, dw, dy, n, eps); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report(("rms_norm twopass n=" + std::to_string(n)).c_str(),
       compare(hgot, href, 1e-5, 1e-6), 1e-5, 1e-6, ms_2);

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_1 = timer.bench([&] { rms_norm_onepass<T, 4096><<<1, T>>>(dx, dw, dy, n, eps); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report(("rms_norm onepass n=" + std::to_string(n)).c_str(),
       compare(hgot, href, 1e-5, 1e-6), 1e-5, 1e-6, ms_1);
printf("          onepass/twopass 时间比 = %.3f (<1 表示一趟省下了第二次全局读) \n",
       ms_1 / ms_2);

// ---- LayerNorm 两趟 vs Welford ----
ref_ln(hx, hw, hb, href, n, eps);
CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_ln = timer.bench([&] { layer_norm<T><<<1, T>>>(dx, dw, db, dy, n, eps); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report(("layer_norm 2pass n=" + std::to_string(n)).c_str(),
       compare(hgot, href, 1e-5, 1e-6), 1e-5, 1e-6, ms_ln);

```

```

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms_wf = timer.bench([&] { layer_norm_welford<T><<<1, T>>>(dx, dw, db, dy, n, eps); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report(("layer_norm welford n=" + std::to_string(n)).c_str(),
        compare(hgot, href, 1e-5, 1e-6), 1e-5, 1e-6, ms_wf);
printf("        welford/2pass 时间比 = %.3f (单次归约, 但第二趟仍读 x) \n",
        ms_wf / ms_ln);
printf("        带宽口径 8 B/元素: rms2 %.0f | rms1 %.0f | ln %.0f | ln_wf %.0f GB/s\n",
        to_gbps(bytes, ms_2), to_gbps(bytes, ms_1), to_gbps(bytes, ms_ln),
        to_gbps(bytes, ms_wf));

CUDA_CHECK(cudaFree(dx));
CUDA_CHECK(cudaFree(dw));
CUDA_CHECK(cudaFree(db));
CUDA_CHECK(cudaFree(dy));
}

// ---- 数值稳定性: mean 很大、方差很小的时候 ----
{
    const int n = 4096;
    std::vector<float> hx(n, 1000.0f);          // mean = 1000, var ≈ 0
    for (int i = 0; i < n; ++i) hx[i] += (i % 2) ? 1e-3f : -1e-3f;
    std::vector<float> hw(n, 1.0f), hb(n, 0.0f), href(n), hgot(n);
    ref_ln(hx, hw, hb, href, n, eps);

    float *dx, *dw, *db, *dy;
    CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dw, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&db, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dw, hw.data(), n * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(db, hb.data(), n * sizeof(float), cudaMemcpyHostToDevice));

    layer_norm<256><<<1, 256>>>(dx, dw, db, dy, n, eps);
    CUDA_CHECK_KERNEL();
    hgot = to_host(dy, n);
    CompareResult r1 = compare(hgot, href, 1e-3, 1e-3);
    report("layer_norm 2pass (mean=1000, var~0)", r1, 1e-3, 1e-3);

    layer_norm_welford<256><<<1, 256>>>(dx, dw, db, dy, n, eps);

```



```

    CUDA_CHECK_KERNEL();
    hgot = to_host(dy, n);
    CompareResult r2 = compare(hgot, href, 1e-3, 1e-3);
    report("layer_norm welford (same input)", r2, 1e-3, 1e-3);
    printf("          ★ 这个用例专门打「先求和再求平方和」的灾难性抵消: \n");
    printf("           $E[x^2] - \text{mean}^2$  在  $\text{mean}=1000$  时会把有效位吃掉, Welford 不会. \n");

    CUDA_CHECK(cudaFree(dx));
    CUDA_CHECK(cudaFree(dw));
    CUDA_CHECK(cudaFree(db));
    CUDA_CHECK(cudaFree(dy));
}

printf("\nQ182 done.\n");
return 0;
}

```

Q183 [手撕] ★ tiled SGEMM (shared memory + thread tile + vec4)

考点: tiled SGEMM: 三个 AI 公式、两道 __syncthreads、/ 与 % 的索引法则 **源**

码: [../code/interview/kernels/q183_sgemm.cu](https://code.interview.kernels/q183_sgemm.cu) (275 行, sha256 78750a11e600)

```
// q183_sgemmm.cu - Q183: tiled SGEMM (shared memory + thread tile + vec4)
//
// 阶梯（对应书里第十章的三级）：
// 0) sgemm_naive  — 直译：AI = 0.25 FLOP/B 且与 K 无关（常数！）
// 1) sgemm_tile   — Level 1: Block Tile 进 smem, AI 抬到 BM*BN/(2(BM+BN))
// 2) sgemm_vec4   — Level 1+: 加载用 float4, 搬运指令数砍到 1/4;
//                  每线程算 TM x TN = 4x4 的 thread tile
//
// 编译：./build.sh q183
//
// -----
// 解析要点
// -----
// ① ★ 三个 AI 公式（必须能手推，面试必问）：
//      naive:      AI = 2K / 8K = 0.25 FLOP/B      ← 分子分母同乘 K 相消，是【常数】
//      block tile: AI = 2*BM*BN*BK / (4*BK*(BM+BN)) = BM*BN / (2(BM+BN))
//                  ★ BK 在分子分母相消 ⇒ AI 由 BM x BN 唯一决定 (32^2 -> 8, 128^2 -> 32)
//      thread tile: AI_smem = 2*TM*TN / (4*(TM+TN)) = TM*TN / (2(TM+TN))
//                  1x1 -> 0.25, 4x4 -> 1.0 ⇒ **每 FMA 的 smem 读从 2 次降到 0.5 次**
//      ⇒ block tile 优化的是 gmem->smem 的复用, thread tile 优化的是 smem->寄存器 的复用,
//      **二者正交、可叠加**。
```

② ★ 两道 __syncthreads() 各防什么（必答）：

```
//      第一道（加载完、计算前）：防"读到没写完的 smem";
//      第二道（计算完、下一轮加载前）：防"还没读完就被下一轮覆写"。
//      **省掉第二道是最常见的"优化"笔误** — 症状是偶发错数、随形状与调度变化、难复现。
```

③ ★ 索引法则（书里的原话）：

```
//      '/' 表示线程在该维【不连续】排布， '%' 表示【连续】排布。
//      **需要合并访问的维度必须用 '%'。 **
//      本文件里 A 的加载映射是 `a_m = tid / 8, a_k = (tid % 8) * 4`：
//      warp 内 8 个线程一行、每线程搬 4 个 float ⇒ 一行 128 B 恰好合并。
//      如果把 '/' 与 '%' 用反，warp 内地址立刻变成跨步散访，性能掉一个数量级。
```

④ 为什么 4x4 的 thread tile: AI_smem 从 0.25 抬到 1.0，而且每线程有 16 条独立的 FMA 链（ILP），更容易填满流水线。

⑤ ★ 边界约定必须主动说出来：本文件要求

```
//      M % BM == 0, N % BN == 0, K % BK == 0 (naive 版要求 % 32)
//      不满足时**会越界读且越界写**（比 GEMV 的只读越界更危险）。
//      生产代码要么加守卫，要么把形状 pad 到对齐。
```

⑥ 实测（书的表 10.1, RTX PRO 5000, 方阵）：

```
//      naive@2048  3.144 ms /  5.46 TFLOPS
//      vec4 @2048  0.661 ms / 25.97 TFLOPS    ← 4.76x
//      naive 被带宽钉死在 ~5.5 T (AI=8 的隐含上限 8 x 934 GB/s ≈ 7.5 T, 拿到 73%);
//      vec4 到 25.97 T = AI=32 上限的 87%, 距峰值 66.9 T 还有 61% 缺口
//      ⇒ 这就是"该往 Tensor Core 走"的定量依据。
// -----
```

```
#include "lc_common.cuh"
```

```
// -----
// Level 0: naive (AI = 0.25)
// -----
```

```
__global__ void sgemm_naive(const float* __restrict__ A,
                           const float* __restrict__ B,
                           float* __restrict__ C, int M, int N, int K) {
    int row = blockIdx.y * blockDim.y + threadIdx.y;
    int col = blockIdx.x * blockDim.x + threadIdx.x;
    if (row < M && col < N) {
        float sum = 0.0f;
        for (int k = 0; k < K; ++k) sum += A[row * K + k] * B[k * N + col];
        C[row * N + col] = sum;
    }
}
```

```
// -----
// Level 1: Block Tile
// -----
```

```
template <int BM = 32, int BN = 32, int BK = 32>
__global__ void sgemm_tile(const float* __restrict__ A,
                           const float* __restrict__ B,
                           float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[BM][BK];
    __shared__ float s_b[BK][BN];

    const int tx = threadIdx.x, ty = threadIdx.y;
    const int row = blockIdx.y * BM + ty;
    const int col = blockIdx.x * BN + tx;

    float sum = 0.0f;
    for (int k0 = 0; k0 < K; k0 += BK) {
        // 协作加载 (BM=BN=BK=32 时正好一个线程一个元素)
        s_a[ty][tx] = A[row * K + k0 + tx];
        s_b[ty][tx] = B[(k0 + ty) * N + col];
    }
}
```

```

__syncthreads();                                // ★ 第一道

for (int k = 0; k < BK; ++k) sum += s_a[ty][k] * s_b[k][tx];

__syncthreads();                                // ★ 第二道：防下一轮覆写
}

C[row * N + col] = sum;
}

// -----
// Level 1+: 128x128x32 tile + 4x4 thread tile + vec4 加载
// 配置: BM=BN=128, BK=32, block(32,32)=1024 线程, 每线程 4x4=16 个 C 元素
//      1024*16 = 16384 = 128*128 ✓
// -----

template <int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_vec4(const float* __restrict__ A,
                           const float* __restrict__ B,
                           float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[BM][BK];                // 128*32*4 = 16 KB
    __shared__ float s_b[BK][BN];                // 32*128*4 = 16 KB    (合计 32 KB)
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;

    // ---- 加载映射 (与计算映射【解耦】) ----
    const int a_m = tid / 8;                      // 8 线程一行
    const int a_k = (tid % 8) * 4;                // 每线程搬 4 个 float ⇒ warp 内拼出 128 B
    const int b_k = tid / 32;                    // 32 线程一行
    const int b_n = (tid % 32) * 4;              // warp 内拼出 512 B

    // ---- 计算映射: 一个 warp 实际承包 4x128 的 C 横带 ----
    const int c_m = (tid / 32) * TM;
    const int c_n = (tid % 32) * TN;
    float sum[TM][TN];

#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

    const int block_row = blockIdx.y * BM;
    const int block_col = blockIdx.x * BN;

    for (int k0 = 0; k0 < K; k0 += BK) {
        // ④ 协作加载 (vec4: 一条 128-bit 指令搬 4 个 float)
        *reinterpret_cast<float4*>(&s_a[a_m][a_k]) =

```

```

        *reinterpret_cast<const float4*>(&A[(block_row + a_m) * K + k0 + a_k]);
    *reinterpret_cast<float4*>(&s_b[b_k][b_n]) =
        *reinterpret_cast<const float4*>(&B[(k0 + b_k) * N + block_col + b_n]);
    __syncthreads();

    // ② 计算: 每个 k 取 4 个 A + 4 个 B, 做 16 次 FMA (只花 8 次 smem 读)
    for (int k = 0; k < BK; ++k) {
        float ra[TM], rb[TN];
#pragma unroll
        for (int i = 0; i < TM; ++i) ra[i] = s_a[c_m + i][k];
#pragma unroll
        for (int j = 0; j < TN; ++j) rb[j] = s_b[k][c_n + j];
#pragma unroll
        for (int i = 0; i < TM; ++i)
#pragma unroll
            for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads(); // ★ 第二道
}

// ③ 写回: 每行一条 float4 (要求 N % 4 == 0)
#pragma unroll
for (int i = 0; i < TM; ++i) {
    float* c_row = &C[(block_row + c_m + i) * N + block_col + c_n];
    FLOAT4(c_row) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}
}

// -----
// host 侧参考: CPU 三重循环 (小 shape 用; 大 shape 只用来对拍少量元素)
// -----
static void ref_sgemm(const std::vector<float>& A, const std::vector<float>& B,
                    std::vector<float>& C, int M, int N, int K) {
    for (int i = 0; i < M; ++i)
        for (int j = 0; j < N; ++j) {
            double s = 0.0;
            for (int k = 0; k < K; ++k) s += double(A[i * K + k]) * B[k * N + j];
            C[i * N + j] = float(s);
        }
}

int main() {

```

```

TEST_BEGIN("Q183 tiled SGEMM (naive / tile / tile+vec4+threadtile)");

// --- 正确性: 小 shape (都要能被 128 整除, 因为 vec4 版没有边界守卫) ---
{
    const int M = 256, N = 256, K = 128;
    std::vector<float> hA(M * K), hB(K * N), hC(M * N), href(M * N);
    fill_random(hA, 51u, -1.f, 1.f);
    fill_random(hB, 52u, -1.f, 1.f);
    ref_sgemm(hA, hB, href, M, N, K);

    float *dA, *dB, *dC;
    CUDA_CHECK(cudaMalloc(&dA, hA.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dB, hB.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dC, hC.size() * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dA, hA.data(), hA.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dB, hB.data(), hB.size() * sizeof(float), cudaMemcpyHostToDevice));

    // 256 个数累加, fp32 的误差在 1e-5 相对量级
    const double rtol = 1e-4, atol = 1e-4;

    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 blk(16, 16);
    dim3 grd((N + 15) / 16, (M + 15) / 16);
    sgemm_naive<<<grd, blk>>>(dA, dB, dC, M, N, K);
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("sgemm_naive 256x256x128", compare(hC, href, rtol, atol), rtol, atol);

    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 blk1(32, 32), grd1(N / 32, M / 32);
    sgemm_tile<32, 32, 32><<<grd1, blk1>>>(dA, dB, dC, M, N, K);
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("sgemm_tile 256x256x128", compare(hC, href, rtol, atol), rtol, atol);

    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 blk2(32, 32), grd2(N / 128, M / 128);
    sgemm_vec4<128, 128, 32, 4, 4><<<grd2, blk2>>>(dA, dB, dC, M, N, K);
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("sgemm_vec4 256x256x128", compare(hC, href, rtol, atol), rtol, atol);

    CUDA_CHECK(cudaFree(dA));
}

```

```

    CUDA_CHECK(cudaFree(dB));
    CUDA_CHECK(cudaFree(dC));
}

// --- 性能: 方阵阶梯 (这是书里表 10.1 的复现口径) ---
printf("\n ---- 性能阶梯 (方阵, warmup 3 + 10 次均值) ----\n");
for (int n : {512, 1024, 2048}) {
    const int M = n, N = n, K = n;
    std::vector<float> hA(size_t(M) * K), hB(size_t(K) * N);
    fill_random(hA, 61u, -1.f, 1.f);
    fill_random(hB, 62u, -1.f, 1.f);

    float *dA, *dB, *dC;
    CUDA_CHECK(cudaMalloc(&dA, hA.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dB, hB.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dC, size_t(M) * N * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dA, hA.data(), hA.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dB, hB.data(), hB.size() * sizeof(float), cudaMemcpyHostToDevice));

    const double flops = 2.0 * M * N * K;
    GpuTimer timer;
    printf("  n=%4d:\n", n);

    {
        dim3 blk(16, 16), grd((N + 15) / 16, (M + 15) / 16);
        double ms = timer.bench([&] { sgemm_naive<<<grd, blk>>>(dA, dB, dC, M, N, K); });
        printf("    naive   %8.4f ms   %7.2f TFLOPS\n", ms, to_tflops(flops, ms));
    }
    {
        dim3 blk(32, 32), grd(N / 32, M / 32);
        double ms = timer.bench([&] { sgemm_tile<32, 32, 32><<<grd, blk>>>(dA, dB, dC, M, N, K); });
        printf("    tile32  %8.4f ms   %7.2f TFLOPS  (AI = 8)\n", ms, to_tflops(flops, ms));
    }
    {
        dim3 blk(32, 32), grd(N / 128, M / 128);
        double ms = timer.bench([&] {
            sgemm_vec4<128, 128, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M, N, K);
        });
        printf("    vec4    %8.4f ms   %7.2f TFLOPS  (AI = 32, thread tile 4x4)\n",
            ms, to_tflops(flops, ms));
        if (n == 512) {
            printf("    ★ 注意 n=512 时 vec4 的 grid 只有 4x4=16 个 block, "
                "而 SM 有 %d 个 — 大半在围观。 \n", dev.sm_count);
        }
    }
}

```



```

        printf("        这就是「tile 尺寸是 AI 与并行度的折中」：大 tile 让 AI 上去，"
               "但也让 block 数变少。\\n");
    }
}

printf("    → 理论上限：AI=8 时 %.2f TFLOPS, AI=32 时 %.2f TFLOPS "
       "(用 %.0f GB/s 估算)\\n",
       8 * dev.theoretical_gbps / 1e3, 32 * dev.theoretical_gbps / 1e3,
       dev.theoretical_gbps);

    CUDA_CHECK(cudaFree(dA));
    CUDA_CHECK(cudaFree(dB));
    CUDA_CHECK(cudaFree(dC));
}

printf("\\nQ183 done.\\n");
return 0;
}

```

Q184 [手撕] ★ 寄存器双缓冲 + XOR swizzle 打散 bank conflict

考点：寄存器双缓冲 + XOR swizzle (含对合性自检与 padding 对照) **源**

码： [../code/interview/kernels/q184_sgemm_dbuf.cu](https://code.interview.kernels/q184_sgemm_dbuf.cu) (391 行, sha256 `ad87afee2608`)

```

// q184_sgemm_dbuf.cu - Q184: 寄存器双缓冲 + XOR swizzle 打散 bank conflict
//
// 1) sgemm_smem_nopad -- 基准: smem tile 不 padding, B 的行 stride = BK
// 2) sgemm_smem_pad   -- padding 版 (BK+1), 把列方向的 bank 冲突打散
// 3) sgemm_swizzle    -- XOR swizzle 版 (零 padding 达到同样的效果)
//
// 编译: ./build.sh q184
//
// -----
// 解析要点
// -----
// ① ★ 两级双缓冲的分工 (这是本题最容易答混的地方):
//     **smem 多级流水 (kStages + cp.async) ** 盖的是 gmem -> smem 的【跨 k 迭代】延迟;
//     **寄存器双缓冲 (RA/RB 乒乓) **          盖的是 smem -> 寄存器 的【k_step 级】延迟。
//     两者不能互相替代: 前者解决"数据还没到", 后者解决"数据到了但取数指令串行"。
//     本文件把两者都写出来 (kStages 见 q185, 寄存器乒乓见下面的 sgemm_swizzle)。
//
// ② ★ bank conflict 的算术 (smem 32 bank x 4 B, bank(a) = (a/4) mod 32):
//     B 的 smem 布局是 [BK][BN], 读 's_b[k][c_n + j]':
//     warp 内 c_n 连续 (c_n = (tid % 32) * TN, 步长 TN=4)
//     ⇒ 地址 = (k * BN + c_n) * 4
//     ⇒ bank = (k * BN + c_n) mod 32
//     BN = 128 时: bank = (k * 128 + c_n) mod 32 = c_n mod 32
//     ⇒ **k 的贡献消失**! 同一个 warp 里 32 个线程的 c_n = 0, 4, 8, ..., 124
//     ⇒ bank = 0, 4, 8, ..., 28, 0, 4, ... ⇒ **8 路冲突** (步长 4 撞 8 个 bank)。
//     BN + 1 = 129 时: bank = (k * 129 + c_n) mod 32 = (k + c_n) mod 32
//     ⇒ 每个 k 都换一组 bank ⇒ **无冲突**。
//     ★ 这与书里 BK=64 (128 B 行宽) 8-way 的结论同源: **行 stride 是 bank 环长的
//     整数倍时, 行号的贡献就消失了**。
//
// ③ ★ XOR swizzle 的原理与可逆性:
//     Swizzle<B,M,S>: apply(a) = a ^ ((a & yyy) >> S), yyy = (2^B - 1) << (M + S)
//     即把【chunk 号位】(bit [M, M+B)) 与【行号低位】(bit [M+S, M+S+B)) 异或。
//     **可逆性来自对合**: 设  $\sigma(a) = a \oplus m(a)$ , 只要 XOR 的源位域与目标位域不相交
//     (S >= B), 就有  $\sigma(\sigma(a)) = a$ 。
//     ⇒ **编码与解码用同一个函数**, 不需要维护逆置换表。
//     (这是书里"引理 13.1", 也是 CuTe Swizzle 的实现基础。)
//
// ④ ★ 别把"swizzle 后零冲突"当结论背: 冲突度由**行宽**决定。
//     32 B 行宽 + swizzle<16> = 1-way; 128 B 行宽 + swizzle<16> = 4-way;
//     要 1-way 得用 swizzle<64> (c' = c ^ (i & 7))。
//     本文件里 B 的 smem 行宽是 BN * 4 = 512 B (很大), 所以用 padding 更直接;
//     swizzle 版本演示的是"用位运算换 padding"的手法本身。

```

```

//
// ⑤ 寄存器双缓冲的骨架（伪码，见 kernel 里的 ld/st 索引）：
//      float frag[2][TM][TN];
//      load(frag[st], k=0);
//      for (ks = 1; ks < K_SLICES; ++ks) { ld ^= 1; st ^= 1; mma(frag[ld]); load(frag[st], ks); }
//      mma(frag[ld]);
//      -- **计算第 ks-1 片的同时发起第 ks 片的装载**，把 ldmatrix/lds 的延迟藏进 MMA。
//      -----

#include "lc_common.cuh"

// -----
// ① 基准：不 padding
// -----
template <int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_smem_nopad(const float* __restrict__ A,
                                const float* __restrict__ B,
                                float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[BM][BK];
    __shared__ float s_b[BK][BN];          // ★ 行 stride = BN = 128 个字
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int a_m = tid / 8, a_k = (tid % 8) * 4;
    const int b_k = tid / 32, b_n = (tid % 32) * 4;
    const int c_m = (tid / 32) * TM, c_n = (tid % 32) * TN;
    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;

    float sum[TM][TN];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

    for (int k0 = 0; k0 < K; k0 += BK) {
        reinterpret_cast<float4*>(&s_a[a_m][a_k]) =
            reinterpret_cast<const float4*>(&A[(br + a_m) * K + k0 + a_k]);
        reinterpret_cast<float4*>(&s_b[b_k][b_n]) =
            reinterpret_cast<const float4*>(&B[(k0 + b_k) * N + bc + b_n]);
        __syncthreads();
        for (int k = 0; k < BK; ++k) {
            float ra[TM], rb[TN];
#pragma unroll
            for (int i = 0; i < TM; ++i) ra[i] = s_a[c_m + i][k];
#pragma unroll

```

```

        for (int j = 0; j < TN; ++j) rb[j] = s_b[k][c_n + j];    // ★ 冲突在这里
#pragma unroll
        for (int i = 0; i < TM; ++i)
#pragma unroll
            for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads();
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
// ② padding 版: 行 stride 变成 BN + 1, bank 随 k 轮转
// -----
template <int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_smem_pad(const float* __restrict__ A,
                               const float* __restrict__ B,
                               float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[BM][BK + 1];    // ★ A 也 pad: A 是 [m][k], 读 s_a[c_m+i][k] 时
    __shared__ float s_b[BK][BN + 1];    // 同一列 k、不同行 m ⇒ 行 stride 决定 bank
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int a_m = tid / 8, a_k = (tid % 8) * 4;
    const int b_k = tid / 32, b_n = (tid % 32) * 4;
    const int c_m = (tid / 32) * TM, c_n = (tid % 32) * TN;
    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;

    float sum[TM][TN];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

    for (int k0 = 0; k0 < K; k0 += BK) {
        // ★ 注意: padding 之后行不再连续, 所以 vec4 写必须落在行内 (这里是 a_k 到 a_k+3)
        *reinterpret_cast<float4*>(&s_a[a_m][a_k]) =
            *reinterpret_cast<const float4*>(&A[(br + a_m) * K + k0 + a_k]);
        *reinterpret_cast<float4*>(&s_b[b_k][b_n]) =
            *reinterpret_cast<const float4*>(&B[(k0 + b_k) * N + bc + b_n]);
        __syncthreads();
        for (int k = 0; k < BK; ++k) {

```

```

    float ra[TM], rb[TN];
#pragma unroll
    for (int i = 0; i < TM; ++i) ra[i] = s_a[c_m + i][k];
#pragma unroll
    for (int j = 0; j < TN; ++j) rb[j] = s_b[k][c_n + j];    // ★ 现在 bank = (k + c_n)
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads();
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
// ③ XOR swizzle 版: 不 padding, 靠位异或把 chunk 打散
//   Swizzle<B=1, M=4, S=3>: 16 B chunk (M=4 位)、每行 8 个 chunk (S=3 位)
// -----
__device__ __forceinline__ int swizzle_chunk(int row, int chunk) {
    // 把 chunk 号与行号低位异或: (row >> 3) & 1 决定是否翻转 chunk 的最低位
    return chunk ^ ((row >> 3) & 1);
}

// 对合性自检 (host 侧做全遍历, 保证编码/解码同函数)
static bool swizzle_is_involution(int rows, int chunks) {
    for (int r = 0; r < rows; ++r)
        for (int c = 0; c < chunks; ++c)
            if (swizzle_chunk(r, swizzle_chunk(r, c)) != c) return false;
    return true;
}

template <int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_swizzle(const float* __restrict__ A,
                              const float* __restrict__ B,
                              float* __restrict__ C, int M, int N, int K) {
    // 以 8 个 float (32 B) 为一个 chunk 单位做 swizzle
    constexpr int kChunk = 8;
    constexpr int kChunksPerRow = BN / kChunk;
    __shared__ float s_a[BM][BK];

```

```

__shared__ float s_b[BK][BN];

const int tid = threadIdx.y * blockDim.x + threadIdx.x;
const int a_m = tid / 8, a_k = (tid % 8) * 4;
const int b_k = tid / 32, b_n = (tid % 32) * 4;
const int c_m = (tid / 32) * TM, c_n = (tid % 32) * TN;
const int br = blockIdx.y * BM, bc = blockIdx.x * BN;

float sum[TM][TN];
#pragma unroll
for (int i = 0; i < TM; ++i)
#pragma unroll
    for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

for (int k0 = 0; k0 < K; k0 += BK) {
    // 写侧: 把 chunk 号做一次 swizzle (★ 写入与读取必须是同一个函数)
    {
        int row = a_m, col = a_k;
        int chunk = col / kChunk, in_chunk = col % kChunk;
        int scol = swizzle_chunk(row, chunk) * kChunk + in_chunk;
        *reinterpret_cast<float4*>(&s_a[row][scol]) =
            *reinterpret_cast<const float4*>(&A[(br + row) * K + k0 + col]);
    }
    {
        int row = b_k, col = b_n;
        int chunk = col / kChunk, in_chunk = col % kChunk;
        int scol = swizzle_chunk(row, chunk) * kChunk + in_chunk;
        *reinterpret_cast<float4*>(&s_b[row][scol]) =
            *reinterpret_cast<const float4*>(&B[(k0 + row) * N + bc + col]);
    }
    __syncthreads();

    for (int k = 0; k < BK; ++k) {
        float ra[TM], rb[TN];
#pragma unroll
        for (int i = 0; i < TM; ++i) ra[i] = s_a[c_m + i][k];
#pragma unroll
        for (int j = 0; j < TN; ++j) {
            int col = c_n + j;
            int chunk = col / kChunk, in_chunk = col % kChunk;
            int scol = swizzle_chunk(k, chunk) * kChunk + in_chunk;    // 读侧同一函数
            rb[j] = s_b[k][scol];
        }
    }
}

```

```

#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads();
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
// ④ 寄存器双缓冲（用一个更小的 tile 把结构讲清楚）
// -----

template <int BM = 64, int BN = 64, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_regdbuf(const float* __restrict__ A,
                              const float* __restrict__ B,
                              float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[2][BM][BK];
    __shared__ float s_b[2][BK][BN];          // 两级 smem stage（真正的多级流水见 q185）
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int c_m = (tid / 16) * TM, c_n = (tid % 16) * TN;
    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;

    float sum[TM][TN];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

    auto load_stage = [] (int st, int k0) {
        for (int i = tid; i < BM * BK; i += blockDim.x * blockDim.y)
            (&s_a[st][0][0])[i] = A[(br + i / BK) * K + k0 + i % BK];
        for (int i = tid; i < BK * BN; i += blockDim.x * blockDim.y)
            (&s_b[st][0][0])[i] = B[(k0 + i / BN) * N + bc + i % BN];
    };

    load_stage(0, 0);
    __syncthreads();

    int nk = K / BK;

```



```

for (int kt = 0; kt < nk; ++kt) {
    int cur = kt & 1, nxt = (kt + 1) & 1;
    // ★ 先发起下一 stage 的装载（隐藏 gmem->smem 延迟），再算当前 stage
    if (kt + 1 < nk) load_stage(nxt, (kt + 1) * BK);

    // ★ 寄存器双缓冲：每个 k 片先把下一片的 A/B 片段预取进寄存器，再算当前片
    float ra_next[TM], rb_next[TN];
#pragma unroll
    for (int i = 0; i < TM; ++i) ra_next[i] = s_a[cur][c_m + i][0];
#pragma unroll
    for (int j = 0; j < TN; ++j) rb_next[j] = s_b[cur][0][c_n + j];

    for (int k = 0; k < BK; ++k) {
        float ra[TM], rb[TN];
#pragma unroll
        for (int i = 0; i < TM; ++i) ra[i] = ra_next[i];
#pragma unroll
        for (int j = 0; j < TN; ++j) rb[j] = rb_next[j];
        // 预取下一片 (k+1)，与上面的 FMA 在流水线上重叠
        if (k + 1 < BK) {
#pragma unroll
            for (int i = 0; i < TM; ++i) ra_next[i] = s_a[cur][c_m + i][k + 1];
#pragma unroll
            for (int j = 0; j < TN; ++j) rb_next[j] = s_b[cur][k + 1][c_n + j];
        }
#pragma unroll
        for (int i = 0; i < TM; ++i)
#pragma unroll
            for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads();    // ★ 保证所有线程读完 cur，再允许覆写
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
static void ref_sgemm(const std::vector<float>& A, const std::vector<float>& B,
                    std::vector<float>& C, int M, int N, int K) {
    for (int i = 0; i < M; ++i)
        for (int j = 0; j < N; ++j) {

```

```

        double s = 0.0;
        for (int k = 0; k < K; ++k) s += double(A[i * K + k]) * B[k * N + j];
        C[i * N + j] = float(s);
    }
}

int main() {
    TEST_BEGIN("Q184 register double-buffer + XOR swizzle");

    // ---- swizzle 的可逆性自检 (对合) ----
    {
        bool ok = swizzle_is_involution(64, 16);
        printf("  %-34s %s    (S>=B 保证源/目标位域不相交  $\Rightarrow \sigma(\sigma(a))=a$ ) \n",
            "swizzle involution self-check", ok ? "PASS" : "FAIL");
    }

    // ---- 正确性 + 性能 ----
    const int M = 512, N = 512, K = 256;
    std::vector<float> hA(size_t(M) * K), hB(size_t(K) * N), hC(size_t(M) * N), href(size_t(M) * N);
    fill_random(hA, 71u, -1.f, 1.f);
    fill_random(hB, 72u, -1.f, 1.f);
    ref_sgemm(hA, hB, href, M, N, K);

    float *dA, *dB, *dC;
    CUDA_CHECK(cudaMalloc(&dA, hA.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dB, hB.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dC, hC.size() * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dA, hA.data(), hA.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dB, hB.data(), hB.size() * sizeof(float), cudaMemcpyHostToDevice));

    const double flops = 2.0 * M * N * K;
    const double rtol = 1e-4, atol = 1e-4;
    GpuTimer timer;
    dim3 blk(32, 32);

    {
        CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
        dim3 grd(N / 128, M / 128);
        double ms = timer.bench([&] { sgemm_smem_nopad<128, 128, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M, N, K);
        CUDA_CHECK_KERNEL();
        hC = to_host(dC, hC.size());
        report("sgemm_smem_nopad (8-way)", compare(hC, href, rtol, atol), rtol, atol, ms);
        printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
    }
}

```

```

}
{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 grd(N / 128, M / 128);
    double ms = timer.bench([&] { sgemm_smem_pad<128, 128, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M,
    CUDA_CHECK_KERNEL());
    hC = to_host(dC, hC.size());
    report("sgemm_smem_pad (+1)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
}
{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 grd(N / 128, M / 128);
    double ms = timer.bench([&] { sgemm_swizzle<128, 128, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M, N
    CUDA_CHECK_KERNEL());
    hC = to_host(dC, hC.size());
    report("sgemm_swizzle (no pad)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
}
{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 grd(N / 64, M / 64);
    double ms = timer.bench([&] { sgemm_regdbuf<64, 64, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M, N,
    CUDA_CHECK_KERNEL());
    hC = to_host(dC, hC.size());
    report("sgemm_regdbuf (64x64 tile)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
}

printf("\n ★ 观察: padding / swizzle 两个版本的数值结果应当【完全一致】（都是精确重排, \n");
printf("    没有改变任何浮点运算的顺序）；差异只体现在时间上。 \n");
printf("    如果 swizzle 版数值不对, 99% 是「写入与读取用了不同的 swizzle 函数」--\n");
printf("    这不会越界、不会报错, 只是数据在 chunk 粒度错位。 \n");

// ---- 用 ncu 可观察的 bank conflict 探针（单独跑一次即可）----
printf("\n 想看 bank conflict 的实测计数, 用 ncu 抓这两个 kernel 对比: \n");
printf("    ncu --metrics lltex__data_bank_conflicts_pipe_lsu_mem_shared_op_ld.sum \\ \n");
printf("        --kernel-name regex:sgemm_smem_nopad ./q184\n");
printf("    书里的参考量级 (M=N=K=512): BK=16 无 swizzle 98,304 次 / BK=64 无 swizzle\n");
printf("    691,067 次 / BK=64 + swizzle 297,628 次 (8-way -> 4-way, 耗时 30.2 -> 20.7 μs)。 \n");

CUDA_CHECK(cudaFree(dA));
CUDA_CHECK(cudaFree(dB));

```

```
CUDA_CHECK(cudaFree(dC));  
printf("\nQ184 done.\n");  
return 0;  
}
```

Q185 [手撕] ★ 软件流水 (cp.async 多级 stage)

考点：cp.async 多级流水：commit/wait_group 语义、wait 后为什么还要同步 **源**

码： [../code/interview/kernels/q185_sgemm_async.cu](https://github.com/zhongqiangliu/code-interview/blob/master/kernels/q185_sgemm_async.cu) (291 行, sha256 `2b54af484a30`)

```

// q185_sgemmm_async.cu - Q185: 软件流水 (cp.async 多级 stage)
//
// 1) sgemm_sync      -- 同步搬运: 加载 -> __syncthreads -> 计算 -> __syncthreads
// 2) sgemm_async_s2  -- cp.async + 2 级 stage
// 3) sgemm_async_s3  -- cp.async + 3 级 stage (稳态允许 1 组在途)
//
// 编译: ./build.sh q185
//
// -----
// 解析要点
// -----
// ① cp.async 三件套的语义 (★ 必背)
//     cp.async.cg.shared.global [smem], [gmem], 16;
//     - 从 global 直接拷到 shared, **绕过寄存器**
//     - '.cg' 只走 L2、不分配 L1, **16 B 是 '.cg' 唯一合法宽度**
//       ('.ca' 支持 4/8/16 B 且会分配 L1 -- 用 '.cg' 是为了不污染 L1)
//     cp.async.commit_group;
//     - 把**本线程**未提交的拷贝打包成一个组
//     cp.async.wait_group N;
//     - 阻塞到**最多剩 N 组未完成**
//     - ★ N 是"允许保留的未完成组数", **不是"第 N 组完成"**
//     - 建立期/排空期用 0; 稳态满载用 kStages - 2
//
// ② ★ 为什么 wait 之后必须再跟一次 __syncthreads() (这是本题最常考的一问)
//     cp.async 的组是 **per-thread** 的: 'wait_group' 只保证「本线程发出的搬运」完成,
//     而计算要读的 smem **可能由别的线程搬入**。
//     ⇒ 漏掉这一次同步就是 warp 间数据竞争, **症状是偶发错数** (不是稳定错)。
//
// ③ 双缓冲的时序数学
//     单缓冲: T_step = T_ld + T_cp
//     双缓冲: T_step = max(T_ld, T_cp)          ← 稳态
//     S 级流水: 允许 in-flight 的搬运组数为 S - 2
//     ⇒ "加深 stage" 的收益在 S 超过 (搬运延迟 / 迭代时间) 之后归零。
//     书里的实测佐证: FA2 TMA+WS 版 **Sk=2 即饱和** (Sk 2->3 收益 < 0.5%),
//     而 Sk=3 的 smem 增长反而挤掉 2 blocks/SM 的驻留可能。
//
// ④ 本文件用"统一循环" (k 从 0 起跳、带边界条件) 而不是"主循环 + 尾部排空":
//     好处是消除尾部重复代码块, 代价是两个分支判断;
//     对 K 不是 kStages 倍数的形状更稳健。
//
// ⑤b ★ 与 LeetCode `kernels/sgemm/sgemm_async.cu` 的对照 (读源码时别困惑):
//     - 那份实现也是 cp.async 双缓冲, 但 **wait_group 的参数恒为 0**, stage 数固定为 2,
//     换 stage 的写法是 `smem_sel = (bk - 1) & 1; smem_sel_next = bk & 1;`;

```

```

// 它**没有**做到"稳态只等 kStages-2 组", 所以流水深度其实没有真正拉开。
// - 它还**只把 B 走 cp.async**, A 仍然走 LDG -> 寄存器 -> smem (顺带做 online 转置)。
// 本文件两个都走 cp.async (更接近书里 hgemm 的做法), A 不做转置。
// - 它**没有动态 smem** (全部静态分配); 本文件用 `extern __shared__` +
// `cudaFuncSetAttribute`, 因为 S=3 的 96 KB 已经超过 48 KB 的默认上限。
// => 所以"cp.async 双缓冲"这四个字下面至少有三种不同实现, 面试时说清是哪一种。
//
// ⑤ smem 账: A 是 [BM][BK]、B 是 [BK][BN], 两个都是 4 B/元素。
// BM=BN=128, BK=32 时每 stage = (128*32 + 32*128) * 4 = 32 KB;
// S=2 要 64 KB、S=3 要 96 KB — **必须 cudaFuncSetAttribute opt-in**
// (默认每 block 动态 smem 上限只有 48 KB, 超了直接 launch 报 invalid argument)。
// -----

#include "lc_common.cuh"

// -----
// ① 同步搬运 (基准)
// -----

template <int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_sync(const float* __restrict__ A,
                          const float* __restrict__ B,
                          float* __restrict__ C, int M, int N, int K) {
    __shared__ float s_a[BM][BK];
    __shared__ float s_b[BK][BN];
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int a_m = tid / 8, a_k = (tid % 8) * 4;
    const int b_k = tid / 32, b_n = (tid % 32) * 4;
    const int c_m = (tid / 32) * TM, c_n = (tid % 32) * TN;
    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;

    float sum[TM][TN];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

    for (int k0 = 0; k0 < K; k0 += BK) {
        reinterpret_cast<float4*>(&s_a[a_m][a_k]) =
            reinterpret_cast<const float4*>(&A[(br + a_m) * K + k0 + a_k]);
        reinterpret_cast<float4*>(&s_b[b_k][b_n]) =
            reinterpret_cast<const float4*>(&B[(k0 + b_k) * N + bc + b_n]);
        __syncthreads();
        // 加载完 -> 才能算
        for (int k = 0; k < BK; ++k) {

```

```

    float ra[TM], rb[TN];
#pragma unroll
    for (int i = 0; i < TM; ++i) ra[i] = s_a[c_m + i][k];
#pragma unroll
    for (int j = 0; j < TN; ++j) rb[j] = s_b[k][c_n + j];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads(); // 算完 -> 才能覆写
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
// ② / ③ cp.async 多级流水 (kStages 用模板参数)
// -----
template <int kStages, int BM = 128, int BN = 128, int BK = 32, int TM = 4, int TN = 4>
__global__ void sgemm_async(const float* __restrict__ A,
                           const float* __restrict__ B,
                           float* __restrict__ C, int M, int N, int K) {
    extern __shared__ float smem[];
    // 每 stage 的 A 与 B 布局: A[BM][BK]、B[BK][BN]
    constexpr int kAElems = BM * BK;
    constexpr int kBElements = BK * BN;
    constexpr int kStageElems = kAElems + kBElements;
    float* s = smem; // s[stage * kStageElems + ...]

    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int nthreads = blockDim.x * blockDim.y;
    const int c_m = (tid / 32) * TM, c_n = (tid % 32) * TN;
    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;
    constexpr int nk = 0; // (占位, 避免误用)

    float sum[TM][TN];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = 0.0f;

```



```

// 一个 stage 的搬运: 每个线程负责若干个 16 B (4 个 float)
// A: BM*BK/4 个 16B 块; B: BK*BN/4 个 16B 块
auto issue_stage = [] (int stage, int k0) {
    float* sa = s + stage * kStageElems;
    float* sb = sa + kAElems;
    // A 的行主序: 第 m 行、第 k 列 -> 线性 m*BK + k
    for (int idx = tid * 4; idx < kAElems; idx += nthreads * 4) {
        int m = idx / BK, k = idx % BK;
        CP_ASYNC_CG(&sa[idx], &A[(br + m) * K + k0 + k]);
    }
    // B 的行主序: [k][n], 线性 k*BN + n
    for (int idx = tid * 4; idx < kBElems; idx += nthreads * 4) {
        int k = idx / BN, n = idx % BN;
        CP_ASYNC_CG(&sb[idx], &B[(k0 + k) * N + bc + n]);
    }
    CP_ASYNC_COMMIT_GROUP();
};

const int nk_tiles = K / BK;
// 预载 kStages-1 个 stage
for (int t = 0; t < kStages - 1 && t < nk_tiles; ++t) {
    issue_stage(t, t * BK);
}

for (int t = 0; t < nk_tiles; ++t) {
    const int cur = t % kStages;
    // 统一循环: 先补发下一块 (若还在范围内), 再等 + 算
    const int next = t + kStages - 1;
    if (next < nk_tiles) issue_stage(next % kStages, next * BK);

    // 满载期等 (kStages-2) 组; 排空期等 0 组
    if (t + kStages - 1 < nk_tiles) {
        CP_ASYNC_WAIT_GROUP(kStages - 2);
    } else {
        CP_ASYNC_WAIT_GROUP(0);
    }
    __syncthreads();          // ★ per-thread 的组 + 跨线程可见性

    const float* sa = s + cur * kStageElems;
    const float* sb = sa + kAElems;
    for (int k = 0; k < BK; ++k) {
        float ra[TM], rb[TN];

```

```

#pragma unroll
    for (int i = 0; i < TM; ++i) ra[i] = sa[(c_m + i) * BK + k];
#pragma unroll
    for (int j = 0; j < TN; ++j) rb[j] = sb[k * BN + c_n + j];
#pragma unroll
    for (int i = 0; i < TM; ++i)
#pragma unroll
        for (int j = 0; j < TN; ++j) sum[i][j] = fmaf(ra[i], rb[j], sum[i][j]);
    }
    __syncthreads();          // ★ 算完才能让下一轮覆写这个 stage
}

#pragma unroll
for (int i = 0; i < TM; ++i)
    *reinterpret_cast<float4*>(&C[(br + c_m + i) * N + bc + c_n]) =
        make_float4(sum[i][0], sum[i][1], sum[i][2], sum[i][3]);
}

// -----
static void ref_sgemm(const std::vector<float>& A, const std::vector<float>& B,
                    std::vector<float>& C, int M, int N, int K) {
    for (int i = 0; i < M; ++i)
        for (int j = 0; j < N; ++j) {
            double s = 0.0;
            for (int k = 0; k < K; ++k) s += double(A[i * K + k]) * B[k * N + j];
            C[i * N + j] = float(s);
        }
}

int main() {
    TEST_BEGIN("Q185 software pipeline with cp.async");

    const int M = 512, N = 512, K = 512;
    std::vector<float> hA(size_t(M) * K), hB(size_t(K) * N), hC(size_t(M) * N), href(size_t(M) * N);
    fill_random(hA, 81u, -1.f, 1.f);
    fill_random(hB, 82u, -1.f, 1.f);
    ref_sgemm(hA, hB, href, M, N, K);

    float *dA, *dB, *dC;
    CUDA_CHECK(cudaMalloc(&dA, hA.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dB, hB.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dC, hC.size() * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dA, hA.data(), hA.size() * sizeof(float), cudaMemcpyHostToDevice));

```

```

CUDA_CHECK(cudaMemcpy(dB, hB.data(), hB.size() * sizeof(float), cudaMemcpyHostToDevice));

const double flops = 2.0 * M * N * K;
const double rtol = 1e-4, atol = 1e-4;
GpuTimer timer;
dim3 blk(32, 32), grd(N / 128, M / 128);

// 每个 stage 的字节数 (动态 smem)
constexpr int kAElems = 128 * 32, kBElems = 32 * 128;
const int stage_bytes = (kAElems + kBElems) * 4; // = 32 KB

{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    double ms = timer.bench([&] { sgemm_sync<128, 128, 32, 4, 4><<<grd, blk>>>(dA, dB, dC, M, N, K);
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("sgemm_sync (no pipeline)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
}

// S=2: 动态 smem = 64 KB > 48 KB 默认上限 ⇒ 必须 opt-in
{
    const int smem_bytes = stage_bytes * 2;
    CUDA_CHECK(cudaFuncSetAttribute(sgemm_async<2, 128, 128, 32, 4, 4>,
                                     cudaFuncAttributeMaxDynamicSharedMemorySize, smem_bytes));
    printf("  cp.async S=2 需要动态 smem %d B (opt-in 上限 %d B)\n", smem_bytes,
           dev.smem_per_block_optin);
    if (smem_bytes > dev.smem_per_block_optin) {
        printf("  SKIP: 超过本机 opt-in 上限\n");
    } else {
        CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
        double ms = timer.bench([&] {
            sgemm_async<2, 128, 128, 32, 4, 4><<<grd, blk, smem_bytes>>>(dA, dB, dC, M, N, K);
        });
        CUDA_CHECK_KERNEL();
        hC = to_host(dC, hC.size());
        report("sgemm_async S=2 (wait<0>)", compare(hC, href, rtol, atol), rtol, atol, ms);
        printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
    }
}

// S=3: 96 KB, 进一步考验 opt-in 上限
{

```

```

const int smem_bytes = stage_bytes * 3;
printf("  cp.async S=3 需要动态 smem %d B\n", smem_bytes);
if (smem_bytes > dev.smem_per_block_optin) {
    printf("  SKIP: 超过本机 opt-in 上限 (%d B) — 这正是「stage 不是越深越好」的物理上限\n",
           dev.smem_per_block_optin);
} else {
    CUDA_CHECK(cudaFuncSetAttribute(sgemmm_async<3, 128, 128, 32, 4, 4>,
                                     cudaFuncAttributeMaxDynamicSharedMemorySize, smem_bytes));
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    double ms = timer.bench([&] {
        sgemm_async<3, 128, 128, 32, 4, 4><<<grd, blk, smem_bytes>>>>(dA, dB, dC, M, N, K);
    });
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("sgemm_async S=3 (wait<1>)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
    printf("          ★ 注意 stage 加深会挤占 occupancy: S=3 的 96 KB 让每 SM 只能驻留 1 个\n");
    printf("          block (本机 smem/SM 约 %d B), stage 的收益可能被 occupancy 抵消.\n",
           dev.smem_per_block_optin);
}
}

printf("\n 用 ncu 验证流水是否真的生效: \n");
printf("  ncu --metrics smp__average_warps_issue_stalled_long_scoreboard_per_issue_active.rat
printf("  --kernel-name regex:sgemm_ --launch-count 2 ./q185\n");
printf("  cp.async 版应当看到 long_scoreboard 明显下降 (装载不再裸露)。\n");

CUDA_CHECK(cudaFree(dA));
CUDA_CHECK(cudaFree(dB));
CUDA_CHECK(cudaFree(dC));
printf("\nQ185 done.\n");
return 0;
}

```

Q186 [手撕] ★ Tensor Core HGEMM (mma.sync m16n8k16 + ldmatrix + 3 级流水)

考点: mma.sync m16n8k16 + ldmatrix 手写 HGEMM (对照 WMMA 版) 源

码: [../code/interview/kernels/q186_hgemm_mma.cu](https://code.interview/kernels/q186_hgemm_mma.cu) (319 行, sha256 30fda8f31f9a)

```
// q186_hgemmmma.cu - Q186: Tensor Core HGEMM (mma.sync m16n8k16 + ldmatrix + 3 级流水)
//
// 1) hgemmmmma      -- 用 WMMA API (m16n16k16) 的版本: 能跑, 但看不到 fragment
// 2) hgemmmmma      -- 手写 PTX: mma.sync.aligned.m16n8k16 + ldmatrix + cp.async 三级流水
//
// 编译: ./build.sh q186      (需要 sm_80+)
//
// -----
// 解析要点
// -----
// ① ★ 指令逐字段 (面试会让你念)
//      mma.sync.aligned.m16n8k16.row.col.f16.f16.f16.f16 {d0,d1},{a0..a3},{b0,b1},{c0,c1};
//      .sync      全 warp 到齐才继续
//      .aligned **要求全 warp 执行同一条指令 ⇒ 条件分歧下使用未定义行为**
//      .m16n8k16 A 16x16 / B 16x8 / C,D 16x8 ⇒ 一条 =  $2 \times 16 \times 8 \times 16 = 4096$  FLOP**
//      .row/.col 是 A/B 的 fragment 主序
//      四个类型依次 D/A/B/C; 变体 f32.f16.f16.f32 用 4 个 f32 寄存器做累加
//
// ② ★ fragment 几何 (口诀:  $g = \text{lane} \gg 2$  管行/列块,  $\text{tig} = \text{lane} \bmod 4$  管 2 元素对)
//      A: row =  $g$  ( $i < 2$  或  $4 \leq i < 6$ ) 否则  $g+8$ ; col =  $2 \times \text{tig} + (i \% 2) + 8 \times [i \geq 4]$ 
//      ⇒ 每 lane 持两行、四个寄存器按 [左上, 左下, 右上, 右下] 四象限排布
//      B: row =  $2 \times \text{tig} + (i \% 2) + 8 \times [i \geq 2]$ ; col =  $g$ 
//      C: row =  $g + 8 \times [i \geq 2]$ ; col =  $2 \times \text{tig} + (i \% 2)$ 
//      寄存器带宽 (每 warp 每条指令): A 4 个 .b32、B 2 个、C/D 各 2 个。
//
// ③ ★ 精度语义 (PTX 原文三条, 必须背)
//      1) 元素乘【至少单精度】执行;
//      2) **C 与 D 都是 .f16 时累加至少半精度** -- f16.f16.f16.f16 变体在**每条 mma
//          边界处都舍回 fp16**, K 很长时误差沿 ** $\sqrt{K}$ ** 增长 (书里实测  $K=128$  约  $1.5e-2$ );
//      3) PTX 明确声明**累加顺序、舍入与次正规处理均未指定** ⇒ 不同架构/驱动逐位
//          结果可不同 ⇒ **正确性判定必须用容差** (本文件用  $\text{TOL\_F16ACC} = 5e-2$ )。
//
// ④ ★ ldmatrix 的寻址协议
//      ldmatrix.sync.aligned.m8n8.x4.shared.b16 {r0,r1,r2,r3}, [addr];
//      - 每矩阵 8 行 → **8 个 lane 各供一行 16 B 的首地址**
//      - x4 用全 32 lane 的地址 (lane t 的地址属于第  $t/8$  个矩阵的第  $t \% 8$  行);
//      - x2 只用 lane 0-15 (lane 16-31 的地址被硬件忽略)
//      - `.trans` 是"按列主序装载"; **不加 .trans 才是行装载**
//      (书里源码注释在这一点上写反了, 以 PTX ISA 为准)
//      - 结果天然匹配 mma fragment: 矩阵 i 的行 r 落在 lane  $4r + \text{tig}$  的寄存器 r_i
//
// ⑤ ★ TN 布局为什么是默认姿势
//      A 行主序 + **B^T 行主序** ⇒ 两侧内维都是 K、搬运对称 16 B 连续;
```

```

// 且 mma 要求的 .row.col 恰好被「逐行装 B^T = 逐列装 B」天然满足
// => **ldmatrix 一个 .trans 都不用加**。
//
// ⑥ 怎么确认真的跑在 Tensor Core 上（两级证据）
// SASS: cuobjdump -sass ./q186 | grep -E "HMMA.16816|LDSM"
// ncu : sm__inst_executed_pipe_tensor_op 应当主导；
// **若 HMMA 计数为零而 FFMA/HFMA2 居高 => 被宏门控剪掉、走了 CUDA Core fallback**
// -----

#include "lc_common.cuh"
#include <cuda_fp16.h>
#include <mma.h>

// smem 地址转 u32 (ldmatrix 的地址操作数要求 .shared 空间的 32-bit 地址)
__device__ __forceinline__ unsigned smem_u32(const void* p) {
    return static_cast<unsigned>(__cvta_generic_to_shared(p));
}

// -----
// ① WMMA 参考版（能看到“厚抽象”的代价：fragment 布局不可假设）
// -----
namespace wmma = nvcuda::wmma;

template <int BM = 128, int BN = 128, int BK = 16, int WMMA_M = 16, int WMMA_N = 16,
          int WMMA_K = 16>
__global__ void hgemm_wmma(const __half* __restrict__ A, const __half* __restrict__ Bt,
                           float* __restrict__ C, int M, int N, int K) {
    using namespace wmma;
    __shared__ __half s_a[BM][BK];
    __shared__ __half s_b[BN][BK];          // ★ B^T 行主序: TN 布局
    const int tid = threadIdx.y * blockDim.x + threadIdx.x;
    const int warp = tid / 32;
    const int warp_m = warp % 2, warp_n = warp / 2;    // 2x4 warp 排布

    fragment<matrix_a, WMMA_M, WMMA_N, WMMA_K, __half, row_major> a_frag;
    fragment<matrix_b, WMMA_M, WMMA_N, WMMA_K, __half, row_major> b_frag;
    fragment<accumulator, WMMA_M, WMMA_N, WMMA_K, float> c_frag;
    fill_fragment(c_frag, 0.0f);

    const int br = blockIdx.y * BM, bc = blockIdx.x * BN;
    for (int k0 = 0; k0 < K; k0 += BK) {
        // 加载 A tile 与 B^T tile: 每线程搬 2 个 half (4 B) — 教学写法, 不追求最优
        for (int i = tid; i < BM * BK; i += blockDim.x * blockDim.y)

```

```

    s_a[i / BK][i % BK] = A[(br + i / BK) * K + k0 + i % BK];
for (int i = tid; i < BN * BK; i += blockDim.x * blockDim.y)
    s_b[i / BK][i % BK] = Bt[(bc + i / BK) * K + k0 + i % BK];
__syncthreads();

for (int kk = 0; kk < BK; kk += WMMA_K) {
    // 每个 warp 负责 [warp_m*2*WMMA_M .. ] x [warp_n*4*WMMA_N ..] 的子块
#pragma unroll
    for (int mi = 0; mi < 2; ++mi) {
        load_matrix_sync(a_frag, &s_a[warp_m * 2 * WMMA_M + mi * WMMA_M][kk], BK);
#pragma unroll
        for (int ni = 0; ni < 4; ++ni) {
            load_matrix_sync(b_frag, &s_b[warp_n * 4 * WMMA_N + ni * WMMA_N][kk], BK);
            mma_sync(c_frag, a_frag, b_frag, c_frag);
        }
    }
    __syncthreads();
}

// ★ accumulator 的 fragment 布局不可假设 ⇒ 必须用 store_matrix_sync 落地
__shared__ float s_c[BM][BN];
#pragma unroll
for (int mi = 0; mi < 2; ++mi) {
    for (int ni = 0; ni < 4; ++ni) {
        // 这里只演示一个 fragment 的落地（完整版应循环 mi/ni）
        if (mi == 0 && ni == 0) {
            load_matrix_sync(a_frag, &s_a[0][0], BK); // 占位，避免未使用告警
        }
    }
}

// 简化：直接把 c_frag 落到全局（每个 warp 覆盖自己的子块）
store_matrix_sync(&s_c[warp_m * 2 * WMMA_M][warp_n * 4 * WMMA_N], c_frag, BN,
    mem_row_major);
__syncthreads();
for (int i = tid; i < BM * BN; i += blockDim.x * blockDim.y)
    C[(br + i / BN) * N + (bc + i % BN)] = s_c[i / BN][i % BN];
}

// -----
// ② 手写 mma 版：BM=128, BN=128, BK=16, 3 级 cp.async 流水
// 配置：kMmaM=16, kMmaN=8, kMmaK=16, kMmaTileM=2, kMmaTileN=4, kValTileM=4, kValTileN=4
// BM = 16*2*4 = 128, BN = 8*4*4 = 128, BK = 16

```



```
// -----
template <int kStages = 3, int BM = 128, int BN = 128, int BK = 16>
__global__ void __launch_bounds__(256) hgemm_mma(const __half* __restrict__ A,
                                                const __half* __restrict__ Bt,
                                                float* __restrict__ C, int M, int N,
                                                int K) {

    constexpr int kMmaM = 16, kMmaN = 8, kMmaK = 16;
    constexpr int kTileM = 2, kTileN = 4;      // warp 间排布: 2M x 4N = 8 warp
    constexpr int kValM = 4, kValN = 4;        // warp 内 fragment 重复: 4x4
    extern __shared__ __half smem[];           // [kStages][BM][BK] + [kStages][BN][BK]
    constexpr int kAElems = BM * BK;
    constexpr int kBElems = BN * BK;
    constexpr int kStageElems = kAElems + kBElems;

    const int tid = threadIdx.x;
    const int warp = tid / 32, lane = tid % 32;
    const int warp_m = warp % kTileM;          // 列主序排布 (warp_m = warp_id % 2)
    const int warp_n = warp / kTileM;
    const int g = lane >> 2, tig = lane & 3;    // fragment 几何用到的两个量

    // warp tile = (kMmaM * kValM) x (kMmaN * kValN) = 64 x 32
    const int wm_base = warp_m * (kMmaM * kValM);
    const int wn_base = warp_n * (kMmaN * kValN);

    // ---- cp.async 搬运: 每线程一次搬 16 B (= 8 个 half, 恰好半行) ----
    auto issue_stage = [] (int stage, int k0) {
        __half* sa = smem + stage * kStageElems;
        __half* sb = sa + kAElems;
        // A: tid/2 定行 (0..127), tid%2 选 16 B 半行 (k 的 0-7 或 8-15)
        {
            int row = tid / 2, half_sel = tid % 2;
            CP_ASYNC_CG(&sa[row * BK + half_sel * 8],
                        &A[(blockIdx.y * BM + row) * K + k0 + half_sel * 8]);
        }
        // B (B^T 行主序, [BN][K]): 同样按 n 定行
        {
            int row = tid / 2, half_sel = tid % 2;
            CP_ASYNC_CG(&sb[row * BK + half_sel * 8],
                        &Bt[(blockIdx.x * BN + row) * K + k0 + half_sel * 8]);
        }
        CP_ASYNC_COMMIT_GROUP();
    };
};
```

```

float RC[kValM][kValN][4];          // ★ f32 累加: C 用 4 个 f32 寄存器
#pragma unroll
for (int i = 0; i < kValM; ++i)
#pragma unroll
    for (int j = 0; j < kValN; ++j)
#pragma unroll
        for (int r = 0; r < 4; ++r) RC[i][j][r] = 0.0f;

const int nk_tiles = K / BK;
for (int t = 0; t < kStages - 1 && t < nk_tiles; ++t) issue_stage(t, t * BK);

for (int t = 0; t < nk_tiles; ++t) {
    const int next = t + kStages - 1;
    if (next < nk_tiles) issue_stage(next % kStages, next * BK);
    if (t + kStages - 1 < nk_tiles)
        CP_ASYNC_WAIT_GROUP(kStages - 2);
    else
        CP_ASYNC_WAIT_GROUP(0);
    __syncthreads();

    const __half* sa = smem + (t % kStages) * kStageElems;
    const __half* sb = sa + kAElems;

#pragma unroll
    for (int mi = 0; mi < kValM; ++mi) {
#pragma unroll
        for (int ni = 0; ni < kValN; ++ni) {
            uint32_t RA[4], RB[2];
            // ---- ldmatrix: x4 装 A 的 16x16 (lane t -> 第 t/8 个矩阵的第 t%8 行) ----
            {
                int row = wm_base + mi * kMmaM + (lane % 16);          // 16 行由 lane 0-15 提供
                int col8 = ((lane / 16) % 2) * 8;                      // 左右两个 8 列
                LDMATRIX_X4(RA, smem_u32(&sa[row * BK + col8]));
            }
            // ---- ldmatrix x2 装 B 的 16x8 (只需 lane 0-15 的地址) ----
            {
                int row = wn_base + ni * kMmaN + (lane % 8);
                int col8 = ((lane / 8) % 2) * 8;
                LDMATRIX_X2(RB, smem_u32(&sb[row * BK + col8]));
            }
            (void)g;
            (void)tig;
            HMMA16816_F32(RC[mi][ni], RA, RB, RC[mi][ni]);
        }
    }
}

```

```

    }
}
__syncthreads();
}

// ---- epilogue: C fragment 每 lane 持 (row = g/g+8, col = 2*tig + i%2) ----
// 简化写出: 每个 lane 写它的 4 个元素 (不做 shuffle 收拢, 避免过度复杂)
#pragma unroll
for (int mi = 0; mi < kValM; ++mi) {
#pragma unroll
    for (int ni = 0; ni < kValN; ++ni) {
        const int r0 = blockIdx.y * BM + wm_base + mi * kMmaM + g;
        const int c0 = blockIdx.x * BN + wn_base + ni * kMmaN + 2 * tig;
        C[r0 * N + c0 + 0] = RC[mi][ni][0];
        C[r0 * N + c0 + 1] = RC[mi][ni][1];
        C[(r0 + 8) * N + c0 + 0] = RC[mi][ni][2];
        C[(r0 + 8) * N + c0 + 1] = RC[mi][ni][3];
    }
}
}

// -----
// host 侧参考
// -----
static void ref_hgemm(const std::vector<float>& A, const std::vector<float>& Bt,
                    std::vector<float>& C, int M, int N, int K) {
    // A: [M][K], Bt: [N][K] (B^T 行主序)
    for (int i = 0; i < M; ++i)
        for (int j = 0; j < N; ++j) {
            double s = 0.0;
            for (int k = 0; k < K; ++k) s += double(A[i * K + k]) * Bt[j * K + k];
            C[i * N + j] = float(s);
        }
}

int main() {
    TEST_BEGIN("Q186 Tensor Core HGEMM (wmma / mma.sync)");
    REQUIRE_ARCH(8, 0, "mma.sync m16n8k16 / WMMA 需要 sm_80+");

    const int M = 256, N = 256, K = 128;
    std::vector<float> hA(size_t(M) * K), hB(size_t(N) * K), hC(size_t(M) * N),
        href(size_t(M) * N);
    fill_random(hA, 91u, -1.f, 1.f);

```

```

fill_random(hB, 92u, -1.f, 1.f);
ref_hgemm(hA, hB, href, M, N, K);

std::vector<__half> hAh(hA.size()), hBh(hB.size());
for (size_t i = 0; i < hA.size(); ++i) hAh[i] = __float2half(hA[i]);
for (size_t i = 0; i < hB.size(); ++i) hBh[i] = __float2half(hB[i]);

__half *dA, *dB;
float* dC;
CUDA_CHECK(cudaMalloc(&dA, hAh.size() * sizeof(__half)));
CUDA_CHECK(cudaMalloc(&dB, hBh.size() * sizeof(__half)));
CUDA_CHECK(cudaMalloc(&dC, hC.size() * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dA, hAh.data(), hAh.size() * sizeof(__half), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(dB, hBh.data(), hBh.size() * sizeof(__half), cudaMemcpyHostToDevice));

// ★ 容差口径（书里用的三档）：F16Acc 5e-2 / F32Acc 1e-3 / TF32 1e-2
// 本 kernel 用 f32 累加 ⇒ 取 1e-3；但输入被截成 half ⇒ 还要容纳输入量化误差
const double rtol = 1e-2, atol = 1e-2;
const double flops = 2.0 * M * N * K;
GpuTimer timer;

{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    dim3 blk(32, 8), grd(N / 128, M / 128);
    double ms = timer.bench([&] { hgemm_wmma<128, 128, 16><<<grd, blk>>>(dA, dB, dC, M, N, K); });
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("hgemm_wmma (WMMMA API)", compare(hC, href, rtol, atol), rtol, atol, ms);
    printf("          %.2f TFLOPS\n", to_tflops(flops, ms));
}

{
    CUDA_CHECK(cudaMemset(dC, 0, hC.size() * sizeof(float)));
    constexpr int kStages = 3;
    const int smem_bytes = kStages * (128 * 16 + 128 * 16) * sizeof(__half); // 24 KB
    CUDA_CHECK(cudaFuncSetAttribute(hgemm_mma<kStages, 128, 128, 16>,
                                     cudaFuncAttributeMaxDynamicSharedMemorySize, smem_bytes));
    dim3 blk(256, 1), grd(N / 128, M / 128);
    double ms = timer.bench([&] {
        hgemm_mma<kStages, 128, 128, 16><<<grd, blk, smem_bytes>>>(dA, dB, dC, M, N, K);
    });
    CUDA_CHECK_KERNEL();
    hC = to_host(dC, hC.size());
    report("hgemm_mma (m16n8k16 PTX)", compare(hC, href, rtol, atol), rtol, atol, ms);
}

```

```

    printf("        %.2f TFLOPS    smem=%d B (kStages=%d)\n", to_tflops(flops, ms),
           smem_bytes, kStages);
}

printf("\n  验证真的跑在 Tensor Core 上 (两级证据): \n");
printf("    cuobjdump -sass ./q186 | grep -cE 'HMMA|LDSM'        # 应当非零\n");
printf("    ncu --metrics sm__inst_executed_pipe_tensor_op.avg.pct_of_peak_sustained_elapsed \\\
printf("        --kernel-name regex:hgemm_mma ./q186\n");
printf("    ★ 若 HMMA 计数为零而 FFMA/HFMA2 居高 ⇒ 走了 CUDA Core fallback. \n");
printf("\n  书里的参考量级 (PRO 5000, 1024^3): TF32 WMMA 28.19 T -> 手写 mma 76.55 T. \n");
printf("  差距来自三层: f16 通路本身更快、BK 从 8 提到 16 (发射密度翻倍)、三级流水同步更松. \n");

CUDA_CHECK(cudaFree(dA));
CUDA_CHECK(cudaFree(dB));
CUDA_CHECK(cudaFree(dC));
printf("\nQ186 done.\n");
return 0;
}

```

Q187 [hard] ★ Warp Specialization (TMA + mbarrier) 骨架

考点: TMA + mbarrier + WS 骨架: arrive count 怎么算、账本不闭合的两种后果 **源**

码: [../code/interview/kernels/q187_hgemm_ws_tma.cu](https://code.interview.kernels/q187_hgemm_ws_tma.cu) (262 行, sha256 715944e09f27)

```

// q187_hgemm_ws_tma.cu - Q187: Warp Specialization (TMA + mbarrier) 骨架
//
// 1) hgemm_ws_tma -- 1 producer warpgroup(128T) + 1 consumer warpgroup(256T) 的骨架
//
// 编译: ./build.sh q187      (需要 sm_90a / sm_90+, 且 CUDA >= 12.0: TMA 的 driver API 见下)
//
// -----
// 解析要点
// -----
// ① ★ 三件新原语各解决什么 (这是本题的骨架, 先讲清再写码)
//      TMA (cp.async.bulk.tensor.2d)
//      - 一条指令**由单线程提交**, 硬件 DMA 搬整块 2D tile
//      - **地址计算 / OOB 填充 / smem swizzle 全在 descriptor 里声明**
//      - **搬运过程零寄存器开销** (这是相对 cp.async 最大的差别:
//        cp.async 每线程仍要算地址、占发射槽)
//      mbarrier
//      - 自带 **arrive count** 与 **tx count** 两个独立计数器
//      - TMA 搬完指定字节数后**硬件自动做 complete-tx 记账**
//      - **相位翻转条件:  $P = 0 \wedge T = 0$ **
//      - ★ 核心洞察: **「多少个信号」与「多少字节数据」是两把独立的锁**
//        ⇒ producer / consumer 之间**不需要任何 __syncthreads**
//      WGMMMA
//      - 矩阵乘从 warp 级 (32 线程) 升到 **warpgroup 级 (128 线程)**
//      - A/B **直接从 smem 读**, 不需要 ldmatrix 中转
//      - **异步**: 发射后 warpgroup 继续推进, 用 wgmma.wait_group 收割
//      ⚠ 本文件面向 **sm_90a**:, 如果在 sm_120 上编译 WGMMMA 部分会失败,
//        用 '-DSKIP_WGMMMA=1' 编译可只保留 TMA + mbarrier 的骨架 (消费侧用 mma.sync)。
//
// ② ★ arrive count 怎么算 (年年考、最容易错)
//      129 = 128 + 1: consumer 是**整个 128 线程 warpgroup** (warpgroup 对齐指令)
//      257 = 256 + 1: consumer 用 **warp 级 mma.sync** 时, **8 个 warp 独立推进,
//        每个线程都必须 arrive 一次**
//      129 (FA3 的 per-WG): 屏障按 [cid][stage] 切开, 每张只放行一个 WG
//      ⇒ **「协议只认线程数, 不认角色」**。
//      本文件是 WGMMMA 路径 ⇒ **129**。
//
// ③ ★ 账本不闭合的两种后果
//      **少算 ⇒ 永不翻转 ⇒ 挂死** (没有报错、没有超时, 最难查)
//      **多算 ⇒ 提前翻转 ⇒ 读到半新半旧数据 ⇒ 静默错误** (更危险)
//      TMA 的 expect_tx 同理: **少报挂死、多报静默错**。
//
// ④ ★ producer / consumer 的分工与「点火」
//      producer 四拍: P0 装 A 一次 (arrive_expect_tx); P1 预取前 Sk-1 个 stage;

```

```

//          P2 稳态循环 (等 empty -> 发 TMA -> arrive_expect_tx)
//      consumer: **C0 点火** = 把每张 empty[s] 预存 kConsumerThreads 次 arrive,
//          然后 full_Q.wait(...) 一次 -- **漏掉 C0 就是全体挂死**.
//
// ⑤ ★ 两个 ptxas 静默降级陷阱
//      TMA dst 写成 `shared::cluster` => ptxas 以 **C7506 静默丢弃 setmaxnreg**
//          (必须写 `shared::cta`)
//      `__launch_bounds__(N)` 缺第二个参数 => **C7508**
//      排查: cuobjdump -sass 检索 `USETMAXREG` (注意 SASS 助记符没有 "n")
//
// ⑥ ★ 一个「挂死但没有任何报错」的经典事故 (setmaxnreg 池数学)
//      每 SM 寄存器文件 65536 个, triple-WG 配置提出公因子 128 =>  $r_p + 2 \cdot r_c \leq 512$ 
//      正常  $40 + 2 \cdot 168 = 376$ ; **事故  $64 + 2 \cdot 224 = 512$  (恰好等于上界)**
//      -- 驱动对寄存器文件另有保留份额、有效池小于 65536 => alloc 永远凑不齐 =>
//      **consumer 卡在 setmaxnreg、producer 卡在等 barrier arrive, 双向互等纯挂死**
//      修复: 留  $\geq 2048$  slack =>  $64/208/208 = 480$ .
//  _____

#include "lc_common.cuh"

#if defined(__CUDA_ARCH__) && (__CUDA_ARCH__ < 900)
#define SKIP_TMA_IMPL 1
#else
#define SKIP_TMA_IMPL 0
#endif

// driver API: cuTensorMapEncodeTiled. build.sh 会尝试 -lcuda;
// 拿不到就 dlopen, 避免"驱动 API 头找不到"导致整个文件编译不过。
#if !SKIP_TMA_IMPL
#include <cuda.h>

// -----
// TMA 装载: 一条指令搬整块 2D tile
// -----
__device__ __forceinline__ void tma_load_2d(const CUtensorMap* map, void* smem_dst,
                                             int c0, int c1) {
    unsigned s = static_cast<unsigned>(__cvta_generic_to_shared(smem_dst));
    asm volatile(
        "cp.async.bulk.tensor.2d.shared::cluster.global.mbarrier::complete_tx::bytes"
        " [%0], [%1, {%2, %3}], [%4];\n" :: "r"(s),
        "l"(reinterpret_cast<uint64_t>(map)), "r"(c0), "r"(c1), "r"(0));
}

```



```

// mbarrier: init / arrive_expect_tx / arrive / wait
__device__ __forceinline__ void mbar_init(uint64_t* bar, unsigned count) {
    unsigned s = static_cast<unsigned>(__cvta_generic_to_shared(bar));
    asm volatile("mbarrier.init.shared::cta.b64 [%0], %1;\n" ::"r"(s), "r"(count));
}

__device__ __forceinline__ void mbar_arrive_expect_tx(uint64_t* bar, unsigned bytes) {
    unsigned s = static_cast<unsigned>(__cvta_generic_to_shared(bar));
    asm volatile(
        "mbarrier.arrive.expect_tx.shared::cta.b64 _, [%0], %1;\n" ::"r"(s), "r"(bytes));
}

__device__ __forceinline__ void mbar_arrive(uint64_t* bar) {
    unsigned s = static_cast<unsigned>(__cvta_generic_to_shared(bar));
    asm volatile("mbarrier.arrive.shared::cta.b64 _, [%0];\n" ::"r"(s));
}

// 等到相位翻转（阻塞版，教学用；生产应用 try_wait 循环 + nanosleep 退避）
__device__ __forceinline__ void mbar_wait(uint64_t* bar, unsigned phase) {
    unsigned s = static_cast<unsigned>(__cvta_generic_to_shared(bar));
    asm volatile(
        "{\n\t.reg .pred P;\n\t"
        "WAIT:\n\t"
        "mbarrier.try_wait.parity.shared::cta.b64 P, [%0], %1;\n\t"
        "@!P bra WAIT;\n\t}\n" ::"r"(s),
        "r"(phase));
}

// TMA 是"异步代理", 写进 smem 的数据要 fence 之后普通 load 才可见
__device__ __forceinline__ void fence_proxy_async_shared() {
    asm volatile("fence.proxy.async.shared::cta;\n" ::);
}

// setmaxnreg: producer 释放寄存器、consumer 领走
__device__ __forceinline__ void reg_dealloc(unsigned n) {
    asm volatile("setmaxnreg.dec.sync.aligned.u32 %0;\n" ::"n"(n));
}

__device__ __forceinline__ void reg_alloc(unsigned n) {
    asm volatile("setmaxnreg.inc.sync.aligned.u32 %0;\n" ::"n"(n));
}

#endif // !SKIP_TMA_IMPL

// -----
// WS 骨架: 128 producer + 256 consumer = 384 线程
// BM = BN = 128, BK = 64 (A/B 各 128*64 half = 16 KB / stage)
// -----

#define SK_STAGES 2
#define BM 128

```

```

#define BN 128
#define BK 64
#define CONSUMER_THREADS 256
#define ARRIVE_COUNT (CONSUMER_THREADS + 1) // ★ 257: warp 级 mma.sync 的算法
// 若消费侧换成 WGMMMA (warpgroup 对齐), 应改成 129

// no-launch: 本文件是【协议骨架】— 真正的 launch 需要 host 侧先用
// cuTensorMapEncodeTiled 构造 descriptor 并用 __grid_constant__ 传入,
// 那段 host 代码约 40 行、与要讲的协议无关, 故此处只保留 kernel 结构。
__global__ void __launch_bounds__(384, 1)
hgemm_ws_tma(const __grid_constant__ CUtensorMap tma_a,
             const __grid_constant__ CUtensorMap tma_b, float* __restrict__ C, int M,
             int N, int K) {
#ifdef SKIP_TMA_IMPL
    if (threadIdx.x == 0 && blockIdx.x == 0)
        printf(" (arch < sm_90: TMA/mbarrier 路径已跳过)\n");
#else
    extern __shared__ __align__(1024) char smem_raw[]; // ★ 1024B 对齐是硬约束
    __half* s_a = reinterpret_cast<__half*>(smem_raw); // [Sk][BM][BK]
    __half* s_b = s_a + SK_STAGES * BM * BK; // [Sk][BN][BK]
    __shared__ __align__(8) uint64_t full[SK_STAGES], empty[SK_STAGES];

    constexpr int kTileBytesA = BM * BK * sizeof(__half); // 16 KB
    constexpr int kTileBytesB = BN * BK * sizeof(__half); // 16 KB
    const int tid = threadIdx.x;
    const bool is_producer = (tid < 128);
    const int prod_tid = tid; // producer 用 0..127
    const int cons_tid = tid - 128; // consumer 用 0..255

    // ---- 屏障初始化 (一个线程做即可) ----
    if (tid == 0) {
#pragma unroll
        for (int s = 0; s < SK_STAGES; ++s) {
            mbar_init(&full[s], ARRIVE_COUNT);
            mbar_init(&empty[s], ARRIVE_COUNT);
        }
    }

    __syncthreads(); // 只用于保证 init 可见 (init 之后就没用了)

    const int nk_tiles = K / BK;
    const int m_tiles = M / BM;
    const int bm = blockIdx.y % m_tiles;
    const int bn = blockIdx.y / m_tiles;

```

```

if (is_producer) {
    // ----- producer: 只有 thread 0 真正发 TMA -----
    if (prod_tid == 0) {
        for (int t = 0; t < nk_tiles; ++t) {
            const int st = t % SK_STAGES;
            const unsigned phase = (t / SK_STAGES) & 1;
            mbar_wait(&empty[st], phase ^ 1);      // 等 consumer 释放该 stage
            tma_load_2d(&tma_a, &s_a[st * BM * BK], /*k0=*/t * BK, /*m0=*/bm * BM);
            tma_load_2d(&tma_b, &s_b[st * BN * BK], /*k0=*/t * BK, /*n0=*/bn * BN);
            // ★ 一个 K-tile 的 A+B 共 32768 B, 一次声明总事务量
            mbar_arrive_expect_tx(&full[st], kTileBytesA + kTileBytesB);
        }
    }
} else {
    // ----- consumer: mbarrier 协调, 消费侧用 mma.sync -----
    // ★ C0 点火: 每张 empty[s] 预存 [本 WG 线程数] 次 arrive。
    // 漏掉这一步 ⇒ producer 首轮等 empty 永远等不到 ⇒ 全体挂死 (而且没有任何报错)。
#pragma unroll
    for (int s = 0; s < SK_STAGES; ++s) mbar_arrive(&empty[s]);

    const int lane = cons_tid % 32, warp = cons_tid / 32;
    (void)lane;
    (void)warp;
    float acc[4] = {0.f, 0.f, 0.f, 0.f};

    for (int t = 0; t < nk_tiles; ++t) {
        const int st = t % SK_STAGES;
        const unsigned phase = (t / SK_STAGES) & 1;

        // 拍一: 等数据落盘 (P = 0 ∧ T = 0 才翻相位), 然后 fence 才能读
        mbar_wait(&full[st], phase);
        fence_proxy_async_shared();

        // 拍二/拍三: 这里本该是 ldmatrix + HMMA + softmax 之类;
        // 完整实现见 q186 (本文件只保留协议骨架, 不重复贴 100 行 mma 代码)。
        // 拍四: ★ early release — 数据已进寄存器就放行该 stage,
        // producer 因此最早可以在下一拍就开始覆盖它。
        mbar_arrive(&empty[st]);
    }

    // 收尾: epilogue 归 consumer (producer 早就流到头退出了)
    if (cons_tid == 0) C[0] = acc[0];
}

```

```

}
#endif // SKIP_TMA_IMPL
}

int main() {
    TEST_BEGIN("Q187 warp specialization skeleton (TMA + mbarrier + WGMMMA)");

    printf("\n 这一题是【骨架 + 协议】，不是完整可用的 HGEMM: \n");
    printf("    完整 TMA HGEMM 需要 host 侧先用 cuTensorMapEncodeTiled 建 descriptor\n");
    printf("    (row-major 时 globalDim 写作 (K, M) — minor 在前，这是最容易背反的约定)，\n");
    printf("    再用 __grid_constant__ 传进 kernel。那段 host 代码 40 行、与算法无关，\n");
    printf("    本文件省略，只保留面试要讲的三件事：TMA 装载、mbarrier 账本、WS 分工。 \n\n");

    printf("  ★ 账本（本题要背的数字）： \n");
    printf("    arrive count = %d    (%d consumer + 1 producer) \n", ARRIVE_COUNT,
        CONSUMER_THREADS);
    printf("    每个 stage 的 expect_tx = %d B (A %d KB + B %d KB) \n",
        (BM * BK + BN * BK) * 2, BM * BK * 2 / 1024, BN * BK * 2 / 1024);
    printf("    相位翻转条件：P = 0 ∧ T = 0\n");
    printf("    smem = %d stages x %d KB = %d KB\n", SK_STAGES,
        (BM * BK + BN * BK) * 2 / 1024, SK_STAGES * (BM * BK + BN * BK) * 2 / 1024);

    printf("\n  ★ 与 Hopper 的数字对照（书里）： \n");
    printf("    HGEMM WGMMMA 版 arrive count = 129 (128 warpgroup + 1) \n");
    printf("    FA2 TMA+WS 版   arrive count = 257 (256 线程 + 1, warp 级 mma.sync) \n");
    printf("    FA3 per-WG 版   arrive count = 129 (屏障按 [cid][stage] 切开) \n");
    printf("    ⇒ 「协议只认线程数，不认角色」 \n");

    printf("\n  ★ 实测收益（书里）：TMA+WS 相对 cp.async 版在 attention 上稳定 +20%； \n");
    printf("    HGEMM 上 2048^3 从 104.66 T 提到 164.64 T (1.57x)，**计算指令一条没改**。 \n");

    // 真正跑需要 descriptor: 这里只跑一个"协议自检": mbarrier 的语义在 host 上是
    // 无法模拟的，所以我们只验证 kernel 能被 launch（架构不支持时 kernel 内部会打印跳过）
    DeviceInfo dev = query_device();
    if (dev.cc_major >= 9) {
        printf("\n  尝试 launch 骨架 kernel（无 descriptor，只验证能起来）...\n");
        // 注意：真要用 CUTensorMap 参数就必须走 driver API；这里故意不 launch，
        // 避免在没有 descriptor 的情况下产生无意义的非法访问。
        printf("  跳过（需要 host 侧 cuTensorMapEncodeTiled 构造 descriptor）。 \n");
    } else {
        printf("\n  本机 sm_%d%d < 9.0, TMA/mbarrier 路径不适用，仅阅读协议。 \n",
            dev.cc_major, dev.cc_minor);
    }
}

```

```
printf("\nQ187 done.\n");  
return 0;  
}
```

Q188 [手撕] ★ per-token 的 safe softmax 与 online softmax

考点：naive / safe / online 三版 softmax，含「溢出用例」与带宽对照 **源**

码： [../code/interview/kernels/q188_softmax.cu](https://code.interview.kernels/q188_softmax.cu) (229 行, sha256 44d0d7af90a0)

```

// q188_softmax.cu - Q188: per-token 的 safe softmax 与 online softmax
//
// 1) softmax_naive  -- 按定义直译（演示溢出：大输入直接出 nan）
// 2) softmax_safe   -- 减 max 的两遍扫描（工业标配基线）
// 3) softmax_online  -- (m, d) 双状态单遍联动更新、一次融合归约
//
// 编译: ./build.sh q188
//
// -----
// 解析要点
// -----
// ① ★ 数值稳定性的数学基础是【平移不变性】
//      softmax(x - c*1) = softmax(x)      （分子分母同乘 e^{-c} 严格约掉）
//      ⇒ **减 max 不改变结果，只改变中间量的量级**。
//      溢出界: fp32 下 e^t 不溢出的充要条件是 t <= ln(FLT_MAX) ≈ 88.72;
//      **fp16 下这个界只有 11**（5 位指数）。
//      减 max 后的界: x(i) - m <= 0 ⇒ e^{x(i)-m} <= 1 ⇒ 分子绝不溢出;
//      分母是 n 个不超过 1 的正数之和（最大为 n），也绝不溢出。
//
// ② ★ online softmax 的核心: 把「状态 + 元素」的递推推广成「状态 + 状态」的**可归约**运算
//      单元素递推: m_new = max(m, x);  d_new = d * e^{m - m_new} + e^{x - m_new}
//      二元合并:   m = max(m1, m2);    d = d1 * e^{m1 - m} + d2 * e^{m2 - m}
//      ★ **二元合并满足结合律**（书里引理 5.1）⇒ 可以直接套蝶形/树形归约，
//      **与归约顺序无关**，5 步蝶形后每个 lane 都拿到全行的正确状态。
//      这正是 FlashAttention 能把 softmax 塞进 KV 分块流水线的原因。
//
// ③ 两版实现的差别（面试要能说清代价）
//      扫描遍数: 2 -> 1 (x 只读一次、一直躺在寄存器里)
//      块级同步: 2 次 -> 1 次
//      代价: 归约算子从「一个加法」变成「一次合并」（1 个 max + 2 个 exp + 2 个 FMA），
//      且写回用近似指令（__expf / __fdividef）
//
// ④ 书里的实测 (S=4096 token x H=256, PRO 5000):
//      naive 690.6 GB/s | safe 572.9 GB/s | online 591.6 GB/s
//      ★ **naive 反而最快**（比 safe 少一次 block 归约）—— 但它的前提「输入有界」
//      在生产环境不可保证; safe 相对 naive 慢约 21%，**买到的是任意有限输入下的确定性**。
//
// ⑤ 边界单位的坑: 不满的线程必须携带**状态单位元** (-FLT_MAX, 0),
//      否则 (0, 0) 会把 d 拉成 0、把 m 拉成 0，结果全错（而且是静默错）。
// -----

#include "lc_common.cuh"

```

```

// -----
// ① naive: 不减 max (会溢出)
// -----
template <int kThreads = 256>
__global__ void softmax_naive(const float* __restrict__ x, float* __restrict__ y,
                             int n) {
    const int tid = threadIdx.x;
    const float* xr = x + static_cast<size_t>(blockIdx.x) * n;
    float* yr = y + static_cast<size_t>(blockIdx.x) * n;

    float s = 0.0f;
    for (int i = tid; i < n; i += kThreads) s += __expf(xr[i]);
    s = block_reduce_sum<kThreads>(s);
    const float inv = 1.0f / s;
    for (int i = tid; i < n; i += kThreads) yr[i] = __expf(xr[i]) * inv;
}

// -----
// ② safe: 两遍扫描
// -----
template <int kThreads = 256>
__global__ void softmax_safe(const float* __restrict__ x, float* __restrict__ y,
                             int n) {
    const int tid = threadIdx.x;
    const float* xr = x + static_cast<size_t>(blockIdx.x) * n;
    float* yr = y + static_cast<size_t>(blockIdx.x) * n;

    // pass 1: max (边界线程给 -FLT_MAX 这个 max 的单位元)
    float m = -FLT_MAX;
    for (int i = tid; i < n; i += kThreads) m = fmaxf(m, xr[i]);
    m = block_reduce_max<kThreads>(m);

    // pass 2: sum of exp (第二遍重新读 x, 通常 L1 命中, 但不是零)
    float s = 0.0f;
    for (int i = tid; i < n; i += kThreads) s += __expf(xr[i] - m);
    s = block_reduce_sum<kThreads>(s);

    const float inv = 1.0f / s;
    for (int i = tid; i < n; i += kThreads) yr[i] = __expf(xr[i] - m) * inv;
}

// -----
// ③ online: (m, d) 状态融合归约, 一趟

```

```

// -----
struct MD {
    float m, d;
};

__device__ __forceinline__ MD md_merge(MD a, MD b) {
    MD r;
    r.m = fmaxf(a.m, b.m);
    // ★ 以新 max 为基准重缩放两侧（较小的一侧会乘上 e^{负} 收缩）
    r.d = a.d * __expf(a.m - r.m) + b.d * __expf(b.m - r.m);
    return r;
}

template <int kThreads = 256>
__global__ void softmax_online(const float* __restrict__ x, float* __restrict__ y,
                               int n) {
    const int tid = threadIdx.x;
    const float* xr = x + static_cast<size_t>(blockIdx.x) * n;
    float* yr = y + static_cast<size_t>(blockIdx.x) * n;

    // ★ 边界给状态单位元: m = -FLT_MAX (max 的单位元)、d = 0 (加法单位元)
    float xi = (tid < n) ? xr[tid] : -FLT_MAX;
    MD st{xi, (tid < n) ? 1.0f : 0.0f};

    // warp 内 5 步蝶形合并（与 block_reduce_sum 同构，只是算子换成了 md_merge）
#pragma unroll
    for (int mask = 16; mask >= 1; mask >>= 1) {
        MD o{__shfl_xor_sync(0xfffffffffu, st.m, mask),
             __shfl_xor_sync(0xfffffffffu, st.d, mask)};
        st = md_merge(st, o);
    }
    // 跨 warp: 写 smem -> 第一个 warp 再合并 -> 广播
    __shared__ MD warp_md[kThreads / 32];
    const int lane = tid & 31, warp = tid >> 5;
    if (lane == 0) warp_md[warp] = st;
    __syncthreads();
    if (warp == 0) {
        MD o = (lane < kThreads / 32) ? warp_md[lane] : MD{-FLT_MAX, 0.0f};
#pragma unroll
        for (int mask = 16; mask >= 1; mask >>= 1) {
            MD p{__shfl_xor_sync(0xfffffffffu, o.m, mask),
                 __shfl_xor_sync(0xfffffffffu, o.d, mask)};
            o = md_merge(o, p);
        }
    }
}

```



```

    }
    if (lane == 0) warp_md[0] = 0;      // 复用第 0 槽做广播（节省一次同步）
}

__syncthreads();
const MD tot = warp_md[0];

const float inv = 1.0f / tot.d;
for (int i = tid; i < n; i += kThreads) yr[i] = __expf(xr[i] - tot.m) * inv;
}

// -----
// host 侧参考（double 版，作为真值）
// -----
static void ref_softmax(const std::vector<float>& x, std::vector<float>& y, int n) {
    double m = -1e308;
    for (int i = 0; i < n; ++i) m = std::max(m, double(x[i]));
    double s = 0.0;
    for (int i = 0; i < n; ++i) s += std::exp(double(x[i]) - m);
    for (int i = 0; i < n; ++i) y[i] = float(std::exp(double(x[i]) - m) / s);
}

int main() {
    TEST_BEGIN("Q188 softmax (naive / safe / online)");

    const int T = 256;
    struct Case { int n; float lo, hi; const char* name; };
    // ★ 第三个用例是"溢出用例":  $x \in [80, 120]$ , naive 必然出 nan
    const std::vector<Case> cases = {{256, -5.f, 5.f, "normal [-5,5]"},
                                     {100, -5.f, 5.f, "n=100 (block 不满)"},
                                     {256, 80.f, 120.f, "large [80,120] -> 溢出"}};

    for (const auto& c : cases) {
        const int n = c.n;
        std::vector<float> hx(n), href(n), hgot(n);
        fill_random(hx, 101u, c.lo, c.hi);
        ref_softmax(hx, href, n);

        float *dx, *dy;
        CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
        CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));
        CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));

        printf("\n --- case: %s (n=%d) ---\n", c.name, n);
    }
}

```

```

const double rtol = 1e-4, atol = 1e-6;
GpuTimer timer;
const size_t bytes = size_t(n) * 2 * sizeof(float);

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms1 = timer.bench([&] { softmax_naive<T><<<1, T>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
{
    CompareResult r = compare(hgot, href, rtol, atol);
    report("softmax_naive", r, rtol, atol, ms1);
    if (!r.ok && c.lo > 80) {
        printf("          ↑ 这是**预期的溢出**：输入 80~120 时 e^x 直接 inf, inf/inf = nan\n");
    }
}

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms2 = timer.bench([&] { softmax_safe<T><<<1, T>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report("softmax_safe (2 passes)", compare(hgot, href, rtol, atol), rtol, atol, ms2);

CUDA_CHECK(cudaMemset(dy, 0, n * sizeof(float)));
double ms3 = timer.bench([&] { softmax_online<T><<<1, T>>>(dx, dy, n); });
CUDA_CHECK_KERNEL();
hgot = to_host(dy, n);
report("softmax_online(1 pass)", compare(hgot, href, rtol, atol), rtol, atol, ms3);

printf("          带宽口径 8 B/元素: naive %.0f | safe %.0f | online %.0f GB/s\n",
        to_gbps(bytes, ms1), to_gbps(bytes, ms2), to_gbps(bytes, ms3));
printf("          时间比 online/safe = %.3f (一趟 vs 两趟) \n", ms3 / ms2);
}

// ---- 与「块顺序无关」的一致性自检：把 online 的两半分别算再合并 ----
{
    const int n = 512;
    std::vector<float> hx(n), href(n), hgot(n);
    fill_random(hx, 102u, -5.f, 5.f);
    ref_softmax(hx, href, n);

    float *dx, *dy;
    CUDA_CHECK(cudaMalloc(&dx, n * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dy, n * sizeof(float)));

```

```

    CUDA_CHECK(cudaMemcpy(dx, hx.data(), n * sizeof(float), cudaMemcpyHostToDevice));
    softmax_online<256><<<1, 256>>>(dx, dy, n);
    CUDA_CHECK_KERNEL();
    hgot = to_host(dy, n);
    printf("\n  online vs 参考 (n=512) : ");
    CompareResult r = compare(hgot, href, 1e-4, 1e-6);
    printf("%s  max_abs=%.3e\n", r.ok ? "PASS" : "FAIL", r.max_abs);
    CUDA_CHECK(cudaFree(dx));
    CUDA_CHECK(cudaFree(dy));
}

printf("\nQ188 done.\n");
return 0;
}

```

Q189 [手撕] ★ FlashAttention 的内层循环 (online rescale)

考点：FlashAttention 内层循环：online rescale 五步 + 与朴素版的显存账对照 **源**

码： [../code/interview/kernels/q189_flash_attn.cu](https://code.interview/kernels/q189_flash_attn.cu) (261 行, sha256 `f690035644c6`)

```

// q189_flash_attn.cu - Q189: FlashAttention 的内层循环 (online rescale)
//
// 1) attn_reference  -- 朴素三 kernel 版 (物化 S/P 矩阵, 演示 IO 灾难)
// 2) attn_flash      -- tiling + online softmax: S/P 只在寄存器/smem 里,
//                      0 全程未归一化、循环外只除一次  $Q$ 
// 3) attn_flash_split -- split- $Q$  (每个 warp 独占若干行  $Q$ , 零跨 warp 归约)
//
// 编译: ./build.sh q189
//
// -----
// 解析要点
// -----
// ① ★ online rescale 的五步 (必须能默写, 第 2 步是"减【新】max")
// 1)  $m_{\text{new}} = \max(m_{\text{old}}, \text{rowmax}(S))$ 
// 2)  $P = \exp(S - m_{\text{new}})$  ← 减新 max
// 3)  $l_{\text{new}} = \exp(m_{\text{old}} - m_{\text{new}}) * l_{\text{old}} + \text{rowsum}(P)$ 
// 4)  $O \leftarrow O * \text{diag}(\exp(m_{\text{old}} - m_{\text{new}})) + P @ V$  ←  $l$  与  $O$  用【同一个】因子
// 5) (全部块扫完后【只做一次】)  $O \leftarrow \text{diag}(1/l) O$ 
// ★ 顺序不能换: 先算  $m_{\text{new}}$ , 再同时修正  $l$  与  $O$ , 最后累加新块。
// ★ 首块  $m_{\text{old}} = -\text{inf}$  时用三元判断让  $m_{\text{new}}$  顶替旧值, 避免  $e^{\{-\text{inf}\}}$  与  $0 * \text{inf}$  污染。
//
// ② ★ 为什么  $1/l$  只做一次 (FA2 相对 FA1 的关键简化)
// 0 全程保持【未归一化】 $\Rightarrow$  每块省掉一次对角修正。
// 副产品: 退化情形天然安全 ( $e^{\{-\text{inf}\}} = 0$  精确给出, 不产生 NaN)。
//
// ③ ★ 行归约宽度必须是 4, 不是 32
// 由 m16n8 C fragment 布局: 行  $r \in [0, 8)$  的 8 个列元素分布在 lane  $4r..4r+3$ 
//  $\Rightarrow$  先在 lane 内跨  $j$  tile 局部归约, 再 warp_reduce_max<4> (掩码 {2,1})。
// **误用整宽 32 会把不同行的 max/sum 混在一起 — 静默错误。**
// 本文件的简化实现按"一行一个 warp"来组织 (教学清晰), 完整 fragment 版见 q186。
//
// ④ ★ 为什么  $K$  双缓冲、 $V$  单级 (一个很漂亮的论证)
// 迭代  $t$  内提交两组搬运:  $V_t$  (当前) +  $K_{t+1}$  (预取)。
// ** $V_t$  的在途窗口恰好覆盖  $QK$  mma 与 softmax** (softmax 全在 CUDA Core/SFU 上跑)
//  $\Rightarrow$  一个 stage 就够;  $K_{t+1}$  有整整一个迭代余量  $\Rightarrow$  需要双缓冲。
//
// ⑤ 复杂度与算术强度
// FLOPs 不变 ( $4 * N^2 * d$ , 分块只重排顺序); 显存  $\text{Theta}(N^2) \rightarrow \text{Theta}(N * d)$ 
//  $\text{IO\_FA} = \text{Theta}(Nd + N^2 d^2 / M)$ ,  $\text{AI\_FA} \approx \text{Br} = 64 \sim 128$ 
//  $\text{AI\_naive} \approx d/2 = 32$  ( $d=64$ , fp16)
// ★ 数字直觉:  $B=1, H=32, N=4096, D=64$  时朴素实现的中间矩阵 HBM 往返  $\approx 4.3$  GB,
// 而有效数据 ( $Q/K/V$  读入 +  $O$  写出) 只有 67 MB — **1/64**。  

// 总 FLOPs  $\approx 137$  GFLOP  $\Rightarrow$  计算下界 0.83 ms; 按 2 TB/s 乐观带宽仅搬运就要 2.2 ms。

```

```

//      ⇒ **memory-bound 无疑，且  $O(N^2)$  的显存账在长序列下先于时间把方案毙掉。**
//
// ⑥ 精度分层（两条 acc 路径共同的精度地板）
//      S/O 累加器 f32、exp/max/rowsum/rescale 全走 fp32、P 写回寄存器是 fp16。
//      实测（书里）：F16Acc  $\sim 2e-4$ 、F32Acc  $\sim 5e-5$ ；
//      ★ 而且 **F32Acc 反而更快**（FA2 MMA 版 175.88 T vs 166.56 T）——
//      因为 f32 累加省掉了 softmax/rescale 阶段 half $\leftrightarrow$ float 的整簇转换。
//
// -----

#include "lc_common.cuh"

// -----
// ① 朴素参考：物化 S 与 P（只在小 shape 上跑，用来对拍）
// -----

__global__ void attn_reference_kernel(const float* __restrict__ Q,
                                     const float* __restrict__ K,
                                     const float* __restrict__ V,
                                     float* __restrict__ O, float* __restrict__ S,
                                     int N, int D, float scale) {

    // 一个 block 处理一行 query
    const int qi = blockIdx.x;
    const int tid = threadIdx.x;
    // S[qi][j] = sum_d Q[qi][d] * K[j][d] * scale
    for (int j = tid; j < N; j += blockDim.x) {
        float s = 0.0f;
        for (int d = 0; d < D; ++d) s += Q[qi * D + d] * K[j * D + d];
        S[qi * N + j] = s * scale;
    }
    __syncthreads();
    // softmax 行
    float m = -FLT_MAX;
    for (int j = tid; j < N; j += blockDim.x) m = fmaxf(m, S[qi * N + j]);
    m = block_reduce_max<256>(m);
    float sum = 0.0f;
    for (int j = tid; j < N; j += blockDim.x) {
        float p = __expf(S[qi * N + j] - m);
        S[qi * N + j] = p;
        sum += p;
    }
    sum = block_reduce_sum<256>(sum);
    // O[qi][d] = sum_j P[qi][j] * V[j][d] / sum
    for (int d = tid; d < D; d += blockDim.x) {
        float acc = 0.0f;

```

```

    for (int j = 0; j < N; ++j) acc += S[qi * N + j] * V[j * D + d];
    O[qi * D + d] = acc / sum;
}
}

// -----
// ② FlashAttention: tiling + online softmax
// 组织方式：一个 block 处理一行 query; KV 按 kBc 分块；每线程负责一个输出维度。
// 这是"结构完全正确"的教学版（生产版要把 P 留在 fragment 寄存器里，
// 并且用 split-Q 让每个 warp 独占 16 行 Q —— 见下面的说明）。
// -----
template <int kThreads = 128, int kD = 64, int kBc = 64>
__global__ void attn_flash_kernel(const float* __restrict__ Q,
                                   const float* __restrict__ K,
                                   const float* __restrict__ V, float* __restrict__ O,
                                   int N, float scale) {

    __shared__ float s_k[kBc][kD];
    __shared__ float s_v[kBc][kD];
    __shared__ float s_p[kBc];    // 本块的 P 行（一行 query ⇒ 只有一行）

    const int qi = blockIdx.x;
    const int tid = threadIdx.x;
    const float* q = Q + static_cast<size_t>(qi) * kD;

    float m = -FLT_MAX, l = 0.0f;
    float o_acc = 0.0f;
    const int dcol = tid;          // 每线程负责一列输出

    for (int j0 = 0; j0 < N; j0 += kBc) {
        // 装载 K/V
        for (int i = tid; i < kBc * kD; i += kThreads) {
            const int r = i / kD, c = i % kD;
            const int j = j0 + r;
            s_k[r][c] = (j < N) ? K[static_cast<size_t>(j) * kD + c] : 0.0f;
            s_v[r][c] = (j < N) ? V[static_cast<size_t>(j) * kD + c] : 0.0f;
        }
        __syncthreads();

        // S 的一列 + 行 max 的候选
        float s_ij = -FLT_MAX;
        if (tid < kBc) {
            const int j = j0 + tid;
            if (j < N) {

```

```

        float acc = 0.0f;
#pragma unroll 4
        for (int d = 0; d < kD; ++d) acc += q[d] * s_k[tid][d];
        s_ij = acc * scale;
    }
}

const float block_max = block_reduce_max<kThreads>(s_ij);
const float m_new = fmaxf(m, block_max);          // ★ 第 1 步
const float p_ij = (s_ij > -FLT_MAX) ? __expf(s_ij - m_new) : 0.0f; // ★ 第 2 步
if (tid < kBc) s_p[tid] = p_ij;
const float rowsum = block_reduce_sum<kThreads>(p_ij);
const float rescale = __expf(m - m_new);          // ★ 同一个因子
l = l * rescale + rowsum;                         // ★ 第 3 步
__syncthreads();

// 0 <- 0*rescale + P @ V
if (dcol < kD) {
    float acc = 0.0f;
#pragma unroll 4
    for (int r = 0; r < kBc; ++r) {
        const int j = j0 + r;
        if (j < N) acc += s_p[r] * s_v[r][dcol];
    }
    o_acc = o_acc * rescale + acc;                 // ★ 第 4 步
}
m = m_new;
__syncthreads();
}

if (dcol < kD) O[static_cast<size_t>(qi) * kD + dcol] = o_acc / l; // ★ 第 5 步
}

// -----
// host 侧参考 (attention 的 CPU 直算, double 累加)
// -----

static void ref_attn(const std::vector<float>& Q, const std::vector<float>& K,
                    const std::vector<float>& V, std::vector<float>& O, int N, int D) {
    const double scale = 1.0 / std::sqrt(double(D));
    for (int i = 0; i < N; ++i) {
        std::vector<double> s(N);
        double m = -1e308;
        for (int j = 0; j < N; ++j) {
            double acc = 0.0;
            for (int d = 0; d < D; ++d) acc += double(Q[i * D + d]) * K[j * D + d];

```

```

        s[j] = acc * scale;
        m = std::max(m, s[j]);
    }
    double sum = 0.0;
    for (int j = 0; j < N; ++j) {
        s[j] = std::exp(s[j] - m);
        sum += s[j];
    }
    for (int d = 0; d < D; ++d) {
        double acc = 0.0;
        for (int j = 0; j < N; ++j) acc += s[j] * V[j * D + d];
        O[i * D + d] = float(acc / sum);
    }
}

}

int main() {
    TEST_BEGIN("Q189 FlashAttention inner loop (online rescale)");

    const int N = 256, D = 64;
    const float scale = 1.0f / std::sqrt(float(D));

    std::vector<float> hQ(size_t(N) * D), hK(size_t(N) * D), hV(size_t(N) * D),
        hO(size_t(N) * D), href(size_t(N) * D), hgot(size_t(N) * D);
    fill_random(hQ, 111u, -1.f, 1.f);
    fill_random(hK, 112u, -1.f, 1.f);
    fill_random(hV, 113u, -1.f, 1.f);
    ref_attn(hQ, hK, hV, href, N, D);

    float *dQ, *dK, *dV, *dO, *dS;
    CUDA_CHECK(cudaMalloc(&dQ, hQ.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dK, hK.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dV, hV.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dO, hO.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dS, size_t(N) * N * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dQ, hQ.data(), hQ.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dK, hK.data(), hK.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dV, hV.data(), hV.size() * sizeof(float), cudaMemcpyHostToDevice));

    // 注意力输出是加权平均  $\Rightarrow$  尺度小、舍入多;  $1e-3$  的相对容差是合理口径
    const double rtol = 1e-3, atol = 1e-5;
    GpuTimer timer;

```



```

{
    CUDA_CHECK(cudaMemset(d0, 0, h0.size() * sizeof(float)));
    double ms = timer.bench([&] {
        attn_reference_kernel<<<N, 256>>>(dQ, dK, dV, d0, dS, N, D, scale);
    });
    CUDA_CHECK_KERNEL();
    hgot = to_host(d0, h0.size());
    report("attn_reference (materialize S/P)", compare(hgot, href, rtol, atol),
        rtol, atol, ms);
    printf("          ★ 显存账: 它额外物化了 S = %d x %d x 4 B = %.1f MB\n", N, N,
        double(N) * N * 4 / 1e6);
}

{
    CUDA_CHECK(cudaMemset(d0, 0, h0.size() * sizeof(float)));
    double ms = timer.bench([&] {
        attn_flash_kernel<128, D, 64><<<N, 128>>>(dQ, dK, dV, d0, N, scale);
    });
    CUDA_CHECK_KERNEL();
    hgot = to_host(d0, h0.size());
    report("attn_flash (tiling + online)", compare(hgot, href, rtol, atol), rtol, atol, ms);
    printf("          ★ 它没有物化 S/P: KV 分块后中间量只在 smem/寄存器里\n");
}

// ---- 长序列的显存对比 (不解  $O(N^2)$  的话会直接 OOM) ----
{
    const int Nl = 4096;
    const double s_bytes = double(Nl) * Nl * 4;
    printf("\n 长序列 (N=%d, D=%d) 的显存账: \n", Nl, D);
    printf("    朴素版物化 S 需要 %.0f MB, 再加上 P 又是 %.0f MB ⇒ 单头就 %.1f GB\n",
        s_bytes / 1e6, s_bytes / 1e6, 2 * s_bytes / 1e9);
    printf("    32 个头的 S/P 共约 %.1f GB -- **这就是  $O(N^2)$  显存账**\n",
        32 * 2 * s_bytes / 1e9);
    printf("    FlashAttention 只需  $O(N*d) = %.1f$  MB (+ smem 里的分块) \n",
        double(Nl) * D * 4 * 3 / 1e6);
    printf("    书里的 kPad=0 消融则显示: 不物化 S/P 只是入场券, **smem 读写两端的平衡\n");
    printf("    才是把 73%% 变成 90%% 的功课** (120.0 T vs 166.6 T 的差距来自 LDGSTS wavefronts)。 \n");
}

CUDA_CHECK(cudaFree(dQ));
CUDA_CHECK(cudaFree(dK));
CUDA_CHECK(cudaFree(dV));
CUDA_CHECK(cudaFree(d0));
CUDA_CHECK(cudaFree(dS));

```

```
printf("\nQ189 done.\n");  
return 0;  
}
```

Q190 [hard] ★ merge_attn_states (LSE 合并, 用于 split-KV / FlashDecoding)

考点: merge_attn_states: LSE 合并、两套口径不可混搭、空段退化 **源**

码: [../code/interview/kernels/q190_merge_attn.cu](#) (270 行, sha256 `ed524a9abf67`)

```

// q190_merge_attn.cu - Q190: merge_attn_states (LSE 合并, 用于 split-KV / FlashDecoding)
//
// 1) split_attn_partial -- 把 KV 切成 2 段, 各自算【未归一化】的 O 与 (m, l)
// 2) merge_attn_states -- 用 LSE 把两段合并 (本文件的核心)
// 3) 对照: 一次性算完整 attention (证明合并结果与一次性结果逐元素相等)
//
// 编译: ./build.sh q190
//
// -----
// 解析要点
// -----
// ① ★ 两套口径不可混搭 (这是本题最重要的一句话)
// **FA 主循环的 O 是【未归一化】的** (配合递推里的  $e^{m_{old} - m_{new}}$ );
// **merge_attn_states 的 LSE 形式作用在【已归一化】的 O 上**。
// 混搭是最常见的隐蔽错误 -- 结果不会报错, 只是数值系统性偏大/偏小。
//
// ② LSE 的定义与合并 (要能默写)
// LSE = m + log(l) ← 把 (m, l) 两个数【无损】打包成一个标量
// L = max(LSE_A, LSE_B) ← 以最大者为 pivot
// w_A =  $e^{LSE_A - L}$ ; w_B =  $e^{LSE_B - L}$ 
// alpha = w_A / (w_A + w_B); beta = w_B / (w_A + w_B) ← alpha + beta = 1 (凸组合)
// O = alpha * O_A + beta * O_B
// ★ 以 max 为 pivot 让两个权重都  $\leq 1 \Rightarrow$  **数值上绝不上溢**。
//
// ③ 与 FA 递推的关系 (面试官很可能追问)
// 递推里的  $e^{m_{old} - m_{new}}$  是「**在线合并**」(寄存器里一份 O 滚动);
// LSE 式是「**事后合并**」(两块各落盘 O 与 LSE 后用 elementwise kernel 拼回)。
// 后者服务 split-KV / FlashDecoding: 把长序列切成多段并行算, 再拼回来。
// ★ 块数 > 2 怎么办? → 多用几次这个 kernel 折叠, 或把 LSE 也做成可归约的
// (m, l) 状态:  $m = \max(m_1, m_2)$ ;  $l = l_1 \cdot e^{m_1 - m} + l_2 \cdot e^{m_2 - m}$  (注意这次是【未归一化】口径)。
//
// ④ 书里的实测: merge kernel 0.7849 ms / 1031.4 GB/s ( $\approx$  峰值 77%, 搬 809.5 MB),
// **结果与一次性 softmax 逐元素相等** -- 这是"合并是无损的"的实测证据。
//
// ⑤ 一个容易忽略的边界: 如果某一段的 l == 0 (该段全被 mask 掉),
// LSE = m + log(0) = -inf  $\Rightarrow$  w =  $e^{-inf - L}$  = 0  $\Rightarrow$  该段权重为 0, 自动退化。正确。
// 但如果**两段都**是 0, 则 w_A + w_B = 0  $\Rightarrow$  除零  $\Rightarrow$  NaN。**全 mask 的行要由调用方保证非空**
// -----

#include "lc_common.cuh"

// -----
// ① 分段的 partial: 对第 [j_begin, j_end) 段 KV 算【未归一化】的 O 与 (m, l)

```

```

// 一个 block 处理一行 query; 输出 o_partial[qi][d] 与 lse[qi]
// -----
template <int kThreads = 128, int kD = 64, int kBc = 64>
__global__ void split_attn_partial(const float* __restrict__ Q,
                                   const float* __restrict__ K,
                                   const float* __restrict__ V,
                                   float* __restrict__ o_partial,
                                   float* __restrict__ lse, int N, int j_begin,
                                   int j_end, float scale, bool normalize_o) {

    __shared__ float s_k[kBc][kD];
    __shared__ float s_v[kBc][kD];
    __shared__ float s_p[kBc];

    const int qi = blockIdx.x;
    const int tid = threadIdx.x;
    const float* q = Q + static_cast<size_t>(qi) * kD;

    float m = -FLT_MAX, l = 0.0f, o_acc = 0.0f;
    const int dcol = tid;

    for (int j0 = j_begin; j0 < j_end; j0 += kBc) {
        for (int i = tid; i < kBc * kD; i += kThreads) {
            const int r = i / kD, c = i % kD;
            const int j = j0 + r;
            const bool ok = (j < j_end);
            s_k[r][c] = ok ? K[static_cast<size_t>(j) * kD + c] : 0.0f;
            s_v[r][c] = ok ? V[static_cast<size_t>(j) * kD + c] : 0.0f;
        }
        __syncthreads();

        float s_ij = -FLT_MAX;
        if (tid < kBc && (j0 + tid) < j_end) {
            float acc = 0.0f;
#pragma unroll 4
            for (int d = 0; d < kD; ++d) acc += q[d] * s_k[tid][d];
            s_ij = acc * scale;
        }

        const float m_new = fmaxf(m, block_reduce_max<kThreads>(s_ij));
        const float p_ij = (s_ij > -FLT_MAX) ? __expf(s_ij - m_new) : 0.0f;
        if (tid < kBc) s_p[tid] = p_ij;
        const float rowsum = block_reduce_sum<kThreads>(p_ij);
        const float rescale = __expf(m - m_new); // 首块 m = -inf ⇒ rescale = 0
        l = l * rescale + rowsum;
    }
}

```

```

__syncthreads();

if (dcol < kD) {
    float acc = 0.0f;
#pragma unroll 4
    for (int r = 0; r < kBc; ++r) {
        const int j = j0 + r;
        if (j < j_end) acc += s_p[r] * s_v[r][dcol];
    }
    o_acc = o_acc * rescale + acc;
}
m = m_new;
__syncthreads();
}

// ★ 输出两种口径, 由 normalize_o 决定 (这正是"混搭会错"的那个开关)
if (dcol < kD) {
    o_partial[static_cast<size_t>(qi) * kD + dcol] =
        normalize_o ? (o_acc / l) : o_acc;
}
if (tid == 0) lse[qi] = m + __logf(l);          // ★ LSE = m + log(l)
}

// -----
// ② merge: 把两段的 (0, LSE) 合成最终输出 — 本文件的核心 kernel
// -----
__global__ void merge_attn_states_kernel(const float* __restrict__ o_a,
                                         const float* __restrict__ lse_a,
                                         const float* __restrict__ o_b,
                                         const float* __restrict__ lse_b,
                                         float* __restrict__ out, int rows, int D) {

    const int i = blockIdx.x * blockDim.x + threadIdx.x;
    if (i >= rows * D) return;
    const int row = i / D;

    const float la = lse_a[row], lb = lse_b[row];
    const float L = fmaxf(la, lb);                // ★ 以 max 为 pivot
    const float wa = __expf(la - L), wb = __expf(lb - L); // 两者都 <= 1 ⇒ 不上溢
    const float inv = 1.0f / (wa + wb);
    const float alpha = wa * inv, beta = wb * inv; // alpha + beta = 1 (凸组合)

    // ★ 这里要求 o_a / o_b 已经是【已归一化】的分段输出
    out[i] = alpha * o_a[i] + beta * o_b[i];
}

```

```

}

// -----
// host 侧参考
// -----
static void ref_attn(const std::vector<float>& Q, const std::vector<float>& K,
                    const std::vector<float>& V, std::vector<float>& O, int N, int D) {
    const double scale = 1.0 / std::sqrt(double(D));
    for (int i = 0; i < N; ++i) {
        std::vector<double> s(N);
        double m = -1e308;
        for (int j = 0; j < N; ++j) {
            double acc = 0.0;
            for (int d = 0; d < D; ++d) acc += double(Q[i * D + d]) * K[j * D + d];
            s[j] = acc * scale;
            m = std::max(m, s[j]);
        }
        double sum = 0.0;
        for (int j = 0; j < N; ++j) {
            s[j] = std::exp(s[j] - m);
            sum += s[j];
        }
        for (int d = 0; d < D; ++d) {
            double acc = 0.0;
            for (int j = 0; j < N; ++j) acc += s[j] * V[j * D + d];
            O[i * D + d] = float(acc / sum);
        }
    }
}

int main() {
    TEST_BEGIN("Q190 merge_attn_states (LSE merge for split-KV)");

    const int N = 512, D = 64;
    const float scale = 1.0f / std::sqrt(float(D));
    const int mid = N / 2;

    std::vector<float> hQ(size_t(N) * D), hK(size_t(N) * D), hV(size_t(N) * D),
        href(size_t(N) * D);
    fill_random(hQ, 121u, -1.f, 1.f);
    fill_random(hK, 122u, -1.f, 1.f);
    fill_random(hV, 123u, -1.f, 1.f);
    ref_attn(hQ, hK, hV, href, N, D);
}

```

```

float *dQ, *dK, *dV;
CUDA_CHECK(cudaMalloc(&dQ, hQ.size() * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dK, hK.size() * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dV, hV.size() * sizeof(float)));
CUDA_CHECK(cudaMemcpy(dQ, hQ.data(), hQ.size() * sizeof(float), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(dK, hK.data(), hK.size() * sizeof(float), cudaMemcpyHostToDevice));
CUDA_CHECK(cudaMemcpy(dV, hV.data(), hV.size() * sizeof(float), cudaMemcpyHostToDevice));

const size_t o_elems = size_t(N) * D;
float *d0a, *d0b, *d0merged, *dLseA, *dLseB;
CUDA_CHECK(cudaMalloc(&d0a, o_elems * sizeof(float)));
CUDA_CHECK(cudaMalloc(&d0b, o_elems * sizeof(float)));
CUDA_CHECK(cudaMalloc(&d0merged, o_elems * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dLseA, N * sizeof(float)));
CUDA_CHECK(cudaMalloc(&dLseB, N * sizeof(float)));

const double rtol = 1e-3, atol = 1e-5;
GpuTimer timer;

// ---- 分两段各算 partial (★ 输出【已归一化】的 0 与 LSE, 才符合 LSE 口径) ----
timer.bench([&] {
    split_attn_partial<128, D, 64><<<N, 128>>>(dQ, dK, dV, d0a, dLseA, N, 0, mid, scale, true);
    split_attn_partial<128, D, 64><<<N, 128>>>(dQ, dK, dV, d0b, dLseB, N, mid, N, scale, true);
});
CUDA_CHECK_KERNEL();

// ---- 合并 ----
const int threads = 256;
const int blocks = (int)((o_elems + threads - 1) / threads);
double ms_merge = timer.bench([&] {
    merge_attn_states_kernel<<<blocks, threads>>>(d0a, dLseA, d0b, dLseB, d0merged, N, D);
});
CUDA_CHECK_KERNEL();

std::vector<float> hgot = to_host(d0merged, o_elems);
CompareResult r = compare(hgot, href, rtol, atol);
report("merge 2 partials -> full attn", r, rtol, atol, ms_merge);
printf("      ★ 合并结果应当与【一次性算完整 attention】逐元素相等 — 合并是无损的\n");
printf("      merge kernel 峰值: 读 2*0(+LSE) + 写 0 = %.2f MB, 带宽 %.0f GB/s\n",
    (2.0 * o_elems + 2.0 * N + o_elems) * 4 / 1e6,
    to_gbps((2 * o_elems + 2 * N + o_elems) * 4, ms_merge));

```

```
// ---- 口径错误的演示：用【未归一化】的 0 去合并会怎样 ----
{
    timer.bench([&] {
        split_attn_partial<128, D, 64><<<N, 128>>>(dQ, dK, dV, d0a, dLseA, N, 0, mid, scale, false);
        split_attn_partial<128, D, 64><<<N, 128>>>(dQ, dK, dV, d0b, dLseB, N, mid, N, scale, false);
    });
    CUDA_CHECK_KERNEL();
    merge_attn_states_kernel<<<blocks, threads>>>(d0a, dLseA, d0b, dLseB, d0merged, N, D);
    CUDA_CHECK_KERNEL();
    hgot = to_host(d0merged, o_elems);
    CompareResult bad = compare(hgot, href, rtol, atol);
    report("BAD: merge unnormalized 0", bad, rtol, atol);
    printf("          ↑ 这是**故意做错**的版本：把未归一化的 0 喂给 LSE 合并。\\n");
    printf("          它不会报错、形状也合法，只是数值系统性错 —— 这就是「口径混搭」的代价。\\n");
}

// ---- 极端的一段为空（全 mask） ----
{
    const int D2 = D;
    std::vector<float> hz(size_t(N) * D2, 0.0f);
    std::vector<float> hlse_a(N, -1e30f), hlse_b(N, 0.0f); // A 段全 mask ⇒ LSE = -inf 近似
    float *dz, *dla, *dlb, *dout;
    CUDA_CHECK(cudaMalloc(&dz, hz.size() * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dla, N * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dlb, N * sizeof(float)));
    CUDA_CHECK(cudaMalloc(&dout, hz.size() * sizeof(float)));
    CUDA_CHECK(cudaMemcpy(dz, hz.data(), hz.size() * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dla, hlse_a.data(), N * sizeof(float), cudaMemcpyHostToDevice));
    CUDA_CHECK(cudaMemcpy(dlb, hlse_b.data(), N * sizeof(float), cudaMemcpyHostToDevice));
    std::vector<float> ob(hz.size(), 3.0f);
    CUDA_CHECK(cudaMemcpy(dz, ob.data(), ob.size() * sizeof(float), cudaMemcpyHostToDevice));
    merge_attn_states_kernel<<<blocks, threads>>>(dz, dla, dz, dlb, dout, N, D2);
    CUDA_CHECK_KERNEL();
    std::vector<float> hz2 = to_host(dout, hz.size());
    double mx = 0.0;
    for (float v : hz2) mx = std::max(mx, std::fabs(double(v) - 3.0));
    printf("\\n %-34s %s max_abs_err=%.3e (A 段 LSE=-inf ⇒ w_A=0 ⇒ 结果应等于 B 段) \\n",
        "merge with one empty segment", mx < 1e-6 ? "PASS" : "FAIL", mx);
    CUDA_CHECK(cudaFree(dz));
    CUDA_CHECK(cudaFree(dla));
    CUDA_CHECK(cudaFree(dlb));
    CUDA_CHECK(cudaFree(dout));
}
```



```

CUDA_CHECK(cudaFree(dQ));
CUDA_CHECK(cudaFree(dK));
CUDA_CHECK(cudaFree(dV));
CUDA_CHECK(cudaFree(dOa));
CUDA_CHECK(cudaFree(dOb));
CUDA_CHECK(cudaFree(dOmerged));
CUDA_CHECK(cudaFree(dLseA));
CUDA_CHECK(cudaFree(dLseB));

printf("\nQ190 done.\n");

return 0;
}

```

§8 系统设计 (Q191–Q200, 10 题)

Q191 [开放] ★ 设计一个支持 1000 QPS 的推理服务

答· 四步：① **问清约束**：模型多大、上下文多长、SLO 是什么 (TTFT/ITL 的 p99)、什么卡；② **算资源**：权重显存 + KV cache 上界 $\Rightarrow$ 单卡能开多大 batch $\Rightarrow$ 需要几卡；③ **选并行**：单机内 TP (NVLink 域内)、跨机 PP/EP、DP 做副本；④ **设计层**：路由/负载均衡、**prefix cache 共享**、PD 分离 (如果 ITL 要求严)、限流与排队策略、可观测性 (指标 + trace)。数字· **务必说出 goodput 而不是吞吐** —— 因为 1000 QPS 是「达标请求数」。

Q192 [开放] 设计一个 PD 分离的部署

答· **prefill 池 + decode 池 + KV 传输通道**：① 按算力特性配比 (prefill 吃算力、decode 吃带宽，比例要按负载实测调)；② **KV 传输选型** (RDMA 网络 / NVLink 同机 / 共享存储)，说清**带宽需求 = 每 token KV 字节 $\times$ 并发**；③ **调度器要感知两池状态** (不然一边空转一边排队)；④ **失败处理**：传输失败 $\Rightarrow$ 重新 prefill (把代价说清楚)。数字· **主动说「它不提升总吞吐，提升的是 SLO 下的有效吞吐与资源利用率」**。

Q193 [开放] 设计一个 MoE 模型的推理部署

答· ① **EP 切分** (专家放不下就跨卡) + **TP/DP 的取舍**；② **all-to-all 的 backend 选择** (按网络与量化要求)；③ **负载均衡**：EPLB 周期重排 + 冗余专家；④ **容量规划**：MoE 的显存是「专家参数 + KV cache」，**激活值很小**；⑤ **通信与计算重叠** (DBO / kernel 融合)。数字· **主动提「all-to-all 是数据依赖的 $\Rightarrow$ 负载不均 $\Rightarrow$ 需要 EPLB」这条链**。

Q194 [开放] 给定一张 8 卡机，怎么跑一个 70B 模型？

答· ① **权重显存**： $70B \times 2 B (fp16) = 140 GB \Rightarrow 8 卡 \times 80 GB = 640 GB$ 放得下，但要给 KV cache 留空间；② **TP=8 单机** (NVLink 域内) 最常见；③ **KV cache 预算 = 总显存 $\times 0.92$ - 权重 - 激活峰值**，算出 concurrent tokens；④ **量化选项**：fp8 权重 $\Rightarrow$ 权重降到 70 GB，KV cache 空间翻倍；⑤ **验证**：压测 TTFT/ITL/goodput，并和理论值对。数字· `gpu_memory_utilization` 默认 0.92；**启动日志的 `Maximum concurrency` 就是第 ③ 步的结果**。

Q195 [开放] 设计一个多租户的推理平台

答· 隔离维度：**显存**（MPS/MIG 切分 or 分实例）、**算力**（SM 配额/优先级）、**缓存**（prefix cache 要不要跨租户共享——这是安全与效率的取舍）、**SLO**（按租户排队与限流）。**数字·**主动说「prefix cache 跨租户共享会泄漏 prompt 信息」——这是个安全点。

Q196 **[开放]** 怎么给一个国产加速卡适配一个算子？

答· 六步：① **确认它支持什么原语**（有没有等价的 DMA/矩阵指令/barrier）；② **先跑通参考实现**（不优化，建立正确性基线 + 容差）；③ **摸清它的内存层级与带宽**（用微基准测峰值带宽/算力）；④ **按它的瓶颈重做优化**（不能照搬 CUDA 的 tiling/swizzle 参数）；⑤ **精度对齐**（国产卡的低精度路径常常与 NVIDIA 不同）；⑥ **性能对齐 + 记录差异**。**数字·**最花时间的往往不是写 kernel，而是「算子支持度对齐和精度对齐」。

Q197 **[开放]** 设计一个 profiling / 可观测性体系

答· 三层：① **指标 (Metrics)**：吞吐/延迟分位/显存/KV 使用率/通信量；② **Trace**：nsys / torch.profiler，按需开启、注意采样开销；③ **计数器 (Counters)**：ncu，只在定位到具体 kernel 后用。**数字·**要主动说「profiler 本身有开销、会改变时序」，所以线上默认只开 metrics，trace 按需。

Q198 **[开放]** 怎么设计一个论文复现实验？

答· ① **先确认证文的口径**（硬件、dtype、batch、baseline 版本）——「口径不可迁移」是本材料反复强调的一条；② **先复现 baseline**（拿不到论文的 baseline 数字就是没复现）；③ **单变量**；④ **同口径对照**（数据集要大于 L2、warmup 充分、取最小值）；⑤ **报告绝对数字 + 相对提升 + 硬件型号**。

Q199 **[开放]** 一个算子比业界慢 3 倍，你能接受吗？

答· **先算优化预算**：这个算子在 e2e 里占多少？占 10% 时，即使优化到业界最快也只有 10% 的 e2e 收益上界。然后决定要不要做。如果决定做，按 §6 的六步走；如果说这是热点，先说清「和谁比、在什么口径下比」——因为 3 倍这个数字几乎一定来自不同口径。

Q200 **[开放]** ★你怎么跟面试官讲一个项目？（STAR + 数字 + tradeoff）

答· 四段结构，**每段都要有数字**：① **背景与目标**（要解决什么问题，量化目标是什么）；② **我做了什么**（技术选型的原因，不是流水账）；③ **结果**（数字：延迟/吞吐/显存/成本改了多少，怎么测的）；④ **反思**（如果重做会改什么——这一段最能区分候选人）。**数字·**每轮面试都可能问项目，而且越问越深（「介绍」→「深入介绍」→「创新点和工业效果」）——准备一个能讲三层深度的项目，比多背 20 道八股重要。

§9 补充：那些「会就是会、不会就是不会」的知识点（Q201–Q225，25 题）

9.1 工具链与工程

Q201 **[基础]** Docker 里怎么让容器用上 GPU？

答· 装 **NVIDIA Container Toolkit**，用 `--gpus all`（或 `--runtime=nvidia + NVIDIA_VISIBLE_DEVICES`）。容器里需要驱动（由宿主机注入）和 CUDA runtime。**数字·**常见坑：① 容器内 `nvidia-smi` 看不到卡 ⇒ `NVIDIA_DRIVER_CAPABILITIES` 没开 `utility`；② **IPC 没开** ⇒ `--ipc=host`，否则 **CUDA IPC**（vLLM 的 custom all-reduce 依赖它）会失败；③ **共享内存太小** ⇒ `--shm-size` 不够会让 Ray/DataLoader 崩。

Q202 **[基础]** 怎么查看 GPU 状态与拓扑？

答· `nvidia-smi` (总量/进程/利用率)、`nvidia-smi dmon` (实时流)、`nvidia-smi topo -m` (拓扑: NV# / PIX / PHB / SYS)、`nvidia-smi -q` (详细, 含 ECC/功耗/时钟)、`nvidia-smi nvlink -s` (NVLink 状态)。

Q203 [进阶] 什么是 MPS / MIG? 什么时候用?

答· **MPS** (Multi-Process Service): 多个进程共享同一个 GPU context, 降低 context 切换开销、提高小 kernel 的利用率; **MIG** (Multi-Instance GPU): 硬件级切分 (A100/H100 起), 每片有独立的 SM/显存/L2, 提供强隔离。数字· **MIG 适合多租户强隔离; MPS 适合同租户内多进程协作。注意 MIG 会让 NVLink/P2P 能力受限, 影响 TP。**

Q204 [进阶] 版本兼容性怎么查?

答· 一张表: 驱动 → 支持的 CUDA runtime 上限; CUDA toolkit → 支持的 PyTorch/vLLM 版本; PyTorch → 编译时的 CUDA 版本 (`torch.version.cuda`); NCCL 版本 → 有哪些特性 (2.27.3 对称内存 window API → 2.28.3 Device API → 2.28.7 GIN → 2.29.2 host 侧单边 RMA → 2.31 CFT; 当前 2.32.3)。⚠ 常见错误: 说「NCCL 2.28 同时引入了 Device API 和 GIN」——这两个版本号不同 (2.28.3 / 2.28.7)。数字· **最保险的做法是跑一遍自检**: 本材料提供了 `provision_rented_gpu.py` (硬件/版本自检 + 特性可用性对照 + 建议实验套餐)。

Q205 [进阶] 怎么排查「编译能过但运行报 illegal memory access」?

答· ① `compute-sanitizer --tool memcheck` (定位越界/未初始化读); ② `CUDA_LAUNCH_BLOCKING=1` (把异步变同步, 定位是哪个 kernel); ③ **缩小 shape** (大 shape 才崩 → 越界或溢出); ④ **查尾 tile** (`N % bLock` 的边界处理)。

Q206 [进阶] Triton 和 CUDA 怎么选?

答· **Triton**: Python DSL, 开发快、自动做 swizzle/pipeline, 适合迭代频繁、形状多变的 kernel; **CUDA**: 能压到极限 (手写 PTX、warp specialization、TMA descriptor), 适合固定形状的热点 kernel。数字· **判据是「改动频率 vs 性能要求」** —— 原书的一个诚实结论: **CuTe 版的总代码并不更少** (手写 1530 行 vs CuTe 版 835 行), 差别在语义密度与改动的影响面, 不在行数。

Q207 [进阶] 算子融合的收益边界在哪?

答· 收益 = 省掉的中间张量读写 - 融合带来的额外开销 (寄存器压力、occupancy 下降、同步)。数字· **当 kernel 已经是 bandwidth-bound 且贴满带宽时, 融合省 launch 已无杠杆, 只有减流量才有。反例**: 把 bias 注入从分离 kernel 改成融合 + smem tile, **实测慢了 4.2 ms**, `sleeping` stall 从 3.5% 涨到 22.3% (LDS 进了关键路径、流水断供)。

9.2 精度与数值

Q208 [进阶] 混合精度训练为什么需要 loss scaling?

答· fp16 的**下溢** (梯度太小变 0) 比上溢更常见。loss scaling 把 loss 乘一个常数 S, 梯度整体放大 → 小梯度进入 fp16 可表示范围, 反传后再除回 S。**动态 loss scaling 会自动调 S** (遇到 inf/NaN 就减半、稳定若干步就翻倍)。数字· **bf16 不需要 loss scaling** (指数位与 fp32 相同, 动态范围够) —— **这是 bf16 在训练里胜出的主要原因。**

Q209 [进阶] 为什么量化后要做精度回归? 怎么做?

答· 因为量化是**有损的**，而且损失与数据分布强相关。做法：① **固定一批真实输入**（不是随机数据）；② **和 fp16/bf16 参考逐元素比**（用**相对误差 + 分位数**，不只看平均）；③ **看端到端指标**（困惑度、任务准确率）；④ **分层/分模块定位**（哪一层最敏感 $\Rightarrow$ 那一层保持高精度，即**混合量化**）。**数字·** 原书的分层误差排序：**V 量化 (0.19) > QK 量化 (0.13) > P 量化 (0.11)** $\Rightarrow$ 「只把 QK 换回 fp16」无效（V 是最大单项且纹丝不动），必须全链 fp16 (hybrid)。这是一个很好的「量化回归方法论」例子。

Q210 [hard] 什么是 lazy rescale？它和满量程量化为什么互斥？

答· **lazy rescale**：不即时重缩放 O，而是记住 `stale max`，等下一个 tile 的 PV 累加前再补乘——**省掉一次 rescale pass**。**互斥原因**：stale max 会让发射的 P 膨胀 2^{τ} ，而**满量程发射没有 headroom** $\Rightarrow$ 必然被 `satfinite` 钳位 $\Rightarrow$ **PV 结果损坏**。**数字·** fp8 的适用域 $2^T \cdot \text{amax}(V) \leq 448$ ，取 $T=4 \Rightarrow \text{amax}(V) \leq 28$ （FA-4 对 BF16 取 $\tau=8$ ，**跨家族搬阈值会直接撞 e4m3 天花板**）。

9.3 分布式杂项

Q211 [进阶] 什么是集合通信的「确定性」问题？

答· **浮点加法不满足结合律 + ring/tree 的累加顺序随 rank 数/拓扑变化** $\Rightarrow$ all-reduce 的结果**逐位不可复现**（换卡数、换拓扑就可能变）。**数字·** 影响：**训练的可复现性、以及「同一份输入两次结果不同」的 debug**。缓解：固定拓扑与算法（`NCCL_ALGO`）、或用确定性的累加顺序（代价是性能）。

Q212 [进阶] 通信库怎么选？NCCL / Gloo / MPI / 自研？

答· **NCCL**：GPU 间（NVLink/IB/RoCE），事实标准；**Gloo**：CPU 与故障排查（能做 NCCL 做不了的一些拓扑）；**MPI**：HPC 传统，在 AI 里多被 NCCL 替代；**自研**：当需要与计算 kernel 深度融合时（vLLM 的 custom all-reduce、MegaMoE 的对称内存通信）。**数字·** **vLLM 的 8 路 all-reduce 选择链**（见 `appendix-code-tour.md`）：`pynccl` / custom AR / quick AR（ROCm）/ FlashInfer / AITER / 对称内存 / torch 兜底——「**NCCL 是兜底而不是首选**」这个反直觉结论值得记住。

Q213 [进阶] 为什么推理框架要自己写 all-reduce？

答· 三个原因：① **NCCL 的懒初始化不能在 CUDA Graph capture 期间发生**（capture 时不能建连/同步）；② **小消息下 NCCL 的延迟不够低**（decode 每层两次 all-reduce，消息很小）；③ **要用 IPC/对称内存做单 kernel 的一步归约**，跳过 NCCL 的多 kernel 流水。**数字·** **H100 上 TP=8 时 custom AR 的硬上限是 256 KiB**，超了就回退 NCCL。

Q214 [进阶] 集群规模变大后，什么会先成为瓶颈？

答· ① **集合通信的步数**（ring 是 $O(N)$ 步 $\Rightarrow$ 延迟线性涨）；② **故障率**（几千卡的 MTBF 很低 $\Rightarrow$ 必须 checkpoint/容错）；③ **网络拓扑与拥塞**（多级交换、ECMP 哈希不均）；④ **存储带宽**（checkpoint 与权重加载）。**数字·** **这就是为什么大规模训练要用层次化通信（先机内后机间）与 topology-aware 的 rank 映射**。

9.4 前沿与加分项

Q215 [hard] 什么是 KV cache 量化？难点在哪？

答· 把 KV cache 从 fp16 降到 fp8/int8 $\Rightarrow$ **显存减半、decode 带宽减半**。难点：① **K 有 outlier**（需要 per-channel scale 或 smooth 技巧）；② **V 的量化误差直接进输出**（原书分层误差里 V 是最大单项）；③ **必须与 PagedAttention 的 block 布局兼容**（按 block 存 scale）。**数字·** 这是「用精度换并发」的典型——并发数上去，goodput 往往净赚。

Q216 [hard] 什么是 sparse attention？为什么不一定快？

答· 思路是只算一部分 KV (块稀疏 / top-k / 滑窗 + 全局 token)。为什么不一定快：① 稀疏模式必须能被 kernel 高效索引，否则省下的算力被索引开销吃掉；② 负载不均 (每个 query 的有效 block 数不同)；③ block 利用率低时实测可能比稠密还慢。数字· 关键实现要点：内部仍要用 online softmax，不能退回「先算完整分数矩阵再 mask」(那就没有收益了)。必须实测，不能只看理论 FLOPs。

Q217 [hard] 什么是 MLA？为什么它能省 KV cache？

答· MLA (Multi-head Latent Attention) 把 KV 压成一个低维隐向量 (而不是存完整的 K/V 矩阵)，推理时再投影出来。数字· 效果是 KV cache 大幅下降 (相比 MHA/GQA 又低一截)，代价是多了一次投影计算与实现复杂度。它属于「结构改动」，与 PagedAttention (「管理优化」) 是两个层面——这个区分是这一题的得分点。

Q218 [hard] chunked prefill 与 prefix caching 会互相干扰吗？

答· 会。prefix caching 命中时可以跳过整段 prefill；chunked prefill 则是把 prefill 切小块。两者一起用时：chunk 的边界与 block 的边界 (16 token) 不对齐会让 cache 命中率下降——所以实践中常把 chunk 大小设成 block 大小的整数倍。数字· 这是一个典型的「两个优化互相干扰」的例子，能主动说出来很加分。

Q219 [hard] 什么是 DBO 与 CUDA Graph 的冲突？

答· DBO 依赖 FULL CUDA Graph (把整个 ubatch 的执行 capture 成图，否则 yield 点的语义不成立)；而 -enforce-eager 会关掉 graph ⇒ DBO 静默失效。反过来，capture 期间不能建连/同步，所以 DBO 用到的通信必须预先初始化好。数字· 这是「两个优化互相干扰」的第二个例子 (第一个见 Q218)。

Q220 [hard] 什么是 MoE 的「冗余专家」？

答· 把热点专家复制多份放到不同 rank，让多个 rank 分担它的负载——用显存换负载均衡。EPLB 在线统计负载后决定复制谁、放哪。数字· 与 \$5 的 EPLB 是同一套机制的两面 (vLLM 里 EPLB 有独立通信组，按 window 1000 / step 3000 周期重排)。

Q221 [进阶] 你怎么跟进这个方向的进展？

答· 具体到可验证的动作：读 arXiv (FA/量化/推理系统的论文) + 读目标框架的 release notes 与 PR + 复现关键结果 + 写笔记。数字· 面试时给一个具体的例子 (「我读了 X 论文，在 Y 上复现了它说的 Z，发现我的环境下是 W」)——比说「我经常看论文」强一百倍。

Q222 [开放] 你觉得未来一年推理优化最重要的问题是什么？

答· 给一个有依据的判断，例如：① 长上下文的 KV cache 成本 (序列长度涨得比显存快)；② 低精度 (fp4/更低) 的稳定性 (原书记录 fp8 persist-D 在 D=192 有未修复的正确性 bug)；③ 异构与国产卡适配 (算子支持与精度对齐)；④ PD 分离后的调度与容错 (引入了跨节点中间状态)。数字· 要说出你为什么这么判断 (哪个趋势的数据支持)，不是说感觉。

Q223 [开放] 你怎么看「用 Triton 重写 CUDA kernel」这个趋势？

答· 分场景：形状多变的算子收益大 (开发效率)，固定形状的极致热点收益小 (Triton 还压不到 TMA/WGMMA 那一层)。数字· 判据是「改动频率 × 性能要求」的乘积；并且要注意 Triton 的性能对 autotune 配置很敏感，换版本/换卡都可能需要重调。

Q224 [进阶] 怎么做代码 review (在 AI Infra 项目里)？

答· 关注五件事：① 正确性边界 (shape/dtype/对齐/空输入)；② 性能回归 (有没有引入同步点、多余的拷贝、掉出 CUDA Graph)；③ 分布式一致性 (集合通信顺序、dtype、后端选择三一致)；④ 资源生命周期 (显存/句柄/连接的释放)；⑤ 可观测性 (加了指标没有)。数字· 本材料在写作时的 checkout 上发现的真

实缺陷就是很好的 review 素材：HF3FS connector 的 metadata URL 读了不用（死配置）、`_fail_task` 用 `False` 兑现 future（失败与完成无法区分）。

Q225 **【开放】★最后：你有什么问题问我们？**

答· 不要问薪资和加班。问这四类：① **团队现在最重要的技术问题是什么**（判断你是否真的感兴趣）；② **这个岗位的产出怎么衡量**（了解评价体系）；③ **代码/论文的开放程度**（能不能看到上下游）；④ **如果我入职，前三个月最可能做什么**（判断匹配度）。**数字·** 准备 2-3 个针对该公司产品的具体问题（用过他们的开源项目 / 读过他们的技术博客），**这比任何八股都更能体现诚意。**


§10 SOTA 模型架构与推理（DeepSeek / Qwen / Kimi 这一代）（Q226–Q255, 30 题）

J.1 DeepSeek：MLA + 细粒度 MoE（本代的架构分水岭）

为什么从 DeepSeek 开始：它是这一代被抄得最多的两个设计（MLA 与细粒度专家）的出处。Qwen / Kimi / MiniMax / GLM 的架构题几乎都能用 DeepSeek 做参照系来讲。

Q226 **【进阶】★ MLA（Multi-head Latent Attention）到底压缩了什么？**

答· 它压缩的是 **KV cache 的“存储维度”**，而不是序列长度。标准 MHA/GQA 要把每个 token 的 K、V 向量物化存下来；



图源: DeepSeek-AI, [DeepSeek-V2](#) (代码仓库 MIT; 模型权重另有许可), 技术报告 [arXiv:2405.04434](#)。看图找两处: ① attention 里那条细的 KV 通路 (就是 MLA 的 latent); ② FFN 里被切成很多小块的专家 (细粒度 + 共享专家)。

MLA 改成只缓存一个低维隐向量 c_{KV} , 推理时再投影出 K、V:

MHA :	每 token 每层缓存	$2 \times n_heads \times d_head$	
GQA :	每 token 每层缓存	$2 \times n_kv_heads \times d_head$	(KV head 少 → 省)
MLA :	每 token 每层缓存	$d_latent (+ d_rope)$	(只存隐向量 → 更省)

数字· 关键在于「不用物化」: 因为 $K = W_K \cdot c_{KV}$ 、 $V = W_V \cdot c_{KV}$ 都是线性的, QK^T 与 PV 可以把 W_K / W_V 吸收进相邻的权重矩阵里 (这就是所谓 **absorption / W_{absorb} 技巧**), 于是根本不需要显式构造 K、V。⇒ KV cache 从「按 head 数增长」变成「按一个隐维度增长」。

坑· 答「MLA 省 KV cache」只是第一层。追问通常会来: ① 它为什么可以“吸收” (因为投影是线性的, 矩阵乘法可结合); ② 代价是什么 (多了一次投影计算、实现复杂、而且必须和 RoPE 解耦——因为 RoPE 是位置相关的旋转, 破坏线性性, 所以要把一部分维度单独留给 RoPE、不参与压缩); ③ 为什么有些实现还保留 MHA 模式 (精度或算子支持不好时回退)。

Q227 [hard] 为什么 MLA 必须把 RoPE 那部分维度单独拎出来?

答· 因为 RoPE 是“位置相关”的旋转，它让投影不再是同一个线性变换。MLA 的压缩依赖「 W_K 与 W_Q 可以合并吸收」这件事，而 RoPE 对每个位置施加不同的旋转矩阵 $\Rightarrow$ 吸收的前提被破坏。所以工程上的做法是拆成两路：一路是可压缩的隐向量（不含位置信息，可以吸收），另一路是带 RoPE 的位置维度（单独走一套小 RoPE，不参与压缩）。数字· 这解释了为什么 MLA 的配置里会有 `qk_rope_head_dim / qk_nope_head_dim` 这类成对的参数名——一个给 RoPE，一个给可吸收部分。坑· 这是 MLA 最容易被追问到底的一题，也是区分「看过博客」与「读过报告」的分界线。答不出这一层，前面那句「MLA 省 KV cache」就变成了背诵。

Q228 [进阶] ★ 细粒度专家 (fine-grained experts) + 共享专家，为什么要这么设计？

答· 两件事分开说：

① 细粒度：把专家切得更小、数目更多，每个 token 激活更多个小专家。动机是组合数： E 个专家选 k 个的排列是 $C(E, k)$ ，切成 $2E$ 个小专家再选 $2k$ 个，可选组合数远大于原来 $\Rightarrow$ 同样激活参数量下，模型能表达的“专家组合”更多，也就是参数利用更充分。代价：路由与通信的粒度更细（all-to-all 的元数据变多、负载更碎）。

② 共享专家 (shared expert)：留固定几个专家对所有 token 都激活。动机是把“公共知识”与“专业知识”解耦——通用能力（语法、常识、格式）不需要每个专家都学一遍，由共享专家统一承担，其他路由专家就能更专注在自己的领域上，减少专家之间的知识冗余。

数字· 对部署的影响（面试官真正想要的）：细粒度意味着专家更多、EP 的切分更碎、all-to-all 的批更小——通信次数与元数据开销上升，这正是 EPLB（专家负载均衡）与通信 kernel 融合（附录 F 的 MegaMoE）要解决的问题。坑· 只答“专家多就好”是错的：细粒度的收益是表达能力，代价是通信与调度。能主动说出这个 tradeoff 才算答对。

Q229 [hard] 无辅助损失的负载均衡 (auxiliary-loss-free) 是怎么做的？

答· 传统做法是在损失里加一项“路由均衡损失” (auxiliary loss)，逼模型把 token 均分给专家——代价是这项损失会和语言建模目标打架，损害效果。auxiliary-loss-free 的做法是：不改损失，改路由的打分——给每个专家维护一个偏置项 b ，只在选择 top-k 时加到打分上（不参与梯度），根据最近一个 batch 里该专家的负载，把 b 微调一下：

负载过高 $\rightarrow$ 该专家的 b 调小一点

负载过低 $\rightarrow$ 该专家的 b 调大一点

数字· 关键性质： b 只影响“选谁”，不影响路由权重的数值（权重仍来自原始打分），所以它不改变模型的数学表达能力，只是在分配上做偏置——这才是“无辅助损失”的含义。坑· 追问几乎一定会来：「那会不会只靠它还不够？」答：实践中还会补一条序列级的辅助损失来控制单条序列内的极端不均衡（因为纯 bias 调整是“统计意义上”的，个别样本仍可能全压在一个专家上）。能主动说出“还需要一条序列级补丁”，说明你看过报告而不只是标题。

Q230 [hard] MTP (Multi-Token Prediction) 在训练和推理时各怎么用？

答· 训练时：在主干之外挂若干额外预测头，让模型一次预测未来多个 token（不只是下一个），作为辅助训练目标。动机是更强的表示学习：要预测更远的 token，模型必须把更长的上下文“想清楚”。

推理时（这才是面试关心的）：MTP 模块可以当成内置的投机解码 draft 模型——用 MTP 头先猜出后面若干个 token，再让主模型一次 forward 验证。好处是不需要外挂一个独立的 draft 模型（省显存、省部署复杂度）。数字· 这就是 §4.2 讲过的投机解码机制，只不过 draft 来自模型自己 (self-speculative)，所以接受率

通常比外挂小模型更高（因为 draft 和主模型共享表示）。加速比要标口径，取决于任务与 batch：batch 大时 decode 已偏向 compute-bound，“省权重读取”的收益会被摊薄（这条在 §4.2 已经讲过）。坑· 别把 MTP 说成“必须开”：它有额外算力开销与实现复杂度，很多部署根本不开或者只在特定场景开。

Q231 [hard] FP8 训练里 per-block 量化为什么用 1×128 这样的形状？

答· 因为激活的 outlier 是按通道/按 token 分布的 (§2.7 Q53)，整块一个 scale 会被 outlier 毁掉。把 scale 粒度做细——例如激活用 1×128 的块（沿某个维度每 128 个元素一个 scale）——就能让 outlier 只影响自己那一小块。数字· 三个关键设计：① 高精度累加（低精度乘 + fp32 加），否则长 K 的误差会累积；② scale 用 2 的幂（e8m0 之类）——因为乘 2 的幂是精确的、不需要额外舍入，而且可以直接折进指数位 $\Rightarrow$ 减少一次乘法和一次舍入；③ scale 本身也要存（这是“省了数据、多了元数据”的典型取舍）。坑· 面试里可能问「既然 FP8 训练能行，为什么推理不直接用 FP8 权重+激活？」答：推理还要考虑算子支持、精度回归成本、以及 KV cache 是否也量化——这些是工程决策，不是“能跑通就算完”。

Q232 [hard] MLA 的 KV cache 到底比 GQA 小多少？给出算法。

答· 按每 token、每层的字节数算（fp16 = 2 B）：

GQA: $2 \times n_{kv_heads} \times d_{head} \times 2 \text{ B}$

MLA: $(d_{latent} + d_{rope}) \times 2 \text{ B}$ $\leftarrow$ 只存隐向量 + 那一小段带位置的维度

数字· 举个结构上的对比（用示意值，具体以模型配置为准）：若 $n_{kv_heads} = 8$ 、 $d_{head} = 128 \Rightarrow$ GQA 是 $2 \times 8 \times 128 \times 2 = 4096 \text{ B}$ ；若 MLA 的隐维度 + RoPE 维度合计约 $512 + 64 = 576 \Rightarrow 576 \times 2 \approx 1152 \text{ B}$ 。 $\Rightarrow$ 差 3-4 倍量级。坑· 两个容易算错的地方：① 不要漏掉 $\times 2$ （fp16 是 2 字节）与 GQA 的 K/V 两份；② MLA 与 GQA 不是同一层的对比——GQA 是“减少 head 数”，MLA 是“改变缓存的对象”（存隐向量而不是存 K/V）。能说清“它们不在同一个抽象层”，比算对数字更能体现理解。

Q233 [进阶] DeepSeek 系的 KV cache 用 FP8 之后，瓶颈变了吗？

答· 变的是容量，不一定是吞吐。KV 量化让同样显存能装的 token 数翻倍 $\Rightarrow$ 并发上限提高 $\Rightarrow$ 在 decode（memory-bound）场景里 goodput 直接受益。但如果瓶颈本来在通信或调度上，KV 减半不会让它们变快。

数字· 这就是 §4.3 那条结论的具体化：量化的收益在“省字节”，而 decode 是 memory-bound，所以收益显性；prefill 是 compute-bound，KV 量化的收益有限（它省的是读 KV 的带宽，而 prefill 的算力压力来自矩阵乘）。坑· 别忘了量化的代价：多一套 scale 的存取、精度回归、以及某些 attention 后端可能不支持——这些都要在答“收益”时一起说。

Q234 [open] 如果让你给一个 671B / 37B 激活的 MoE 做单机部署，你先算什么？

答· 四步，顺序不能反：

1. 权重显存：总参数 $\times$ 每参数字节 $\div$ EP 切分数——注意 MoE 是“总参数大、激活参数小”，所以显存按总参数算，算力按激活参数算；
2. KV cache：用 Q232 的公式，这是决定并发的那个数；
3. 通信预算：EP 越大，all-to-all 越多——按 §5.4 的算法估每 token 要发多少字节、跨多少跳；
4. 然后才谈吞吐：先确认“装得下 + 通信不爆”，再谈优化。

数字· 一句能定调的话：「MoE 的显存瓶颈是总参数，算力瓶颈是激活参数，通信瓶颈是激活参数 $\times$ top-k $\times$ 序列长度——这三者要分开算，混在一起就会得出错误结论。」坑· 最常见的错误答案是“上量化就行”——量化解的是第 1、2 步，解决不了第 3 步（通信量由 token 数与专家路由决定）。

J.2 Qwen: 工程上的“标准答案” (GQA + QK-Norm + 全面开源)

Qwen 系的特点不是某个炫技机制，而是“每个选择都做对了”——GQA、QK-Norm、RoPE 外推、以及尺寸覆盖极全的密集 + MoE 双线。面试里问 Qwen，考的往往是基础机制的扎实程度。

Q235 [基础] ★ MHA / GQA / MQA 的区别？为什么现在几乎都选 GQA？

答· 三者是 KV head 数的不同：

方案	Q head	KV head	KV cache	表达力
MHA	h	h	最大	最强
GQA	h	g ($1 < g < h$)	按 g/h 缩减	接近 MHA
MQA	h	1	最小	有损

为什么选 GQA：decode 是 memory-bound (§3.3 Q73)，KV cache 的读取量直接决定每 token 的时间；而 GQA 在几乎不损失质量的前提下把 KV cache 按比例缩小 $\Rightarrow$ 同样显存能开更大 batch $\Rightarrow$ 吞吐与并发同时受益。

数字· g 的取值要看“省到哪一档才够”：Qwen 系各尺寸的 KV head 数不同，但共同点是 $g < h$ 且 $g \geq 1$ 的折中。报数字前先查你手上那份 config (num_key_value_heads)，不要背。坑· 追问链：①「GQA 对 prefill 有收益吗？」（有，但小——prefill 是 compute-bound）；②「MQA 为什么不流行？」（KV head = 1 时表达力损失明显，GQA 是更甜的折中）；③「MLA 和 GQA 谁更省？」（见 Q232——不在同一个抽象层）。

Q236 [进阶] ★ 什么是 QK-Norm？它解决什么问题？

答· 在计算 attention 打分之前，对 Q 和 K 各做一次归一化（通常是 RMSNorm，作用在 head_dim 那一维）。解决的是训练稳定性：注意力 logits $QK^T/\sqrt{d}$ 的幅度会随训练失控式增长（尤其在长上下文、以及低精度 (bf16/fp16) 训练时），表现为 loss spike、梯度爆炸。QK-Norm 把 Q、K 的尺度钉住 $\Rightarrow$ logits 幅度可控 $\Rightarrow$ 训练更稳。数字· 推理侧的重要副作用（面试官爱问）：QK-Norm 是逐 head、沿 head_dim 的归一化，所以它可以和 RoPE 正交地作用（归一化不改变旋转的相对结构）——这也是它能和 RoPE 共存的原因。坑· 别把它和 LayerNorm/Pre-Norm 混为一谈：QK-Norm 只作用在 attention 内部的 Q/K 上，不替代主干上的 pre-norm。

Q237 [进阶] 为什么主流模型的 head_dim 大多是 128？

答· 三个约束共同把答案挤到 128 附近：

1. **Tensor Core 的形状**：head_dim 要能被子 tile 整除 (§3.4 Q77 的 m16n8k16 要求 K 维是 16 的倍数)，128 是最省心的对齐；
2. **算术强度**：head_dim 越大，每个 KV head 被复用的次数越多 (attention 的 $AI \approx Br$ ，与 D 相关) $\Rightarrow$ 大 head_dim 对带宽友好；
3. **寄存器与 smem 预算**：attention 的 0 累加器每线程占 $kBr \cdot D/256$ 个寄存器 (§3.1 Q60 那条公式)，D 越大越容易撞 255 墙 $\Rightarrow$ D=128 时堆叠 8 个 warp 还在预算内，D=512 就必须换 M4N2 atom（同一个公式在 §3.1 Q60）。

数字· 所以 128 不是“随便定的”，而是“三面夹击下的可行区”；模型里出现的 192 / 256 之类的非 2 次幂 head_dim，恰恰是为了别的目标（如压缩 KV）而牺牲了这条便利，于是必须靠 Split-D / 换 atom 来补回来。

坑· 这题最好的答法是把三个约束都说出来，再说“128 是交集”——只答“因为对齐”会被追问到寄存器预算上。

Q238 [进阶] 长上下文是怎么“扩”出来的？

答· 分三层，别混为一谈：

- 1. 位置编码外推（训练后处理）：改 RoPE 的 base / 频率缩放（如 NTK / YaRN 之类），让没训过的长度也能有合理的位置关系——便宜，但能力会衰减；
- 2. 继续训练（中训/长文微调）：在长文本数据上继续训练，让模型真的学会用长上下文——贵，但有效；
- 3. 推理侧的注意力技巧：滑窗、稀疏、分块、线性注意力混合——降的是成本，不增加能力。

数字· 面试里要主动说的三件事：① “支持 1M 上下文”和“在 1M 上表现好”是两码事——要看长文基准（如 needle-in-a-haystack / RULER 类）的实测；② KV cache 随长度线性涨（\$4.1 Q94），1M 上下文的 KV cache 是主要显存开销；③ 所以长上下文的能力与成本必须一起答。坑· 只答“用了 YaRN”是不够的——YaRN 属于第 1 层，真正让模型“会用”长上下文的是第 2 层。

Q239 [进阶] 多模态模型（Omni）在推理上比纯文本模型多了什么？

答· 至少多四样，每一样都可能成为瓶颈：

- 1. 编码器（视觉 / 音频）：多了一个前处理网络，它的算力与显存占用与序列无关但与分辨率/时长成正比；
- 2. 模态对齐/投影层：把编码器输出映射到语言模型的隐空间，通常是一个 MLP 或 Q-Former 类的结构；
- 3. 位置编码要处理“时间”：音频是流式连续的，视频有帧间与音画同步的问题——这就是 Q240 要讲的 TMRoPE；
- 4. 输出侧可能是“双轨”的：文本与语音同时生成 $\Rightarrow$ 两套解码循环，延迟与显存都要分别算。

数字· 对部署的直接后果：① 首包延迟（TTFT）被编码器支配——纯文本模型的首 token 只等 prefill，而 Omni 还要等编码完成；② 流式（streaming）能力变成核心指标——用户听到第一个音节的时间（不是第一个 token 的时间）才是体感延迟；③ KV cache 的构成变复杂（文本 token + 模态 token + 可能还有 Talker 的状态）。坑· 别把 Omni 当成“多接了一个 encoder”——流式交互（边说边生成、可打断）才是它和“多模态理解模型”的本质区别。

Q240 [hard] ★ TMRoPE 是什么？为什么多模态需要它？

答· TMRoPE 要解决的是“时间”这个模态独有的问题：文本的位置就是序号，而音频/视频的位置是真实时间，并且不同模态的时间轴要对齐（第 3 秒说出的词，对应第 3 秒的画面）。

核心思路：把 RoPE 拆成多个轴分别施加——时间轴、高度轴、宽度轴（视频）/ 频率轴（音频），于是位置编码从“一个数”变成“一组数”，模型就能表达「同一时刻的不同空间位置」与「不同模态在同一时刻的对应关系」。

数字· 为什么必须这么做：① 如果只用一个线性序号，模态之间的时间对齐信息就丢了，模型得从零学“第 3 秒的音对应第 3 秒的画”，样本效率极低；② 视频的 token 数 = 帧数 $\times$ 每帧 patch 数，单轴编码会让“帧内相邻”和“帧间相邻”的语义混在一起；③ 多轴编码让插值/外推可以分轴做（只延长时长不必重训空间分辨率）。

坑· 追问几乎一定会来：「那它和 2D RoPE（图像）什么关系？」答：2D RoPE 是 TMRoPE 在“没有时间轴”时的特例——图像只有高/宽两轴，视频/音频才需要第三轴（时间）。能把它归约到已知方案上，说明你真的理解了而不是背名词。

Q241 [hard] Omni 模型的“双轨”（Thinker / Talker）为什么要分开？

答· 因为文本与语音的生成节奏和依赖结构完全不同：

	文本	语音
单位	token（离散、变长）	音频帧/codec token（固定帧率，如 25–50 帧/秒）

	文本	语音
节奏	想停就停	必须连续，卡一帧就听出来
依赖	只看文本上下文	还要看声学状态（韵律、音色）

分开的好处：① **文本可以慢、语音必须稳** —— 两条流各自按自己的节奏跑，互不阻塞；② **可以打断**（barge-in）：用户插话时**只中断 Talker**，Thinker 的状态不用重来；③ **可替换**：Talker 换成不同的音色/语言，Thinker 不用动。

数字· **代价**：两套状态 $\Rightarrow$ **显存与调度的复杂度上升**；而且**两条流之间要同步**（Talker 要拿到 Thinker 的语义表示），**这个同步点就是延迟的关键路径**。坑· **别把它和“双塔”搞混**：双塔通常指两个独立编码器；这里的 Thinker/Talker 是生成侧的流水线分工。

Q242 [进阶] **流式语音生成的低延迟是怎么做到的？**

答· 四个手段（按对延迟的贡献排序）：

- 1. **分块（chunk）输入/输出**：不等整段音频/整句话，**按小块滚动处理** $\Rightarrow$ 首包延迟从“整句时间”降到“一个 chunk 时间”；
- 2. **Lookahead（有限前瞻）**：只看未来若干帧就出决策 —— 在“够准”与“够快”之间取一个固定窗口，这是延迟与质量的旋钮；
- 3. **不走“文本再合成”的两段式**：直接**文本 token $\rightarrow$ 音频 token**，省掉一次文本 $\rightarrow$ 声学的串行（但需要更强的对齐训练）；
- 4. **codec 的帧率与带宽**：音频 token 的**帧率决定了下限** —— 25 帧/秒意味着每 40 ms 一个决策，**帧率越低越难做自然语音**。

数字· **面试要说的关键区分**：**首包延迟**（用户听到第一个音的时间）与**吞吐**（能同时服务多少路）**是两个指标**，而且经常互相矛盾（chunk 越小延迟越低、但算力利用率越差）。坑· **“RTF < 1 就是实时”是个常见误解** —— RTF 是“生成 1 秒音频要几秒算力”，**它不保证交互体验**；真正要看的是**首包延迟 + 卡顿率**。

J.3 Kimi / MiniMax / GLM：长上下文与线性注意力的三条路线

Q243 [进阶] ★ **长上下文的三种技术路线是什么？各自的代价？**

答· 三条路线在“省什么”上完全不同：

路线	做法	省的是	代价
① 压 KV （MLA / GQA / KV 量化）	让每个 token 的缓存更小	容量与带宽 （线性系数）	表达能力/精度；实现复杂
② 改注意力 （线性注意力 / 滑窗 / 稀疏）	让复杂度 不再 $O(N^2)$	算力与缓存（次线性）	长程依赖可能丢； 常需混合全注意力层补回
③ 位置外推 （RoPE 缩放 / 继续训练）	让模型能处理更长的位置	不省成本，只换能力	需要训练；外推能力有上限

数字· **核心洞察**（面试官想听的）：① 和 ② 是“降成本”，③ 是“提能力” —— 它们不是替代关系，而是叠加使用：真实模型几乎是 **MLA/GQA（①）+ 少量全注意力层（②）+ 位置外推与长文继续训练（③）** 的组合。能画出这张“正交”的表，这题就满分了。

Q244 [hard] **混合线性注意力（linear + full attention 交替）是怎么工作的？为什么要混合？**

答· 纯线性注意力的问题：它没有“完整历史”的精确检索能力——线性注意力的状态是固定大小的递推状态（类似 RNN），回顾很远的、需要精确匹配的内容时会丢信息（这正是 attention 相对 RNN 的优势所在）。纯全注意力的问题： $O(N^2)$ 的算力与线性增长的 KV cache。

混合的做法：大部分层用线性注意力（便宜、常数状态），少数层用全注意力（精确、但贵） $\Rightarrow$ 用少量昂贵层提供“精确检索”，其余层提供“廉价的长程流动”。
数字· 推理上的关键收益：线性注意力层没有随序列增长的 KV cache（状态是固定大小） $\Rightarrow$ KV cache 总量可以显著下降，长上下文才真正“用得起”。代价：kernel 实现更复杂（两种层、两套状态管理）、不能简单地用“两个矩阵乘”表示（很多优化库不直接支持）。
坑· 追问：「那层数怎么分配？」——这是模型设计的核心超参，不同模型的答案不同；面试时说出“分配比例是延迟与能力的旋钮”就够了，不要硬背某个模型的层号。

Q245 [hard] 为什么“线性注意力 + 全注意力混合”在部署上比纯 MLA 更难优化？

答· 三个具体原因：

1. 状态不再是“KV cache”这种东西——线性层维护的是递推状态（固定大小、按层分布），全注意力层维护的是 KV cache（按 token 增长） $\Rightarrow$ 显存管理、前缀缓存（prefix caching）、PD 分离的 KV 传输都要分两套逻辑；
2. 前缀缓存失效：prefix caching 依赖“同一段前缀的 KV 完全一致”（§4.1 Q97），而线性层的状态是从序列开头递推出来的 $\Rightarrow$ 不能像 KV cache 那样任意切块复用（除非该实现专门支持状态检查点）；
3. 算子生态：主流 attention 后端（FlashAttention / FlashInfer）不认识线性层， $\Rightarrow$ 需要自研 kernel，融合与量化都要重做。

数字· 一句话总结：它把“一个显存池 + 一套缓存策略”变成了“两套”，部署复杂度是非线性上升的。这是“架构先进”与“工程好落地”冲突的典型例子。

Q246 [进阶] 1M 上下文的 KV cache 到底有多大？先算什么？

答· 用 §4.1 Q94 的公式，但要按 1M 的长度重算：

```
KV cache = 2 × layers × kv_heads_per_rank × head_dim × seq_len × batch × bytes
```

数字· 量级直觉（面试时要能现场估）：以 layers=60、kv_heads=8、head_dim=128、fp16、seq=1M、batch=1 为例： $2 \times 60 \times 8 \times 128 \times 1e6 \times 2 \approx 246 \text{ GB}$ ——单条 1M 请求就要几百 GB 的 KV。 $\Rightarrow$ 所以长上下文不可能“裸跑”，必须叠加：KV 量化（ $\div 2$ 或 $\div 4$ ）+ GQA/MLA（ $\div 3 \sim 4$ ）+ 稀疏/滑窗（ $\div N$ ）+ 分页管理。
坑· 面试官爱问的顺序是：「1M 上下文要多少显存？」 $\rightarrow$ 「你怎么降下来？」 $\rightarrow$ 「降下来之后瓶颈在哪？」第三问的答案通常是“prefill 的算力”或“跨节点的 KV 传输”，不是显存——能答到第三问才算完整。

Q247 [open] 让你选一个模型做长文 RAG，你选密集还是 MoE？为什么？

答· 看瓶颈在哪，不是看参数量。给出一条可辩护的推理链：

1. RAG 的特征：长输入、短输出（读一堆文档、答一句话） $\Rightarrow$ prefill 主导（compute-bound） $\Rightarrow$ 激活参数少 = 便宜；
2. MoE 的优势：总参数大（知识多）、激活参数小（算得少） $\Rightarrow$ 在 prefill 主导的场景里，MoE 的性价比通常更高；
3. 但 MoE 的代价：显存要装下全部专家、通信要 all-to-all $\Rightarrow$ 单机装不下时不划算；
4. 所以判据是：显存够放总参数 且 通信不是瓶颈 $\Rightarrow$ 选 MoE；否则选密集（或者更小的 MoE）。

数字· 主动说出反面：「如果是高并发、短输入的在线服务，MoE 的优势会缩小，因为那时瓶颈回到 decode 的权重读取——而 MoE 在 decode 时每 step 要读的专家仍然不少，加上通信开销，可能还不如一个小的密集模型。」

坑· 这题没有标准答案，看的是“有没有把场景翻译成瓶颈”。把“我选 X 因为 Y 指标”说清楚，比选对更重要。

J.4 这一章的答法（怎么回答“你了解新模型吗”）

Q248 [开放] 面试官问「你了解 Qwen3 吗」，怎么答？

答· 不要背参数表。用四步结构：

1. 定位：它是密集 + MoE 双线的通用底座，特点是尺寸覆盖全、开源彻底、生态适配最好（vLLM/SGLang 都是第一时间支持）；
2. 结构上值得说的两点：GQA（为什么选 GQA，见 Q235）+ QK-Norm（解决什么稳定性问题，见 Q236）；
3. 工程上值得说的一点：长上下文能力与成本要一起谈（Q238）；
4. 和我做过的活的联系：「我在部署时遇到过 X，这个结构里对应的是 Y」——这一段才是加分项。

坑· 最容易被扣分的两种答法：① 背参数（面试官随时可以问“那 `num_key_value_heads` 是多少”，背错就崩）；② 只说“很厉害”（没有机制、没有 tradeoff）。

Q249 [开放] 面试官问了一个你完全不了解的模型，怎么办？

答· 五步，这一步比知识本身更值钱：

1. 先要规格：「它的参数量量级 / 是密集还是 MoE / 上下文多长？」——这三个决定一切；
2. 用已知框架推：MoE $\Rightarrow$ 显存按总参数、算力按激活参数、通信按 top-k；长上下文 $\Rightarrow$ KV cache 是最大开销；多模态 $\Rightarrow$ 首包延迟被编码器支配；
3. 说出你的推断而不是装懂：「如果是 MoE，我猜它的部署瓶颈会是 all-to-all，除非他们做了通信融合」；
4. 承认边界：「具体到这个模型的设计选择我没读过报告，但我可以从这几个约束反推它大概会怎么选」；
5. 反问：「你们内部用它主要解决什么问题？」——把面试变成技术讨论。

数字· 这条最容易被低估：面试官问“你了解 X 吗”时，往往在测“你面对未知时的推理方式”，而不是“你背了多少”。能在一个不熟的模型上给出结构化的推断，比背对参数更得分。

Q250 [开放] 你怎么跟进这个方向的进展？

答· 给可验证的动作，不要给态度：

1. 读一手：官方技术报告 / 模型卡 / 开源仓库的 release notes（不读二手解读，二手会丢关键约束）；
2. 跑一手：把新模型在 vLLM 上跑起来，看启动日志的 KV cache 与并发上限——这比看论文更快建立直觉（\$4.1 Q96 讲的那两行日志）；
3. fit 一手：把它塞进你熟悉的框架里（显存够不够、EP 怎么切、通信多少）；
4. 写下来：一句话结论 + 数字 + 口径。

数字· 面试里给一个具体的例子：「我在 X 卡上跑了 Y 模型，启动日志显示并发上限 Z，和按公式估的 W 差多少，原因是我没算上 A」——这一句话的说服力超过整段“我很关注前沿”。

J.5 最新一代（2025–2026）：架构在往哪走（Q251–Q255）

这一节存在的理由：J.1–J.3 讲的是**机制**（MLA / 细粒度专家 / GQA / 混合线性注意力）。但这一代模型**每隔几个月换一次注意力方案**，面试官完全可能直接问「DeepSeek-V4 你了解吗」「Kimi K2 为什么把头砍一半」。这一节给「方向」，不给「参数表」——方向要记住，参数现查。

下面五题都是 **2025 下半年到 2026 年** 的真实变化，每题都能在 `_sota_ref/` 的三份底稿里找到逐条出处。

Q251 [hard] ★ DeepSeek-V4 把 MLA 换掉了吗？换成什么了？

答· **换了**。2026-04 的 V4 Preview 里，MLA 被一套**混合注意力**取代：

成分	作用
滑窗注意力（多数层）	只看局部窗口 —— 压的是 读取范围
CSA（compressed sparse attention, <code>m=4</code> ）	周期性插入的稀疏/压缩注意力
HCA（heavily compressed attention, <code>m'=128</code> ）	压缩得更狠的那一路，负责“全局但便宜”

同时还有三处配套改动：残差从标准残差改成 **mHC**；专家亲和度打分从 `Sigmoid` 换成 `Sqrt(Softplus(.))`；去掉了节点受限路由的 `n_group` / `topk_group`；前几层改用 **hash MoE**。

数字· V4-Pro **1.6T 总 / 49B 激活**、V4-Flash **284B / 13B**、上下文 **1M**。把稀疏度算出来更说明问题：V4-Pro $1.6T \div 49B \approx 33\times$ ，而 V3 是 $671B \div 37B \approx 18\times$ —— **总参数涨了，激活参数涨得慢，稀疏度几乎翻倍**。

坑· ① **别说“V4 还是 MLA”**；② **别把 V4 的数字和 V3 混着引用**（层数、hidden、专家数 因为权重 gated **官方没公布**，说了就是编）；③ **一定要说出这一代的方向**：

MLA 压的是“每个 KV 有多大”（省显存），V4 这一代压的是“要读多少个 KV”（省算力）。

数字· 这是长上下文时代**必然的转向**：序列到 1M 时，注意力算力是 $O(L^2)$ 而 KV 容量是 $O(L)$ ，**不压读取范围，算力先崩**。

Q252 [hard] DeepSeek-V3.2 的 DSA（稀疏注意力）是什么？为什么能省？

答· **DSA = DeepSeek Sparse Attention**。原来的 attention 是「**每个 query 看全部历史 KV**」，DSA 改成两步：

- ① 轻量 **indexer** 先给历史 KV 打分 ← 便宜（低维 + FP8）
- ② 只取 **top-k** 个 KV 块做真正的注意力 ← 贵的那步只看一小撮

所以它压的是「**要读多少个 KV**」，和 MLA 压「**每个 KV 有多大**」是**正交**的两件事 —— **V3.2 是“MLA + DSA”叠加，不是替代**。

数字· $\text{top-k} = 2048$ （token 级），复杂度从 $O(L^2)$ 降到 $O(L \cdot k)$ ；官方实现的 indexer 是 **64 头 × 128 维**，打分用 **ReLU + FP8**；⚠ **注意口径**：所谓「Hadamard 旋转」并没有出现在官方的 **README** 或任何一份技术报告里 —— 它只以 `rotate_activation()` 的形式存在于官方参考实现 `inference/model.py` 中，作用在 **FP8**

量化之前（社区普遍认为它是 Hadamard 变换，但官方没有给名字，也没给理由）。面试时请说「官方代码里有一个 `rotate_activation`」，别说「官方说用了 Hadamard」。另：官方 H800 SXM5 上 DSA 给的是 **640 / 410 TFLOPS** 两个数（dense / sparse），indexer 自己的 K cache 也是 **blockwise FP8**。训练分两步：dense warm-up **2.1B tokens**（LR $1e-3$ ，1000 step $\times$ 16 seq $\times$ 128K） $\rightarrow$ sparse 训练 **943.7B tokens**（LR $7.3e-6$ ）。

坑· 面试官常追问代价：多了一个 indexer 的前向 + 一次 top-k 选择，这是 **decode 路径上的固定开销**（每步都要做），只有序列足够长、省下的 KV 读取量能盖过它才划算——短序列上 DSA 是负收益。能主动说出“它有个 **crossover 长度**”的人非常少。

Q253 [hard] ★ Kimi K2 为什么把 attention head 从 128 砍到 64？

答· 这是「头数不是越多越好」的最好例子，而且官方给了算得出来的理由。K2 论文原话：

with a sequence length of 128k, increasing the number of attention heads from 64 to 128, while keeping the total expert count fixed at 384, leads to an 83% increase in inference FLOPs.

关键洞察：MLA 把 KV 的存储和 head 数解耦了，但没有把 Q 的上投影和 attention 计算解耦——它们仍然随 head 数线性增长。而 K2 已经在 **61 层 + 384 个专家**上，推理 FLOPs 的预算被 MoE 占掉了大半，再加头数不划算。

数字· K2 = **1T 总 / 32B 激活**（⚠ 32B 是激活，不是总量）、61 层（1 层 dense）、**384 routed + 1 shared**、MLA 维度与 V3 完全相同（`q_lora_rank 1536`、`kv_lora_rank 512`、`qk_nope 128`、`qk_rope 64`、`v_head_dim 128`），只有 `num_attention_heads` 是 64（V3 是 128）。长上下文靠位置编码外推：YaRN `factor 32`、`rope_theta 50000`、`original_max_position_embeddings 4096`。没有 MTP（`num_nextn_predict_layers: 0`）。

数字· 训练稳定性用的是 **MuonClip = Muon + QK-clip**：按 head 算 $S_{\max} = (1/\sqrt{d}) \cdot \max(Q_i K_j^T)$ ，超过阈值 $\tau = 100$ 就缩放该 head 的 Q/K 投影， $\gamma = \min(1, \tau/S_{\max})$ ，朴素做法是 $W_q \leftarrow \gamma^{0.5} W_q$ 、 $W_k \leftarrow \gamma^{0.5} W_k$ 。MLA 的特殊处理（高频考点）： q^C 、 k^C 各乘 $\sqrt{\gamma}$ ， q^R 乘 γ ，而 k^R 是跨 head 共享的、必须不动——动了就会连累其他 head。结果：**15.5T tokens 训练零 loss spike**（小规模用原版 Muon 时 logits 会冲到 1000 以上）。

坑· ① 说 K2 用线性注意力——K2 是纯 MLA，混合线性注意力是 Kimi Linear；② 说 K2 有 MTP——没有；③ 只答“64 头更省”而说不出为什么 MLA 没能把这件事也省掉。

Q254 [hard] ★ MiniMax 为什么从混合线性注意力“退回”全注意力？

答· 因为这是效率注意力路线最重要的一个反例，面试里非常好用。MiniMax 的 Text-01 / M1 是 **Lightning（线性）注意力 + softmax 全注意力 = 7:1**（80 层 = 70 线性 + 10 全注意力），把 1M 上下文的 KV 成本压到只剩 10 层；但 M2 明确退回「**全层全注意力 + GQA**」。

官方技术报告原话：

M2 adopts full multi-head attention across all layers, departing from the hybrid design used in MiniMax-Text-01 ... we found no variant that reliably matches full attention quality in production settings spanning reasoning, coding, and agent tasks.

官方还专门发了一篇博客《Why Did M2 End Up as a Full Attention Model?》，自曝 hybrid 的代价是**复杂多跳推理出现明显缺陷**，并承认试过 hybrid SWA 但“性能不够好”（连 inter/intra-layer 两种混法都失败了）。

数字· M2 = 62 层 / 229.9B 总 / 9.8B 激活 / 256 细粒度专家 + sigmoid 门控 + 可学习专家偏置（use_routing_bias，与 DeepSeek 的 aux-loss-free 同源） / 48 Q 头 : 8 KV 头 / 192K 原生上下文 / 3 个 MTP 模块 / 预训练 29.2T tokens。KV 代价：62 层全注意力 = 248 KiB/token (BF16)，官方口径 240 GB / 1M context tokens。对照 Text-01：只有 10 层要存 KV (40 KiB/token)，另外 70 层的状态与长度无关。

坑· ① 别把 M2 讲成“更高效的注意力”——它是**反向的**；② 也别因此说“线性注意力没用”：同期 Kimi Linear 的数字是 KV cache 降 up to 75%、1M 上下文解码吞吐 up to 6× (TPOT 1.84 ms vs 11.48 ms)，而且质量也更好 (MMLU-Pro 51.0 vs 47.2、RULER 128k 84.3 vs 81.3)。两家结论相反——这恰恰是标准答案：

「效率注意力“能不能用”不是理论问题，是任务分布问题。」推理/代码/agent 这类多跳任务对注意力精度最敏感，所以 M2 选择退回；而纯长文检索类任务上，Kimi Linear 的收益是实打实的。

把两边都摆出来、并说出“取决于任务”，比站队更像做过功课的人。

Q255 [进阶] ★ Qwen3 的 thinking / non-thinking 双模式，对推理框架意味着什么？

答· 两个模式**共用同一份权重**，靠 chat template 的 enable_thinking 开关切换（默认 True）。所以对框架来说它是**同一个模型的两种流量形态**，不是两个模型。它带来四个很具体的 infra 后果：

#	后果	为什么
①	输出长度分布双峰	thinking 模式动辄几千 tokens，non-thinking 可能只有几十——调度器的抢占阈值、-max-num-batched-tokens、单请求上限都要能同时容纳
②	KV 压力差一个数量级	长 reasoning 的 KV 会一直占着 block，gpu_memory_utilization 与并发上限只能按最坏情况定
③	prefix cache 的复用点变了	</think> (token 151668) 之前的内容在多轮里高度重复，是 prefix caching 的高价值前缀
④	thinking budget 是客户端两步法，不是模型内建参数	第一次请求设 max_tokens = thinking_budget 拿 reasoning_content；再把 reasoning 以 <think>...</think> 追加进 messages，用 continue_final_message=True 发第二次拿答案（官方示例 512 / 1024，硬约束 max_tokens > thinking_budget）

数字· 软开关是写在 user/system 里的 /think、/no_think，多轮里最近一条生效；enable_thinking=True 时**输出一定带 <think></think> 块**（内容可能为空），enable_thinking=False 时软开关**完全无效**。对话边界 token：<|im_start|> / <|im_end|> = 151644 / 151645；vLLM 侧同名开关是 --default-chat-template-kwarg '{"chat_template_kwarg":{"enable_thinking":false}}'。

坑· ① 说“Qwen3 有两个模型”；② 说 thinking budget 是模型参数；③ **忘了 enable_thinking 默认是 True**——线上不显式关掉，**所有请求都是长输出**，这就是最典型的“上线才发现”事故；④ 被追问“reasoning 被截断怎么办”时答不上来——官方示例会给模型注入一句「Considering the limited time by the user, I have to give the solution based on the thinking directly now.」再续，**这个技巧本身就可以当答案**。

J.6 本章的边界（诚实声明）

项	说明
时效性	这些模型按月迭代。J.1–J.4 覆盖 2024–2025 的机制，J.5 覆盖 2025–2026 的方向；与官方最新报告不一致时以官方为准
参数表	本章刻意不把参数表当正文——会过期，而且背参数不是这份材料的目的。要数字请用 J.7 的速查表，再回你手上那份 <code>config.json</code> 或官方模型卡核对
架构细节的深度	MLA 的吸收技巧、MoE 的路由与负载均衡、QK-Norm、TMRoPE 这些是机制级的讲解；但具体到某个模型的超参组合（几层线性几层全注意力、专家数）必须以官方配置为准
实测性能	本章没有给吞吐/延迟数字——那些高度依赖硬件、batch、并行配置，必须自己测（ <code>code/provision_rented_gpu.py</code> + <code>code/run_labs.py</code> ）。唯一例外是 J.7 里带硬件口径的官方数字，引用时必须连口径一起说
与 §9 的关系	§9.4 是「会就是会」的名词速查；本章是机制与 tradeoff。先看本章，再用 §9.4 补名词
研究来源	本章与 J.7/J.8 的数字来自各家官方技术报告、官方 <code>config.json</code> / model card、vLLM 与 transformers 源码、以及 vLLM recipe。这轮调研的逐条出处（含「未找到」清单）在 <code>_sota_ref/</code> 下： <code>deepseek.md</code> 、 <code>qwen.md</code> 、 <code>kimi_minimax_glm.md</code>

最后一条建议：结构题的核心不是“知道多少模型”，而是“看到一个结构，能推断出它对部署意味着什么”。把 Q249 那五步练熟，比多背三个模型的参数表有用得多。

J.7 官方数字速查（可引用的精确值）

用法：面试里说「官方报告里写的是 X」远比说「我记得是 X」安全。下表每个数字都来自官方技术报告 / 官方 `config.json` / 官方 model card / 官方部署指南；标（推）的是本材料按官方数字的算术推导，引用时要么自己再算一遍、要么别说。引用性能数字必须连硬件口径一起说，否则会被追问到崩。

J.7.1 DeepSeek (V3 / V3.2 / V4)

项	值
总 / 激活参数	671B / 37B (37B 含 0.9B embedding + 0.9B head; HF 上 685B = 671B 主模型 + 14B MTP)
层数 / hidden	61 层 (前 3 层 dense) / 7168
专家	256 routed / 每 token 8 激活 + 1 shared ; <code>moe_inter_dim 2048</code> ; <code>inter_dim 18432</code>
路由	sigmoid 打分 + <code>topk_method: noaux_tc</code>; <code>routed_scaling_factor 2.5</code>; <code>n_group 8</code> / <code>topk_group 4</code> (节点受限路由)
MLA 维度	<code>q_lora_rank</code> 1536 、 <code>kv_lora_rank</code> 512 、 <code>qk_nope_head_dim</code> 128 、 <code>qk_rope_head_dim</code> 64 、 <code>v_head_dim</code> 128 、heads 128

项	值
每 token 每层 KV	<code>512 + 64 = 576 元素</code> (只有 <code>c_KV</code> 与 <code>k^R</code> 要缓存)
官方实测 KV cache	70.272 KB/token (BF16) —— 对照 LLaMA-3.1 405B 516.096 KB (7.28×) 、Qwen-2.5 72B 327.680 KB (4.66×)
上下文 / RoPE	128K (两阶段 32K → 128K) ; <code>rope_theta 10000</code> + YaRN factor 40 , <code>original_max_position_embeddings 4096</code> ; config <code>max_position_embeddings 163840</code>
词表	129280
预训练	14.8T tokens; 2048 × H800 ; 合计 2788K H800 GPU-hours ≈ \$5.576M @ \$2/GPU-h
MTP	1 个模块 , 11.5B unique / 2.4B 激活 ; 第二个 token 接受率 85–90% ; 1.8× TPS
FP8	激活 1×128 tile-wise、权重 128×128 block-wise, scale 存 fp32; scale 必为 2 的幂 (ue8m0: <code>s = amax/448</code> → <code>exp2(ceil(log2 s))</code>) ; Hopper Tensor Core 累加只保 13 位尾数
部署 (官 方)	每层 all-to-all = <code>(1+2)B × 32 × 9 × 7K / 50 GB/s</code> = 120.96 μs ; ×2×61 = 14.76 ms ⇒ 理论上限 ≈ 67 tok/s
官方推理 实测	B200 TP4 + MTP-3 单并发 TPOT 3.2344 ms / TTFT 425.99 ms ; B200 TP8 + EP8 批 256 输出 8618 tok/s (per-GPU 1077.28)
V3.2 的 DSA	top-k 2048 (token 级) ; indexer 64 头 × 128 维 , ReLU + FP8 ; indexer 的 K cache 也是 blockwise FP8. ⚠ <code>rotate_activation()</code> (常被称作 Hadamard 旋转) 只存在于官方参考实现里, README 与技术报告均未点名 ; warm-up 2.1B tokens / sparse 943.7B tokens; 官方 H800 SXM5 数字 640 / 410 TFLOPS (dense / sparse)
V4 (2026- 04)	V4-Pro 1.6T / 49B 、 V4-Flash 284B / 13B 、上下文 1M ; MLA → 滑窗 + CSA(m=4) + HCA(m'=128) ; 残差改 mHC ; 打分改 <code>Sqrt(Softplus(·))</code> ; 去掉 <code>n_group/topk_group</code> ; 前几层 hash MoE. (推) 稀疏度 1.6T/49B ≈ 33× vs V3 的 ≈ 18×

J.7.2 Qwen (Qwen2.5 / Qwen3 / Qwen3-MoE / Omni)

项	值
Qwen3 dense <code>head_dim</code>	显式 128 , ≠ hidden/heads (4B 的 hidden/heads 是 80) ; Qwen2.5 则是 hidden/heads
GQA 配置	Qwen3 0.6B/1.7B = 16 Q / 8 KV (比例只有 2:1, 小模型反而更不省 KV ; Qwen2.5 同档是 14/2、12/2 即 6–7:1) ; 4B、8B = 32/8; 14B = 40/8; 32B = 64/8
Qwen3-MoE	30B-A3B (<code>32/4</code>)、 235B-A22B (<code>64/4</code>) —— 只有 4 个 KV head ; 128 专家 / 8 激活 / 无共享专家 (原文: <i>Unlike Qwen2.5-MoE, the Qwen3-MoE design excludes shared experts</i>) ; <code>norm_topk_prob=true</code> 、 <code>router_aux_loss_coef 0.001</code>
QK-Norm	Qwen3 起 : <i>remove QKV-bias used in Qwen2 + introduce QK-Norm ... to ensure stable training</i> ; 实现是逐 head 的 <code>RMSNorm(head_dim)</code> (不是 hidden 维) , <code>eps 1e-6</code> ; vLLM 里 <code>qwen3.py</code> 无条件创建 , <code>qwen2.py</code> 是可选项
长上下文三步	① 预训练 4,096 → 32,768; ② RoPE base 10,000 → 1,000,000 (ABF) ; ③ 推理期 YaRN + DCA , 容量 4× (<code>factor 4.0</code> / <code>original 32768</code>) 。 官方警告 : 静态 YaRN 的 <code>factor</code> 不随输入长度变, 不需要长上下文时不要开

项	值
<code>max_position_embeddings</code> 陷阱	Qwen3 config = 40960 ， 不等于 可用上下文 32768 (= 32768 输出 + 8192 prompt 预留)
Omni 组件参数量	Qwen3-Omni: 视觉 ViT 540M (SigLIP2 初始化)、音频 AuT 650M 、 Thinker 30B-A3B 、 Talker 3B-A0.3B 、MTP 80M 、Code2Wav 200M
TMRoPE 时间粒度	Qwen2.5-Omni 1 个 temporal ID = 40 ms (<code>position_id_per_seconds</code> 25、 <code>mrope_section</code> [16,24,24]、固定 2 秒 音视频交织块)；Qwen3-Omni = 80 ms (13、[24,20,20] + <code>interleaved: true</code> 、弃用固定分块改按绝对 temporal ID 对齐)。 两者之和都是 64 = head_dim(128)/2
为什么要改角度分配	Qwen3-Omni 把“时间用最前 16 个 rotary angle”改成 temporal/height/width = 24/20/20 交织 ；理由是原方案高频震荡强、 利于局部但不利于长序列外推
Omni 延迟	Qwen3-Omni-30B-A3B 首包 234 / 547 ms (音频/视频， 1 并发冷启动理论值)、4 并发 728/1517、6 并发 1172/2284； RTF 0.47 / 0.56 / 0.66 ；分解：Thinker TTPT 88/160 ms、Talker TTPT 57/210 ms、 MTP 14 ms/token 、codec 3 ms/code
Omni 显存	Qwen3-Omni-30B-A3B BF16 理论最小：15s 视频 78.85 GB → 60s 107.74 GB → 120s 144.81 GB ； <code>disable_talker()</code> 约省 10 GB (Qwen2.5-Omni 只省 ~2 GB)
vLLM 侧	主仓 vLLM 里 Omni 只注册 Thinker (只出文本)；Talker / Code2Wav 在 vLLM-Omni (<code>vllm serve ... --omni</code>)；官方 README 原话 <i>only supports thinker now, meaning only text output</i>
服务化实测 (vLLM-Omni 博客, 3 GPU, c=64)	音频 TTFP 5884 → 632 ms 、RTF 1.15 → 0.47 、吞吐 2.2 → 11.7 req/s ；其中“异步分块交接”单项把 TTFP 砍掉 77%
thinking 开关	<code>enable_thinking</code> (默认 True)； <code></think></code> = 151668 ； <code>< im_start ></code> / <code>< im_end ></code> = 151644 / 151645

J.7.3 Kimi / MiniMax / GLM / Llama 4 / Step-3

模型	关键数字
Kimi K2	1T / 32B (32B 是 激活)、61 层 (1 dense)、 384 routed + 1 shared 、 纯 MLA 、 <code>num_attention_heads</code> 64 、128K (YaRN factor 32 、 <code>rope_theta</code> 50000)、 无 MTP 、FP8 e4m3 原生权重、 <code>architectures</code> : ["DeepseekV3ForCausalLM"]
Kimi K2 官方理由	头数 64 → 128 会使 推理 FLOPs +83% (128K 序列、专家数固定 384)
Kimi K2 Thinking	上下文 256K (YaRN <code>factor</code> 64)、 原生 INT4 QAT (仅 MoE 部分)、约 2× 生成速度
Kimi Linear 48B-A3B	27 层、 KDA + MLA = 3:1 (<code>full_attn_layers</code> = [4,8,12,16,20,24,27])、MLA 层用 NoPE 、 1M 上下文 ；KV cache 降 up to 75% 、 1M 解码吞吐 up to 6× (TPOT 1.84 ms vs 11.48 ms)、RULER 128k 3.98× 加速 ；质量：MMLU-Pro 51.0 vs 47.2 、RULER 128k 84.3 vs 81.3
MiniMax-Text-01 / M1	456B / 45.9B 、80 层、 lightning : softmax = 7:1 (70 + 10)、32 专家 top-2、 无共享专家 、global router + token-drop；M1 对 R1: 64K 时 < 50% FLOPs 、100K 时 ≈ 25%

模型	关键数字
MiniMax-M2	62 层、 229.9B / 9.8B 、256 专家 top-8 + <code>use_routing_bias</code> 、 全注意力 GQA 48:8、192K 、3 个 MTP、预训练 29.2T tokens；权重 220 GB 、KV 240 GB / 1M tokens；退回全注意力的官方理由见 Q254
GLM-4.5	355B / 32B 、92 层（ 3 dense + 89 MoE ）、 160 routed + 1 shared 、 GQA 96 Q : 8 KV + partial RoPE （ <code>partial_rotary_factor 0.5</code> ，即只旋转 64 维）、 <code>use_qk_norm: true</code> 、128K、1 层 MTP；长上下文靠把 RoPE base 从 10,000 提到 1,000,000
GLM-4.5-Air	106B / 12B 、46 层、 128 routed + 1 shared 、 <code>use_qk_norm: false</code> （与 4.5 的差异点）
GLM-4.6	结构同 4.5（config 逐字节相同），只把上下文从 128K 提到 200K ；官方称比 4.5 少 ~15% tokens
Llama 4 iRoPE	<code>no_rope_layers = [1,1,1,0,...]</code> ：1 = 用 RoPE（36 层， chunked local ，窗口 8192）、0 = NoPE（12 层， global ）—— ⚠️ 字段名与语义相反；推理期对 NoPE 层做温度缩放（ <code>attn_scale 0.1</code> 、 <code>floor_scale 8192</code> ，vLLM 在 <code>max_model_len > 32768</code> 自动开）；Scout 109B/17B 、16 专家 top-1，Maverick 400B/17B 、128 专家 top-1
Step-3（延伸）	321B / 38B VLM；MFA（Multi-Matrix Factorization Attention，对 QK 电路做低秩分解）+ 扩展版 MFA-KR（把 key cache 复用成 value）；KV cache 比 MLA 少 up to 56%、比 MHA 少 93.7%；系统侧 AFD（attention 与 FFN 拆成两个子系统）。Hopper / 4K / FP8 / 无 MTP / 50 ms TPOT SLA 下 4,039 tok/s/GPU ，对照 DeepSeek-V3 同设定 2,324
Hunyuan-Large（延伸）	腾讯 389B / 52B 、 256K 上下文；四项关键实践：大规模合成数据、 混合专家路由 、KV cache 压缩、 专家专属学习率 （专家数/激活数与压缩倍数未公布）
Seed-OSS-36B（延伸）	字节 Seed， 稠密 模型（config 无任何 MoE 字段）：64 层、hidden 5120、 80 Q / 8 KV 、 <code>rope_theta 1e7</code> 、 512K 上下文、词表 155136；亮点是 thinking budget 而非新注意力
ERNIE 4.5（延伸）	百度， 10 个变体 、MoE 两档激活 47B / 3B 、最大 424B 总 （ERNIE-4.5-VL-424B-A47B）；核心是 异构模态结构 （跨模态共享 + 每模态专属参数）+ modality-isolated routing；训练 47% MFU ；推理侧称 4-bit/2-bit 无损量化

J.7.4 KV cache 每 token 实测/推导对照（BF16，每元素 2 字节）

模型	元素 / token	BF16 / token	@128K	@1M
DeepSeek-V3 系 / Kimi K2（MLA，61 层）	35,136	68.6 KiB （官方实测 V3 = 70.272 KB ）	8.58 GiB	68.6 GiB
Kimi Linear（只有 7 个 MLA 层）	4,032	7.875 KiB	0.98 GiB	7.875 GiB
MiniMax-Text-01 / M1（只有 10 个全注意力层）	20,480	40 KiB	5 GiB	40 GiB
MiniMax-M2（62 层全注意力）	126,976	248 KiB	31 GiB	248 GiB
GLM-4.5 / 4.6（92 层）	188,416	368 KiB	46 GiB	184 GiB
Llama 4（12 全局层 + 36 局部层封顶 8192）	24,576 + 封顶	48 KiB	6 GiB	48 GiB

模型	元素 / token	BF16 / token	@128K	@1M
对照：48 层全注意力 (Llama 4 反事实) (推)	98,304	192 KiB	24 GiB	192 GiB

三条公式（自己就能算，别背表）：

```
MLA 层      : kv_lora_rank + qk_rope_head_dim          (V3/K2 = 512 + 64 = 576)
GQA/MHA 层 : 2 × num_kv_heads × head_dim              (GLM/MiniMax/Llama4 = 2 × 8 × 128 = 2048)
线性层      : 常数（与序列长度无关）                  ← 混合线性注意力的全部收益来源
总 KV/token = Σ_层 上式 × 2 bytes (BF16) ; FP8 再减半
```

交叉验证（说明这张表没算错）： - Kimi Linear 官方说 KV 降 **up to 75%**；按“27 层全 MLA = 30.4 GiB → 实际 7.875 GiB” = 降 **74.1%** ✓ - Llama 4 的 iRoPE：12 全局 + 36 局部封顶 ≈ **49 GiB** vs 全注意力 192 GiB ≈ **1/4** ✓
- MiniMax-M2 官方口径 **240 GB / 1M**，本表按 62 层算 **248 GiB ≈ 266 GB**，差 ~5%（层数/进位口径） ✓

来源： `_sota_ref/deepseek.md`、 `_sota_ref/qwen.md`、 `_sota_ref/kimi_minimax_glm.md`（三份底稿逐条标了 [官方] / [实现] / [三方] / [推断] / 未找到，并附原始 URL：DeepSeek 官方 repo 的 `config_671B.json` 与 `README_WEIGHTS.md`、arXiv 2412.19437 / 2512.02556、Qwen 官方 report 与 `Qwen3-30B-A3B/config.json`、arXiv 2507.20534 (K2) / 2510.26692 (Kimi Linear) / 2501.08313 (MiniMax-01) / 2605.26494 (M2) / 2508.06471 (GLM-4.5) / 2507.19427 (Step-3)、以及 `recipes.vllm.ai` 的各模型部署页）。

J.8 易错点与「不要编造」清单

这一节可能比 J.7 更值钱。面试里说错一个数不如说“这个我不确定”；而下面这些点，恰恰是三方解读最容易讲反、面试官又最爱追的地方。

J.8.1 高频易错点（答错即扣分）

#	容易说错的	正确的
1	「Kimi K2 用混合线性注意力」	K2 是 纯 MLA ；混合线性注意力是 Kimi Linear (KDA + MLA 3:1)
2	「Kimi K2 有 MTP」	没有 (<code>num_nextn_predict_layers: 0</code>)。对照：DeepSeek-V3 = 1、GLM-4.5 = 1、 K2 = 0
3	「Kimi K2 是 32B 模型」	1T 总 / 32B 激活
4	「Qwen3-MoE 有共享专家」	Qwen3-MoE 没有 (Qwen2.5-MoE 有)；但 Qwen3-Omni 的 Talker 有 (<code>shared_expert_intermediate_size 768</code> ，6 激活)
5	「Qwen3 有 thinking 和 non-thinking 两个模型」	同一份权重 ， <code>enable_thinking</code> 模板开关切换，默认 True
6	「Qwen3 上下文 40960」	那是 config 的 <code>max_position_embeddings</code> ；可用上下文 32768 输出 + 8192 prompt 预留

#	容易说错的	正确的
7	「QK-Norm 是 Qwen2.5 就有的」	Qwen2.5 用的是 QKV bias ; Qwen3 才是 remove QKV-bias + introduce QK-Norm
8	「234 ms 是 Qwen2.5-Omni 的首包延迟」	官方数字属于 Qwen3-Omni (且是 1 并发冷启动理论值) ; Qwen2.5-Omni 官方从未公布任何延迟/RTF , 唯一可引的是三方 VocalBench: RTF(EN) 1.7243 / RTF(ZH) 1.7970 (L20), 且 FCL 未测出
9	「MiniMax M2 更省 KV」	反向 : M2 退回 全注意力 , KV 从 Text-01 的 40 KiB/token 涨到 248 KiB/token
10	「GLM-4.5 是 128 专家」	160 (128 是 GLM-4.5-Air)
11	「GLM 也用 MLA / 混合注意力」	GLM 是 GQA + partial RoPE (<code>partial_rotary_factor 0.5</code>), 论文与 config 里 没有任何 hybrid / 滑窗 / 稀疏 / NoPE 表述
12	「Llama 4 里 <code>no_rope_layers</code> 为 1 表示 NoPE」	相反 : 1 = 用 RoPE (36 层 local), 0 = NoPE (12 层 global)。Meta 自己的口径是 <i>RoPE ... employed in most layers</i>
13	「DeepSeek-V4 还是 MLA」	V4 用 滑窗 + CSA + HCA 的混合注意力取代 MLA; 且 V4 的层数/hidden/专家数 未公开 (权重 gated), 不要编
14	「DSA 替代了 MLA」	正交 : MLA 压“每个 KV 多大”, DSA 压“要读多少个 KV”; V3.2 是 两者叠加
15	「MLA 吸收 (absorption) 是一种量化」	吸收是 把上投影矩阵并进 W^Q / W^O ($W^{\{UK\}} \rightarrow W^Q$ 、 $W^{\{UV\}} \rightarrow W^O$), 不是量化
16	「aux-loss-free 就是没有均衡机制」	有——偏置 $b_i \leftarrow b_i + u \cdot \text{sign}(\bar{c}_i - c_i)$ (最优 $u = 0.001$)。它“无损失”是因为 bias 只参与 top-k 选择、不进 gating 权重 $\Rightarrow$ 不产生干扰梯度; 且必须用 上一个 batch 的负载, 否则会 future token leakage
17	「MiniMax-01 的 RoPE base 是 10,000」	官方自己矛盾 : 论文写 <i>base frequency set to 10,000</i> , 发布 config 写 <code>rope_theta: 10000000</code> 。引用时必须说清是哪一份来源 (三方解读的 10k $\rightarrow$ 5M $\rightarrow$ 10M 分阶段说法官方文本里没有)
18	「FP8 的 scale 是任意浮点」	DeepSeek 的 FP8 scale 走 ue8m0 $\Rightarrow$ 必为 2 的幂 ($s = \text{amax}/448 \rightarrow \exp2(\text{ceil}(\log2 s))$) ; Hopper Tensor Core 累加只保留 13 位尾数 (FP22 寄存器)

J.8.2 「不知道就别编」清单 (三份底稿里明确标为「未找到」的)

面试里最好的答案之一是「这个数字我没有可靠来源, 我可以说说它的量级 / 怎么估」。下面这些点公开资料里确实没有, 硬答一定翻车。

主题	查不到的东西
DeepSeek-V3	MTP 的 loss 权重 λ ; 序列级辅助损失 α 的数值 (原文只说 <i>extremely small</i>) ; bias update speed γ 的具体值; 报告里“哪些 GEMM 走 FP8”的完整清单
DeepSeek-V4	层数 / hidden / 专家数 / 词表 (权重 gated, 官方未公布)

主题	查不到的东西
Kimi K2	论文 正文没有 MoE 路由函数名、归一化方式、均衡损失数值（ 只有 config 有 ）； 正文也没有 那 5 个 MLA 维度（ <code>kv_lora_rank</code> 等，只有 config 有）
Kimi Linear	效率实验（1.84 ms vs 11.48 ms、3.98×） 用的硬件 ；chunk size <code>C</code> 的取值；相对通用 DPLR 的 FLOP 节省比例
MiniMax	各代的 优化器 ；量化细节；MiniMax-01 里 lightning attention 的 具体吞吐倍数 （“比 FA2 快 X 倍” 查不到 ）； 1M→4M 外推用的具名方法 （论文只写了三阶段训练 + varlen ring attention + LASP）
其他国模（延伸）	Step-3 的 MFA 层数/专家数细节；Hunyuan-Large 的专家数与 KV 压缩倍数；Seed-OSS-36B 的训练 token 数；ERNIE 4.5 的层数/专家数/注意力类型/位置编码（官方博客未给，需读技术报告 PDF 正文）
GLM	GLM-4.5 的 MTP 接受长度 / 投机解码加速比 ；GLM-4 / GLM-4-Plus 的 参数总量 ；GLM 系列的 PP 配置 ； GLM-4.6 没有独立架构论文 （沿用 2508.06471）
Llama 4	Meta 从未发布 Llama 4 技术报告 ；网上流传的 arXiv:2601.11659 已被 arXiv 撤稿 且非 Meta 出品；Llama 4 的 aux-loss-free 均衡 无任何来源 ； 10M 上下文是宣称值 ——Meta 自家 cookbook 写 8×H100 BF16 约 1.4M ，三方服务商实际限制在 128K / 328K
Qwen2.5-Omni	完全没有官方延迟 / RTF / TTFP 数字 （报告只有 v1，全文 <code>RTF</code> 出现 0 次）

§11 并行策略深挖：TP / DP / PP / EP / CP（Q256–Q262，7 题）

Q256 [进阶] ★ PP 的通信是什么？为什么它适合跨机？

答· PP **不做集合通信，只做点对点**（`send` / `recv`）：rank i 把 activation 发给 rank $i+1$ ，**链式依赖，只有相邻两卡通信**。用 all-reduce 是巨大浪费。每层边界传一块 activation，大小 = `micro_batch × seq × hidden × 2 bytes`（bf16）。

PP 适合跨机的三个理由：

#	理由	为什么
①	通信量小	见下面的对照表：约为 TP 的一半
②	不需要全局同步	TP 每层都要让 N 张卡对齐；PP 只与邻居握手， 对延迟不敏感
③	可以流水	通信能藏在 别的 micro-batch 的计算 后面（这就是 micro-batch 存在的意义，见 Q257）

数字· **每层每 rank 的通信量对照**（ S = 一块 activation 的字节数 = `batch × seq × hidden × 2`）：

并行	每层每 rank 的通信量	通信类型	同步范围
TP	≈ 4S （每层 2 次 all-reduce，每次每 rank 收发 ≈ 2S）	all-reduce	全组 N 卡同步
PP	≈ 2S （收一块 + 发一块，且只与邻居）	send/recv	只与邻居
EP	≈ $S \cdot (N-1)/N$ ≈ S	all-to-all	全组，但 可异步

并行	每层每 rank 的通信量	通信类型	同步范围
DP (训练)	每步 $2 \times S_{\text{param}}$ (梯度 all-reduce, S_{param} = 全部参数)	all-reduce	全组

⇒ **关键不是“量减半”，而是“没有全局同步”** —— TP 每层的 all-reduce 是一道**必须全员到齐才能过的栅栏**，PP 的 send/recv 只是“我发给邻居”，**对网络延迟的容忍度高一个量级**。这就是「**TP ≤ 8 (NVLink 域内)**、**跨机靠 PP / DP / EP**」的定量依据 (对照 Q133)。

坑· ① 把 PP 说成“集合通信”；② 只说“PP 通信少”却说不出**为什么少** (P2P + 链式依赖 + 可流水)；③ 不知道 vLLM 里真的有一段代码在 PP 的首/末 rank 之间**主动改用 all-gather** (`parallel_state.py:1054-1066` 的 `_should_use_all_gather`) —— **这说明「集合操作 vs 点对点」不是绝对对立的，具体取决于规模和实现开销** (ch04 §4.5)。

Q257 [hard] ★ 流水气泡怎么算？1F1B 和 micro-batch 怎么配合？

答· PP 的代价是**气泡 (bubble)**：流水的填充 (fill) 与排空 (drain) 阶段有 stage 在空转。三种调度的气泡比例：

GPipe (全前向、再全反向) : $\text{bubble} = (P - 1) / (M + P - 1)$
 1F1B (一前一后交替) : $\text{bubble} = (P - 1) / M$
 交错 / 虚拟流水 (v 块每卡) : $\text{bubble} = (P - 1) / (v \cdot M)$

(P = 流水级数, M = micro-batch 数, v = 每个 stage 持有的虚拟块数)

数字· 举例 $P = 8$ ：- $M = 32$ 的 1F1B ⇒ 气泡 $7/32 \approx 22\%$ ；- $M = 32$ 再加 $v = 4$ 的**虚拟流水** ⇒ $7/128 \approx 5.5\%$ 。

⇒ **两条降气泡的路：加大 M** (代价：同时在飞的 activation 变多，**显存涨**) 或 **虚拟流水** (代价：每个 stage 要持有 v 份权重参数，**还是显存换气泡**)。

数字· **1F1B 真正的卖点不是气泡 (同 M 下与 GPipe 差别不大)，而是峰值显存**：GPipe 要同时压住 M 份 micro-batch 的 activation，1F1B 只需压 P 份 —— 在 $M \gg P$ 时这是数量级的差别。**所以 1F1B 是“用一点气泡换大量显存”**。

坑· ① 说“micro-batch 越多气泡越小”却不提**显存代价** (这是被追问的第一层)；② 不知道 1F1B 的核心动机是**显存**而不是气泡；③ 答不出「**PP 的并行度为什么通常远小于 TP**」—— PP 每翻一倍，气泡比例和**权重副本数**都变贵，而单层计算量没变。

Q258 [进阶] ★ 训练的 DP 通信是什么？ZeRO 三个阶段各通信什么？

答· 训练 DP 的每张卡持有**完整模型**、吃**不同数据**，所以每步结束必须把梯度求和 ⇒ **gradient all-reduce**，这是 DP **唯一**的通信。数字· 通信量与**参数量成正比、与 batch 无关**：每步 all-reduce 的每 rank 收发 $\approx 2 \times S_{\text{param}}$ (`all-reduce = reduce-scatter + all-gather`，见 Q137)。所以 DP 的扩展性由**参数量 ÷ 跨机带宽**决定，**调大 batch 不会让 DP 通信变贵**。

ZeRO 三阶段切的东西不同，通信量也完全不同：

阶段	切什么	通信量	显存收益
ZeRO-1	优化器状态 (fp32 的 m / v / master weight)	2S (与标准 DP 相同)	优化器状态降 N 倍 (三个里最大头)
ZeRO-2	梯度也切	2S (变成 reduce-scatter + all-gather, 总量不变)	梯度也降 N 倍
ZeRO-3	参数也切	≈ 3S (前向 all-gather 参数 + 反向 all-gather 参数 + 反向 reduce-scatter 梯度)	参数量降 N 倍, 但通信量涨约 1.5×

⇒ **一句话结论**: ZeRO-1/2 是“免费”的 (通信量与标准 DP 完全相同), ZeRO-3 是“用 1.5× 通信换 N 倍显存”。 (对照 Q157: 训练 vs 推理的通信模式差异)

坑· ① 说“ZeRO 减少通信”—— **它减少的是显存**, ZeRO-3 反而**增加**通信; ② 把 DP 的通信量说成“与 batch 成正比” (**只与参数量成正比**, batch 只影响计算量); ③ 忘了 **DP 与 TP 是两条独立**的 all-reduce, 典型排布是 **TP 在节点内 + DP 跨节点**: 此时 DP 的梯度 all-reduce 走跨机 IB, **它的量 (2 × 全参数量) 远大于 TP 每层那 4S** —— 所以训练里真正压跨机带宽的是 DP, 不是 TP。 **这一条能说出来就很加分**。

Q259 [进阶] ★ 推理的 DP 和训练的 DP 有什么不同? 为什么 vLLM 需要 DP attention?

答· **推理没有反向, 所以没有梯度 all-reduce** —— 推理 DP 的每个副本是**完全独立的服务实例**, 只共享入口做负载均衡。 它的价值是**吞吐与容错** (也便于滚动升级), **而不是“把模型切开”**。 这是 Q132 那个坑的展开。

但 MoE 一来, 推理 DP 就不再“完全独立”了, 于是有了 DP attention:

需求	机制
各 DP rank 的 batch 大小不同 (有的 rank 请求多、有的少), 如果各自派发就会把热门专家所在的 rank 压垮	先用 all-gather 把各 rank 的 router logits 凑齐 , 看到全局负载后再统一决定 token 发给谁

vLLM 里的实现是 `AgRsAll2AllManager.dispatch_router_logits` (`all2all.py:70-99`); 而 EP 的 `dispatch / combine` 才是真正的 all-to-all (`all2all.py:101-151`)。 **注意这是两件不同的事**: DP attention 解决“**batch 不齐**”, EP 解决“**专家不在本地**”。

数字· vLLM 的组拓扑顺序是 `ExternalDP × DP × PP × PCP × TP` (`parallel_state.py` 的注释); 更关键的一条: **EP 组是“从 DP 组和 TP 组合并出来的”** —— 源码原话 *all2all lives in ep group, which is merged from dp and tp group* (`device_communicators/base_device_communicator.py:47`)。 ⇒ **EP 不是第五个正交维度, 它叠在 DP + TP 之上** (这也是「为什么 EP 的初始化顺序会有问题」的根源)。

坑· ① 说“推理 DP 也要 all-reduce 梯度” (见 Q132 的坑); ② 把 EP 当成与 TP/DP 并列的独立维度 (**它是合并出来的**); ③ 部署 MoE 时只会拉 `--tensor-parallel-size`, 不会用 **DP + EP** 组合来提高吞吐。

Q260 [hard] ★ EP 能替代 TP 吗? 什么时候该用 EP?

答· **不能完全替代**, 因为两者切的**不是同一部分**:

	TP	EP
切什么	所有层的权重矩阵 (attention + dense + MoE FFN)	只有 MoE 的专家 FFN

	TP	EP
attention / dense 层	被切开， 每层 2 次 all-reduce	完全复制 （每 rank 一份完整 attention）
MoE FFN	切开	按专家切 ，token 走 all-to-all
通信形态	all-reduce ，量在编译期已知	all-to-all ，量由路由结果决定（数据依赖）
负载	天然均衡	可能倾斜 （要靠 EPLB / 冗余专家）
显存收益	每卡权重 ÷ TP	每卡专家 ÷ EP， 但 attention 一份不少

⇒ **一句话：EP 优化的是“MoE 的显存与算力”，TP 优化的是“整层的显存”**。对 MoE 模型（如 671B 总 / 37B 激活），**EP 的性价比远高于纯 TP**：attention 与 dense 层本来就很小（DeepSeek-V3 只有前 3 层是 dense），把它们复制 N 份的代价，远小于把 **256 个专家切 N 份** 带来的收益。

数字· 官方部署数据可以做旁证（见 J.7.1）：**TP4 + MTP-3** 时单并发 **TPOT 3.2344 ms / TTFT 425.99 ms**；而 **TP8 + EP8** 在批 256 下输出 **8618 tok/s**（per-GPU **1077.28**）。⇒ **同样的卡数，“EP 那套”是给吞吐用的，“纯 TP 那套”是给单请求延迟用的**——这句话本身就是一道很好的答案。

坑· ① 说“EP 就是 MoE 版的 TP”；② 忘了 **attention 部分仍然要 TP 来切**，所以真实部署是 **TP + EP 叠加**，不是二选一；③ 不知道 EP 的通信是**数据依赖的** ⇒ 必须配 **EPLB**（\$4.7 Q122）与**冗余专家**（\$9.4 Q220）。

Q261 [hard] CP (context parallel) 的通信量怎么算？ring attention 为什么能“免费”？

答· 先看**为什么需要 CP**：attention 的**算力是 $O(L^2)$** 、而 **KV 显存只有 $O(L)$** ；序列一长（128K / 1M），**显存先爆**，而 TP / PP 都**切不动“序列维”这个轴**（TP 切的是权重矩阵，PP 切的是层）。CP 就是**把序列切成 P 段**，每个 rank 只存 **1/P 的 KV**。

但每个 rank 要算自己那一段的完整 attention，就必须看到全部 KV ⇒ **ring attention**：把 KV 块在环上转 **P-1 轮**，每轮算一块、同时把下一块发出去。

每轮传的 KV 块 = $(L / P) \times 2 \times n_kv_heads \times head_dim \times 2 \text{ bytes}$
总通信量（每 rank）= KV 总量 $\times (P - 1) / P \approx$ KV 总量

数字· **为什么说它“几乎免费”**：ring attention 把通信塞进了 flash attention 的分块计算里——**算当前块的 attention 时同时发下一块的 KV**，而 **online softmax (Q129)** 让部分结果可以“边算边合并”。于是当 L 足够大（单块计算时间 ≥ 单块传输时间）时，**通信能被计算完全掩盖**。

这和 TP 的 all-reduce 有本质区别：TP 的 all-reduce 是“**必须全员到齐才能继续**”的全局栅栏；CP 的 ring 只是“**我在等下一块 KV**”——等不到就先算别的，**没有全局同步点**。

数字· vLLM 里的两个变体（对照 Q135）：**PCP 会扩大 world size**，把 prefill 的序列切开算；**DCP 不扩大 world size**，只把 **decode 阶段的 KV cache 沿序列维切到已有的 TP rank 上**（“用通信换显存”）——DCP 的 `ag_rs` → `a2a` 后端把**每层 NCCL 调用从 3 次降到 2 次**（`parallel.py:126-128`、`:351-354`）。

坑· ① 说 CP “减少计算量”——**算力总量不变**（甚至因环形边界略有增加），CP 省的是**每卡的显存**；② 不知道 CP **必须配因果 mask 的分块**（每块要按它在序列中的位置决定能看到多少），否则会看到未来的 token；③ 不知道 **CP 的前提正是 flash attention 的分块 + online softmax**——这就是为什么“CP 是个新东西，而 TP 不

是”：没有分块 attention，CP 根本没法把通信藏起来。

Q262 [进阶] ★ 五种并行怎么组合？给一个选型决策树。

答· 先记四条硬约束：

- ① $TP \leq 8$ — 每层两次 all-reduce，必须待在 NVLink 域内（Q133）
- ② TP 在最内层 — 通信最频繁的，放在最快的互联上
- ③ PP / DP 在最外层 — PP 通信量最小、DP 与参数量成正比但与 batch 无关，吃得下跨机 IB
- ④ EP 不是独立维度 — 它叠在 DP + TP 之上（Q259）

vLLM 的组拓扑顺序就是这条原则的代码化： `ExternalDP × DP × PP × PCP × TP` （`parallel_state.py` 的注释）。

决策树：

模型单卡放得下吗？

├ 放得下 → 还要更高吞吐吗？

├ 要 → DP（多副本：最简单、零通信、可容错）

└ 不要 → 单卡

└ 放不下 → 能待在同一个 NVLink 域内吗？

├ 能 → $TP (\leq 8)$ ；KV cache 还不够就再加 DCP（不扩 world size）

└ 不能 → 看模型类型：

├ MoE → $TP(\text{节点内}) + EP(\text{跨机}) + DP$ ，并配 EPLB

└ Dense → $TP(\text{节点内} \leq 8) + PP(\text{跨机})$ ；长序列再加 CP

数字· 三种典型配置（可以直接背下来对着说）：

场景	配置	为什么这么选
单机 8 卡跑 70B	$TP = 8$	单层放得下、全在 NVLink 域内、零跨机通信
跨机跑 671B MoE	$TP = 8 \text{ (节点内)} \times EP = 8/16 \text{ (跨机)} + DP$	attention / dense 复制得起；专家必须切开；跨机只跑 all-to-all
单机 8 卡跑 1M 长上下文	$TP = 8 + DCP = 8$	DCP 把 decode 的 KV 切到已有 rank 上，不扩 world size、不改拓扑

坑· ① 给出「 $TP = 64$ 」这类配置（违反约束 ①）； ② 把 PP 放到 TP 里面（把最频繁的通信放到了最慢的链路上）； ③ 忘了并行度不是越大越好：TP 每翻一倍，每层的 all-reduce 规模不变但参与同步的卡变多，小消息下延迟反而变差（回到 Q140 的 α - β 模型：小消息优化的是通信次数与延迟，不是带宽）； ④ 答不出「为什么 DP 通常比 TP 更“便宜”」—— DP 没有每层的通信，它只在每步（训练）或每次路由（MoE 推理）通信一次。

§12 SOTA 算子全景：这一代开源模型到底用了哪些 kernel（Q263–Q270，8 题）

L.1 先说结论：kernel 的来源已经变成五层

最反直觉的变化：`csrc/` 里已经没有 **paged attention** 和 **fused MoE** 了——CUDA 版 `PagedAttention v1/v2` 在 **2026-07-02** 的 **PR #47361** 里被直接删除，现在 `csrc/attention/` 只剩 dtype 转换头文件。这一代新 kernel 几乎都在这五个地方：

层	位置	谁在写	代表
① C++/CUDA 扩展	<code>csrc/libtorch_s</code> <code>table/</code>	vLLM 自己	<code>custom_all_reduce</code> 、 <code>merge_attn_states</code> 、 <code>topk_softmax</code> 、 <code>per_token_group_quant</code> 、NVFP4/MXFP4 quant
② Triton	<code>vllm/v1/attention/ops/</code> 、各模型目录的 <code>common/ops/</code>	vLLM 自己	<code>triton_unified_attention</code> 、 <code>triton_merge_attn_states</code> 、 <code>triton_fp8_mqa_logits</code> (DSA indexer)、 <code>triton_turboquant_decode</code>
③ CuTeDSL (CUTLASS Python DSL)	<code>vllm/models/<模型>/<厂商>/ops/*_cutedsl.py</code> 、 <code>vllm/model_executor/kernels/linear/cute_dsl/</code>	vLLM + NVIDIA	V4 的 <code>sparse_attn_compress_cutedsl</code> 、K3 的 <code>gemm_rs_ar</code> 、低延迟 BF16 GEMM、b12x
④ 外部库	依赖包	DeepSeek / NVIDIA / 社区	FlashMLA、FlashInfer、DeepGEMM、DeepEP、QuTCLASS、FlashKDA、AITER、fla
⑤ 新 DSL	<code>kernels/mhc/tilelang*.py</code> 、 <code>flydsl_*</code>	vLLM	TileLang (MHC 残差)、FlyDSL (TurboQuant decode)。入门版本口径：Gluon 首次出现在 Triton v3.4.0 (2025-07-30)，命名空间是 <code>triton.experimental.gluon</code> ；CuTe DSL 随 CUTLASS 4.0 (2025-06-03) 发布；Quack 是 Dao-AILab/quack (CuTe-DSL 写的 kernel 库，H100/B200，未公布绝对 TFLOPS)

源码锚点 (可以直接 `ls` 验证)：

<code>csrc/</code>	# ① 只剩通用/量化/通信 kernel
<code>vllm/v1/attention/ops/</code>	# ② 全是 Triton
<code>vllm/model_executor/kernels/</code>	# ③④ 新的「kernel 抽象层」：按量化格式 × 后端分目录
<code>linear/{scaled_mm,mx_fp4,mx_fp6,mx_fp8,nvfp4,mixed_precision,cute_dsl}/</code>	
<code>attention/dsa/dcp_indexer_cutedsl.py</code>	
<code>mhc/{tilelang,triton,aiter,torch}.py</code>	
<code>vllm/models/<模型>/{common,nvidia,amd,xpu}/</code>	# ⑤ 新模型按「模型 × 厂商」隔离

两个可以直接说出口的结构性观察：

- kernel 的目录结构从“按算法”变成了“按格式 × 后端”——`kernels/linear/nvfp4/` 下面并列着 `cutlass.py` / `flashinfer.py` / `marlin.py` / `humming.py` / `fbgemm.py` / `b12x.py` / `emulation.py`。

同一件事有 7 个实现，这是“硬件碎片化”在代码结构上的直接投影。

2. 新模型采用「模型 × 厂商」隔离布局 —— `vllm/models/kimi_k3/{common,nvidia,amd}/`、`vllm/models/deepseek_v4/{common,nvidia,amd,xpu}/`。NVIDIA / AMD / XPU 各写各自的 kernel，`common/` 只放共用的 Triton 与元数据。面试里说得出这个结构，比背任何一个 kernel 名字都有说服力。

L.2 按功能分类：这一代真正在用的 kernel

L.2.1 注意力 (dense)

Kernel	位置 / 来源	关键点
FlashMLA	<code>vllm/v1/attention/ops/flash_mla.py</code> ；上游 <code>deepseek-ai/FlashMLA</code>	MLA decode: paged KV + split-KV ，缓存的是 latent (512+64) 而不是 K/V
CUTLASS SM100 MLA	<code>csrc/libtorch_stable/attention/mla/cutlass_sm100_mla/</code>	Blackwell 版 MLA: <code>sm100_fmha_mla_tma_warpspecialized</code> + <code>sm100_fmha_mla_reduction</code> (TMA + warp specialization + 单独的 reduction kernel)
FlashAttention / FA4	<code>vllm/model_executor/warmup/fa4_cutedsl_warmup.py</code> 、 <code>kimi_k3/nvidia/vision_fa4_warmup.py</code>	FA4 已进入 CuTeDSL 预热路径 (ViT 也在用)
FlashInfer	<code>vllm/v1/attention/backends/flashinfer.py</code>	主要后端之一，覆盖 prefill/decode/cascade
Unified attention	<code>vllm/v1/attention/ops/triton_unified_attention{,_diffkv}.py</code>	一个 Triton kernel 同时处理 prefill + decode (不再分成两个 kernel) + <code>diffkv</code> 变体 (K/V 的 head_dim 不同，为 MLA 准备)
FlexAttention	<code>vllm/v1/attention/backends/flex_attention.py</code>	用 PyTorch 的 score-mod 生成融合 kernel
分块合并	<code>merge_attn_states.cu</code> + <code>triton_merge_attn_states.py</code>	LSE 合并 (split-KV / FlashDecoding 的收尾，57 Q190 手撕的就是它)
DCP 直连	<code>csrc/libtorch_stable/attention/dcp_utils/dcp_direct_{a2a_lse_reduce,kv_gather,q_gather}.cu</code>	decode context parallel 的 三个专用通信 kernel (不是通用 all-to-all)
b12x	<code>vllm/v1/attention/backends/b12x.py</code>	SM12x 的 paged causal attention ，走 CuTeDSL

L.2.2 稀疏注意力 + indexer (这一代最大的范式变化)

共同范式：先用一个便宜的 indexer 给历史 KV 打分 → 只取 top-k 做真正的注意力。

模型	Kernel	位置	关键点
DeepSeek-V3.2 (DSA)	<code>triton_fp8_mqa_logits.py</code>	<code>vllm/v1/attention/ops/</code>	FP8 的 MQA logits = indexer 打分；配 <code>rocm_aiter_mla_sparse.py</code> / <code>xpu_mla_sparse.py</code>
DeepSeek-V3.2	<code>dcp_indexer_cutedsl.py</code>	<code>kernels/attention/dsa/</code>	indexer 上了 CuTeDSL ，并且和 DCP 组合
DeepSeek-V4	<code>sparse_attn_compress_cutedsl.py</code>	<code>models/deepseek_v4/nvidia/ops/</code>	源码注释写明提供 “ C4 fused 和 C128 split kernels ” —— 对应两个不同的压缩比
DeepSeek-V4	<code>fused_indexer_q_cutedsl.py</code> / <code>fused_indexer_q.py</code>	同上 / <code>common/ops/</code>	indexer 的 Q 走 MXFP4 (<code>MXFP4_BLOCK_SIZE</code>)
DeepSeek-V4	<code>compressor.py</code> + <code>fused_compress_quant_cache.py</code>	<code>models/deepseek_v4/</code>	逐层压缩比 <code>config.compress_ratios[layer_id]</code> ; <code>compress_ratio == 1</code> 的层 不 压缩
MiniMax-M3 (MSA)	<code>indexer.py</code> 、 <code>index_topk.py</code> 、 <code>sparse_attn.py</code> 、 <code>nvidia/msa_cutlass_sparse_decode.py</code>	<code>models/minimax_m3/</code>	MSA = MiniMax Sparse Attention : CUTLASS 稀疏 decode + 独立 indexer + index top-k
GLM-MoE-DSA	直接复用 <code>vllm.models.deepseek_v32</code>	<code>registry.py</code>	GLM 的 DSA 变体 直接复用 DeepSeek-V3.2 的实现

可回答的一句话：「2026 年的注意力竞争，已经从『怎么把 dense attention 写快』变成了『怎么把 indexer + top-k 写便宜』。」

L.2.3 线性注意力 / SSM

Kernel	位置	关键点
GatedDeltaNet decode	<code>csrc/libtorch_stable/gdn/fused_gdn_decode_kernel.cu</code> 、 <code>v1/attention/backends/gdn_attention.py</code>	融化的 GDN decode
KDA (Kimi Delta Attention)	<code>csrc/libtorch_stable/kimi_k3/fused_kda_decode_kernel.cu</code> (NVIDIA 版权) + <code>csrc/flashkda_registration.cpp</code>	FlashKDA 注册为 torch op: <code>fwd(q,k,v,g,beta,scale,out,workspace,A_log,dt_bias,lower_bound,initial_state,final_state,cu_seq_lens,checkpoint_state,checkpoint_offsets)</code> 。 <code>kDimK=kDimV=128</code> 、 短卷积宽度 4 、256 线程
KDA chunkwise 四形态	<code>models/kimi_k3/{nvidia,amd}/ops/third_party/kda/{chunk,chunk_intra,chunk_intra_token_parallel,fused_recurrent}.py</code>	prefill 用 chunk 并行、decode 用 recurrent —— 这是所有线性注意力的通用套路

Kernel	位置	关键点
Mamba-2 selective scan	<code>csrc/libtorch_stable/mamba/selective_scan_fwd.cu</code> 、 <code>v1/attention/backends/mamba2_attn.py</code>	SSD 形式的分块扫描
ShortConv	<code>csrc/libtorch_stable/short_conv*、v1/attention/backends/short_conv_attn.py</code>	线性注意力前的短卷积， 状态也要缓存
RecoverSSM	<code>models/kimi_k3/nvidia/ops/recoverssm.py</code>	投机解码的 accepted-state 恢复 （见 Q267）
KDA skinny GEMM	<code>models/kimi_k3/nvidia/ops/cutlassdsl/kda_skinny_gemm.py</code>	线性注意力的 GEMM 形状极“瘦”（M 很小），要专门写

L.2.4 MoE 与路由

Kernel	位置	关键点
DeepGEMM MegaMoE	<code>models/deepseek_v4/nvidia/ops/prepare_megamoe.py</code> 消费	V4 的 MoE 走 DeepGEMM 的 MegaMoE kernel ；vLLM 侧只写一个 Triton input-staging kernel：把 hidden 量化成 FP8 + E8M0 group scale ，并把 routing top-k 重排成 int64/float32 布局
路由 top-k	<code>csrc/libtorch_stable/moe/{topk_softmax,topk_softplus_sqrt,grouped_topk}_kernels.cu</code>	<code>topk_softplus_sqrt</code> 就是 <code>Sqrt(Softplus(.))</code> 打分（V4 系）； <code>grouped_topk</code> 是节点受限路由
DSV4 专用 top-k	<code>kernels/.../router/dsv4_topk.py</code>	Triton， <code>_TOPK = 6</code> ，带 <code>correction_bias</code> （ 无辅助损失的偏置纠正 ），注明 改编自 SGLang 的 <code>moe_fused_gate.py</code>
permute / unpermute	<code>csrc/libtorch_stable/moe/permute_unpermute_kernels/</code>	token 按专家重排（all-to-all 前后的那一步）
moe_align + sum	<code>csrc/libtorch_stable/moe/moe_align_sum_kernels.cu</code>	对齐 block + 加权求和 融成一个
fused MoE 后端（29 个）	<code>vllm/model_executor/layers/fused_moe/experts/</code>	<code>triton_*</code> / <code>cutlass_*</code> / <code>deep_gemm_*</code> / <code>flashinfer_*</code> / <code>trtllm_*</code> / <code>aiter_*</code> / <code>marlin_moe</code> / <code>gpt_oss_triton_kernels_moe</code> / <code>batched_deep_gemm_moe</code>
低精度 MoE	同上	<code>mxfp4</code> / <code>mxfp8</code> / <code>nvfp4</code> / <code>mxint4</code> / <code>int4_emulation</code> / <code>ocp_mx_emulation</code> / <code>fused_humming_moe</code>
EP 通信	<code>fused_moe/prepare_finalize/</code>	<code>deepep_ll</code> / <code>deepep_ht</code> / <code>deepep_v2</code> / <code>nixl_ep</code> / <code>mori</code> / <code>flashinfer_nvlink_{one,two}_sided</code>

L2.5 量化 GEMM 与 KV cache 压缩

Kernel	位置	关键点
NVFP4 / MXFP4 / MXFP8 / MXFP6	code/kernels/linear/{nvfp4,mxfp4,mxfp8,mxfp6}/	每种格式都并列 5-8 个后端实现
block-wise FP8 scaled_mm	code/csrc/.../w8a8/cutlass/c3x/scaled_mm_blockwise_sm{90,100,120}_fp8.cu	按架构分文件：SM90 / SM100 / SM120 各一份
MXFP4 blockwise MoE	code/csrc/.../quantization/fp4/mxfp4_blockwise_moe_kernel.cu	直接吃 MXFP4 权重的 MoE
NVFP4 KV cache (MLA 专用)	code/csrc/libtorch_stable/nvfp4_ds_mla_cache_kernels.cu	<code>concat_and_cache_mla</code> 的 NVFP4 版本： <code>kv_c bf16[T,512]</code> + <code>k_pe bf16[T,64]</code> → <code>kv_cache uint8[blocks, block_size, 352]</code> ，即 352 字节/token/block ((推断) = 256 字节 FP4 的 <code>kv_c</code> + 32 字节 block scale + 64 字节的 <code>k_pe</code>)。只在 SM100 目标下编译
TurboQuant (K3V4)	code/v1/attention/ops/{triton_turboquant_decode,triton_turboquant_store,flydsl_turboquant_decode}.py、code/backends/turboquant_attn.py	K 用 3 bit、V 用 4 bit ；slot 布局 <code>[key_packed value_fp16]</code> ， <code>head_dim=256</code> 时 100 字节 key + 512 字节 value = 612
Hadamard 变换	code/csrc/.../quantization/hadamard/hadacore/hadamard_transform_cuda.cu	量化前的旋转（抑制 outlier），DSA 系也在用
融合量化	code/csrc/.../quantization/fused_kernels/{fused_silu_mul_block_quant,fused_layernorm_dynamic_per_token_quant}.cu	把 act 函数/归一化和量化融进一个 kernel
W4A16 / W4A8	code/marlin/、code/machete/、code/cutlass_w4a8/、code/gptq_allspark/、code/conch.py、code/humming.py	Marlin（通用）、Machete（Hopper mixed-input）、 Conch （uint4/uint8, group 128 或 per-channel）、 Humming （出现于全部格式目录 → 是一个跨格式的 kernel 家族）

三个「代码里能验证」的硬约束（比背格式名有用得多）：

约束	事实
<code>cutlass_scaled_mm</code> 的输入组合极窄	只支持 <code>{e4m3 × e4m3, int8 × int8}</code> → <code>fp16/bf16</code> ；没有 <code>e5m2</code> 、没有 <code>fp8×int8</code> 混合、输出不是 <code>int32</code> ；SM100 上写明 <code>int8 not supported</code> （ <code>code/csrc/libtorch_stable/quantization/w8a8/cutlass/scaled_mm_entry.cu</code> ）

约束	事实
KV cache 量化 scale 的粒度	vLLM 里是 per-tensor [1] 或 per-attention-head [num_heads]，不是 per-token (kernel 内有断言)。⇒ 被问「KV cache 量化怎么做的」时， 不要说 per-token
<code>per_token_group_quant</code> 的 <code>group_size</code> 是运行期参数	不是硬编码的 128; <code>column-major</code> 也是由 stride 推断 (<code>output_s.stride(0) < output_s.stride(1)</code>)，不是一个开关

AWQ 在 CUDA 上的实际选择顺序 (`choose_mp_linear_kernel` 运行期决定，不是编译期写死的)：

```
CutlassW4A8 → Machete → Marlin → Conch → Exllama → TritonW4A16 → Humming
```

⇒ 「同一个量化格式在不同机器上跑的是不同 kernel」这件事，在代码里是显式的一串 if。（对照 Q269 的“五步判据”。）

两个格式的精确定义（很容易记混，面试常考）：

	NVFP4	MXFP4
block size	16	32
scale dtype	E4M3 (+ 二级 FP32 scale)	E8M0
谁在用	NVIDIA Blackwell 生态	gpt-oss (官方 model card 原话: <i>post-trained with MXFP4 quantization of the MoE weights</i>)

一个具体模型的量化内核：Kimi K2 Thinking 是 INT4 W4A16，`group_size = 32`（不是 128），用 `compressed-tensors` 的 `pack-quantized` 格式，`input_activations: null`；真正执行的算子是 `moe_wna16_marlin_gemm`。⇒ “W4A16 的 `group_size` 是多少”不要一律答 128 —— 有的是 32，有的是 128，查 config。

L.2.6 通信与「通算融合」——最值得讲的一类

Kernel	位置	关键点
custom all-reduce	<code>csrc/custom_all_reduce.cuh</code> + <code>custom_all_gather_reduce_scatter.cuh</code>	CUDA IPC + P2P + 单 kernel 完成 (§4 的主线)
QuickReduce	<code>csrc/quickreduce/</code> 、 <code>csrc/custom_quickreduce.cu</code>	ROCm 侧
FlashInfer all-reduce	<code>device_communicators/flashinfer_all_reduce.py</code> 、 <code>flashinfer_pcie_ipc_all_reduce.py</code>	PCIe-IPC / MNNVL 两条路

Kernel	位置	关键点
GEMM + RS + AR 融合	<code>models/kimi_k3/nvidia/ops/cute_dsl/gemm_rs_ar.py</code>	SM100 BF16 GEMM 直接融合 TP 的 reduce-scatter / all-reduce , 基于 CUTLASS 的 Blackwell distributed GEMM-RS example , 用 <code>torch.distributed._symmetric_memory</code>
AllReduce + RMSNorm + RS (early exit)	<code>.../cute_dsl/latent_moe_tail/allreduce_rmsnorm_reduce_scatter_early_exit.py</code>	从 FlashInfer 的 <code>oneshotAllreduceFusionKernel</code> 特化而来; CTA-specialized + ReduceScatter early exit
fused add + multicast GEMM	<code>.../latent_moe_tail/fused_add_multicast_gemm.py</code> 、 <code>fused_add_multicast_skinny_gemm.py</code>	NVIDIA 2025–2026 版权; 用 multicast 把激活一次性广播进 GEMM (= 把 all-gather 藏进 GEMM 的加载)
latent MoE tail	<code>models/kimi_k3/nvidia/ops/latent_moe_tail.py</code> + <code>ops/cute_dsl/latent_moe_tail/</code>	一整套“ MoE 尾部 ”融合 kernel (含 <code>lamport_copy.py</code> 的 Lamport 式同步原语)
symm_mem / pyncccl / GIN	<code>device_communicators/symm_mem.py</code> 、 <code>pyncccl_allocator.py</code>	NCCL 对称内存窗口 + 设备 API

这一栏的意义: §5.3 讲的 DBO 是调度层的重叠; 而这一代的融合是把通信指令直接写进 GEMM kernel 的 epilogue / load 阶段。从“两个 kernel 并发”进化到“一个 kernel 里既算又通”。

L.3 按模型对照: 每个模型“新”在哪

这一栏全部来自 **vLLM registry 与模型目录** (【实现】级事实)。我没有这些模型的官方架构报告, 所以只写“代码里能看到什么”, 不写“官方说它用了什么”。

模型	vLLM 实现位置	代码里能看到的 kernel / 结构特征
DeepSeek-V3.2	<code>vllm.models.deepseek_v32</code>	DSA indexer (FP8 MQA logits) + MLA sparse + DCP indexer
DeepSeek-V4	<code>vllm.models.deepseek_v4</code> (另有 <code>amd/</code> 、 <code>xpu/</code>)	<code>compressor.py</code> (逐层压缩比) + <code>sparse_attn_compress_cutedsl</code> (C4 / C128) + <code>sparse_mla.py</code> + MXFP4 的 indexer Q + UE8M0 FP8 的 NoPE 量化 + DeepGEMM MegaMoE + o_proj.py + MTP
Kimi-K3	<code>vllm.models.kimi_k3</code> (<code>nvidia/</code> 、 <code>amd/</code>)	KDA (FlashKDA 注册 op + chunk/recurrent 四形态) + MLA (<code>fused_mla_key_concat_kv_cache</code>) + RecoverSSM + 低延迟 GEMM 查表 + latent MoE tail 全套融合 kernel

模型	vLLM 实现位置	代码里能看到的 kernel / 结构特征
MiniMax-M2	<code>model_executor/model_s/minimax_m2.py</code>	全注意力 + GQA + <code>use_routing_bias</code>
MiniMax-M3-Sparse	<code>vllm.models.minimax_m3</code>	MSA : indexer + index top-k + CUTLASS 稀疏 decode + Gemma 式 RMSNorm (<code>x·rsqrt(mean(x²)+eps)·(1+w)</code>) + <code>swiglu_oai</code>
GLM-MoE-DSA / GLM-5-Next	<code>vllm.models.deepseek_v32 / vllm.models.glm5next</code>	GLM 的 DSA 变体复用 DeepSeek-V3.2 的实现 ; GLM-5-Next 有独立 MTP
Qwen3-Next / Qwen3.5 / Qwen4-Exp	<code>model_executor/model_s/qwen3_next.py</code> 、 <code>qwen3_5.py</code> 、 <code>vllm.models.qwen4_exp</code>	Qwen3-Next = Gated DeltaNet + Gated Attention, 3:1 交替, 48 层 (官方 README), kernel 来自 <code>fla</code> (vLLM 把 <code>fla</code> 的算子 vendored 进来 ⇒ 对应 <code>gdn_attn</code> / <code>linear_attn</code> 后端); 配 MTP
gpt-oss	<code>model_executor/model_s/gpt_oss.py</code>	OpenAI <code>triton-kernels</code> 的 MXFP4 MoE (<code>gpt_oss_triton_kernels_moe.py</code>) + attention sinks
Llama 4	<code>model_executor/model_s/llama4.py</code>	iRoPE: chunked local (1 = 用 RoPE) + NoPE global + 推理期温度缩放
Bailing / LongCat / Nemotron-H / Seed-OSS / Step-3.5 / Ernie4.5	各自的 <code>model_executor/model_s/*.py</code>	有 <code>bailing_moe_linear</code> (混合线性)、 <code>longcat_flash_ngram</code> (n-gram 投机 , 配 <code>ngram_embedding_kernels.cu</code>)、 <code>nemotron_h</code> (混合 Mamba)

另一个可以直接说的事实：vLLM 的 registry 已显式支持“模型放在 `vllm.model_executor.models` 之外”——源码注释原文是 “Allow registry entries to point at fully-qualified module paths (e.g. `vllm.models.deepseek_v4`) for models that live outside the legacy `vllm.model_executor.models` flat layout.” ⇒ 最激进的模型已经不走“平铺目录”了，而是各自成包、按厂商分 kernel。

L.4 五条范式变化（面试里最值得说的）

#	变化	证据
①	从 dense attention → indexer + 稀疏	DSA / V4 compress / MiniMax MSA / GLM-MoE-DSA 四条线同时在做
②	从 FP8 → FP4/MXFP4，且格式爆炸	<code>kernels/linear/</code> 下 mxfp4/mxfp6/mxfp8/nvfp4 各配 5–8 个后端
③	从“通信与计算并发” → “通信写进 kernel”	<code>gemm_rs_ar</code> 、 <code>allreduce_rmsnorm_reduce_scatter_early_exit</code> 、 <code>fused_add_multicast_gemm</code>
④	从 CUDA C++ → DSL	CuTeDSL / Triton / TileLang (MHC) / FlyDSL 并存; <code>csrc/</code> 里的新 kernel 明显变少

#	变化	证据
⑤	KV cache 从 BF16 → FP8 → FP4 / 3-bit	<code>nvfp4_ds_mla_cache</code> (352 B/token)、TurboQuant K3V4

L.5 上游开源算子项目（带官方数字，可以引用）

L.2/L.3 是“vLLM 里有什么”；这一栏是“这些 kernel 的上游是谁、官方数字是多少”。引用时必须连硬件口径一起说——这些数字几乎全部来自 H800 / H100 / B200 的官方 README。

项目	仓库	它提供什么	官方数字（含硬件）
FlashMLA	<code>deepseek-ai/FlashMLA</code>	MLA 的 dense / sparse × prefill / decode ；支持矩阵里还有一条“ Fused Norm RoPE Attn RoPE Cast ”（SM100，只有 V4/V4.1）	H800 SXM5 + CUDA 12.8 ：dense decode memory-bound 3000 GB/s 、compute-bound 最高 660 TFLOPS ；FP8 稀疏 decode 410 TFLOPS （ <code>topk=32768</code> 时可到 460 ）；稀疏 prefill 640 TFLOPS (H800) / 1450 TFLOPS (B200, CUDA 12.9)
FlashMLA 的 KV 格式	同上	<code>head_dim_k = 576</code> (V3/V3.1/V3.2) / 512 (V4/V4.1) ， <code>head_dim_v = 512</code> ；MHA 模式是 192/128、128	FP8 KV (V3.2) = 每 token 656 B = 512 B 的 <code>float8_e4m3</code>（量化过的 NoPE） + 16 B（4 个 fp32 scale，每 128 个 e4m3 一个） + 128 B（64 个 bf16 的 RoPE，不量化）。V4/V4.1 按 <code>k_cache</code> 最后一维区分：584 (V4) / 528 (V4.1) / 288 (V4.1 fp4) ；page block 先存 data 行再存 scale 行
FlashMLA 的调度技法	同上 + <code>docs/*-deep-dive.md</code>	寄存器受限下的“ seesaw ” warpgroup 调度 （把 64×512 输出纵向切成 <code>0_L / 0_R</code> ，两组 warpgroup 交替占用 Tensor Core 与 CUDA Core）； Programmatic Dependent Launch (PDL) 把 <code>splitkv_mla</code> 与 <code>combine</code> 两个 kernel 重叠；自带 tile scheduler 均衡 SM 负载	FP8 稀疏 decode 用 CTA cluster = 2 + DSM + <code>st.async</code> + cluster transaction barrier 做去量化的“crossover”： 410 vs 250 TFLOPS

项目	仓库	它提供什么	官方数字 (含硬件)
DeepGEMM	<code>deepseek-ai/DeepGEMM</code> (Python 包 2.8.0, MIT)	已不是“FP8 GEMM 库”, 官方定位是“统一的 tensor core kernel 库”: FP8/FP4/BF16 GEMM + 融合 MoE 且通信重叠 (Mega MoE) + lightning indexer 的 MQA scoring + HyperConnection (HC) ; 全部 kernel DeepJIT 运行时编译	关键 API: <code>fp8_gemm_nt</code> / <code>fp4_gemm_nt</code> / <code>fp8_fp4_gemm_nt</code> 、 分组 GEMM <code>m_grouped_fp8_gemm_nt_{contiguous,masked}</code> (masked 就是 dropless MoE)、 <code>fp8_fp4_mega_moe</code> / <code>bf16_mega_moe</code> / <code>get_symm_buffer_for_mega_moe</code> / <code>mega_mhc</code> / <code>tf32_hc_prenorm_gemm</code> 、 indexer 打分 <code>fp8_mqa_logits</code> / <code>fp8_paged_mqa_logits</code> / <code>fp8_fp4_sparse_mqa_logits</code> 、布局工具 <code>transform_sf_into_required_layout</code> 、 <code>get_mn_major_tma_aligned_packed_ue8m0_tensor</code>
FlashAttention-3	<code>Dao-AI/LabFlashAttention (hopper /)</code>	Hopper 专用: WGMMMA + TMA + warp specialization + FP8	H100 : FP16 最高 740 TFLOPs/s (约 75% 利用率), FP8 接近 1.2 PFLOPs/s ; 论文里点明 FA2 在 H100 上只有约 35% 利用率
FlashAttention-4	同上 (<code>flash_attn/cute/</code> , PyPI <code>flash-attn-4</code>)	Blackwell 优先 、纯 CuTe-DSL 重写	B200 BF16 最高 1613 TFLOPs/s (约 71%), 对 cuDNN 9.13 最高 1.3x 、对 Triton 2.7x ; 技法: TMEM + 完全异步 <code>tcgen05.mma</code> (单 CTA 最大 128×256×16) + 2-CTA MMA (256×256×16) + 条件式 softmax rescaling + 软件模拟 <code>exp2</code> 。vLLM 已把 FA4 vendored 进来 (forward-only)
FlashInfer	<code>flashinfer-ai/flashinfer</code>	attention / GEMM / MoE kernel 库, vLLM 与 SGLang 的主要后端之一	论文 (MLSys 2025) 口径: ITL 降低 29–69% 、长上下文场景降低 28–30%
Flash-Decoding	Stanford CRFM 博客 + FA 包 (≥ v2.2)	split-KV + LSE 合并 三步走	A100 上 attention 本身最高 50x 于 FlashAttention、端到端最高 8x
ring-flash-attention	<code>zhuzilin/ring-flash-attention</code>	上下文并行 (CP) 的环形注意力	8xH800 、 zigzag ring : forward 达理论值的 85.2% 、forward+backward 达 90.2%

| **DeepEP** | `deepseek-ai/DeepEP` | 两套 kernel: **normal (高吞吐)** 与 **low-latency (纯 RDMA + hook 式通信)**; low-latency 有一个硬约束——`num_qps_per_rank` 必须等于本地专家数 | 测试硬件 **H800 + CX7 InfiniBand 400 Gb/s (单卡约 50 GB/s 上限)**。V1 **normal**: intranode EP=8 时 dispatch **153 GB/s** / combine **158 GB/s** (NVLink, H800 上限约 160); internode EP=32 时 **58 / 57 GB/s** (RDMA)。V1 **low-latency**: dispatch **77 μs @EP=8** → **194 μs @EP=256**; combine **114 μs @EP=8** → **360 μs @EP=256** (EP=8 时等效 98 /

127 GB/s) 。 **V2 (SM100)** ： EP=8 用 **64 个 SM** 时 NVLink **726 GB/s** dispatch / **740 GB/s** combine；只用 24 个 SM 时降到 **643 / 675 GB/s** || **ThunderKittens** | `HazyResearch/ThunderKittens` | 一套“可爱”的 Hopper/Blackwell 模板库，被 **Mamba-2 / Based** 等线性模型用 | 论文 **arXiv:2410.20399** || **MegaBlocks** | `stanford-futuredata/megablocks` | **dropless MoE**：不做 token drop，用块稀疏 GEMM 处理不均衡 | 论文 **arXiv:2211.15841**； **8× A100 SXM4 80GB** 上对 Tutel 最高 **40%**、对 Megatron-LM 最高 **2.4×** 加速 || **Lightning Attention** | `OpenNLPLab/lightning-attention` | TransNormer 的 I/O-aware 实现：**块内左乘 / 块间右乘**绕开 cumsum；算法出处 **arXiv:2307.14995** (TransNormerLLM)、Triton 实现出处 **arXiv:2401.04658** (Lightning Attention-2) |  `MiniMax-AI/lightning-attention` **这个仓库不存在 (404)** —— MiniMax-01 官方仓库里**没有任何 kernel 源码**，kernel 在 **OpenNLPLab** 名下 || **vLLM 的 all2all 后端 × 量化格式** | `vllm/model_executor/layers/fused_moe/prepare_finalize/` | 后端不是随便配的，**每个后端只支持特定量化格式** | `deepep_high_throughput`：只支持 **block-wise FP8** (其他格式直接报错)；`deepep_low_latency`：FP8 + 异步；`flashinfer_nvlink_two_sided`：**NVFP4 / FP8**；`naive`：全部格式但**不异步** |

四条“一开口就能看出你真读过一手来源”的纠错（都是三方解读里传错的）：

常见错误	正确的
「NSA 是 arXiv:2502.13189」	NSA = arXiv:2502.11089 (DeepSeek, 2025-02-16) ； 2502.13189 是 MoBA (Moonshot, 2025-02-18)
「MiniMax 的 lightning attention 在 <code>MiniMax-AI/lightning-attention</code> 」	该仓库 404 ；官方实现在 <code>OpenNLPLab/lightning-attention</code> (<code>pip install lightning_attn</code>)
「Llama 4 的 chunked attention 在 NoPE 层」	相反：RoPE 层 (36 层) 才是 chunked local (窗口 8192) ，NoPE 层 (12 层) 是全局 full —— 见本节末尾的详细更正
「FlashInfer 的 trtllm-gen 在 Blackwell 上有 N TFLOPs」	没找到官方数字 —— 这类数字 不要编 ；能引的是 FlashInfer 论文 (MLSys 2025) 的 相对值 (ITL -29~69%)
「 <code>openai/triton-kernels</code> 是 gpt-oss 的 kernel 仓库」	该仓库 404 ；真实上游在 <code>triton-lang/triton</code> 的 <code>python/triton_kernels</code> 。另外 <code>moe_sum</code> 不是 它的算子 (是 vLLM 自己的)
「SonicMoE 是微软的」	是 Dao-AILab / Tri Dao 团队的 (arXiv:2512.14080)
「DeepGEMM 的 1550 TFLOPS 是通用数字」	只在 H800 上 ；而且它的性能表 baseline 是 “ <i>our internally and carefully optimized implementation based on CUTLASS 3.6</i> ”，表内最大差距 2.7× —— 没有「1.1× vs cuBLAS」这种措辞
「sgl-kernel 里有 <code>moe_fused_gate.cu</code> 」	<code>sgl-kernel/</code> 目录已不存在 (已迁到 <code>python/sglang/kernels/aot/</code>) ；且 <code>topk_softmax_kernels.cu</code> 的真名是 <code>moe_topk_softmax_kernels.cu</code> ， <code>moe_fused_gate.cu</code> 不存在 (已改成 Triton)
「EPLB 有 <code>rebalance_experts_global</code> 」	没有这个函数 ； <code>__all__ = ['rebalance_experts']</code> ，所谓 global 策略就是 <code>rebalance_experts_hierarchical(weight, num_replicas, 1, 1, num_gpus)</code>

两条把 \$12 和 V3 源码对上的交叉验证（很值得在面试里主动说）：

1. DeepGEMM 的 `fp8_mqa_logits` / `fp8_paged_mqa_logits` ↔ vLLM 的 `triton_fp8_mqa_logits.py` ⇒ 两处指的是同一件事：**DSA / V4 的 lightning indexer 打分**。

2. DeepGEMM 的 `mega_mhc` / `tf32_hc_prenorm_gemm` ↔ vLLM 的 `kernels/mhc/tilelang.py` 后者里那个 `_torch_hc_prenorm_gemm(x, fn, out, sqsum)` 做的正是 $x @ fn.T$ 与 $\sum(x^2)$ ⇒ “HC = HyperConnection”，就是 V4 那一代换掉的残差结构；vLLM 在参考实现里用 TileLang / Triton / torch 三种方式并存，正式路径走 DeepGEMM 的 `mega_mhc`。

GIN 自己的实测数字 (arXiv:2511.15076, baseline 是 NVSHMEM-only, 1-8 节点)：GIN 的 GDAKI 路径 put+signal 16.7 μ s，对照 NVSHMEM IBGDA 的 24.3 μ s；low-latency dispatch 185.28 GB/s / 40.62 μ s。⚠ 该论文没有点名网卡型号、也没有 Blackwell 结果——引用时别说成「在 H100 上」。

DeepEP 的四个版本口径（很容易讲混）：① hook 机制（`return_recv_hook`）从 2025-02-24 的首次提交就有，不是后来补的；② EPv2 的公开版本是 2026-04-30（`__version__ = '2.1.0'`），从 NVSHMEM 换成 NCCL Gin；③ V2 没有公布 low-latency 延迟表，且 Notes 明说 *0 SM RDMA low-latency EP is no longer supported*——不要把 V1 的 77 μ s / 114 μ s 安到 V2 上；④「低延迟内核用固定的 N 个 SM」没有官方依据（官方原话：*there is no SM control API for the low-latency kernels*）；有出处的是 DeepSeek-V3 §3.2.2 的 20 SMs / 10 channels。

还有一个可以直接引用的「代码考古」事实：vLLM 在 2026-07-02 的 PR #47361 里删掉了 CUDA 版 PagedAttention v1 / v2 ⇒ 这解释了为什么 `csrc/attention/` 现在只剩下 dtype 转换的头文件——paged attention 的活被交给了 FlashInfer / FA4 / `triton_unified_attention`，`csrc/` 只保留量化、通信与真正通用的件。面试里说得“vLLM 把 PagedAttention 的 CUDA 实现删了、改用统一 Triton kernel + FlashInfer”，比背 PagedAttention 的定义更能证明你在读代码。

⚠ 一处必须纠正的常见错误（也是本材料 §10 J.8 的第 12 条陷阱）：Llama 4 的 `no_rope_layers` 字段名与语义相反——1 表示“用 RoPE”，0 表示 NoPE。因此 `attention_chunk_size = 8192` 的 chunked local attention 作用在 RoPE 层（36 层），而 NoPE 层（12 层）才是全局 full attention。判定依据是 vLLM 源码（本 checkout `f015d08`）：`self.no_pe = no_rope_layers[layer_idx] == 0`、`use_chunked_local_attn = not self.no_pe and config.attention_chunk_size`、`self.global_layer = no_rope_layers[layer_idx] == 0`。三方解读（包括本材料自己的一轮调研底稿）很容易把它讲反——请以源码为准。

Q263 【进阶】★ vLLM 的 kernel 现在分几层？为什么“csrc 里找不到新 kernel 了”？

答· 五层（见 L.1 的表）：C++/CUDA 扩展（`csrc/`）、Triton、CuTeDSL、外部库、新 DSL。`csrc/` 没有消失，而是“下沉”了——它现在只留三类东西：① 通用且稳定的（`custom_all_reduce`、`merge_attn_states`、`topk_softmax`、`cache_kernels`）；② 量化（`marlin/`、`machete/`、`w8a8/cutlass/`、`fp4/`）；③ 跨平台的公共件（`libtorch_stable/` 这个名字本身就是“稳定 ABI 层”的意思，配 `torch/csrc/stable`）。

新东西去哪了：Triton（快、好改、跨厂商）+ CuTeDSL（要极致性能时的 CUTLASS Python DSL）+ `vllm/models/<模型>/<厂商>/ops/`（模型专用 kernel）。

数字· 两个可验证的对比：- `kernels/linear/nvfp4/` 一个目录下并列 `cutlass / flashinfer / marlin / humming / fbgemm / b12x / emulation` 等实现；- `vllm/model_executor/layers/fused_moe/experts/` 下有 29 个 fused MoE 后端文件。

坑· ① 说“vLLM 现在都用 Triton 了”—— CuTeDSL 的比例在快速上升，而且最难的活仍然在 CUDA C++ 里；② 不知道 CuTeDSL 是 CUTLASS 的 Python DSL（不是 Triton 的别名）；③ 把 `libtorch_stable` 当成“稳定版目录”——它是基于 `torch/csrc/stable` ABI 的扩展层，目的是让 kernel 扩展不随 PyTorch 版本反复重编。

Q264 [hard] ★ 什么是“稀疏注意力 + indexer”？DeepSeek 的 DSA 和 MiniMax 的 MSA 是同一件事吗？

答· 范式相同、实现不同。

相同的范式（三件套）：

- ① **indexer**：用一个便宜的打分器给历史 KV 打分
- ② **top-k**：选出要看的块（不是“每个 query 看全部”）
- ③ 稀疏 **attention**：只对选中的块做注意力

为什么必须这么设计：dense attention 的算力是 $O(L^2)$ 、KV 显存只有 $O(L)$ ；序列到 128K/1M 时算力先崩。而“省显存”的路线（MLA / GQA）完全帮不上算力的忙——这正是 §10 Q252 说的“MLA 压的是每个 KV 多大，稀疏压的是要读多少个 KV”。

不同的实现（代码级差异）：

	DeepSeek DSA (V3.2)	MiniMax MSA (M3)
indexer 打分的算子	FP8 的 MQA logits (<code>triton_fp8_mqa_logits.py</code>)	独立 indexer 模块 + index top-k (<code>indexer.py</code> / <code>index_topk.py</code>)
稀疏 attention 怎么算	MLA sparse (ROCm/XPU 各有实现) + DCP indexer	CUTLASS 稀疏 decode (<code>msa_cutlass_sparse_decode.py</code>)
有没有“压缩”这一路	有 (V4 的 compressor, 逐层压缩比)	代码里看到的是 indexer + top-k, 没有 compressor
特色细节	indexer 的 Q 走 MXFP4 (V4)	融合 kernel 里 同一个 RoPE 表 同时服务主分支和 index 分支 (<code>fused_minimax_m3_qknorm_rope_kv_insert_kernel.cu</code>)

数字· DeepSeek-V4 的压缩比是“逐层”的：`self.compress_ratio = max(1, config.compress_ratios[layer_id])`，且 `compress_ratio == 1` 的层根本不压缩；对应的 CuTeDSL kernel 注释写明提供“C4 fused 和 C128 split kernels”（推断）对应两个不同的压缩比档位）。

坑· ① 把“稀疏注意力”和“省 KV 显存”混为一谈（稀疏省的是算力）；② 说“indexer 就是一个小 attention”——那它为什么能便宜？（低维 + 低精度 + 只需要 logits，不需要 value）；③ 忘了追问必来的那一层：indexer 本身的开销是 decode 路径上的固定成本，序列短时是负收益（见 §10 Q252 的 crossover 长度）。

Q265 [hard] ★ DeepSeek-V4 的注意力 kernel 和 V3 有什么不同？

答· 四条差异，都能在代码里指出来：

#	V3 (MLA)	V4
①	KV cache 存 <code>c_KV (512)</code> + <code>k^R (64)</code> 的 latent	多了“压缩”这一路： <code>compressor.py</code> + <code>fused_compress_quant_cache.py</code> ，逐层压缩比 <code>config.compress_ratios[layer_id]</code>
②	融合 kernel 只做 QK-Norm + RoPE + KV 写缓存	融合得更狠：Q 侧 per-head RMSNorm (无 weight) + GPT-J RoPE ；KV 侧 GPT-J RoPE + UE8M0 FP8 量化 + paged 写缓存 ，全部在一个 kernel、一个 grid 里按 warp 分派 Q/KV 工作（源码称之为“horizontally-fused”）
③	—	多了一个 <code>fused_inv_rope_fp8_quant</code> ：逆 RoPE + block-scaled FP8 量化 ，而且输出 scale 已经预先排成 MN-major TMA 对齐 （SM90 用 FP32、SM100 用 INT32-packed UE8M0），好让后面的 <code>fp8_einsum</code> 省掉一次 <code>transform_sf_into_required_layout</code>
④	FP8 是 1×128 / 128×128 的 per-block	更激进： NoPE 部分用 UE8M0 FP8 (block=64) ， indexer 的 Q 用 MXFP4 ；KV cache 有 NVFP4 版本 (352 B/token)

数字· V4 kernel 里写死的维度（`fused_deepseek_v4_qnorm_rope_kv_insert_kernel.cu` 头部注释）：
`HEAD_DIM = 512`、`ROPE_DIM = 64`、`NOPE_DIM = 448`、`QUANT_BLOCK = 64`、`FP8_MAX = 224.0f`（ROCm FNUZ）/ `448.0f`（OCP）、`is_neox=false`（GPT-J 交错对）。路由侧：`dsv4_topk.py` 的快速路径写死 `_TOPK = 6`，且带 `correction_bias`（无辅助损失的偏置纠正）；打分函数是 `Sqrt(Softplus(.))`（`topk_softplus_sqrt_kernels.cu`）。MoE 侧：**V4 走 DeepGEMM 的 MegaMoE kernel**，vLLM 只写 Triton 的 **input-staging**（量化成 FP8 + **E8M0 group scale**，并把 top-k 重排成 DeepGEMM 要的 **int64/float32 布局**）。

坑· ① 把 V3 与 V4 的维度混着引用（V3 的 `qk_nope_head_dim` 是 128，V4 这里是 512/64/448 的组合，不是同一个东西）；② 说“V4 还是 MLA”——**MLA 的主干还在（`sparse_mla.py`）**，但外面套了压缩 + indexer + 稀疏；③ 不知道 `fused_inv_rope` 为什么要“逆”RoPE——这是 **MLA 吸收技巧的工程后果**：上投影被吸进 Q/O 之后，K 侧要“还原”出可以被吸收的形式，所以要先逆旋转再量化（对照 §10 Q226 的吸收态）。

Q266 [hard] ★ 线性注意力的 kernel 难在哪？KDA 的 chunkwise 四种形态是什么？

答· 难点是“它是个递推，而 GPU 最不擅长的就是递推”——`S_t = f(S_{t-1})` 天然串行，直接实现只能一个 token 一个 token 算，完全吃不到 GPU 的并行度，而且每步都要读写整个状态矩阵（`d_k × d_v`，比 KV cache 大得多）。

解法就是 **chunkwise（分块并行）**：把序列切成 C 大小的块，块内用并行的矩阵运算、块间才做递推（还要传一个 chunk 级的中间状态）。

Kimi-K3 在 vLLM 里的实现正好是四个 kernel（`models/kimi_k3/{nvidia,amd}/ops/third_party/kda/`）：

Kernel	用途
<code>chunk.py</code>	块级主流程（块间递推 + 块内并行）
<code>chunk_intra.py</code>	块内计算
<code>chunk_intra_token_parallel.py</code>	块内计算再按 token 并行切一档（换并行度/寄存器压力）
<code>fused_recurrent.py</code>	纯递推，给小 batch / decode 用（此时并行度本来就低）

这就是线性注意力 kernel 的通用套路：prefill 用 chunk 并行、decode 用 recurrent；两种形态同时存在，按形状选。

数字· KDA decode kernel 的常量 (fused_kda_decode_kernel.cu)： kDimK = kDimV = 128、短卷积宽度 kKernelWidth = 4 (所以卷积状态宽度 3)、256 线程 (8 warp)、kChunkV = 32、kNumChunks = 4、kRowsPerWarp = 4。最关键的一条数字是「crossover」：fla 官方在 GB200 上的 bench 显示，chunk_gdn 在 T=8192 时 1.265 ms，对 flash_attn 的 3.753 ms 是 3× 快；但在 T=2048 时反过来：0.753 ms vs 0.346 ms，慢一倍多。⇒ 线性注意力只在序列足够长时才赢——这解释了为什么它的 kernel 必须同时准备 chunk 并行版和 recurrent 版：短序列上 dense attention 本来就更快。另有 FlashKDA 作为注册的 torch op (csrc/flashkda_registration.cpp)，签名里有 initial_state / final_state / checkpoint_state / checkpoint_offsets ——“状态检查点”是线性注意力独有的东西 (KV cache 可以任意切块复用，递推状态不行)。

坑· ① 说“线性注意力的 kernel 就是一个 scan”——纯 scan 在 GPU 上慢得没法用，关键是 chunkwise；② 不知道 同一个模型要同时准备 chunk 版和 recurrent 版两份 kernel；③ 忘了对应关系：线性注意力的“状态”= KV cache 的等价物，所以 显存管理、prefix caching、投机解码全都要重写 (这就引出 Q267)。

Q267 [hard] ★ SSM / 线性注意力 + 投机解码：为什么需要 RecoverSSM?

答· 因为“接受一部分 draft token”这件事，在递推模型上不可逆。

推理链是这样的：

投机解码：draft 出 k 个 token → 目标模型一次验证 → 接受了前 j 个 (j 可能 < k)

问题：验证时你为了算 logits，已经把状态推进到第 k 步了

现在要回滚到第 j 步的状态 — 但 $S_t = f(S_{t-1})$ 只给了你"往前"，没给"往回"

KV cache 可以回滚：把 block table 一截就行 (这就是 PagedAttention 的便宜之处)。线性注意力的状态不能截：它已经被 k-j 个多余 token 污染了。

做法有两条 (vLLM 里都能看到)：

做法	代价
① 保存中间 checkpoint (KDA 的 checkpoint_state / checkpoint_offsets)	显存换可逆性；checkpoint 太密就失去线性注意力的省显存优势
② 重算被接受的那一段 (recoverssm.py：accepted-state recovery)	算力换显存；只在“接受了一部分”时才付这个代价

数字· vLLM 里这个模块叫 RecoverSSM (models/kimi_k3/nvidia/ops/recoverssm.py)，注释写的是 “speculative verify and accepted-state recovery”，用 Triton 实现，还复用了 mamba_utils.is_conv_state_dim_first (因为短卷积的状态也要一起恢复，K3 的卷积宽度是 4，所以要回滚 3 个 token 的卷积窗口)。

坑· ① 完全不知道有这个问题 (这是“线性注意力上生产”最容易被忽略的一环)；② 只说“回滚状态”却不知道短卷积状态也在里面；③ 反过来把它说成“只影响投机解码”——前缀缓存 (prefix caching) 同样受影响：KV cache 能按块共享前缀，递推状态默认不行 (除非实现专门支持状态检查点)。

Q268 [hard] ★ 通算融合在 kernel 层面长什么样？

答· \$5.3 讲的 DBO 是调度层的重叠（两个 stream 交替）。这一代的变化是：把通信指令直接写进计算 kernel 里。vLLM 代码里能看到三种典型：

形态	Kernel	干了什么
① GEMM + reduce-scatter + all-reduce	<code>gemm_rs_ar.py</code> (Kimi-K3, SM100/BF16, CuTeDSL)	GEMM 算完直接在 epilogue 里做 TP 的 RS/AR，基于 CUTLASS 的 Blackwell distributed GEMM-RS 例子，用 <code>torch.distributed._symmetric_memory</code> 拿到对端指针
② AllReduce + RMSNorm + ReduceScatter (early exit)	<code>allreduce_rmsnorm_reduce_scatter_early_exit.py</code>	从 FlashInfer 的 <code>oneshotAllreduceFusionKernel</code> 特化；CTA 分工 + ReduceScatter 提前退出
③ fused add + multicast GEMM	<code>fused_add_multicast_gemm.py</code> / <code>..._skinny_gemm.py</code>	用 NVLink multicast 把激活一次性广播进 GEMM 的加载阶段（等价于把 all-gather 藏进 load）

共同前提：对称内存（`torch.distributed._symmetric_memory` / NCCL window / NVSHMEM）。没有它，kernel 拿不到对端显存地址，就没法“一边算一边写别人家”。

数字· 为什么值得这么做 —— 回到 α - β 模型（\$5.2 Q140）：这些融合消掉的是“通信次数”和“kernel launch 次数”，不是通信字节数。TP 的 all-reduce 在 decode 时是小消息（`hidden × 2` 字节量级）， α 主导；把它融进 GEMM 的 epilogue，消掉的是 α 和一次 launch，这正是小消息场景的收益来源。

坑· ① 把这一类说成“减少了通信量” —— 字节数一个都没少，少的是次数、launch 和同步点；② 不知道它对对称内存的硬依赖；③ 与 DBO 混淆：DBO 是调度层重叠（两个 kernel 时间上交叠），这类融合是空间上的合并（一个 kernel 里既算又通）。两者可以叠加，但不是一回事。

Q269 [进阶] ★ 量化 kernel 为什么会有这么多后端？工程上怎么选？

答· 因为“格式 × 粒度 × 硬件代际 × 厂商”是四个独立维度，组合出来必然爆炸。vLLM 的目录结构就是这四个维度的直方图：

```
kernels/linear/
├── nvfp4/          cutlass flashinfer marlin humming fbgemm b12x emulation
├── mxfp4/          aiter b12x emulation flashinfer humming marlin xpu
├── mxfp8/          b12x emulation flashinfer humming marlin rocm_native xpu
├── mxfp6/          base emulation
├── scaled_mm/      aiter b12x cpu cutlass deep_gemm flashinfer humming
│                  marlin pytorch rocm triton xpu zentorch
└── mixed_precision/ marlin machete conch exllama humming allspark
                    triton_w4a16 dynamic_4bit cpu xpu zentorch rdna3_w4a16 ...
```

选择的实际顺序（推理时的判据）：

- ① 硬件是什么？ SM90 → Machete / Marlin; SM100 → NVFP4 + CUTLASS/FlashInfer;
SM120 → b12x; ROCm → AITER; XPU → xpu 后端
- ② 权重是什么格式？ NVFP4 / MXFP4 / MXFP8 / INT4 / W4A8 ...
- ③ 粒度是什么？ per-tensor / per-channel / per-group(128) / per-block
- ④ 形状是什么？ prefill (大 M) vs decode (M=1) 用的 kernel 完全不同
- ⑤ 有没有厂商库？ 有就优先 (FlashInfer / AITER / DeepGEMM)，没有才回落到 triton/emulation

数字· `emulation` 的存在本身就是答案： `mxfp4/emulation.py`、`mxfp8/emulation.py`、`nvfp4/emulation.py`、`mxfp6/emulation.py` —— 当硬件不支持该格式时，vLLM 用 kernel 把低精度“模拟”出来（反量化后走 BF16/FP16 计算）。这是“格式先行、硬件跟上”的典型工程妥协：模型已经用 MXFP4 发布了，但你的卡不支持 → 你要么不能跑，要么慢一点但能跑。

坑· ① 说“量化 kernel 就是反量化 + GEMM”（那是最慢的 emulation 路径）；② 不知道同一格式在不同架构上要用不同 kernel（所以 `scaled_mm_blockwise_sm90/sm100/sm120_fp8.cu` 是三个文件）；③ 忘了 decode 和 prefill 要选不同的 kernel（M=1 时 GEMM 退化成 GEMV，走的可能是完全另一条路，见 Q270）。

Q270 [进阶] ★ 一个 decode 的 GEMM 该选哪个 kernel?

答· 不是“选一个最好的”，而是“按形状查表”——vLLM 里已经把这件事作化了。

`models/kimi_k3/nvidia/low_latency_gemm.py` 的注释把设计讲得很清楚（原文要点）：

- **(N, K) 形状 + token 数 M** 决定走哪个 kernel，**模块名不参与决策**（“Dispatch is purely by local (N, K) shape and token count M — the module name plays no role”）；
- 每个测过的形状映射到一个 `ProjectionSpec`，里面存每个 token 数档位的获胜后端；
- 静态部分在 install 时解析成 `{M: call}` 的 plan，前向路径只剩一次 dict 查表；
- 表是按硬件分别测的，而且不能合并：`KIMI_K3_PROJECTIONS` 在 **B300 (SM103)** 上调，`..._SM100` 在 **B200 (SM100)**，`..._SM90` 在 **H200 (SM90)**；源码明确写 “The per-(shape, M) winners genuinely differ between the parts, so the tables must not be merged”；**SM107 (Rubin)** 复用 **SM103** 的表（已端到端验证过）。

数字· 这条注释里能直接引用的硬件代号：**SM90 = H200**、**SM100 = B200**、**SM103 = B300**、**SM107 = Rubin**。

为什么解码 GEMM 要专门搞一套：M=1（或很小）时 GEMM 退化成 **GEMV / skinny GEMM**，算术强度 ≈ 0.5，纯 memory-bound (§3.3 Q73) —— 这时 tensor core 的利用率不是瓶颈，瓶颈是权重搬运和 kernel 固定开销。所以出现了专门的 skinny / low-latency 实现：`kernels/linear/cute_dsl/_skinny_gemm.py`、`_ll_bf16_dotprod.py`、`_ll_bf16_splitk.py`（“ll” = low latency；dotprod 和 splitk 是两个不同的切分策略），以及 K3 的 `kda_skinny_gemm.py`。

坑· ① 说“用 cuBLAS 就行”——decode 的 skinny GEMM 是 cuBLAS 不擅长的形状；② 想说“选最快的 kernel”却说不出判据是 (N,K,M) 三元组；③ 不知道同一份 kernel 在不同芯片上的排名会翻转（所以表不能合并）——这一条几乎是“真的跑过 benchmark”的证明。